



IA PARA VALORACIÓN DE OPCIONES: MODELOS DE VOLATILIDAD EXPLICABLES

PEDRO GALLEGO LÓPEZ Y DANIEL RECUERO CORDOBÉS

Trabajo Final de Máster

Máster en Inteligencia Artificial y Computación Cuántica
Aplicada a los Mercados Financieros


Dirección

Enrique Castellanos

INSTITUTO BME

BOLSAS Y MERCADOS ESPAÑOLES

Madrid, 17 de mayo de 2026



IA para valoración de opciones: modelos de volatilidad explicables

Pedro Gallego López
Daniel Recuero Cordobés

Palabras clave:

Volatilidad implícita, opciones IBEX, Black-76, aprendizaje automático, IA explicable, SHAP, dashboard, API, cloud

Resumen

Este Trabajo Final de Máster tiene como objetivo desarrollar modelos de volatilidad implícita para opciones sobre el IBEX mediante técnicas de inteligencia artificial e integrarlos en un marco de explicabilidad riguroso. La motivación central es combinar la capacidad de los modelos de IA para capturar relaciones no lineales complejas en la superficie de volatilidad con los requisitos de interpretabilidad y auditabilidad propios de la modelización financiera tradicional.

A partir de operaciones reales, contratos, futuros subyacentes y series de tipos EONIA/€STR, se construye una base de volatilidad implícita mediante validaciones financieras e inversión numérica del modelo Black-76. Sobre esta base se entrenan varias familias de modelos de regresión: regresión lineal, Random Forest, XGBoost, redes neuronales y una arquitectura *quantum inspired*, inspirada en conceptos de computación cuántica. La evaluación no se limita al error predictivo, sino que incorpora estabilidad temporal, control de sobreajuste, coherencia financiera de la superficie y análisis por tramos de moneyness y vencimiento.

La contribución principal consiste en transformar modelos predictivos en sistemas explicables, auditables y consultables mediante un dashboard y un servicio API. La explicabilidad se aborda con SHAP global y local, superficies de volatilidad, curvas ICE y ALE, árboles surrogate, regresión simbólica, vecinos históricos y diagnósticos de residuales. Esta combinación permite justificar las predicciones con un lenguaje cercano al de los modelos tradicionales, sin renunciar a la capacidad de aproximación de la IA. El resultado es una arquitectura reproducible orientada a la validación de modelos, la auditoría interna y el uso operativo en entornos financieros.

Adicionalmente, se ha implementado una API que permite el despliegue y consumo de estos modelos en distintos contextos de uso.

AI for option pricing: explainable volatility models

Pedro Gallego López
Daniel Recuero Cordobés

Keywords:

Implied volatility, IBEX options, Black-76, machine learning, explainable AI, SHAP, dashboard, API, cloud

Abstract

The main objective of this Master's Thesis is to develop implied-volatility models for IBEX options using artificial-intelligence techniques and to integrate them into a rigorous explainability framework. The central motivation is to combine the ability of AI models to capture complex nonlinear relationships across the volatility surface with the interpretability and auditability requirements of traditional financial modelling.

Starting from real trades, contracts, underlying futures and EONIA/€STR rate series, the project builds an implied-volatility database through financial validations and numerical inversion of the Black-76 pricing model. Several regression families are then trained, including linear regression, Random Forest, XGBoost, neural networks and a quantum-inspired architecture, based on quantum computing concepts as its name suggests. The evaluation is not restricted to predictive error; it also considers temporal stability, overfitting control, financial coherence of the surface, and performance across moneyness and maturity segments.

The main contribution is to turn predictive models into explainable, auditable and queryable systems through a dashboard and an API service. Explainability is addressed through global and local SHAP, volatility surfaces, ICE and ALE curves, surrogate trees, symbolic regression, historical neighbours and residual diagnostics. This combination makes it possible to justify predictions in a language close to traditional financial models, without giving up the approximation power of AI. The resulting architecture is reproducible and oriented towards model validation, internal audit and operational use in financial environments.

Additionally, an API has been implemented to support the deployment and consumption of these models across different usage contexts.

ÍNDICE GENERAL

1. INTRODUCCIÓN	7
1.1. Planteamiento del problema	7
1.2. Relevancia financiera y profesional	8
1.3. Antecedentes	9
1.4. Objetivos	10
1.5. Contribución del TFM	10
1.6. Estructura de la memoria	12
2. MARCO TEÓRICO	13
2.1. Opciones, futuros y volatilidad implícita	13
2.2. Smile, moneyness y estructura temporal	14
2.3. Aprendizaje automático para volatilidad	15
2.4. Explicabilidad en modelos financieros	16
2.5. Métricas de error, estabilidad y fidelidad	16
2.6. Gobierno de modelos y preguntas de validación	17
3. METODOLOGÍA	18
3.1. Diseño general del estudio	18
3.2. Datos y muestra analizada	19
3.3. Validaciones y tratamiento financiero	24
3.4. Variables y feature engineering	24
3.5. Familias de modelos	26
3.6. Splits temporales y selección	27
3.7. Reentrenamiento y progressive ATM	28
3.8. Construcción del dashboard	30
3.9. API, almacenamiento y cloud	32
3.10. reproducibilidad	34
3.11. Arquitectura del repositorio	34
3.12. Riesgos metodológicos y controles	36
4. RESULTADOS Y DISCUSIÓN	37
4.1. Resultados	37
4.1.1. Comparativa general de modelos	37
4.1.2. Entrenamiento estándar frente a progressive ATM	38
4.1.3. Modelo de referencia	39
4.1.4. Diagnóstico de rendimiento	40
4.1.5. Behaviour And Surface	44
4.1.6. Explicabilidad global	45
4.1.7. Modelos equivalentes: árboles y regresión simbólica	46
4.1.8. Explicabilidad local y soporte histórico	48

4.1.9.	Síntesis comparativa por temática	50
4.2.	Aplicaciones operativas y validación independiente	51
4.2.1.	Validación independiente de modelos internos	51
4.2.2.	Interpolación y suavizado: alcance real del enfoque	51
4.2.3.	Detección de anomalías de precio y errores de mercado	52
4.2.4.	Valoración de ilíquidas, control de mesa, auditoría y cobertura	52
4.3.	Discusión	53
4.3.1.	Lectura financiera	53
4.3.2.	Lectura de IA y Data Science	54
4.3.3.	Lectura de ingeniería y cloud	55
4.3.4.	Limitaciones	55
5.	CONCLUSIONES	56
A.	ESQUEMA DETALLADO DE DATOS Y ETL	58
B.	METODOLOGÍA DE DESARROLLO, VALIDACIÓN Y DESPLIEGUE	62
C.	FUNDAMENTOS DE SHAP	65
C.1.	Modelo aditivo de explicación	65
C.2.	Valores de Shapley	66
C.3.	Función de valor en explicabilidad de modelos	67
C.4.	Propiedades de los valores SHAP	68
C.5.	Interpretación local y global	69
C.6.	Aproximación mediante permutaciones	70
C.7.	Variables de fondo y valor base	71
C.8.	Limitaciones interpretativas	71
C.9.	Uso en este proyecto	72
D.	CURVAS ALE	73
E.	MODELO QUANTUM INSPIRED	76
E.1.	Arquitectura general: flujo de datos desde entrada a predicción	76
E.2.	Etapas preparatorias y transformación estructural	77
E.2.1.	Normalización e Embedding denso	77
E.2.2.	Reshape a tensor de alta dimensionalidad	77
E.3.	El núcleo Quantum Inspired: Descomposición Tensor-Train	78
E.3.1.	La cadena de contacto (Contact Chain) y propagación de de- pendencias	78
E.3.2.	Implementación: estructura concreta de los núcleos	79
E.3.3.	Contracción: cómo se produce una salida TT	79
E.3.4.	Ejemplo concreto: relación entre dimensiones de entrada, ran- gos y salidas	80
E.4.	Etapas finales: Agregación y salida	80
E.5.	Justificación del enfoque Quantum Inspired	81
E.6.	Ventajas frente a una red densa estándar	81
F.	FUNDAMENTOS DE REGRESIÓN SIMBÓLICA	83
F.1.	Motivación	83
F.2.	Espacio de búsqueda de expresiones	84

F.3.	Objetivo de optimización	85
F.4.	Búsqueda evolutiva	86
F.5.	Frontera precisión-complejidad	86
F.6.	Regresión simbólica como modelo sustituto	87
F.7.	Configuración utilizada en el proyecto	87
F.8.	Evaluación de fidelidad	89
F.9.	Interpretación de la ecuación simbólica	90
F.10.	Limitaciones	90
F.11.	Relación con la explicabilidad del proyecto	91
G.	ENTRENAMIENTO PROGRESSIVE ATM	92

INTRODUCCIÓN

1.1 PLANTEAMIENTO DEL PROBLEMA

La volatilidad implícita es un concepto central en mercados de derivados. En una opción negociada, el precio observable resume expectativas, oferta y demanda, liquidez, microestructura y percepción de riesgo. Sin embargo, para comparar contratos con strikes y vencimientos distintos, los profesionales no suelen razonar únicamente en precios: transforman esos precios en volatilidades implícitas y analizan smiles, skews y estructuras temporales [Hull, 2022, Derman and Miller, 2016].

El problema de este trabajo surge de una doble exigencia en finanzas cuantitativas. Por un lado, los modelos de aprendizaje automático pueden aproximar relaciones no lineales entre strike, subyacente, vencimiento, tipo de interés y volatilidad. Por otro lado, en un entorno financiero no basta con obtener una predicción numéricamente competitiva. El modelo debe poder auditarse: hay que saber dónde falla, qué variables explican sus predicciones, si respeta patrones razonables de la superficie y si una predicción concreta está respaldada por datos históricos similares.

En este contexto, el proyecto construye modelos de volatilidad explicable, consultable y útil vía API. La explicabilidad se entiende en dos niveles. A nivel de ingeniería, sirve para detectar sesgos, errores de datos, incoherencias, discontinuidades y comportamientos no deseados. A nivel financiero y profesional, permite justificar decisiones ante revisiones internas, auditorías, model validation o análisis de riesgo.

Operativamente, el problema se concreta en cuatro preguntas.

- Cómo transformar operaciones reales de mercado en una base de volatilidad implícita que sea consistente, trazable y reutilizable.
- Cómo aproximar la superficie $\sigma(K, T)$ con modelos suficientemente flexibles sin introducir sesgos temporales o dependencias espurias.
- Cómo operacionalizar ese modelo de forma utilizable, de manera que no quede encerrado en notebooks o tablas estáticas.

- Cómo saber cuándo una predicción es robusta y cuándo conviene tratarla con cautela porque está en una región poco soportada o mal explicada.

La memoria se construye alrededor de esa cadena completa. No se limita a entrenar un predictor, sino que conecta datos de mercado, inversión de Black-76, selección de familias, explicabilidad global y local, diagnóstico por zonas de la superficie y despliegue. Ese enfoque es coherente con el tipo de uso que tendría el sistema en un entorno profesional: consulta repetida, revisión crítica y necesidad de justificar el resultado más allá de una métrica agregada.

Estas cuatro preguntas se responden de forma progresiva en el [chapter 3](#) (construcción y validación del pipeline), en el [chapter 4](#) (evidencia empírica y lectura operativa) y en el [chapter 5](#) (síntesis final y alcance práctico).

1.2 RELEVANCIA FINANCIERA Y PROFESIONAL

La volatilidad implícita condensa información de mercado y se utiliza en valoración, cobertura, gestión de riesgos y análisis de escenarios. En opciones sobre índices, la forma de la superficie de volatilidad puede reflejar demanda de protección, asimetría percibida, presión de liquidez o cambios de régimen. Un modelo que suaviza en exceso los extremos de moneyness, que comprime volatilidades extremas o que presenta saltos artificiales en vencimientos cortos puede producir señales engañosas aunque su RMSE agregado sea aceptable.

La literatura clásica de derivados establece que la volatilidad no debe interpretarse como un simple parámetro estadístico fijo, sino como una magnitud inferida del precio bajo un modelo de valoración [Black, 1976, Hull, 2022]. La literatura específica sobre smile muestra que los mercados organizan la volatilidad en torno a moneyness y vencimiento, no solo en torno a niveles absolutos de strike [Derman and Miller, 2016]. Por ello, el proyecto se diseña desde la geometría financiera de la superficie: el aprendizaje automático se usa para aproximar una función de volatilidad, pero la evaluación exige interpretar su forma.

La relevancia práctica aparece en varios frentes.

- **Valoración y marking:** una estimación coherente de volatilidad implícita permite comparar contratos y revisar precios fuera de rango.
- **Gestión de riesgos:** la sensibilidad del error por moneyness y vencimiento importa tanto como el error medio total.
- **Gobierno de modelos:** el área usuaria necesita entender si el modelo reacciona con lógica financiera y no solo si ajusta bien una muestra histórica.
- **Infraestructura analítica:** si el modelo no puede consultarse, versionarse y explicarse, su valor operativo cae de forma drástica.

Desde esa perspectiva, un buen resultado no es únicamente “predecir bien”. También implica poder distinguir entre una predicción bien soportada, una extrapolación razonable y una salida que requiere revisión adicional. Ese matiz es el que justifica que la memoria dedique espacio tanto a finanzas como a IA y a arquitectura de servicio.

1.3 ANTECEDENTES

La valoración de opciones sobre futuros se apoya tradicionalmente en Black-76 [Black, 1976]. En ese marco, el precio de una opción europea depende del futuro subyacente, el strike, el vencimiento, el tipo de interés y la volatilidad. Cuando el precio de mercado se observa, la volatilidad implícita se obtiene resolviendo numéricamente la ecuación inversa.

En paralelo, el uso de modelos de aprendizaje automático para superficies financieras responde a la necesidad de capturar no linealidades, interacciones y patrones empíricos que no quedan completamente descritos por modelos paramétricos simples. Sin embargo, la adopción profesional de modelos flexibles exige herramientas de interpretación. SHAP proporciona una semántica aditiva para atribuir predicciones a variables [Lundberg and Lee, 2017]; ICE y ALE ayudan a estudiar respuestas funcionales [Goldstein et al., 2015, Apley and Zhu, 2020]; los árboles surrogate y la regresión simbólica aproximan modelos complejos mediante objetos interpretables [Cranmer, 2023].

Los antecedentes relevantes convergen en tres líneas.

- **Línea financiera:** la inversión de modelos como Black-76 convierte precios observados en volatilidades comparables y lleva el problema al terreno de la superficie.
- **Línea empírica:** los smiles y las estructuras temporales muestran que la volatilidad de mercado no es constante y que la relación con strike y vencimiento es no lineal.
- **Línea metodológica:** los modelos de caja negra ganan flexibilidad, pero obligan a complementar la predicción con mecanismos de explicación y validación.

Este trabajo se sitúa precisamente en la intersección de esas tres líneas. Toma la formulación clásica de derivados como base para construir la variable objetivo, utiliza familias de aprendizaje automático sobre datos tabulares para aproximar la función de volatilidad y añade una capa de explicabilidad y servicio para hacer la solución defendible en un contexto profesional.

1.4 OBJETIVOS

El objetivo general es desarrollar una solución reproducible para estimar, explicar y consultar volatilidad implícita de opciones del IBEX. Este objetivo se concreta en los siguientes objetivos específicos:

1. Construir una base de volatilidad implícita a partir de operaciones, contratos, futuros subyacentes y curvas de tipos, con validaciones de calidad y trazabilidad.
2. Diseñar un conjunto de variables financieras coherentes con la geometría de la superficie de volatilidad.
3. Entrenar y comparar varias familias de modelos de regresión bajo una metodología temporal que reduzca lookahead bias y data snooping.
4. Generar componentes de explicabilidad global, local, funcional y de diagnóstico.
5. Implementar una API y un dashboard que permitan consultar predicciones, explicar muestras concretas y revisar el comportamiento del modelo.
6. Preparar infraestructura cloud reproducible para almacenar modelos, paquetes explicativos y metadatos de servicio.

Tomados en conjunto, estos objetivos cubren los tres planos que estructuran la memoria. El primero es **financiero**, porque la variable objetivo y las transformaciones deben respetar la lógica de opciones sobre futuros. El segundo es **de IA y Data Science**, porque la comparación entre familias exige un diseño temporal riguroso, métricas correctas y lectura crítica del error. El tercero es **de ingeniería**, porque el resultado final no es un gráfico aislado, sino un sistema consultable y versionable.

1.5 CONTRIBUCIÓN DEL TFM

La principal contribución del TFM es integrar en un único flujo operativo elementos que habitualmente se tratan por separado: construcción de datos de mercado, inversión de Black-76, entrenamiento de modelos, explicabilidad, diagnóstico financiero, API y despliegue cloud. La Figura 1 resume esta cadena con las mismas dependencias que la documentación técnica.




Figura 1: Vision general del proyecto.

La aportación académica se sitúa en la metodología de modelización y validación; la aportación profesional, en la capacidad de convertir un modelo de volatilidad en una herramienta inspeccionable y desplegable.

De forma más concreta, la contribución del trabajo puede resumirse así:

- **Contribución financiera:** construir una base de volatilidad implícita a partir de datos reales enlazando operaciones de opciones, futuros y curvas de tipos.
- **Contribución metodológica:** comparar familias heterogéneas con el mismo protocolo temporal, las mismas métricas y el mismo criterio de selección.
- **Contribución de explicabilidad:** combinar atribuciones SHAP, curvas ICE y ALE, modelos equivalentes, superficies y vecinos históricos en un único flujo de lectura.
- **Contribución de ingeniería:** dejar el modelo convertido en un paquete auto-contenido consumible por dashboard y API, con almacenamiento reproducible y despliegue desacoplado.

Desde el punto de vista de negocio en derivados, el valor aplicado se concreta en ocho usos directos:

- **Valoración de opciones ilíquidas o poco negociadas:** la predicción se apoya en estructura de superficie y soporte histórico de vecinos, no sólo en una cotización puntual.
- **Interpolación y suavizado de superficies de volatilidad:** el dashboard permite revisar continuidad por moneyness y vencimiento y detectar escalones no deseados.
- **Detección de precios anómalos o errores de mercado:** los residuales por zonas de superficie ayudan a localizar observaciones fuera de patrón.
- **Validación independiente de modelos internos:** el pipeline puede usarse como contraste externo frente a pricers de mesa o librerías internas.
- **Control de riesgos de mesa de derivados:** el error deja de leerse sólo en promedio y se monitoriza por tramos relevantes de moneyness y vencimiento.
- **Explicación ante auditoría interna o model validation:** cada predicción puede justificarse con SHAP, curvas funcionales y evidencia de soporte histórico.
- **Análisis de sensibilidad por moneyness y vencimiento:** superficies locales, ICE y ALE aportan lectura funcional de cómo reacciona el modelo.
- **Soporte a decisiones de cobertura:** la lectura conjunta de smile, term structure y diagnóstico local ofrece contexto operativo para coberturas.

Esa combinación es la que hace que el proyecto no sea sólo un ejercicio de entrenamiento de modelos. El valor añadido está en que cada capa técnica responde a una pregunta concreta y útil: cómo se construye la volatilidad, cómo se estima, cómo se valida, cómo se explica y cómo se despliega.

1.6 ESTRUCTURA DE LA MEMORIA

El [chapter 2](#) presenta los fundamentos financieros, de aprendizaje automático, explicabilidad e infraestructura. El [chapter 3](#) describe la construcción de datos, variables, modelos, validación, dashboard, API y cloud. El [chapter 4](#) analiza las métricas persistentes y la lectura que debe hacerse desde las vistas del dashboard. El [chapter 5](#) resume conclusiones y líneas futuras. Los anexos desarrollan SHAP, ICE, ALE, explicadores equivalentes y entrenamiento progressive ATM con mayor profundidad.

El orden de lectura responde al flujo real del proyecto.

1. En la **Introducción** se delimita el problema y se justifica por qué la explicabilidad es parte del resultado, no un añadido posterior.
2. En el **Marco Teórico** se fijan las piezas conceptuales necesarias para interpretar Black-76, smiles, familias de modelos, métricas y gobierno de modelos.
3. En la **Metodología** se documenta la implementación efectiva: ETL, features, validación temporal, reentrenamiento, generación del paquete de dashboard y despliegue.
4. En **Resultados y Discusión** se conectan métricas, superficies, explicaciones y limitaciones con una lectura financiera y técnica unificada.
5. En los **Anexos** se amplían los mecanismos de explicabilidad y entrenamiento para que la memoria principal conserve foco sin perder profundidad técnica.

MARCO TEÓRICO

2.1 OPCIONES, FUTUROS Y VOLATILIDAD IMPLÍCITA

Una opción financiera otorga a su comprador el derecho, pero no la obligación, de comprar o vender un activo subyacente a un precio de ejercicio K en una fecha futura. En el caso de opciones sobre futuros, el subyacente relevante para valoración es el precio del futuro F . La literatura de derivados enfatiza que el valor de una opción depende de la distribución esperada del subyacente y, de forma operativa, de la volatilidad usada en el modelo de valoración [Hull, 2022].

En el modelo Black-76, una call europea sobre un futuro se valora como:

$$C = e^{-rT} (FN(d_1) - KN(d_2)), \quad (1)$$

donde

$$d_1 = \frac{\ln(F/K) + \frac{1}{2}\sigma^2 T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}. \quad (2)$$

Para una put:

$$P = e^{-rT} (KN(-d_2) - FN(-d_1)). \quad (3)$$

En estas expresiones, r es el tipo de interés, T el tiempo a vencimiento en años, σ la volatilidad y $N(\cdot)$ la función de distribución normal estándar. La volatilidad implícita σ_{imp} es el valor de σ que iguala el precio teórico al precio observado en mercado:

$$P_{mercado} = P_{Black76}(F, K, T, r, \sigma_{imp}). \quad (4)$$

La ecuación (4) no se puede resolver en forma cerrada en general; se obtiene mediante métodos numéricos. En el proyecto se emplea bisección dentro de límites configurados, descartando filas no resolubles o no finitas.

Para el proyecto, esta formulación tiene varias implicaciones directas.

- La calidad de la volatilidad implícita depende de la calidad del precio de opción y del emparejamiento con el futuro subyacente.
- El tiempo a vencimiento no es un mero metadato: entra de forma no lineal a través de $\sqrt{T}$, por lo que errores en fechas o vencimientos contaminan la variable objetivo.
- El tipo de interés afecta tanto al descuento como a la construcción de variables derivadas basadas en el forward ajustado.
- Calls y puts comparten el mismo concepto de volatilidad implícita, pero pueden situarse en zonas distintas de la superficie y, por tanto, inducir respuestas diferentes en el modelo.

Por eso la memoria no trata la volatilidad implícita como una etiqueta estadística cualquiera. Antes de entrenar ningún modelo, la variable objetivo debe quedar bien definida desde el punto de vista financiero y bajo un procedimiento numérico reproducible.

2.2 SMILE, MONEYNES Y ESTRUCTURA TEMPORAL

Si la volatilidad fuese constante, opciones con distinto strike y vencimiento compartirían una misma σ . En mercados reales aparece una superficie de volatilidad:

$$\sigma_{imp} = \sigma(K, T), \quad (5)$$

o, de forma más comparable entre niveles de mercado:

$$\sigma_{imp} = \sigma(m, T), \quad m = \frac{F}{K}. \quad (6)$$

La moneyness m indica la posición relativa del subyacente frente al strike. Su transformación logarítmica,

$$\ell = \log(F/K), \quad (7)$$

es especialmente útil porque centra la región ATM en $\ell = 0$ y trata de forma más simétrica las zonas a ambos lados del strike. La literatura sobre smile subraya que la curvatura y pendiente de la volatilidad implícita contienen información sobre

expectativas de mercado, asimetría y demanda de cobertura [Derman and Miller, 2016].

En la práctica, esta superficie se lee a través de varios patrones.

- **Smile o skew:** describe cómo cambia la volatilidad implícita al alejarse de ATM.
- **Estructura temporal:** muestra cómo cambia la volatilidad con el vencimiento para una región dada de moneyness.
- **Interacción entre ambas:** la curvatura del smile no tiene por qué ser la misma en corto plazo que en vencimientos largos.

Esta lectura geométrica justifica el diseño posterior de variables y visualizaciones. Si el fenómeno financiero se organiza en torno a moneyness y vencimiento, es razonable que el feature engineering, la validación y los gráficos de comportamiento del modelo se construyan también alrededor de esas magnitudes.

2.3 APRENDIZAJE AUTOMÁTICO PARA VOLATILIDAD

El problema de modelización se formula como una regresión supervisada:

$$\hat{\sigma} = f(X), \quad (8)$$

donde X contiene variables financieras observables y transformadas. El proyecto compara familias con diferentes niveles de flexibilidad:

- Regresión lineal, como baseline interpretable y control de complejidad.
- Random Forest, basado en agregación de árboles para capturar interacciones no lineales [Breiman, 2001].
- XGBoost, como boosting regularizado con early stopping y buen rendimiento en datos tabulares [Chen and Guestrin, 2016].
- Redes neuronales densas, como aproximadores flexibles de funciones no lineales [Hornik et al., 1989].
- Una red neuronal clásica *quantum inspired*, que introduce una estructura tensorial inspirada en ideas de representación compacta. No se presenta como computación cuántica real, sino como una variante arquitectónica implementada en código.

La comparación no puede basarse solo en error medio. En datos financieros temporales, una evaluación mal planteada puede introducir fuga de información. Por ello se emplean splits temporales, control de contratos compartidos y k-folds temporales, tal como se desarrolla en el [section 3.6](#).

2.4 EXPLICABILIDAD EN MODELOS FINANCIEROS

La explicabilidad cumple una función técnica y una función de gobierno de modelos. Técnicamente, permite detectar variables dominantes, discontinuidades, extrapolaciones y errores locales. Profesionalmente, facilita responder por qué una predicción se considera razonable y en qué condiciones no debería confiarse en ella.

SHAP descompone la predicción de un modelo en un valor base y contribuciones por variable:

$$\hat{\sigma}(x) = \phi_0 + \sum_{j=1}^p \phi_j(x), \quad (9)$$

donde ϕ_j mide la contribución atribuida a la característica j [Lundberg and Lee, 2017]. En este proyecto se complementa con ICE, ALE, árboles surrogate, regresión simbólica y vecinos históricos. La razón es que ninguna herramienta por sí sola responde todas las preguntas relevantes: SHAP explica contribuciones, ICE muestra trayectorias individuales, ALE estima efectos acumulados locales, los modelos surrogate dan reglas aproximadas y los vecinos informan sobre soporte local.

2.5 MÉTRICAS DE ERROR, ESTABILIDAD Y FIDELIDAD

La evaluación de un modelo de volatilidad requiere métricas complementarias. El error absoluto medio,

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (10)$$

ofrece una lectura directa en unidades de volatilidad. Es robusto y fácil de comunicar, pero no penaliza de forma diferencial los errores grandes. Por ese motivo se utiliza también RMSE:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (11)$$

El RMSE es especialmente relevante en model validation porque amplifica errores extremos. En una superficie de volatilidad, esos errores pueden aparecer en vencimientos cortos, extremos de moneyness o zonas con menor liquidez. El coeficiente de determinación,

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (12)$$

resume proporción de variabilidad explicada, aunque debe interpretarse con prudencia en datos financieros heterogéneos.

Junto a estas métricas frente a mercado, el dashboard usa métricas de fidelidad para modelos explicables equivalentes. La fidelidad compara el surrogate con el modelo principal, no con la volatilidad real. Esta distinción es importante: un árbol surrogate puede ser muy fiel a un modelo sesgado, y un modelo principal puede tener buen RMSE pero ser difícil de resumir con reglas simples. Por tanto, la evaluación final debe combinar tres planos: precisión frente a mercado, estabilidad del proceso de selección y fidelidad de las explicaciones.

2.6 GOBIERNO DE MODELOS Y PREGUNTAS DE VALIDACIÓN

En un entorno financiero, un modelo de volatilidad debería poder responder a preguntas de model validation. Algunas son cuantitativas: cuál es el error fuera de muestra, si existe gap entre entrenamiento y validación, si el error cambia por vencimiento o moneyness, y si el resultado es estable entre folds. Otras son cualitativas pero igualmente relevantes: si el modelo reacciona de forma razonable ante cambios de strike, si produce superficies suaves donde el mercado debería ser continuo, si una predicción manual se encuentra dentro de una región observada o si el predictor depende excesivamente de una variable que no debería dominar.

El diseño del proyecto convierte esas preguntas en vistas concretas del dashboard.

- *La pestaña de diagnóstico* responde dónde falla.
- *La pestaña de superficie* responde cómo se comporta como función financiera.
- *La explicabilidad global* responde qué variables tienen mayor influencia en las predicciones del modelo.
- *La pestaña explicabilidad local* responde por qué una muestra concreta obtiene un valor determinado y si existen observaciones históricas cercanas.

Esto evita que una única visualización condicione toda la interpretación. En un entorno de derivados, la confianza en una predicción surge de la coherencia entre varias vistas, no de una sola gráfica llamativa o de una única métrica sintética.

METODOLOGÍA

3.1 DISEÑO GENERAL DEL ESTUDIO

El estudio tiene carácter empírico y aplicado. Parte de datos de mercado, construye una variable objetivo financiera mediante inversión de Black-76, entrena modelos de regresión y evalúa tanto rendimiento predictivo como coherencia explicativa. La Figura 2 resume el flujo metodológico.




Figura 2: Flujo metodológico del TFM.

El flujo no es lineal sólo en apariencia. Cada bloque deja salidas persistidas y comprobables que sirven de entrada al siguiente, de modo que la metodología puede auditarse por etapas. Primero se consolida la base financiera; después se fija un espacio de variables coherente con la superficie; a continuación se comparan familias bajo un protocolo temporal común; y, por último, se transforma el modelo seleccionado en un sistema consultable. Este diseño responde a cuatro principios metodológicos.

- **Separación de responsabilidades:** ETL, modelización, explicabilidad y servicio no se mezclan en un único bloque opaco.
- **Trazabilidad de extremo a extremo:** cada predicción puede rastrearse hasta datos, configuración y versión de modelo.
- **Comparabilidad entre familias:** todas las alternativas compiten bajo las mismas reglas de split, métricas y reentrenamiento.

- **Lectura profesional del resultado:** el producto final no es sólo una tabla de métricas, sino un modelo interpretable y servible.

Esta estructura es importante porque condiciona la credibilidad de los resultados. Si el entrenamiento fuese correcto pero las explicaciones o el servicio no reutilizasen exactamente la misma lógica de features, la calidad del sistema quedaría comprometida aunque las métricas numéricas fueran buenas.

3.2 DATOS Y MUESTRA ANALIZADA

El pipeline de datos transforma ficheros de contratos, operaciones y tipos en una base final de volatilidad implícita. Hay tres fuentes principales:

- **Contratos:** aportan información de código, strike y vencimiento.
- **Operaciones:** aportan precio, cantidad, hora y contrato.
- **Series de EONIA/€STR:** permiten calcular el tipo compuesto aplicable hasta vencimiento.

En el cálculo de tipos se asume una aproximación operativa: no se dispone de un calendario TARGET2 explícito dentro del pipeline, por lo que el conteo de días hábiles se implementa con `pd.bdate_range` (días laborables estándar). La composición se aplica exactamente como en el código: se recorre cada día hábil del intervalo, se toma r_i (retrocediendo al último dato disponible si ese día no existe en la serie) y se multiplica $1 + r_i n_i / 360$, con $n_i = 3$ cuando el día hábil es lunes y $n_i = 1$ en el resto. Después se anualiza como

$$\left(\prod_i \left(1 + \frac{r_i n_i}{360} \right) - 1 \right) \cdot \frac{360}{d_c}.$$




Figura 3: Secuencia principal de procesamiento de datos.

La guía de referencia para la lógica de tipos compuestos es la del BCE para €STR: https://www.ecb.europa.eu/stats/euro-short-term-rates/interest_rate_benchmarks/WG_euro_risk-free_rates/shared/pdf/ecb.Compounded_euro_short-term_rate_calculation_rules.en.pdf. En esta memoria se documenta de forma explícita que la implementación actual reproduce la convención descrita en el código (incluido el peso 3 en lunes) y debe

interpretarse como aproximación operativa mientras no se incorpore un calendario TARGET2 completo en la construcción de Rate.

La cadena ETL se materializa por pasos, como muestran las Figuras 3 y 4. Esta organización permite cachear salidas intermedias, validar contratos de datos y aislar responsabilidades: los *StepLoaders* orquestan lectura, cache y validación, mientras que los *builders* construyen la salida material de cada paso.

La Figura 5 resume esta separación entre clases *loader* y clases *builder*. El detalle extenso de las estructuras de datos que va produciendo cada etapa se recoge además en el [chapter A](#), para no sobrecargar el cuerpo principal con un diagrama demasiado largo.

Los datos se filtran al dominio de opciones IBEX mensuales y futuros mensuales asociados. Las opciones semanales y contratos fuera de dominio se excluyen para mantener coherencia contractual.




Figura 4: Pipeline completo de datos hasta VOLATILITY_DB.




Figura 5: Esquema de responsabilidades entre *loaders* y *builders* en el ETL.

La salida final contiene fecha y hora de ejecución, código de opción, tipo call/put, precio negociado, strike, futuro subyacente, precio del subyacente, desfase temporal opción-subyacente (minutos), tiempo a vencimiento, tipo compuesto y volatilidad implícita.

El **primer paso**, Read Raw Step, normaliza ficheros de mercado con o sin cabecera, elimina columnas auxiliares no pertenecientes al esquema final, convierte fechas, horas y numéricos, filtra prefijos IBEX y construye una serie homogénea de tipos. La base de tipos combina EONIA ajustado por el spread configurado antes de la fecha de corte y €STR desde esa fecha. Figuras 6a, 6b.




Figura 7: Paso 2. Unión por código de contrato y año de sesión.

El **segundo paso**, Merge Raw Step, une operaciones y contratos por ContractCode y año de sesión, imputa vencimientos con la regla del tercer viernes e imputa strikes desde el tramo configurado del código cuando la fuente no lo trae completo. Las Figuras 8a y 7 resumen visualmente esta fase.




Figura 8: Unión de datos contractuales y separación por producto.

El **tercer paso**, Product Split Step, divide la base unificada en opciones, futuros y relación opción-futuro por vencimiento.

El **cuarto**, Underlying Step, garantiza el emparejamiento temporal sin lookahead y resuelve el precio de futuro subyacente mediante una unión temporal *as-of*: para cada opción selecciona el último trade del futuro con instante de ejecución menor o igual al de la opción. Esta decisión evita lookahead dentro del propio ETL.




Figura 9: Paso 4. Asignación de futuro subyacente a cada opción.

El **quinto**, Volatility Step, filtra operaciones sin subyacente fiable o con desfase temporal excesivo, calcula el tipo compuesto hasta vencimiento y resuelve la volatilidad implícita por Black-76 inverso (Figuras 11 y 10).




Figura 10: Paso 5. Solver por bisección de la volatilidad implícita.

En este **último paso** se aplican reglas de calidad relevantes para evitar sesgos en entrenamiento: se excluyen filas sin subyacente válido, filas con desfase opción-subyacente superior al umbral configurado de 180 minutos, y filas cuya volatilidad implícita no puede resolverse de forma válida (por ejemplo, sin cambio de signo del solver o con soluciones no finitas). Estas decisiones son coherentes con el análisis exploratorio y con las validaciones financieras del pipeline.




Figura 11: Paso 5. Cálculo de volatilidad implícita.

3.3 VALIDACIONES Y TRATAMIENTO FINANCIERO

El ETL aplica validaciones transversales: precios positivos, cantidades positivas, ausencia de claves duplicadas, control de missing values, vencimientos coherentes, strikes compatibles con el código de contrato y subyacente temporalmente anterior a la operación de la opción. Esta última condición es crítica para evitar utilizar información futura.

Para evitar ambigüedades, en esta memoria se distinguen dos conceptos de lag: el desfase opción-subyacente del ETL (en minutos) y el lag temporal del split de entrenamiento (en número de fechas) usado más adelante en la validación de modelos.

El cálculo de volatilidad implícita se realiza en el último paso. Se eliminan operaciones sin subyacente fiable, se calcula el tipo compuesto hasta vencimiento y se resuelve la ecuación (4). Si no existe cambio de signo en el intervalo de búsqueda o la solución es no finita, la observación se marca como no resoluble y no alimenta el entrenamiento. La Figura 12 resume estas validaciones sobre el contrato y su interpretación.




Figura 12: Validación e interpretación del código de contrato.

3.4 VARIABLES Y FEATURE ENGINEERING

Las entradas raw visibles son `OptionType`, `StrikePrice`, `UnderlyingPrice`, `TimeToExpiration` y `Rate`. Estas variables son suficientes para reconstruir el vector de entrenamiento y también son comprensibles para un usuario financiero que consulte la API.

No se aplica una fase de selección de variables ex post (ni filtros automáticos de descarte por importancia) porque el foco metodológico es simular una operación directa con un conjunto de entradas financieras estable, reproducible y utilizable tal cual en API/dashboard. La comparación entre familias se hace, por diseño, sobre el mismo espacio de variables para aislar el efecto de la arquitectura y no de una poda específica de features.

El vector transformado se diseña para representar la geometría de la superficie. La Tabla 1 resume las variables derivadas.

Feature	Fórmula	Motivo
TTEYears	$T = T_{\text{días}}/365$	Vencimiento en años
sqrtTTEYears	$\sqrt{T}$	Escala temporal de Black-76
logMoneyness	$\log(F/K)$	Posición relativa frente al strike
logMoneynessSq	$\log(F/K)^2$	Curvatura del smile
logMoneynessXSqrtTTE	$\log(F/K)\sqrt{T}$	Interacción smile-vencimiento
logForwardMoneyness	$\log(Fe^{rT}/K)$	Ajuste por tipo y vencimiento
rate	r	Sensibilidad directa a tipos
isCall, isPut	Indicadores	Tipo de opción

Cuadro 1: Features financieras utilizadas por los modelos.

Esta elección evita que el modelo dependa de niveles absolutos de strike que pueden cambiar con el régimen de mercado. La moneyness permite comparar contratos negociados en momentos distintos del IBEX, mientras que el vencimiento y sus transformaciones capturan estructura temporal. Las Figuras 13 y 14 muestran la construcción y motivación financiera de estas variables.




Figura 13: Construcción de features financieras.




Figura 14: Motivación financiera de las features.

3.5 FAMILIAS DE MODELOS

El repositorio implementa una abstracción común para familias de modelos. Cada familia declara nombre, parámetros fijos, espacio de búsqueda, instanciación, entrenamiento y persistencia. La Tabla 2 resume su papel en el estudio.

Familia	Papel metodológico
Regresión lineal	Baseline interpretable para evaluar cuánto aporta la no linealidad.
Random Forest	Modelo tabular robusto ante interacciones y no linealidades sin escalado.
XGBoost	Boosting regularizado con early stopping interno y alta capacidad predictiva.
Red neuronal secuencial	Aproximador flexible con escalado de variables numéricas y early stopping sobre validación interna.
Quantum Inspired NN	Variante clásica de red neuronal con estructura tensorial inspirada en ideas cuánticas; se evalúa como arquitectura implementada, no como computación cuántica física.

Cuadro 2: Familias de modelos entrenadas en el proyecto.

Todas las familias heredan una interfaz común: declaran parámetros fijos, espacio de búsqueda, instanciación, entrenamiento, persistencia y número de configuraciones exploradas. Esta homogeneidad permite comparar un baseline lineal, modelos de árboles, boosting y arquitecturas neuronales con el mismo protocolo de selección. En la familia Quantum Inspired, el cálculo sigue siendo clásico: las features se proyectan a un embedding, se reordenan como tensor y se contraen mediante una capa tensor-train antes de una capa densa final. El concepto y su implementación práctica se detallan en el [chapter E](#).

La elección de familias responde a una lógica comparativa.

- La **regresión lineal** fija una referencia interpretable y permite medir cuánto valor añade la no linealidad una vez creadas las features correctas.
- **Random Forest** y **XGBoost** representan dos formas distintas de explotar interacciones tabulares complejas sin exigir el mismo tipo de preprocesado que las redes.
- Las **redes neuronales** sirven para comprobar si una arquitectura más flexible mejora realmente el problema o sólo incrementa el coste y la complejidad de explicación.
- La variante **Quantum Inspired** introduce una hipótesis arquitectónica diferenciada manteniendo computación clásica, lo que permite valorar su aportación real frente a alternativas más estándar.

La interfaz común del repositorio hace además que la comparación sea metodológicamente limpia. Todas las familias pasan por los mismos splits temporales, las mismas métricas y el mismo proceso de reentrenamiento y conversión a paquete de dashboard. Eso evita que una familia “gane” por haber sido evaluada con un protocolo distinto del resto.

3.6 SPLITS TEMPORALES Y SELECCIÓN




Figura 15: Esquema conceptual de particiones temporales.

La validación sigue tres principios.

1. Respeto del orden temporal: train precede a validation y test.
2. Puede existir un lag de fechas entre bloques para reducir contaminación temporal.
3. Exclusividad de contratos: si el mismo contrato aparece en más de un split, se conserva en un único bloque según volumetría y prioridad.

Esta última regla es relevante porque una opción puede negociarse durante varios días. Si un contrato aparece en entrenamiento y validación, el modelo podría aprender rasgos idiosincráticos del contrato y ofrecer una estimación optimista. Las Figuras 17, 15, 16 y 18 resumen la lógica temporal, la separación con lag y el control de contratos compartidos.

La búsqueda de hiperparámetros se realiza con k-folds temporales. Estos k-folds se construyen exclusivamente dentro del bloque de entrenamiento, de modo que validation y test externos quedan fuera del proceso de búsqueda. Para cada candidato se calculan MAE, RMSE y R^2 en train y validation.




Figura 16: Control de contratos compartidos entre splits.

La selección usa una métrica compuesta:

$$CE_1 = RMSE_{val} + \alpha \cdot std(RMSE_{val}) + \beta \cdot \max(0, RMSE_{val} - RMSE_{train}). \quad (13)$$

Esta métrica penaliza error de validación, inestabilidad entre folds y gap de sobreajuste. Según la configuración del repositorio, $\alpha = 0,25$ y $\beta = 0,75$.




Figura 17: Control temporal y exclusividad de contratos.




Figura 18: Construcción de k-folds temporales.

3.7 REENTRENAMIENTO Y PROGRESSIVE ATM




Figura 19: Entrenamiento progressive ATM por segmentos.

Después de seleccionar hiperparámetros, el modelo se reentrena en dos fases: train/validation y final test. En la fase final se ajusta con trainval y se evalúa contra test. La métrica de reentrenamiento incorpora el rendimiento observado en selección:

$$CE_2 = RMSE_{val} + \gamma \cdot CE_1 + \beta \cdot \max(0, RMSE_{val} - RMSE_{train}), \quad (14)$$

con $\gamma = 0,25$ y $\beta = 0,75$ en la configuración actual.

Es importante precisar que CE_2 se utiliza para monitorizar consistencia en la fase train/validation. La evaluación definitiva de generalización del modelo se realiza siempre sobre el bloque test fuera de muestra.

El proyecto incluye una variante progressive ATM. Ordena observaciones por $|\log(F/K)|$, de más cercano al ATM a más alejado, y divide el entrenamiento en segmentos. La idea financiera es aprender primero la zona central, habitualmente más líquida y estable, y después incorporar zonas más alejadas. En modelos no iterativos se implementa mediante pesos; en XGBoost y redes se implementa mediante fases acumulativas. Por su carácter experimental, esta variante se menciona aquí y se desarrolla en el [chapter G](#). Las Figuras 20 y 19 muestran el reentrenamiento del mejor candidato y los segmentos ATM.




Figura 20: Reentrenamiento del mejor candidato.

3.8 CONSTRUCCIÓN DEL DASHBOARD

El dashboard no entrena modelos. Consume paquetes autocontenidos generados desde modelos finales (ver Figura 21). Cada paquete contiene dataset con predicciones, residuales y error absoluto, muestras para explicabilidad local, puntos de referencia de superficies, SHAP global y local, árboles surrogate, regresor simbólico, vecinos, superficies, ICE, ALE y diagnóstico agregado.




Figura 21: Conversión de modelo final a paquete visualizable.

La transformación de un modelo final a este paquete no modifica el predictor: carga el runtime, aplica el mismo feature engineering sobre train y test, calcula artefactos explicativos y persiste una carpeta autocontenida en `src/dashboard/saved_models/`.

La aplicación se estructura en cuatro pestañas, resumidas en la Tabla 3. Esta organización responde a preguntas distintas y evita confundir error predictivo con explicación.

En particular, la lectura SHAP se divide en dos niveles complementarios: **SHAP global** en la pestaña *Global Explainability* (drivers y patrones agregados) y **SHAP local** en la pestaña *Sample Explainability*, donde se muestra el *Local SHAP Waterfall* para justificar una predicción concreta.

Las vistas del dashboard son necesarias para localizar dónde aparece esa comprensión. El scatter *predicted vs actual* debe confirmar si los extremos altos y bajos se acercan a la media; el residual heatmap debe separar error por *money*ness y vencimiento; y las cajas *Error by Money*ness y *Error by Maturity* deben indicar si los extremos de *money*ness o los vencimientos cortos concentran el fallo.

Pestaña	Pregunta principal
Behaviour And Surface	¿Cómo responde el modelo ante cambios de money-ness, vencimiento y otras variables financieras?
Global Explainability	¿Qué variables y patrones dominan las predicciones globales?
Sample Explainability	¿Por qué una muestra concreta recibe esa volatilidad y tiene soporte histórico?
Diagnosis	¿Dónde acierta y dónde falla el modelo en la superficie?

Cuadro 3: Pestañas del dashboard y función analítica.

Las Figuras 22, 25, 23, 24 y 26 muestran estos flujos y vistas; en particular, la vista local de *Sample Explainability* es la puerta de entrada al *Local SHAP Waterfall* y al contexto de vecinos históricos.




Figura 22: Flujo de la pestaña Behaviour And Surface.




Figura 23: Flujo de la pestaña Global Explainability.




Figura 24: Flujo de la pestaña Sample Explainability.




Figura 25: Vistas de diagnóstico del modelo final.

3.9 API, ALMACENAMIENTO Y CLOUD

La API se implementa con FastAPI como un servicio *ad hoc* independiente del dashboard. Puede servir cualquier modelo preparado bajo este flujo de entrenamiento, sin depender de la capa visual. El código expone endpoints de salud, predicción y explicabilidad local:

- /health
- /run_model/predict/
- /run_model/sample_explainability/

La petición incluye modelo, tipo de opción, strike, subyacente, tiempo a vencimiento, tipo de interés y, opcionalmente, código de contrato y volatilidad real.

La respuesta de predicción incluye el modelo, la volatilidad estimada y la entrada normalizada. La respuesta de explicabilidad local añade waterfall SHAP, payload de contribuciones, vecinos históricos y distancias. API y dashboard comparten modelos




Figura 26: Construcción de superficies locales de volatilidad.

y paquetes autocontenidos de dashboard, lo que reduce el riesgo de explicar una versión distinta de la usada para predecir.




Figura 27: Arquitectura cloud del sistema: almacenamiento, elementos y servicios de API/dashboard.

El backend de almacenamiento puede ser local o GCP. En GCP se usan Cloud Storage para modelos y paquetes de dashboard, Artifact Registry para imágenes de contenedor, Cloud Run para API y dashboard, e IAM para permisos. Terraform define los recursos y permite reproducir la infraestructura. La parte crítica es mantener sincronizados modelo, scaler, metadatos y paquete explicativo; por eso el reentrenamiento

miento final dispara su construcción después de guardar el modelo. La Figura 27 resume este esquema de despliegue, dejando explícita la separación entre almacenamiento, artefactos de modelo y servicios desplegados.

3.10 REPRODUCIBILIDAD

El trabajo se ha realizado siguiendo todos los pasos descritos en este documento. De la misma manera, siguiendo todos los pasos descritos en este documento junto con los notebooks de ayuda del repositorio y la **documentación de github** (epiblasfunds.github.io/options-pricing/) es posible reproducir el trabajo si contamos con los datos fuentes necesarios (sino, estos datos pueden ser mockeados).

Lo necesario para reproducir el estudio es llevar a cabo los procesos de:

1. Procesado de datos.
2. Entrenamiento de modelos.
3. Conversión de modelos entrenados al formato adecuado para presentar en el dashboard.
4. Tener cuenta de GCP y poder desplegar el dashboard y la API.

Es importante remarcar que aunque la configuración sea la misma es posible que los resultados de entrenamiento varíen un poco y esto provoque métricas, fórmulas de regresión simbólica y árboles de decisión ligeramente distintos.

3.11 ARQUITECTURA DEL REPOSITORIO




Figura 28: Secuencia de ejecución entre paquetes.

La arquitectura del repositorio sigue una separación por funcionalidades: cada paquete tiene un cometido identificable y las salidas persistidas pasan de una etapa

a otra sin mezclar entrenamiento, explicación y servicio. La Figura 28 muestran la secuencia de ejecución, la cadena de salidas y las dependencias entre paquetes.

Paquete o carpeta	Responsabilidad principal
src/config	Carga de configuración, rutas absolutas, logging y objetos de configuración por dominio.
src/enums	Definición centralizada de columnas, tipos de contrato, tipos de opción y nombres de modelos.
src/exceptions	Excepciones de dominio usadas en validaciones de datos y control de errores del ETL.
src/data_management	ETL de datos: loaders, builders, validaciones y utilidades de contrato.
src/volatility_models	Preparación de datos de entrenamiento, splits, k-folds, selección y reentrenamiento.
src/python_models	Abstracciones de familias de modelos y estructuras persistentes de dashboard.
src/model2dashboard	Conversión de modelos finales en paquetes explicativos autocontenidos.
src/dashboard	Aplicación Dash, servicios, callbacks, gráficos y utilidades de validación.
src/api	API FastAPI para predicción y explicabilidad local.
resources	Configuración declarativa (datos, modelos y cliente-servidor) consumida por el runtime.
dockerfiles	Definiciones de imagen para API, dashboard, LaTeX y utilidades de documentación.
scripts	Automatizaciones auxiliares de soporte operativo y generación de artefactos.
terraform	Infraestructura cloud reproducible: buckets, registro de imágenes, Cloud Run e IAM.

Cuadro 4: Arquitectura lógica del repositorio.

La Tabla 4 muestra que el dashboard no reentrena modelos y la API no reconstruye explicaciones desde cero salvo en casos de explicabilidad local manual. Esta separación reduce el acoplamiento y facilita detectar errores. Si una predicción de API no coincide con la vista del dashboard, el problema puede acotarse a carga del paquete autocontenido, transformación de features o versión de modelo.

Vista así, la arquitectura no es sólo una organización de carpetas. Es una forma de aislar responsabilidades, simplificar depuración y poder justificar cada paso del flujo de principio a fin.

Desde esa misma lógica, la arquitectura se apoya en un flujo de trabajo de ingeniería más próximo al de un proyecto real que al de un experimento ad hoc: ramas de trabajo, commits trazables, validaciones antes de integrar y control explícito de cambios sobre código, configuración, documentación y despliegue.

Todos estos paquetes están cubiertos por más del 80 % en cobertura de tests unitarios, haciendo que las funcionalidades sean robustas para futuras evoluciones del código, haciéndolo más escalables. A esta escalabilidad ayuda también el chequeo de formato Flake8. Para obligar a respetar tanto el formato Flake8 como el paso de los tests, se han desarrollado workflows de GitHub para que GitHub actions ejecute en pipelines para comprobar ambas condiciones.

3.12 RIESGOS METODOLÓGICOS Y CONTROLES

Los principales riesgos metodológicos se anticipan desde el diseño.

1. Lookahead bias: controlado mediante orden temporal y subyacentes anteriores a la opción.
2. Data snooping: mitigado separando búsqueda de hiperparámetros, reentrenamiento y evaluación final.
3. Memorización de contratos: tratado con exclusividad de contratos entre splits.
4. Extrapolación en zonas poco cubiertas, diagnosticada con vecinos históricos y heatmaps de error.
5. Confundir explicabilidad del modelo con verdad de mercado: por ello los surrogates se presentan con métricas de fidelidad y los resultados se contrastan frente a residuales y superficies.

RESULTADOS Y DISCUSIÓN

La comparación final muestra que la solución estándar basada en Random Forest ofrece un comportamiento fuera de muestra sólido. En el conjunto de test obtiene $RMSE = 0,088403$, $MAE = 0,054366$ y $R^2 = 0,790941$. La lectura de resultados se organiza en tres planos: rendimiento predictivo, impacto del entrenamiento progressive ATM y capacidad de explicación del modelo de referencia mediante dashboard.

4.1 RESULTADOS

4.1.1 Comparativa general de modelos

Modelo	Entrenamiento	MAE test	RMSE test	R^2 test	CE ₂
Regresión lineal	estándar	0.067585	0.183824	0.096059	0.133738
Regresión lineal	progressive ATM	0.070544	0.187747	0.057069	0.132802
Random Forest	estándar	0.054366	0.088403	0.790941	0.089361
Random Forest	progressive ATM	0.054337	0.088533	0.790326	0.091597
XGBoost	estándar	0.054604	0.091735	0.774885	0.086826
XGBoost	progressive ATM	0.057295	0.113606	0.654747	0.093189
Red neuronal secuencial	estándar	0.055425	0.113506	0.655354	0.090209
Red neuronal secuencial	progressive ATM	0.055634	0.120161	0.613754	0.096304
Quantum Inspired NN	estándar	0.056056	0.143025	0.452787	0.089332
Quantum Inspired NN	progressive ATM	0.055597	0.117404	0.631276	0.100256

Cuadro 5: Comparación final de modelos en test y métrica compuesta de reentrenamiento train/validation.

La Tabla 5 muestra que las familias de árboles dominan el test. Random Forest estándar obtiene el menor RMSE y el mayor R^2 ; XGBoost estándar queda cerca, pero con RMSE ligeramente superior. Las redes neuronales no superan a las familias de árboles en esta muestra, aunque la variante Quantum Inspired mejora claramente al aplicar progressive ATM frente a su versión estándar.

La comparación deja tres mensajes claros.

- El problema parece premiar modelos tabulares capaces de capturar interacciones no lineales sin requerir un ajuste tan delicado como el de las redes.
- La diferencia entre Random Forest y XGBoost es pequeña en valor absoluto, pero suficiente para inclinar la selección final hacia el bosque.
- Las arquitecturas más complejas no aportan automáticamente mejor generalización, lo que refuerza la necesidad de validar fuera de muestra y no por intuición tecnológica.

Por tanto, el resultado agregado ya sugiere una lectura metodológica útil: en esta base de volatilidad implícita, la ventaja no proviene de la familia más sofisticada en abstracto, sino de la que mejor equilibra flexibilidad, robustez y estabilidad temporal.

4.1.2 Entrenamiento estándar frente a progressive ATM

Familia	RMSE base	RMSE prog.	Δ	Lectura
Regresión lineal	0.183824	0.187747	+0.003923	Empeora levemente.
Random Forest	0.088403	0.088533	+0.000130	Prácticamente neutro.
XGBoost	0.091735	0.113606	+0.021871	Degrada test.
Red neuronal secuencial	0.113506	0.120161	+0.006655	Degrada test.
Quantum Inspired NN	0.143025	0.117404	-0.025621	Mejora clara.

Cuadro 6: Impacto agregado de progressive ATM frente a entrenamiento estándar.

El entrenamiento progressive ATM no produce una mejora universal. En Random Forest, que ya muestra un comportamiento muy estable en la comparación, el cambio es casi neutro; en XGBoost y en la red secuencial empeora el RMSE test; en Quantum Inspired sí actúa como regularizador útil. Esto encaja con la interpretación metodológica: ordenar por cercanía a ATM puede estabilizar arquitecturas iterativas más sensibles, pero también puede sesgar el aprendizaje si los extremos de moneyness contienen información necesaria para test. Por tanto, progressive ATM debe tratarse como variante experimental y no como decisión automática.

La evidencia sugiere una lectura por familias.

- En **Random Forest**, la proximidad de resultados indica que el bosque ya capta bien la señal central sin necesitar currículum de entrenamiento.
- En **XGBoost** y en la **red secuencial**, el deterioro sugiere que priorizar ATM puede dejar peor representadas zonas relevantes para la generalización final.

- En **Quantum Inspired**, la mejora apunta a que la estrategia sí puede actuar como regularizador estructural cuando la arquitectura es más sensible al orden de aprendizaje.

La conclusión práctica es sobria: progressive ATM es útil como hipótesis de trabajo y como herramienta de análisis, pero su activación debe justificarse por evidencia empírica en cada familia concreta.

4.1.3 Modelo de referencia

Elemento	Valor final
Modelo de referencia	Random Forest
Estrategia de entrenamiento	Estándar, sin progressive ATM
Ruta del modelo	src/volatility_models/ trained_models/random_forest.joblib
Hiperparámetros principales	500 árboles, profundidad máxima 8, min_samples_leaf=10, max_features=0.5, max_samples=0.6
RMSE test	0.088403
MAE test	0.054366
R^2 test	0.790941
Argumento principal	Buen equilibrio entre error fuera de muestra, estabilidad temporal y facilidad de uso en el paquete explicativo.
Riesgo principal detectado	Predicciones menos dispersas que la volatili- dad real: $\sigma_{\hat{y},test} = 0,149458$ frente a $\sigma_{y,test} =$ 0,193345.

Cuadro 7: Ficha del modelo de referencia.

Más allá del RMSE, la comparación en train/validation muestra una generalización consistente: $RMSE_{train} = 0,071027$, $RMSE_{val} = 0,071080$ y $R^2_{val} = 0,653348$. XGBoost tiene el CE_2 más bajo en train/validation, pero su test queda por detrás. La lectura práctica prioriza rendimiento fuera de muestra, estabilidad razonable y menor degradación al pasar de validación a test.

La selección final combina criterios cuantitativos y operativos.

- **Criterio cuantitativo principal:** mejor RMSE test entre todas las alternativas evaluadas.
- **Criterio de estabilidad:** gap contenido entre entrenamiento, validación y test, sin señales fuertes de sobreajuste.

- **Criterio operativo:** buen encaje con las herramientas de diagnóstico, explicabilidad y servicio generadas para el paquete final.

Con ello, el análisis deja de ser una simple foto de leaderboard. La solución de referencia soporta bien la transición desde el entrenamiento hasta el uso interpretado en dashboard y API.

4.1.4 Diagnóstico de rendimiento

El diagnóstico debe interpretarse a partir del test. La desviación estándar de la volatilidad real es 0.193345 y la de las predicciones de Random Forest es 0.149458. La salida del modelo presenta menos dispersión que la serie observada: conserva la estructura general de la superficie, pero reduce la amplitud de los movimientos extremos. Dicho de otro modo, la predicción actúa como una versión suavizada de la volatilidad real, con una desviación estándar residual de 0.085859, coherente con un RMSE de 0.088403.



Figura 29: Comparativa de la pestaña *Diagnosis* en dos referencias del estudio: Random Forest y XGBoost.

Las vistas del dashboard son necesarias para localizar dónde aparece esa comprensión. El scatter *predicted vs actual* debe confirmar si los extremos altos y bajos se acercan a la media; el residual heatmap debe separar error por moneyness y vencimiento; y las cajas *Error by Moneyness* y *Error by Maturity* deben indicar si los extremos de moneyness o los vencimientos cortos concentran el fallo. La conclusión accionable es que el modelo es competitivo agregadamente, pero su uso debe acompañarse de diagnóstico por zonas de la superficie cuando se consulten contratos poco líquidos o alejados de ATM.

La Figura 29 confirma lo anterior y permite además una lectura transversal de todas las capturas de diagnóstico: Random Forest y XGBoost concentran los mejores indicadores (RMSE 0,0884 y 0,0917, respectivamente), mientras que Sequential NN

(0,1135), Quantum Inspired (0,1430) y, sobre todo, la regresión lineal (0,1838) muestran mayor pérdida de ajuste global. En paralelo, los *Financial Warnings* son informativos: la regresión lineal no dispara alertas de discontinuidad local, pero lo hace a costa de mayor error agregado; en cambio, los modelos más expresivos mejoran ajuste pero pueden introducir saltos locales en smile o term-structure, especialmente en muestras no centrales.

En la práctica, el diagnóstico debe responder tres preguntas consecutivas.

- Si el error está repartido de forma homogénea o se concentra en zonas concretas de la superficie.
- Si la dispersión de predicciones es suficiente o si el modelo tiende a comprimir sistemáticamente los extremos.
- Si los fallos observados son compatibles con escasez de datos, con dificultades intrínsecas del problema o con una arquitectura demasiado rígida.

Este nivel de detalle es necesario porque dos modelos con RMSE parecido pueden implicar riesgos operativos muy distintos. Uno puede fallar de forma estable y moderada; otro puede acertar el promedio pero perder control justo en las zonas más delicadas para valoración o revisión manual.

4.1.4.1 *Análisis del impacto del entrenamiento Progressive ATM*

El proyecto incluyó una variante experimental denominada Progressive ATM (o *Entrenamiento Progresivo Ordenado por ATM*): un enfoque de currículum de aprendizaje que reordena cronológicamente el entrenamiento para presentar primero observaciones cercanas al ATM (moneyness bajo, $|\log(F/K)| < 0,05$), donde concentra la máxima liquidez y menor ruido, para después incorporar progresivamente observaciones hacia extremos de moneyness y vencimientos cortos. La motivación financiera es doble: (1) la zona ATM en opciones sobre índices suele ser la más líquida y menos afectada por sesgos de selección; (2) entrenar primero en datos menos ruidosos podría regularizar arquitecturas sensibles al orden de presentación, como redes neuronales secuenciales y modelos cuánticos inspirados.

Metodología de evaluación. Se reentrenaron independientemente los cinco modelos de la familia de seleccionados bajo esta variante, conservando la validación cruzada 5-fold y los mismos hiperparámetros que en el entrenamiento estándar. Se compararon las métricas test de RMSE, MAE y R^2 entre ambas versiones (estándar vs. ATM) para cada familia. El análisis se complementó con inspección visual de residual heatmaps en el dashboard para verificar si la reordenación producía cambios en la distribución espacial del error (por moneyness y vencimiento).

Resultados observacionales en lo visualizado en el dashboard:

- **Linear Regression (RMSE 0.1838 estándar → 0.1877 ATM).** El entrenamiento ATM no produce un modelo mejor. El incremento en RMSE de +0.0039 (+0.21 %), acompañado de deterioro en MAE (+0.0161) y reducción de R^2 (-0.0219), sugiere que el currículum de ATM no regulariza un modelo ya lineal e inflexible. El residual heatmap en versión ATM muestra mayor concentración relativa de error en bandas específicas de moneyness (entorno $0,95 < m < 1,05$), compatibles con un ajuste lineal que persevera en capturar curvatura local sin el beneficio de datos iniciales informativos. Este resultado es esperado: un modelo lineal no se beneficia de ordenamientos que privilegian información local, puesto que su hipótesis es global.
- **Random Forest (RMSE 0.0884 estándar → 0.0885 ATM).** El modelo más robusto permanece prácticamente invariante. El cambio $\Delta\text{RMSE} = +0,0001$ (0.01 %), $\Delta\text{MAE} = -0,0001$, y $\Delta R^2 = -0,0006$ son negligibles y dentro del ruido estocástico de validación cruzada. El residual heatmap ATM es indistinguible del estándar. Random Forest ya generaliza a través de bootstrapping y agregación de árboles profundos, generando capacidad de regularización inherente. El currículum ATM añade un factor extrínseco que no mejora esta capacidad, confirmando que los modelos ya óptimos no se benefician de reordenamientos de datos de entrenamiento.
- **XGBoost (RMSE 0.0917 estándar → 0.1136 ATM).** La variante ATM no produce un modelo mejor; al contrario, se observa una degradación clara. El incremento en RMSE de +0.0219 (+2.39 %), acompañado de $\Delta\text{MAE} = +0,0027$ y $\Delta R^2 = -0,1202$ (caída de 12 puntos porcentuales en varianza explicada), refleja un efecto perjudicial. El heatmap de diagnóstico ATM muestra intensificación de concentración roja (error absoluto alto) en bandas de vencimiento corto/mediano (0.05 a 0.25 años) y moneyness extrema. La hipótesis interpretativa es que XGBoost, al entrenarse primero en datos homogéneos y centrales (ATM), desarrolla un sesgo inicial hacia esa región. Cuando posteriormente observa datos extremos, su capacidad adaptativa (ya fijada en direcciones ATM) lucha por recalibrar, resultando en superficie menos flexible globalmente. Este efecto sugiere que el boosting secuencial es sensible al orden de entrada y puede sufrir de regularización excesiva en la primera fase.
- **Sequential NN (RMSE 0.1135 estándar → 0.0885 ATM).** La variante ATM produce un modelo mejor. La reducción en RMSE de -0.0250 (-22.03 %), manteniendo estable MAE, indica que el currículum de ATM efectivamente regulariza la red neuronal secuencial. El heatmap residual ATM es visiblemente más uniforme, sin concentraciones rojas en extremos como se observa en la versión estándar. La interpretación es directa: una red secuencial sin mecanismos de regularización explícita (dropout, batch-norm con configuración ATM) sufre de convergencia deficiente cuando enfrenta datos desordenados. El currículum ATM le permite aprender primero patrones estables en región de baja varianza, estableciendo pesos iniciales informados antes de adaptar a variabilidad creciente.

Este hallazgo valida la hipótesis de motivación: arquitecturas iterativas sensibles pueden beneficiarse del currículum.

- **Quantum Inspired (RMSE 0.1430 estándar $\rightarrow$ 0.1174 ATM).** La variante ATM produce un modelo mejora substancial. La reducción en RMSE de -0.0256 (-17.90 %), junto con incremento dramático en R^2 de +0.1785 (pasando de 0.4528 a 0.6313, un aumento de 18 puntos porcentuales), revela que el modelo cuántico inspirado es altamente sensible al orden de entrenamiento. El heatmap ATM muestra reducción visible de concentración roja en extremos de moneyness y vencimiento. El modelo cuántico, basado en búsqueda variacional con inicialización aleatoria, es especialmente vulnerable a convergencia prematura en mínimos locales pobres. Entrenar primero en región ATM de bajo ruido permite al algoritmo establecer línea base de convergencia robusta, desde la cual la progresión hacia datos extremos se realiza de forma más estable. Este es el caso más dramático de regularización por currículum.

Síntesis interpretativa del impacto ATM por arquitectura. Los resultados revelan un patrón sistemático: la técnica Progressive ATM no produce un modelo mejor de forma universal, sino que su efectividad depende críticamente de la arquitectura subyacente.

MODELOS YA ÓPTIMOS (RANDOM FOREST, Y EN MENOR MEDIDA XGBOOST BASE):

El currículum ATM no mejora; en XGBoost incluso resulta perjudicial. La razón es que estos modelos ya poseen mecanismos de regularización o agregación intrínsecos (bootstrap, boosting) que no se benefician de reordenamientos externos. Forzar un orden artificial puede introducir sesgo de inicialización que degrada capacidad global de la arquitectura, particularmente en modelos iterativos como boosting.

MODELOS DE BAJA CAPACIDAD O CONVERGENCIA FRÁGIL (SEQUENTIAL NN, QUANTUM INSPIRED):

El currículum ATM produce mejoras tangibles. Estos modelos carecen de regularización inherente y son sensibles a inicialización y orden de muestras. Entrenar primero en región ATM establece trayectoria de aprendizaje más robusta, evitando convergencia a mínimos pobres que es frecuente cuando se enfrentan datos heterogéneos desde el inicio.

MODELOS LINEALES (LINEAR REGRESSION): El orden es irrelevante puesto que la hipótesis es global. No hay beneficio de regularización local.

Implicación práctica. Random Forest, bajo entrenamiento estándar (sin ATM), funciona como referencia de trabajo para la solución de producción. No solo logra métricas fuera de muestra sólidas (RMSE 0.0884), sino que permanece robusto frente a variantes experimentales como ATM. Un modelo que no mejora con ATM suele indicar que ya ha alcanzado un nivel de regularización apropiado: no es excesivamente sensible a ruido y su capacidad de generalización es estable. Por el contrario, modelos que mejoran significativamente con ATM (Sequential NN, Quantum Inspired)

sugieren que su arquitectura es más sensible al orden de entrenamiento y requeriría un seguimiento cuidadoso.

Conclusión sobre Progressive ATM. La técnica debe considerarse una variante experimental de refinamiento, útil únicamente para arquitecturas específicas que sufren de convergencia deficiente o sensibilidad al orden de los datos. No constituye una mejora universal del pipeline estándar, y en algunos casos (XGBoost, Linear Regression) resulta innecesaria o contraproducente. Su valor académico está en mostrar que modelos de baja capacidad intrínseca pueden beneficiarse de estrategias de currículum; su aplicación práctica debe limitarse a escenarios donde se identifique explícitamente convergencia frágil durante el ajuste de hiperparámetros. En esta ejecución, el entrenamiento estándar ofrece la base más simple y reproducible.

4.1.5 Behaviour And Surface

El modelo final debe leerse como función financiera, no solo como tabla de errores. Las superficies generadas alrededor de puntos de referencia del test permiten inspeccionar $\hat{\sigma}(m, T)$, smiles y estructuras temporales. Dado que Random Forest es un modelo por particiones, la revisión visual debe prestar especial atención a escalones locales: un bosque puede aproximar bien puntos observados y aun así producir transiciones menos suaves que un modelo paramétrico.




Figura 30: Contraste de *Behaviour And Surface* para la misma muestra (ID 1406): Random Forest frente a XGBoost.

La lectura recomendada es usar al menos tres puntos de referencia: una observación ATM líquida, una observación en extremos de moneyness y una observación de vencimiento corto. Si el dashboard muestra saltos alrededor de un punto, la explicación debe cruzarse con vecinos y residual heatmap antes de atribuirlo a señal financiera. Si el smile es suave y el error local bajo, la predicción es más defendible.

La Figura 30 muestra que Random Forest y XGBoost conservan una geometría muy próxima en la muestra comparada, lo que sugiere estabilidad funcional en lo visualizado en el dashboard, sin implicar por sí solo que el patrón deba repetirse en cualquier trade. En ambos aparecen avisos heurísticos de saltos locales, coherentes con arquitecturas de árboles, pero las curvas smile y term-structure mantienen forma financiera interpretable (mínimo en entorno ATM y descenso de volatilidad al aumentar vencimiento para moneyness fija). Al contrastar con Linear Regression en el resto de lo visualizado en dashboard, se observa un patrón compatible con mayor suavidad formal y menor capacidad para capturar variación efectiva fuera de la zona central.

Una secuencia de lectura útil en esta pestaña es la siguiente:

- fijar un ancla representativa y revisar primero el heatmap local;
- comprobar después la superficie 3D para detectar escalones o zonas artificialmente planas;
- descender a smile y term structure para ver si la geometría sigue siendo razonable en cortes financieros conocidos;
- contrastar finalmente con ICE, ALE, vecinos y diagnóstico por zonas de la superficie cuando aparezcan formas dudosas.

Este orden es importante porque evita interpretar una gráfica aislada fuera de contexto. Un escalón puede ser inocuo si coincide con una zona bien soportada y de bajo error, o problemático si aparece en una región escasa y con extrapolación local.

4.1.6 Explicabilidad global

La explicación global debe comprobar que los drivers principales son coherentes con la geometría de volatilidad: moneyness, vencimiento, subyacente, strike, tipo y tipo de opción. SHAP se calcula sobre variables raw visibles y el runtime reconstruye las features transformadas, por lo que una contribución de StrikePrice o UnderlyingPrice debe interpretarse en relación con moneyness y no como efecto causal aislado.

La lectura correcta combina ranking, signo local y dependence plots. Si una variable domina el ranking pero tiene colores mezclados o contribuciones con mucha dispersión, el modelo está usando interacciones. Esa conclusión es razonable en opciones, porque strike, subyacente y vencimiento no son independientes. Si aparecen saltos en dependence plots, deben contrastarse con las superficies y con diagnóstico por zonas de la superficie.

En las cinco variantes revisadas, y para lo que se visualiza en dashboard, la jerarquía global aparece estable: Time To Expiration (days) como driver principal y Strike Price como segundo, seguidas por Underlying Price; Rate y Option Type




Figura 31: SHAP global comparado en los dos modelos con mejor rendimiento fuera de muestra: Random Forest y XGBoost.

tienen peso menor. La Figura 31 hace visible esta regularidad, que coincide con la lectura financiera esperada de superficie. El punto importante es que la consistencia entre modelos se observa en el orden de importancia, no necesariamente en la magnitud de impacto: Quantum Inspired y Sequential NN muestran dispersión SHAP más amplia para algunos rangos, coherente con su mayor sensibilidad local en otras pestañas.

Para que la lectura global sea sólida, conviene exigir tres coherencias a la vez.

- **Coherencia estadística:** que las variables más importantes aparezcan de forma estable en varias visualizaciones SHAP.
- **Coherencia financiera:** que los drivers dominantes sean compatibles con la geometría de moneyness, vencimiento y tipo.
- **Coherencia con error:** que un patrón llamativo en SHAP pueda contrastarse con residual heatmap, superficies y casos locales.

Si una variable parece importante pero esa importancia no se refleja ni en las superficies ni en la lectura por zonas del error, la conclusión debe tomarse con cautela. La explicabilidad global no sustituye al resto de vistas; las organiza.

4.1.7 Modelos equivalentes: árboles y regresión simbólica

Los modelos equivalentes explican el predictor, no la verdad de mercado. Para Random Forest, las métricas de fidelidad de árboles surrogate son:

La fidelidad de los árboles es limitada: ni siquiera profundidades altas reproducen bien el comportamiento completo del bosque. Esto no invalida el modelo principal, pero sí limita el uso de reglas simples como explicación global. La regresión simbólica generada para este paquete muestra métricas no utilizables para defensa del Random Forest, con RMSE de fidelidad extremadamente alto; por tanto, la memoria debe




Figura 32: Contraste de árboles surrogate por profundidad en Random Forest y XGBoost.

Modelo	RMSE simbólico	MAE simbólico	R ² simbólico
Regresión lineal	0.0244	0.0135	0.7585
Quantum Inspired NN	inf	inf	inf
Random Forest	339.9547	3.5845	-5,173,729.5872
Sequential NN	0.0376	0.0316	0.8890
XGBoost	0.0378	0.0219	0.9264

Cuadro 8: Fidelidad de regresión simbólica reportada en dashboard por familia de modelo.

Profundidad	RMSE fidelidad	MAE fidelidad	R ² fidelidad
2	0.139477	0.053488	0.129099
4	0.135217	0.050783	0.181486
8	0.141899	0.058392	0.098593
16	0.144616	0.053187	0.063747

Cuadro 9: Fidelidad de árboles surrogate frente al Random Forest seleccionado.

apoyarse en SHAP, ICE/ALE, superficies y vecinos para explicar el modelo final. La conclusión no debe forzarse: el predictor es bueno, pero no se resume bien en una fórmula compacta en esta ejecución.

La Figura 32, junto con la Tabla 9 y la Tabla 8, permite una conclusión transversal: la facilidad para explicar un modelo mediante reglas o fórmulas compactas no coincide necesariamente con su capacidad predictiva final en test. En esta ejecución, el modelo con menor error de mercado es precisamente uno de los menos comprensibles simbólicamente, mientras que XGBoost y Sequential NN admiten surrogates simbólicos más fieles.

La lectura correcta de estos modelos equivalentes es prudente.

- Si la fidelidad es baja, las reglas o fórmulas sólo valen como resumen parcial y no como explicación suficiente del modelo principal.
- Si la fidelidad mejora con mucha complejidad, la conclusión útil no es que exista una explicación compacta, sino precisamente que el predictor no se deja comprimir bien.
- Si la fidelidad fuese alta con baja complejidad, entonces sí tendría sentido dar más peso a reglas o ecuaciones en la discusión global.

4.1.8 Explicabilidad local y soporte histórico

El análisis local debe seleccionar una muestra representativa y una muestra problemática. Para cada una, el waterfall SHAP explica la predicción como suma de valor base y contribuciones. Los vecinos históricos, calculados contra train en el espacio transformado y estandarizado, indican si la muestra está dentro de una región conocida. En el paquete se guardan hasta 200 vecinos por muestra, usando una referencia de entrenamiento de hasta 20.000 observaciones.




Figura 33: Explicabilidad local en modo *dataset* para la misma muestra (ID 465): comparación Random Forest vs XGBoost.

4.1.9 Síntesis comparativa por temática

Para cerrar la lectura de dashboard con una vista única y defendible, la Tabla 10 resume las conclusiones cualitativas por temática (filas) y por familia de modelo (columnas). Esta síntesis se apoya en las capturas de diagnóstico, comportamiento, explicabilidad global/local y modelos equivalentes revisadas en esta sección.

Temática	Reg. lineal	Random Forest	XGBoost	Sequential NN	Quantum Inspired
Driver SHAP dominante	TTE (muy dominante)	TTE (estable)	TTE (estable)	TTE (estable)	TTE (estable)
Segundo driver global	Strike (alto)	Strike (alto)	Strike (alto)	Strike (medio)	Strike (medio)
Rendimiento diagnóstico test	Bajo	Alto (mejor)	Alto (2°)	Medio-bajo	Bajo
Suavidad de superficie local	Alta (simple)	Media (escalones locales)	Media (escalones locales)	Media-baja	Media-baja
Patrón smile/skew en ICE-ALE	Visible, menos rico	Visible y consistente	Visible y consistente	Visible, más inestable	Visible, más inestable
Coherencia Global → Sample	Media	Alta	Alta	Media	Media
Soporte histórico en casos manuales exigentes	N/A en muestra principal	Distancia alta en estrés corto T	Distancia alta en estrés corto T	N/A en muestra principal	N/A en muestra principal
Compresibilidad en modelo equivalente (simbólico/árbol)	Alta (simple)	Muy baja (no compacta)	Media-alta	Media-alta	Muy baja/No utilizable

Cuadro 10: Síntesis de conclusiones por temática y por familia de modelo a partir de lo visualizado en el dashboard. TTE: Time To Expiration.

Esta síntesis permite sostener dos mensajes, con alcance observacional sobre lo visualizado en el dashboard. Primero, la estructura explicativa principal aparece consistente entre familias: el vencimiento domina y el strike ocupa una posición secundaria relevante, coherente con la geometría de superficie. Segundo, las diferencias clave entre modelos no están tanto en qué variables miran, sino en cómo transforman esa información en estabilidad local, error por zonas y facilidad de explicación compacta. Para afirmar universalidad sobre todos los trades sería necesario un contraste estadístico adicional fuera de las muestras visualizadas.

4.2 APLICACIONES OPERATIVAS Y VALIDACIÓN INDEPENDIENTE

Este apartado conecta los resultados del dashboard con usos profesionales concretos en valoración, control de riesgos y gobierno de modelos. El objetivo no es extrapolar más allá de la evidencia disponible, sino traducir lo observado en reglas de uso defendibles para un entorno de mesa y model validation. El detalle visual de sensibilidad por regiones se amplía en el Anexo ??.

4.2.1 Validación independiente de modelos internos

El modelo final puede utilizarse como referencia independiente para contrastar superficies internas de valoración. En la práctica, la validación no se limita a comparar un único precio, sino que contrasta consistencia por regiones de moneyness y vencimiento. Un desacople localizado entre el pricer interno y la referencia empírica puede señalar problemas de parametrización, de datos de entrada o de régimen de mercado no recogido por el enfoque clásico.

- **Nivel agregado:** contraste de RMSE/MAE y de dispersión global frente a un benchmark interno.
- **Nivel por superficie:** contraste de residual heatmap y cajas de error por moneyness/vencimiento para detectar discrepancias localizadas.
- **Nivel de caso:** uso de SHAP local y vecinos para justificar por qué una diferencia concreta es esperable o requiere revisión.

Este enfoque es especialmente útil cuando el área de validación necesita una segunda opinión cuantitativa que no comparta la misma familia paramétrica que el modelo interno de producción.

4.2.2 Interpolación y suavizado: alcance real del enfoque

Conviene precisar el alcance metodológico. En este trabajo no se impone una interpolación paramétrica cerrada de la superficie (por ejemplo, una sola fórmula global calibrada ex ante). La superficie se aprende de forma empírica a partir de observaciones de mercado mediante modelos supervisados. Por tanto, la “interpolación” se produce de forma implícita a través de la función aprendida $\hat{\sigma}(m, T, \dots)$ y se evalúa visualmente con las vistas de *Behaviour And Surface* y *Diagnosis*.

La suavidad no se da por supuesta: se verifica. Si aparecen escalones locales o concentraciones de error en zonas concretas, el resultado se interpreta como limitación del modelo en esa región, no como propiedad financiera del mercado. Esta distinción

es clave para no confundir capacidad predictiva local con una estructura de superficie económicamente robusta.

4.2.3 *Detección de anomalías de precio y errores de mercado*

La detección de anomalías se construye en dos capas complementarias. La primera está en el ETL, con controles de calidad (precios y cantidades válidas, coherencia temporal opción-subyacente, resolución numérica estable de volatilidad implícita). La segunda está en diagnóstico ex post, donde los residuales por zona de superficie permiten localizar trades atípicos en extremos de moneyness o vencimientos cortos.

En términos operativos, una anomalía no se define sólo por error alto puntual, sino por contexto: error alto junto con baja densidad de vecinos, geometría local inestable o incoherencia entre explicación local y patrón global. Esta lectura reduce falsos positivos y mejora la utilidad del modelo como filtro de revisión manual.

4.2.4 *Valoración de ilíquidas, control de mesa, auditoría y cobertura*

Las aplicaciones más exigentes se apoyan en la misma secuencia de lectura: diagnóstico por zonas, contraste funcional de superficie y justificación local. Con ese flujo, el modelo aporta soporte en cuatro frentes conectados:

- **Valoración de opciones ilíquidas o poco negociadas:** cuando no hay suficiente señal transaccional directa, la predicción basada en superficie y vecinos históricos ofrece una referencia empírica utilizable, con cautela reforzada en extremos.
- **Control de riesgos de mesa de derivados:** la lectura por moneyness y vencimiento permite identificar dónde el error puede contaminar griegas, escenarios o límites de riesgo más que la media global.
- **Explicación ante auditoría interna/model validation:** SHAP global/local, trazabilidad de pipeline y evidencias por superficie permiten defender decisiones de modelo con base reproducible.
- **Soporte a decisiones de cobertura:** la geometría smile/term-structure más el diagnóstico local aportan contexto para priorizar coberturas en zonas de mayor sensibilidad o menor soporte histórico.

La conclusión práctica es que el modelo no sustituye el juicio de mercado, pero sí mejora su calidad: convierte decisiones difíciles en decisiones mejor informadas, trazables y auditables.

4.3 DISCUSIÓN

La pregunta planteada en [section 1.1](#) puede responderse afirmativamente con matices. Sí es posible construir un modelo útil y consultable para volatilidad implícita de opciones del IBEX; el Random Forest seleccionado ofrece buen error fuera de muestra. El matiz es que la explicación no puede descansar en un único resumen global: la fidelidad de modelos equivalentes simples es limitada, y la defensa técnica debe combinar SHAP, superficies, ICE/ALE, vecinos y diagnóstico.

4.3.1 *Lectura financiera*

Financieramente, el proyecto trata la volatilidad como superficie y no como serie unidimensional. El buen RMSE agregado es relevante, pero el dato más importante para gestión de riesgos es dónde se produce el error. La compresión de volatilidades extremas sugiere que deben revisarse los extremos de moneyness y los vencimientos cortos con más cuidado. Este comportamiento es plausible en derivados: esas zonas suelen tener menos liquidez, más ruido de microestructura y mayor sensibilidad al desfase entre opción y futuro subyacente.

- El modelo final es útil para lectura agregada y consulta, pero no debe tratarse como atajo automático del juicio financiero en zonas extremas.
- La geometría de la superficie sigue siendo el criterio principal de plausibilidad: smiles, term structures y suavidad local importan tanto como el error medio.
- La lectura de vecinos y soporte histórico es especialmente valiosa cuando se analiza un contrato poco líquido o lejano de ATM.

En otras palabras, el trabajo refuerza una idea clásica en derivados: el resultado útil no es un único número, sino una predicción situada dentro de una estructura de superficie, de un contexto de mercado y de una evidencia histórica comparable.

También conviene subrayar una implicación práctica. Cuando el modelo se usa como apoyo a valoración o revisión manual, la pregunta correcta no es sólo si “acierta de media”, sino si conserva lógica financiera en la zona concreta que se está consultando. Esa exigencia explica por qué el documento dedica espacio a smiles, extremos de moneyness, vencimientos cortos y soporte local, y no sólo a tablas globales de error. Esta lectura aplicada se concreta en la Sección [4.2](#) y se refuerza con el anexo de sensibilidad por regiones de superficie.

Aportación frente a enfoques clásicos.

La comparación con enfoques clásicos debe plantearse como complementariedad y mejora operativa, no como sustitución automática. Los enfoques paramétricos (por ejemplo, parametrizaciones estáticas de superficie o ajustes locales ad hoc) aportan

estructura financiera explícita y son valiosos para gobernanza. La propuesta de este TFM añade valor en escenarios donde esa estructura no basta por sí sola:

- **Mayor flexibilidad empírica:** captura interacciones no lineales entre moneyness, vencimiento, subyacente y tipo con menor rigidez funcional.
- **Mejor lectura por zonas:** añade diagnóstico de error por región de superficie, clave para contratos ilíquidos o extremos de moneyness.
- **Capacidad de control y auditoría:** incorpora trazabilidad y explicaciones locales/globales en el mismo flujo de servicio.
- **Validación cruzada de pricing:** permite contrastar salidas de modelos clásicos internos con una referencia empírica independiente.

En términos prácticos, la mejora no es sólo bajar una métrica agregada. La mejora principal es disponer de una *superficie utilizable*: consultable, explicable y controlable en producción, especialmente en los casos donde las reglas clásicas requieren juicio manual intensivo.

4.3.2 Lectura de IA y Data Science

Desde la perspectiva de IA, la comparación muestra que modelos tabulares de árboles son más adecuados que redes densas para esta muestra. Random Forest y XGBoost aprovechan interacciones no lineales sin exigir escalado y ofrecen mejor test. La métrica CE_2 favorece a XGBoost en train/validation, pero el test favorece a Random Forest; esto ilustra por qué la selección final no debe quedarse en validación. Progressive ATM mejora Quantum Inspired, pero no a las familias que ya generalizan mejor.

- La validación temporal es más importante que una mejora marginal en entrenamiento.
- La estabilidad entre train, validation y test pesa más que una única métrica brillante en una fase intermedia.
- La explicabilidad posterior también importa: un modelo competitivo pero imposible de leer exige más apoyos y más cautela en su defensa.

Desde esta perspectiva, el trabajo también deja una lección de alcance más general: en datos financieros tabulares, una arquitectura más compleja no merece preferencia por defecto. Primero debe demostrar que generaliza mejor; después, que esa mejora compensa el coste extra de explicación, mantenimiento y servicio.

4.3.3 *Lectura de ingeniería y cloud*

La dimensión cloud aporta valor porque no se usa como adorno: resuelve almacenamiento, carga de modelos, despliegue independiente de API y dashboard y trazabilidad. La separación entre modelo, paquete explicativo, API, dashboard y almacenamiento reduce acoplamientos y facilita auditoría. La principal cautela operativa es mantener sincronizados modelo, scaler, metadatos y componentes explicativos; de lo contrario, el sistema podría predecir con una versión y explicar con otra.

- El almacenamiento centralizado evita duplicidades manuales y facilita compartir la misma versión entre servicios.
- El despliegue desacoplado permite que un problema en dashboard no bloquee necesariamente la API, y viceversa.
- La reproducibilidad de infraestructura es útil sólo si el pipeline mantiene coherencia entre modelo servido y explicaciones persistidas.

La consecuencia práctica es que la ingeniería no aparece aquí como una capa secundaria. Es parte del argumento de calidad del trabajo: un modelo que no puede versionarse, servirse y auditarse con coherencia pierde valor aunque su ajuste estadístico sea aceptable.

4.3.4 *Limitaciones*

Las limitaciones se agrupan en cuatro bloques. Primero, la volatilidad implícita depende de la calidad del enlace opción-subyacente y del solver Black-76. Segundo, el conjunto de datos es heterogéneo en liquidez y cobertura de moneyness/vencimiento, por lo que los extremos deben diagnosticarse localmente. Tercero, la explicabilidad aproxima comportamientos del modelo y no sustituye validación económica. Cuarto, el despliegue cloud exige disciplina de versionado para evitar inconsistencias entre modelos, paquetes de dashboard y metadatos.

- No toda región del espacio de entrada tiene la misma densidad histórica ni la misma calidad de soporte.
- Un modelo explicable sigue pudiendo estar equivocado si aprende sesgos sistemáticos de los datos.
- Las visualizaciones ayudan a detectar problemas, pero no convierten por sí solas una predicción en económicamente válida.

Además, hay una limitación estructural que conviene dejar explícita: el proyecto explica muy bien cómo razona el modelo entrenado, pero no agota por sí solo la validación económica del mercado. Siempre queda margen para contrastar con enfoques paramétricos, con criterios de liquidez más finos o con reglas de suavidad impuestas ex ante sobre la superficie.

CONCLUSIONES

Este TFM desarrolla una cadena integral para estimar volatilidad implícita en opciones del IBEX y convertir el resultado en un sistema explicable y operable. El trabajo parte de datos de mercado, construye una base de volatilidad mediante inversión de Black-76, entrena familias de modelos bajo validación temporal y genera explicaciones y diagnósticos. En test, el enfoque planteado muestra que es posible alcanzar niveles de desempeño del orden de $RMSE = 0,088403$, $MAE = 0,054366$ y $R^2 = 0,790941$.

La primera conclusión es que la calidad de un modelo de volatilidad no puede evaluarse solo con métricas agregadas. En derivados, la forma de la superficie, el comportamiento por moneyness y vencimiento y la localización del error son elementos centrales. Por ello el dashboard no se plantea como una capa estética, sino como parte del mecanismo de validación. En test, la volatilidad predicha presenta menos dispersión que la volatilidad observada: la desviación estándar de las predicciones es inferior a la de la serie real. Eso significa que el modelo reproduce bien la estructura central de la superficie, pero suaviza parte de la amplitud de los extremos, por lo que su lectura debe acompañarse de diagnóstico por zonas cuando se consulte fuera del núcleo más líquido.

La segunda conclusión es que la explicabilidad aporta valor en dos planos. En ingeniería, ayuda a detectar fallos, fugas, sesgos y discontinuidades. En finanzas, permite justificar predicciones y analizar si el modelo se comporta de forma compatible con intuición económica y revisión profesional.

La tercera conclusión es que la arquitectura de software condiciona la utilidad del modelo. Al separar ETL, entrenamiento, paquetes explicativos, API, dashboard y almacenamiento, el proyecto facilita reproducibilidad, mantenimiento y despliegue. Esta separación también reduce el riesgo de que las explicaciones se calculen sobre versiones distintas de las usadas en predicción.

La cuarta conclusión es que progressive ATM no debe presentarse como mejora universal. En esta ejecución mejora la arquitectura Quantum Inspired, pero no al Random Forest final ni a XGBoost. Su utilidad depende de si estabiliza la zona ATM sin degradar los extremos de moneyness ni los vencimientos menos representados.

Desde la perspectiva financiera aplicada, la contribución diferencial frente a enfoques clásicos es doble. Primero, aporta una referencia empírica flexible para valoración y validación en zonas con menor liquidez o cobertura irregular. Segundo, incorpora mecanismos de explicación y control (SHAP, ICE/ALE, vecinos y diagnóstico por superficie) que permiten trasladar el modelo a situaciones operativas reconocibles: contrastar precios internos, revisar anomalías, priorizar coberturas y leer el riesgo por regiones de moneyness y vencimiento.

Esa dimensión aplicada no aparece como un añadido posterior, sino como una consecuencia directa de la forma en que se han unido datos, validación, explicabilidad y servicio. Por eso el trabajo puede leerse también como una herramienta de apoyo a valoración, validación independiente y control de riesgos, con una trazabilidad explícita entre resultados, discusión y desarrollo anexo.

Por ello, el avance del TFM no debe leerse sólo como una mejora de RMSE. Debe leerse como mejora de **capacidad operativa**: detectar anomalías, justificar decisiones, analizar sensibilidad por moneyness/vencimiento y usar el modelo como herramienta de control de riesgos de mesa.

Como líneas futuras, se proponen: complementar la explicabilidad ya incorporada con técnicas no incluidas en este trabajo, como Integrated Gradients o LIME, para contrastar mejor la lectura local; explorar modelos secuenciales como CNN 1D, LSTM o GRU si la muestra se reformula como ventanas temporales por contrato; y comparar el enfoque actual con modelos híbridos que impongan estructura financiera explícita sin perder flexibilidad empírica.

ESQUEMA DETALLADO DE DATOS Y ETL

Este anexo reúne el detalle estructural de las tablas intermedias y finales generadas por el pipeline de datos. Su objetivo no es introducir lógica nueva, sino dejar trazabilidad precisa sobre qué base produce cada etapa del ETL y cómo se encadenan Read Raw Step, Merge Raw Step, Product Split Step, Underlying Step y Volatility Step.

La Figura 35 muestra la fase de ingestión y consolidación inicial. La Figura 36 recoge la separación por producto y la construcción de la relación opción-subyacente. La Figura 37 resume los filtros finales y la construcción de VOLATILITY_DB.




Figura 35: Detalle estructural del ETL (I): fuentes de entrada, normalización inicial y consolidación contractual.




Figura 36: Detalle estructural del ETL (II): separación por producto y construcción de la relación opción-subyacente.




Figura 37: Detalle estructural del ETL (III): filtros previos y construcción final de VOLATILITY_DB.

METODOLOGÍA DE DESARROLLO, VALIDACIÓN Y DESPLIEGUE

Una parte relevante del valor metodológico del proyecto es que no se ha construido como un prototipo monolítico difícil de auditar, sino como un repositorio vivo gestionado mediante prácticas habituales de ingeniería de software. El desarrollo se ha realizado sobre Git y GitHub, con versionado explícito del código, la configuración, la documentación, los artefactos de infraestructura y los componentes desplegables del sistema. Esta organización permite reconstruir la evolución del proyecto y asociar cada resultado técnico a una versión concreta del repositorio.

El flujo de trabajo se apoya en ramas de desarrollo, integración mediante *pull requests* y automatización con GitHub Actions. De este modo, los cambios no se incorporan únicamente por modificación directa del código, sino a través de un proceso controlado donde cada entrega puede ser validada antes de integrarse en la rama principal. Esta práctica resulta especialmente importante en un proyecto que combina extracción y tratamiento de datos financieros, entrenamiento de modelos, explicabilidad, dashboard, API e infraestructura cloud, ya que una modificación local en cualquiera de estos bloques puede afectar silenciosamente al comportamiento global del sistema.

Para reforzar este control, el repositorio incorpora un workflow específico de validación sobre *pull requests*. Dicho workflow instala el entorno Python del proyecto, ejecuta comprobaciones estáticas con `flake8` y lanza la batería de tests mediante `pytest`. Esto permite detectar errores de estilo, problemas de integración y regresiones funcionales antes de aceptar cambios en la rama principal. Además, el proyecto mantiene una cobertura de tests superior al 80 %, lo que aporta una garantía adicional sobre la estabilidad de los módulos principales y reduce el riesgo de introducir modificaciones no controladas en piezas críticas del sistema.

La cobertura de tests no debe interpretarse como una garantía absoluta de corrección, pero sí como una evidencia de madurez metodológica. En este trabajo, las pruebas automatizadas cubren componentes relevantes del repositorio y se complementan con validaciones manuales sobre los artefactos generados, los flujos de datos,

el dashboard y la API. Esta combinación aproxima el desarrollo del TFM al ciclo de vida de un proyecto real: implementar una mejora, verificar su comportamiento, integrarla de forma controlada y conservar una traza reproducible de los cambios realizados.

Junto al workflow de validación, el proyecto incluye automatización específica para la documentación. El workflow de despliegue de documentación construye el sitio generado con MkDocs y lo publica en GitHub Pages a partir de la configuración definida en `../doc/mkdocs.yml`. Esto permite que la documentación técnica evolucione junto con el código y que los cambios incorporados al repositorio puedan reflejarse de manera sistemática en una versión navegable del proyecto. La documentación deja así de ser un artefacto estático y separado, y pasa a formar parte del propio proceso de integración.

El repositorio también automatiza el despliegue de infraestructura cloud mediante Terraform. El workflow de infraestructura carga la configuración del proyecto desde `resources/cloud_config.json`, prepara las variables necesarias para Terraform, autentica contra Google Cloud, inicializa el backend remoto de estado en Google Cloud Storage y ejecuta las fases de `plan` y `apply`. Este proceso permite definir la infraestructura como código, mantener trazabilidad sobre los recursos cloud utilizados y reducir la dependencia de configuraciones manuales no documentadas. Además, el uso de un backend remoto para el estado de Terraform facilita la consistencia entre ejecuciones y evita que el estado de la infraestructura dependa de una máquina local concreta.

Una vez preparada la infraestructura base, el sistema incorpora un workflow reutilizable para construir y desplegar los componentes ejecutables del proyecto: el dashboard y la API. Este workflow construye las imágenes Docker correspondientes a partir de los `Dockerfile` definidos para cada servicio, las publica en Artifact Registry y aplica la configuración necesaria para su despliegue en Cloud Run mediante Terraform. De esta forma, el paso desde código fuente hasta servicio desplegable queda formalizado en una cadena reproducible: construir imagen, publicar artefacto, planificar infraestructura y aplicar cambios.

Esta separación entre workflows tiene una finalidad metodológica clara. El workflow de *pull request* protege la calidad del código antes de la integración; el workflow de documentación mantiene actualizada la documentación técnica; el workflow de infraestructura gestiona los recursos cloud de base; y el workflow de despliegue de dashboard y API materializa los servicios finales. Cada automatización cubre una responsabilidad distinta, evitando mezclar validación, documentación, provisión de infraestructura y despliegue aplicativo en un único proceso opaco.

En este contexto, operaciones como `commit`, `pull`, `push`, *pull request*, `plan` o `apply` no son únicamente acciones operativas. Funcionan como mecanismos de trazabilidad metodológica. Un resultado experimental o una funcionalidad del sistema no

queda defendida sólo por su salida final, sino por la versión concreta del código, la configuración, los tests y la infraestructura que la acompañan. Esta trazabilidad es especialmente relevante en un proyecto financiero, donde pequeñas variaciones en el pipeline de datos, en la configuración de entrenamiento, en los modelos o en la capa de explicación pueden modificar los resultados obtenidos.

Por tanto, el uso de Git, GitHub Actions, tests automatizados, control estático de código, documentación desplegable, Docker, Terraform y Google Cloud no constituye un elemento accesorio de implementación. Forma parte de la metodología del trabajo: asegura reproducibilidad, facilita el control de cambios, reduce regresiones, documenta la evolución del sistema y permite justificar el resultado final no sólo por lo que predice o visualiza, sino por cómo se ha construido, validado, integrado y desplegado.

FUNDAMENTOS DE SHAP

SHAP, acrónimo de *SHapley Additive exPlanations*, es una metodología de explicabilidad basada en los valores de Shapley de la teoría de juegos cooperativos. Su objetivo es asignar a cada variable de entrada una contribución numérica a una predicción concreta del modelo. En lugar de interpretar el modelo de forma global mediante sus parámetros internos, SHAP interpreta localmente una predicción como la suma de un valor base y una serie de aportaciones individuales asociadas a las variables explicativas.

La idea central es considerar una predicción del modelo como el resultado de una “coalición” de variables. Algunas variables están presentes y aportan información; otras se consideran ausentes y su efecto se sustituye por una referencia esperada. El problema consiste entonces en repartir de forma justa la diferencia entre la predicción concreta y el valor medio de referencia entre las variables que intervienen en la predicción.

C.1 MODELO ADITIVO DE EXPLICACIÓN

SHAP pertenece a la familia de métodos de explicación aditiva. Para una observación x , la predicción del modelo $f(x)$ se aproxima o descompone como

$$f(x) = \phi_0 + \sum_{j=1}^p \phi_j(x), \quad (15)$$

donde p es el número de variables explicativas, ϕ_0 representa el valor base de la predicción y $\phi_j(x)$ es la contribución atribuida a la variable j para la observación x . En muchas aplicaciones, ϕ_0 se interpreta como el valor esperado del modelo sobre una distribución de referencia:

$$\phi_0 = \mathbb{E}[f(X)]. \quad (16)$$

Por tanto, cada valor SHAP mide cuánto desplaza una variable la predicción respecto a ese valor base. Si $\phi_j(x) > 0$, la variable j empuja la predicción por encima de la referencia. Si $\phi_j(x) < 0$, la empuja por debajo. La suma de todas las contribuciones reconstruye la predicción del modelo para la observación analizada.

En el contexto de este proyecto, donde el objetivo es explicar predicciones de volatilidad implícita, la lectura natural es la siguiente: el valor base representa una volatilidad de referencia estimada por el modelo, mientras que cada valor SHAP indica cuánto contribuyen variables como el precio del subyacente, el strike, el tiempo a vencimiento o el tipo de interés a desplazar la predicción final hacia arriba o hacia abajo.

C.2 VALORES DE SHAPLEY

El fundamento matemático de SHAP procede de los valores de Shapley. En teoría de juegos cooperativos, se considera un conjunto de jugadores $N = \{1, \dots, p\}$ y una función de valor $v(S)$, que asigna a cada subconjunto de jugadores $S \subseteq N$ el valor que obtiene esa coalición. El objetivo es repartir el valor total $v(N)$ entre los jugadores de forma coherente con su contribución marginal media.

Trasladado a explicabilidad de modelos, los jugadores son las variables del modelo y la función $v(S)$ mide el valor esperado de la predicción cuando se conoce únicamente el subconjunto de variables S . Para una variable j , su valor de Shapley se define como

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)]. \quad (17)$$

El término

$$v(S \cup \{j\}) - v(S) \quad (18)$$

representa la contribución marginal de la variable j cuando se añade a una coalición S que todavía no la contiene. Como esta contribución puede depender fuertemente de qué otras variables estén ya presentes, el valor de Shapley no toma una única contribución marginal, sino una media ponderada sobre todos los subconjuntos posibles.

El peso

$$\frac{|S|!(p - |S| - 1)!}{p!} \quad (19)$$

tiene una interpretación combinatoria. Representa la proporción de órdenes posibles de entrada de las variables en los que el subconjunto S aparece antes que la variable j . De esta forma, el valor de Shapley puede entenderse como la contribución marginal esperada de una variable cuando las variables se incorporan al modelo en todos los órdenes posibles.

Esta construcción evita depender de un único orden arbitrario de incorporación de variables. Por ejemplo, en un modelo financiero, el efecto atribuido al *strike* puede depender de si el precio del subyacente ya se ha considerado o no. SHAP promedia estas situaciones y asigna a cada variable una contribución que tiene en cuenta todas las posibles coaliciones.

C.3 FUNCIÓN DE VALOR EN EXPLICABILIDAD DE MODELOS

Para aplicar los valores de Shapley a modelos predictivos es necesario definir la función de valor $v(S)$. Una formulación habitual consiste en definir

$$v(S) = \mathbb{E} [f(X) \mid X_S = x_S], \quad (20)$$

donde X_S representa el subconjunto de variables incluidas en S , y x_S son los valores observados de esas variables para la instancia que se quiere explicar.

Esta expresión indica que, cuando sólo se conocen las variables de S , la predicción se calcula como el valor esperado del modelo condicionando a que esas variables toman los valores observados. Las variables que no pertenecen a S se integran o sustituyen mediante una distribución de referencia.

En la práctica, esta definición plantea una dificultad importante: no siempre es sencillo estimar la distribución condicional de las variables ausentes. Por ello, diferentes explicadores SHAP utilizan aproximaciones distintas. Algunos métodos asumen independencia entre variables, otros usan muestras de fondo, otros aprovechan la estructura interna del modelo, como ocurre con árboles de decisión, y otros estiman las contribuciones mediante permutaciones.

Esta elección no es un detalle menor. Cuando las variables están correlacionadas, la forma de tratar las variables ausentes afecta a la atribución final. Por ejemplo, en opciones financieras, variables como el precio del subyacente, el *strike* y el *moneyness* no son independientes en sentido económico. Por tanto, los valores SHAP deben interpretarse como atribuciones del modelo bajo una definición concreta de ausencia de variables, no como efectos causales puros.

C.4 PROPIEDADES DE LOS VALORES SHAP

Una de las razones por las que SHAP es ampliamente utilizado es que hereda propiedades teóricas deseables de los valores de Shapley. Entre las más relevantes destacan la eficiencia, la simetría, la nulidad y la aditividad.

La propiedad de eficiencia establece que la suma de las contribuciones asignadas a las variables coincide con la diferencia entre la predicción de la observación y el valor base:

$$\sum_{j=1}^p \phi_j(x) = f(x) - \phi_0. \quad (21)$$

Equivalentemente,

$$f(x) = \phi_0 + \sum_{j=1}^p \phi_j(x). \quad (22)$$

Esta propiedad también se conoce en el contexto de SHAP como *local accuracy*. Garantiza que la explicación local no sólo ordena variables por importancia, sino que reconstruye numéricamente la predicción explicada.

La propiedad de simetría indica que si dos variables aportan exactamente lo mismo a todas las coaliciones posibles, entonces deben recibir la misma contribución. Formalmente, si para dos variables i y j se cumple que

$$v(S \cup \{i\}) = v(S \cup \{j\}) \quad \text{para todo } S \subseteq N \setminus \{i, j\}, \quad (23)$$

entonces

$$\phi_i = \phi_j. \quad (24)$$

La propiedad de nulidad establece que una variable que no cambia el valor de ninguna coalición debe recibir contribución cero. Si

$$v(S \cup \{j\}) = v(S) \quad \text{para todo } S \subseteq N \setminus \{j\}, \quad (25)$$

entonces

$$\phi_j = 0. \quad (26)$$

Finalmente, la propiedad de aditividad indica que si una función de valor puede escribirse como suma de dos funciones,

$$v(S) = v_1(S) + v_2(S), \quad (27)$$

entonces los valores de Shapley asociados también se suman:

$$\phi_j(v) = \phi_j(v_1) + \phi_j(v_2). \quad (28)$$

Estas propiedades hacen que SHAP proporcione una asignación consistente de contribuciones bajo el marco matemático elegido. No obstante, la consistencia formal de la atribución no debe confundirse con causalidad económica ni con validación del modelo.

C.5 INTERPRETACIÓN LOCAL Y GLOBAL

SHAP es, en primer lugar, una técnica de explicación local. Para una observación concreta x_i , produce un vector de contribuciones

$$\phi(x_i) = (\phi_1(x_i), \dots, \phi_p(x_i)), \quad (29)$$

que explica cómo se pasa del valor base ϕ_0 a la predicción individual $f(x_i)$. Esta lectura es especialmente útil cuando se quiere justificar por qué un contrato concreto recibe una determinada predicción de volatilidad.

A partir de las explicaciones locales también pueden construirse medidas globales. Una medida habitual de importancia global de la variable j es la media del valor absoluto de sus contribuciones SHAP sobre un conjunto de observaciones:

$$I_j = \frac{1}{n} \sum_{i=1}^n |\phi_j(x_i)|. \quad (30)$$

Esta magnitud no indica si una variable aumenta o reduce la predicción en promedio, sino cuánto contribuye, en valor absoluto, a modificar las predicciones del modelo. Por ello, debe interpretarse como una medida de intensidad explicativa, no como un coeficiente de regresión ni como una elasticidad financiera.

Además, el signo y la magnitud de $\phi_j(x_i)$ pueden variar entre observaciones. Una misma variable puede aumentar la predicción en una zona del espacio de datos y reducirla en otra. Esta característica resulta especialmente relevante en modelos no lineales, donde el efecto aprendido por el modelo puede depender del nivel de *monotonicity*, del vencimiento o de la región de mercado considerada.

C.6 APROXIMACIÓN MEDIANTE PERMUTACIONES

El cálculo exacto de los valores de Shapley requiere evaluar todos los subconjuntos posibles de variables. Como existen 2^p subconjuntos, el coste computacional crece exponencialmente con el número de variables. Para modelos con muchas variables o predicciones costosas, el cálculo exacto puede ser inviable.

Una forma de aproximar los valores SHAP consiste en estimar las contribuciones marginales mediante permutaciones. En lugar de enumerar explícitamente todos los subconjuntos, se generan distintos órdenes de entrada de las variables. Para cada permutación, se mide cuánto cambia la predicción al incorporar una variable después de las que la preceden en ese orden. Promediando estas contribuciones marginales sobre varias permutaciones, se obtiene una estimación del valor de Shapley.

Sea π una permutación de las variables y sea P_j^π el conjunto de variables que aparecen antes que j en dicha permutación. La contribución marginal de j bajo el orden π puede escribirse como

$$\Delta_j^\pi = v(P_j^\pi \cup \{j\}) - v(P_j^\pi). \quad (31)$$

El valor de Shapley puede interpretarse entonces como la esperanza de esta contribución marginal sobre todas las permutaciones posibles:

$$\phi_j = \mathbb{E}_\pi [\Delta_j^\pi]. \quad (32)$$

En la práctica, esta esperanza se aproxima usando un número finito de permutaciones. Esta aproximación tiene la ventaja de ser independiente de la familia del modelo, por lo que puede aplicarse de forma homogénea a redes neuronales, modelos de árboles, regresiones u otros estimadores. Su principal inconveniente es que puede ser más costosa computacionalmente que explicadores especializados diseñados para una arquitectura concreta.

En este proyecto se utiliza un explicador de permutación mediante `shap.Explainer(..., algorithm="permutation")`. Esta decisión prioriza una semántica común entre modelos heterogéneos frente a la eficiencia máxima que podría obtenerse con explicadores

específicos. El presupuesto mínimo de evaluaciones por observación depende del número de variables p , y en la implementación empleada se controla mediante el parámetro

$$\text{max_evals} \geq 2p + 1. \quad (33)$$

C.7 VARIABLES DE FONDO Y VALOR BASE

El cálculo de SHAP requiere una referencia frente a la cual medir las contribuciones. Esta referencia se construye mediante un conjunto de fondo o *background dataset*. Dicho conjunto representa la distribución de datos que el explicador utiliza para sustituir o integrar las variables ausentes.

El valor base ϕ_0 depende de esta distribución de fondo. Por ello, cambiar el conjunto de referencia puede cambiar las explicaciones, incluso si el modelo predictivo no cambia. En términos prácticos, explicar una predicción respecto a una muestra representativa de todo el mercado no es necesariamente equivalente a explicarla respecto a una muestra restringida a opciones de corto vencimiento o a una región concreta de moneyness.

En este proyecto, el conjunto de fondo se controla mediante el parámetro `shap_background_size`. Las observaciones usadas para generar explicaciones globales se controlan mediante `shap_explain_size`, mientras que las explicaciones locales de contratos concretos se calculan sobre muestras seleccionadas mediante `sample_option_size`. Esta parametrización permite equilibrar coste computacional, estabilidad de las explicaciones y representatividad de la muestra explicada.

C.8 LIMITACIONES INTERPRETATIVAS

Aunque SHAP proporciona una descomposición matemáticamente rigurosa de la predicción del modelo, su interpretación debe hacerse con cautela.

En primer lugar, SHAP no identifica causalidad. Un valor SHAP positivo para una variable indica que, bajo el modelo entrenado y la definición de referencia utilizada, esa variable contribuye a elevar la predicción respecto al valor base. No implica que modificar causalmente esa variable produciría necesariamente el mismo cambio en el mercado real.

En segundo lugar, SHAP explica el comportamiento del modelo, no la verdad del fenómeno financiero subyacente. Si el modelo ha aprendido relaciones espurias, ses-

gos de muestra o patrones inestables, SHAP puede describir esas relaciones con precisión sin que por ello sean económicamente válidas.

En tercer lugar, las correlaciones entre variables pueden afectar a la atribución. En problemas financieros, muchas variables no son independientes: el strike, el precio del subyacente, el moneyness y el tiempo a vencimiento pueden presentar dependencias estructurales. Por tanto, la asignación de contribuciones debe entenderse dentro de la aproximación concreta utilizada por el explicador.

Finalmente, una explicación local detallada no equivale a una garantía de calidad predictiva. Un gráfico SHAP puede mostrar de forma clara cómo el modelo reparte una predicción entre variables, pero no demuestra que la predicción sea precisa. La explicabilidad debe combinarse con métricas de error, validación temporal, análisis de robustez y conocimiento financiero del producto.

C.9 USO EN ESTE PROYECTO

En este trabajo, SHAP se utiliza para explicar modelos de predicción de volatilidad implícita desde dos perspectivas complementarias. A nivel local, permite analizar por qué el modelo asigna una determinada volatilidad a un contrato concreto. A nivel global, permite identificar qué variables concentran mayor intensidad explicativa en el conjunto de observaciones analizadas.

Las explicaciones se calculan sobre variables visibles financieramente interpretables, como `OptionType`, `StrikePrice`, `UnderlyingPrice`, `TimeToExpiration` y `Rate`. Aunque el modelo pueda utilizar transformaciones internas o variables derivadas, la capa de explicabilidad reconstruye las entradas necesarias para mantener una lectura coherente desde el punto de vista financiero.

Los artefactos visuales del dashboard, como gráficos *beeswarm*, rankings de importancia media absoluta, *dependence plots*, *heatmaps* y gráficos *waterfall*, son distintas formas de representar la misma estructura matemática: la descomposición de una predicción en un valor base y un conjunto de contribuciones aditivas. Así, SHAP no se utiliza como sustituto de la validación del modelo, sino como herramienta complementaria para auditar su comportamiento y mejorar la trazabilidad de sus predicciones.

CURVAS ALE

ALE, *Accumulated Local Effects*, estima el efecto medio acumulado de una feature usando variaciones locales dentro de zonas observadas. Complementa a ICE porque resume un efecto agregado menos vulnerable a combinaciones contrafactuales irreales cuando las variables están correlacionadas.

$$ALE_j(z) = \int_{z_0}^z E \left[\frac{\partial f(X)}{\partial X_j} \mid X_j = s \right] ds - C. \quad (34)$$

La constante C centra la curva para que su media sea cero. Un valor ALE positivo no significa volatilidad positiva, sino efecto acumulado por encima del promedio de referencia.

La Figura 38 resume el cálculo por bins y su acumulación.

La implementación por bins calcula bordes por cuantiles entre 0.05 y 0.95, con 13 puntos. Para cada intervalo $[l_k, u_k]$, selecciona observaciones I_k , predice dos escenarios locales y calcula:

$$\Delta_k = \frac{1}{|I_k|} \sum_{i \in I_k} [f(u_k, x_{i,-j}) - f(l_k, x_{i,-j})]. \quad (35)$$

Después acumula y centra:

$$ALE_k^u = \sum_{r \leq k} \Delta_r, \quad ALE_k = ALE_k^u - \frac{1}{K} \sum_{r=1}^K ALE_r^u. \quad (36)$$

En opciones, ALE es útil porque StrikePrice y UnderlyingPrice determinan moneyness, TimeToExpiration depende de calendarios de vencimiento y Rate depende de fecha y plazo. ALE no elimina todas las dificultades de correlación, pero evita




Figura 38: Construcción de curvas ALE por bins locales.

promediar de forma indiscriminada sobre combinaciones globales poco plausibles [Apley and Zhu, 2020].

ALE debe interpretarse como efecto relativo acumulado, no como nivel absoluto.

- Si la curva ALE crece de forma sostenida, esa feature empuja la predicción al alza en las zonas observadas.
- Si la curva es casi plana, el efecto medio local es débil o está compensado entre regímenes distintos.
- Si aparecen cambios bruscos, conviene comprobar si corresponden a bins con poca densidad o a comportamiento realmente no lineal del modelo.

La complementariedad con ICE es clave.

- ICE muestra trayectorias individuales y, por tanto, heterogeneidad.
- ALE resume el efecto agregado dentro de zonas observadas y, por tanto, mejora la robustez de la lectura.

Si ambos apuntan en la misma dirección, la conclusión es más sólida. Si discrepan, el modelo probablemente está mezclando regímenes o usando interacciones que conviene revisar con superficies y diagnóstico por zonas de la superficie.

MODELO QUANTUM INSPIRED

Este anexo describe la arquitectura *Quantum Inspired*, una red neuronal clásica que adopta un paradigma distinto al de matrices densas: utiliza una **factorización tensorial** inspirada en redes tensoriales usadas en física cuántica simulada clásicamente. La idea central es convertir el espacio de características embebidas en un tensor multidimensional y descomponerlo en una cadena de núcleos pequeños interconectados.

Esta estrategia es apropiada para sistemas con muchos grados de libertad (como la superficie de volatilidad) porque combina compresión estructural, regularización implícita y una lectura más trazable de cómo se propagan dependencias entre variables.

E.1 ARQUITECTURA GENERAL: FLUJO DE DATOS DESDE ENTRADA A PREDICCIÓN

La arquitectura transforma un vector de entrada en una predicción escalar de volatilidad siguiendo tres bloques: preparación, núcleo Tensor-Train y agregación final. La Figura 39 resume el flujo.




Figura 39: Arquitectura Quantum Inspired clásica basada en tensor-train.

La clave arquitectónica es que **el componente Quantum Inspired es la capa Tensor-Train**, no el conjunto completo. Las etapas anteriores preparan los datos; las posteriores agregan y refinan la salida. De este modo se separa la responsabilidad de cada bloque: preparación (embedding), transformación tensorial (TT) y agregación (post-TT dense).

E.2 ETAPAS PREPARATORIAS Y TRANSFORMACIÓN ESTRUCTURAL

E.2.1 Normalización e Embedding denso

Sea n_{in} el número de variables de entrada (en este proyecto, típicamente 5). La primera operación es una normalización por lote con transformación $n_{\text{in}} \rightarrow n_{\text{in}}$, que centra y escala cada mini-lote durante entrenamiento.

Después, el embedding denso aplica la transformación $n_{\text{in}} \rightarrow \prod_{k=1}^d n_k$, donde d es el orden del tensor y n_k es la dimensión del modo k del tensor objetivo. Esta proyección es crítica porque:

- **Captura relaciones no lineales:** modela interacciones entre variables desde el inicio.
- **Mejora y enriquecimiento:** la proyección denso-no-lineal reorganiza el espacio de características, destacando direcciones relevantes. Es análogo a un cambio de base adaptativo.
- **Evitación de cercanías espurias:** sin este paso, el reshape directo sería arbitrario. El embedding asegura que la interpretación de índices como “adyacentes” en el tensor tiene sentido matemático real.

El embedding se parametriza mediante:

$$\mathbf{z} = \sigma_{\text{emb}} (\mathbf{W}_{\text{emb}} \mathbf{x} + \mathbf{b}_{\text{emb}}), \quad (37)$$

donde $\mathbf{x} \in \mathbb{R}^{n_{\text{in}}}$ es el vector de entrada y σ_{emb} es la activación Swish. El resultado es $\mathbf{z} \in \mathbb{R}^{\prod n_k}$.

Se utiliza Swish en embedding y post-TT porque suele mantener un flujo de gradientes más estable que alternativas más abruptas.

E.2.2 Reshape a tensor de alta dimensionalidad

El reshape realiza la transformación $\prod n_k \rightarrow n_1 \times n_2 \times \cdots \times n_d$. Es decir, el vector $\mathbf{z}$ se reinterpreta como un tensor de orden d :

$$\mathcal{Z} \in \mathbb{R}^{n_1 \times n_2 \times \cdots \times n_d}, \quad (38)$$

donde cada dimensión $(n_1, n_2, \dots, n_d)$ representa un grado de libertad abstracto que puede codificar factores de riesgo agrupados.

Este reshape no es un mero cambio de vista: es el pivote conceptual que permite pasar de un vector euclidiano a una estructura multiíndice. Una vez que $\mathbf{z}$ es visto

como $\mathcal{Z}(i_1, i_2, \dots, i_d)$ (con $1 \leq i_k \leq n_k$), se pueden aplicar contracciones tensoriales que de otro modo serían imposibles.

La importancia radica en que **genera un objeto de altísima dimensionalidad implícita**. Si por ejemplo $(n_1, n_2, n_3, n_4) = (2, 2, 2, 2)$, entonces $\prod n_k = 16$ componentes se reinterpretan como un tensor de $2^4 = 16$ entradas. La contracción TT que viene después explotará esta estructura multidimensional para comprimir ese espacio de manera exponencial.

E.3 EL NÚCLEO QUANTUM INSPIRED: DESCOMPOSICIÓN TENSOR-TRAIN

La descomposición tensor-train (TT) es una forma estructurada de representar un tensor multidimensional mediante un producto de matrices pequeñas encadenadas. Para un tensor $\mathcal{Z}(i_1, \dots, i_d)$, la descomposición TT escribe:

$$\mathcal{Z}(i_1, i_2, \dots, i_d) \approx G_1[i_1] \cdot G_2[i_2] \cdot \dots \cdot G_d[i_d], \quad (39)$$

donde cada G_k es un tensor de orden 3 con forma (r_{k-1}, n_k, r_k) :

- n_k es la dimensión física del modo k (derivada de $\mathcal{Z}$).
- r_{k-1} y r_k son los **rangos tensoriales** internos que conectan el núcleo $k - 1$ con el k .
- Los rangos en las fronteras son forzados a 1: $r_0 = r_d = 1$, asegurando que el producto final es un escalar (o en nuestro caso, una componente de salida).

Para dejar el esquema claro desde el inicio: **cada salida TT tiene su propia cadena de núcleos**. Si la capa TT produce m_{out} salidas, existen m_{out} cadenas independientes, todas aplicadas sobre el mismo tensor de entrada.

Cada núcleo G_k puede pensarse como una célula local que captura cómo el modo k interactúa con sus vecinos a través de los rangos. El encadenamiento de núcleos es el **contact chain** (cadena de contacto), mecanismo por el cual la información y las dependencias se propagan de un extremo del tensor al otro.

E.3.1 La cadena de contacto (Contact Chain) y propagación de dependencias

Durante el entrenamiento, todos los núcleos $G_1, G_2, \dots, G_d$ aprenden simultáneamente. Los rangos internos $r_1, r_2, \dots, r_{d-1}$ actúan como conexiones que permiten que gradientes y actualizaciones de parámetros se propaguen:

- Un cambio en el núcleo G_k afecta directamente a r_{k-1} y r_k .

- Estos cambios, a su vez, repercuten en G_{k-1} y G_{k+1} a través de las contracciones tensoriales.
- De este modo, la red de dependencias es densa y altamente acoplada.

Esto contrasta radicalmente con una red densa donde cada capa aprende “de forma más independiente”: aquí, cada núcleo no solo aprende su propia parametrización, sino que está en constante diálogo con sus vecinos a través de la estructura tensorial compartida.

E.3.2 Implementación: estructura concreta de los núcleos

En código, cada núcleo para un output dado es creado como:

```
# Para cada salida out_idx in range(output_dim):
#   Para cada nucleo k in range(len(input_dims)):
#       Crear un núcleo con forma (r_k, n_k, r_{k+1})
tt_core = self.add_weight(
    name=f"tt_core_{out_idx}_{core_idx}",
    shape=(
        self.tt_ranks[core_idx],      # r_k
        mode_dim,                    # n_k
        self.tt_ranks[core_idx + 1],  # r_{k+1}
    ),
    initializer=GlorotUniform(), # Inicialización apropiada
    trainable=True,
)
```

Sobre inicialización, en esta familia se usa principalmente **Glorot Uniform** (y opcionalmente **He Uniform** en variantes). El objetivo en ambos casos es arrancar con una escala de pesos compatible con entrenamiento estable en las primeras épocas.

E.3.3 Contracción: cómo se produce una salida TT

Dado un tensor $\mathcal{Z}(i_1, \dots, i_d)$ y una cadena de núcleos $\{G_1, \dots, G_d\}$, la contracción TT produce una salida mediante:

$$\text{output} = \sum_{i_1=1}^{n_1} \cdots \sum_{i_d=1}^{n_d} G_1[i_1] \cdot G_2[i_2] \cdot \dots \cdot G_d[i_d] \cdot \mathcal{Z}(i_1, \dots, i_d). \quad (40)$$

Conceptualmente, la operación itera a través de los núcleos, contrayendo índices de modo con el tensor de entrada y propagando información a través de los rangos internos. Lo crucial es que esta contracción se realiza para *cada* output: si hay m_{out}

salidas, existen m_{out} cadenas independientes de núcleos, cada una contraída separadamente. Todas comparten la misma entrada $\mathcal{Z}$, pero aprenden distintos patrones de interacción.

En la ecuación 40, i_k recorre los índices del modo k , $G_k[i_k]$ es la “rebanada” del núcleo k para ese índice, y el producto encadenado acumula la interacción entre modos y rangos internos.

E.3.4 Ejemplo concreto: relación entre dimensiones de entrada, rangos y salidas

Supongamos:

- Input original: $n_{\text{in}} = 5$ características (precio subyacente, strike, vencimiento, tasa, tipo).
- Tensor target: $(n_1, n_2, n_3, n_4) = (2, 2, 2, 2)$, así $\prod n_k = 16$.
- Embedding: capa densa $5 \rightarrow 16$ (con activación Swish).
- Reshape: los 16 componentes se organizan como tensor $2 \times 2 \times 2 \times 2$.
- Rangos TT: $(r_0, r_1, r_2, r_3, r_4) = (1, 2, 2, 2, 1)$.
- Salidas TT: $m_{\text{out}} = 8$ (especificado en configuración).

Para cada una de las 8 salidas:

- Núcleo 1: forma $(1, 2, 2)$ — conecta “antes” (rango 0, siempre 1) con rango 1.
- Núcleo 2: forma $(2, 2, 2)$ — conecta rango 1 con rango 2.
- Núcleo 3: forma $(2, 2, 2)$ — conecta rango 2 con rango 3.
- Núcleo 4: forma $(2, 2, 1)$ — conecta rango 3 con “después” (rango 4, siempre 1).

Total de parámetros por cadena: $(1 \times 2 \times 2) + (2 \times 2 \times 2) + (2 \times 2 \times 2) + (2 \times 2 \times 1) = 4 + 8 + 8 + 4 = 24$ elementos.

Con 8 salidas: $8 \times 24 = 192$ parámetros en la capa TT, más los 80 parámetros del embedding (5×16) y los bias. Esto es compacto en comparación con una red densa equivalente.

Se utiliza **Swish** como activación post-TT y en el embedding por su suavidad y por mantener un entrenamiento estable.

E.4 ETAPAS FINALES: AGREGACIÓN Y SALIDA

Tras la contracción TT, tenemos m_{out} características aprendidas. Estas pasan por una capa densa intermedia ($m_{\text{out}} \rightarrow u_{\text{dense}}$), seguida opcionalmente de Dropout, y finalmente por una capa de salida ($u_{\text{dense}} \rightarrow 1$) que genera la predicción escalar de volatilidad.

Esta última etapa ejecuta:

$$\hat{\sigma}(\mathbf{x}) = \mathbf{W}_{\text{out}} \cdot \text{Swish}(\mathbf{W}_{\text{post}} \cdot \mathbf{c}_{\text{TT}} + \mathbf{b}_{\text{post}}) + b_{\text{out}}, \quad (41)$$

donde $\mathbf{c}_{\text{TT}}$ son las m_{out} salidas de la contracción TT.

Lectura rápida de los términos: $\mathbf{W}_{\text{post}}$ y $\mathbf{b}_{\text{post}}$ definen la proyección densa intermedia, Swish introduce no linealidad suave, y $\mathbf{W}_{\text{out}}, b_{\text{out}}$ realizan la proyección final al escalar $\hat{\sigma}(\mathbf{x})$.

El Dropout es una regularización estocástica que desactiva aleatoriamente algunas neuronas durante entrenamiento, reduciendo co-adaptación y mejorando generalización.

E.5 JUSTIFICACIÓN DEL ENFOQUE QUANTUM INSPIRED

La etiqueta “quantum inspired” se refiere a que adoptamos paradigmas de redes tensoriales originarios de la simulación clásica de sistemas cuánticos. En física cuántica, un estado multiqubit se describe mediante un tensor exponencialmente grande (en principio, 2^N componentes para N qubits). Para computación tratable se usan descomposiciones tensoriales como tensor-train (conocida como *matrix product state*) que comprimen esa representación en productos de matrices pequeñas.

Aquí hacemos lo análogo en contexto clásico (predicción de volatilidad): reconocemos que aunque los datos sugieren un espacio de altísima dimensionalidad, es potencialmente compresible mediante factorización. Los grados de libertad del sistema (strike, vencimiento, subyacente, tasas) no son independientes; están acoplados por dinámicas de mercado. Capturar esa estructura acoplada mediante núcleos tensoriales es más eficiente que parametrización densa.

El contact chain (cadena de contacto) permite propagación bidireccional de dependencias durante entrenamiento: el modelo aprende no solo factores locales, sino cómo se **coordinan** esos factores en la cadena entera. Esto es esencial para capturar fenómenos como sonrisas de volatilidad.

La inferencia y entrenamiento son completamente clásicos (CPUs/GPUs estándar). No hay computación cuántica real: es puramente una arquitectura neuronal inspirada en estructuras tensoriales de física cuántica, implementada como red clásica bajo el mismo protocolo que otros modelos.

E.6 VENTAJAS FRENTE A UNA RED DENSA ESTÁNDAR

Una red secuencial convencional con capas densas tendría el siguiente flujo:

- Input (5 dimensiones) $\rightarrow$ Dense (32 unidades) $\rightarrow$ Dense (24 unidades) $\rightarrow$ Output (1 dimensión).

Cálculo de parámetros: $(5 \times 32) + (32 \times 24) + (24 \times 1) + \text{biases} \approx 160 + 768 + 24 + 81 = 1033$ parámetros.

La arquitectura Quantum Inspired, con la misma aproximación de complejidad computacional:

- Embedding: $5 \rightarrow 16$ (80 parámetros).
- Tensor-Train (8 salidas, estructura $(2, 2, 2, 2)$, rangos $(1, 2, 2, 2, 1)$): ≈ 192 parámetros.
- Post-TT Dense: $8 \rightarrow 32 \rightarrow 1 \approx 320$ parámetros.
- Total: ≈ 600 parámetros.

Con configuraciones similares de capacidad, el modelo TT es más compacto. Pero la ventaja no es solo la compresión de parámetros: es la **estructura inductiva** que impone la factorización tensorial. Mientras que una red densa puede representar cualquier función (dada suficiente capacidad), también puede aprender cualquier ruido. La factorización TT, al obligar a factorizar el espacio latente, **induce un sesgo inductivo** hacia soluciones que exhiben estructura de rango bajo, lo cual es a menudo una propiedad de sistemas complejos.

Adicionalmente, la propagación de gradientes en una arquitectura TT es más directa: los rangos internos actúan como canales de comunicación entre núcleos, reduciendo la necesidad de capas densas muy anchas para capturar interacciones complejas.

FUNDAMENTOS DE REGRESIÓN SIMBÓLICA

La regresión simbólica es una técnica de aprendizaje automático cuyo objetivo es encontrar una expresión matemática explícita que aproxime la relación entre un conjunto de variables de entrada y una variable objetivo. A diferencia de una regresión lineal, donde la forma funcional se fija de antemano, o de una red neuronal, donde la relación aprendida queda distribuida entre muchos parámetros, la regresión simbólica busca simultáneamente la estructura de la fórmula y sus coeficientes.

En términos generales, dado un conjunto de observaciones

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n, \quad x_i \in \mathbb{R}^p, \quad y_i \in \mathbb{R}, \quad (42)$$

el objetivo consiste en encontrar una función explícita g tal que

$$y_i \approx g(x_i), \quad (43)$$

donde g no pertenece necesariamente a una familia paramétrica cerrada previamente definida. En lugar de asumir, por ejemplo, una forma lineal, polinómica o exponencial concreta, la regresión simbólica explora un espacio de expresiones construido a partir de variables, constantes y operadores matemáticos.

F.1 MOTIVACIÓN

La motivación principal de la regresión simbólica es combinar capacidad predictiva e interpretabilidad. En muchos problemas, especialmente cuando se usan modelos no lineales complejos, el modelo entrenado puede producir buenas predicciones pero ser difícil de interpretar directamente. Una red neuronal, por ejemplo, puede aproximar relaciones muy flexibles, pero no suele proporcionar una ecuación simple que describa su comportamiento.

La regresión simbólica aborda este problema buscando una fórmula cerrada que aproxime la relación aprendida. Esta fórmula puede utilizarse de dos maneras. En primer lugar, como modelo predictivo interpretable si se ajusta directamente sobre la variable objetivo. En segundo lugar, como modelo sustituto o *surrogate* si se ajusta sobre las predicciones de otro modelo más complejo. En este segundo caso, la regresión simbólica no pretende descubrir necesariamente la verdadera ley económica del fenómeno, sino aproximar de forma interpretable el comportamiento de un modelo previamente entrenado.

En este proyecto se utiliza esta segunda lectura. La regresión simbólica se ajusta sobre las predicciones generadas por los modelos de volatilidad implícita. Por tanto, la ecuación obtenida debe interpretarse como una aproximación funcional al modelo original, no como una fórmula financiera exacta ni como una alternativa directa a modelos clásicos de valoración.

F.2 ESPACIO DE BÚSQUEDA DE EXPRESIONES

El elemento central de la regresión simbólica es el espacio de expresiones candidatas. Una expresión simbólica puede construirse combinando variables, constantes y operadores. Por ejemplo, si las variables disponibles son x_1 , x_2 y x_3 , y los operadores permitidos son suma, resta, producto y división, algunas expresiones candidatas podrían ser

$$g_1(x) = x_1 + x_2, \quad (44)$$

$$g_2(x) = \frac{x_1}{x_2 + c}, \quad (45)$$

o

$$g_3(x) = c_1 x_1^2 + c_2 x_3, \quad (46)$$

donde c , c_1 y c_2 son constantes que también deben estimarse.

Este espacio de búsqueda es mucho más amplio que el de una regresión tradicional. No sólo hay que encontrar los valores de los coeficientes, sino también decidir qué variables aparecen, qué operadores se usan, cómo se combinan y cuál es la profundidad o complejidad de la expresión. Por ello, la regresión simbólica suele formularse como un problema de optimización sobre estructuras.

Una forma habitual de representar las fórmulas candidatas es mediante árboles de expresión. En un árbol de expresión, las hojas representan variables o constantes, y los nodos internos representan operadores. Por ejemplo, la expresión

$$g(x) = \frac{x_1 + x_2}{x_3} \quad (47)$$

puede interpretarse como un árbol cuya raíz es una división, cuyo numerador es una suma y cuyo denominador es la variable x_3 . Esta representación permite aplicar operadores de búsqueda, mutación y recombinación sobre fórmulas completas.

F.3 OBJETIVO DE OPTIMIZACIÓN

La regresión simbólica no busca únicamente minimizar el error predictivo. También busca que la expresión resultante sea suficientemente simple para poder ser interpretada. Por ello, el problema se plantea habitualmente como un compromiso entre precisión y complejidad.

Sea g una expresión candidata. Una forma general de definir el objetivo es

$$\mathcal{L}(g) = \frac{1}{n} \sum_{i=1}^n \ell(y_i, g(x_i)) + \lambda C(g), \quad (48)$$

donde ℓ es una función de pérdida, por ejemplo el error cuadrático, $C(g)$ mide la complejidad de la expresión y λ controla la penalización por complejidad.

Si se utiliza error cuadrático medio, la parte de ajuste puede escribirse como

$$\text{MSE}(g) = \frac{1}{n} \sum_{i=1}^n (y_i - g(x_i))^2. \quad (49)$$

El término de complejidad puede depender del número de nodos del árbol, de la profundidad de la expresión, del número de operadores utilizados o de restricciones específicas sobre determinadas operaciones. En la práctica, esta penalización evita que el algoritmo elija fórmulas excesivamente largas que ajustan bien los datos pero son difíciles de interpretar y tienen peor capacidad de generalización.

El parámetro λ refleja el principio de parsimonia: entre dos expresiones con precisión similar, debe preferirse la más simple. Este principio es especialmente importante en un proyecto de explicabilidad, donde una fórmula demasiado compleja puede perder gran parte de su utilidad interpretativa.

F.4 BÚSQUEDA EVOLUTIVA

El espacio de posibles expresiones crece de forma combinatoria con el número de variables, operadores y niveles de profundidad permitidos. Por ello, no suele ser posible enumerar todas las fórmulas candidatas. En su lugar, muchos métodos de regresión simbólica emplean algoritmos evolutivos o estrategias de búsqueda heurística.

El procedimiento general puede resumirse en los siguientes pasos. Primero, se genera una población inicial de fórmulas candidatas. Después, cada fórmula se evalúa de acuerdo con su error y su complejidad. Las expresiones con mejor comportamiento tienen mayor probabilidad de conservarse, modificarse o recombinarse para generar nuevas expresiones. Este proceso se repite durante muchas iteraciones, explorando progresivamente regiones prometedoras del espacio de búsqueda.

De forma esquemática, si $\mathcal{G}$ representa el conjunto de expresiones posibles, la regresión simbólica busca

$$g^* = \arg \min_{g \in \mathcal{G}} \left[\frac{1}{n} \sum_{i=1}^n \ell(y_i, g(x_i)) + \lambda C(g) \right]. \quad (50)$$

La dificultad reside en que $\mathcal{G}$ no es un espacio vectorial simple, sino un conjunto discreto y estructurado de árboles de expresión. Por tanto, la búsqueda combina exploración de estructuras, ajuste de constantes y selección de modelos.

F.5 FRONTERA PRECISIÓN-COMPLEJIDAD

Una característica importante de la regresión simbólica es que no produce necesariamente una única fórmula relevante. Normalmente genera una familia de ecuaciones candidatas con distintos niveles de complejidad y precisión. Algunas fórmulas son muy simples pero aproximan peor los datos. Otras son más complejas y reducen el error, pero resultan menos interpretables.

Esto permite analizar una frontera precisión-complejidad. Para cada expresión candidata g_k , pueden compararse dos magnitudes:

$$\text{Error}(g_k) \quad \text{y} \quad C(g_k). \quad (51)$$

La selección final no debe basarse exclusivamente en el menor error. En contextos de explicabilidad, puede ser preferible una ecuación ligeramente menos precisa pero mucho más clara. Por ejemplo, una fórmula con tres términos interpretables puede

aportar más valor analítico que una expresión muy extensa con una mejora marginal en RMSE.

En este proyecto, el modelo simbólico seleccionado se evalúa mediante métricas como RMSE, MAE y R^2 , pero también se conserva información sobre la complejidad de la ecuación y sobre un conjunto de ecuaciones candidatas. Esta decisión permite no reducir la regresión simbólica a una competición puramente predictiva, sino tratarla como una herramienta de análisis del compromiso entre fidelidad e interpretabilidad.

F.6 REGRESIÓN SIMBÓLICA COMO MODELO SUSTITUTO

En el contexto del proyecto, la regresión simbólica se utiliza como modelo sustituto de modelos de predicción de volatilidad implícita. Sea f el modelo original, por ejemplo una red neuronal o cualquier otro estimador entrenado, y sea g la expresión simbólica buscada. El objetivo no es ajustar g directamente contra la volatilidad observada, sino aproximar las predicciones del modelo original:

$$g(x_i) \approx f(x_i). \quad (52)$$

Por tanto, la pérdida se calcula frente a las predicciones del modelo base:

$$\mathcal{L}_{surrogate}(g) = \frac{1}{n} \sum_{i=1}^n (f(x_i) - g(x_i))^2 + \lambda C(g). \quad (53)$$

Esta formulación tiene una interpretación clara. Si g aproxima bien a f , entonces la ecuación simbólica proporciona una descripción interpretable del comportamiento aprendido por el modelo original. Sin embargo, la fidelidad de g respecto a f no implica necesariamente que f sea correcto respecto al mercado. Una ecuación simbólica puede explicar muy bien un modelo mal calibrado. Por ello, la regresión simbólica debe interpretarse junto con las métricas predictivas del modelo original y con validaciones financieras adicionales.

F.7 CONFIGURACIÓN UTILIZADA EN EL PROYECTO

La implementación del proyecto utiliza PySRRegressor, una herramienta de regresión simbólica basada en búsqueda evolutiva. El modelo simbólico se entrena sobre las predicciones generadas por el modelo original en el conjunto de entrenamiento y se valida sobre las predicciones del modelo original en el conjunto de test. De este modo, la evaluación mide la fidelidad del sustituto simbólico respecto al modelo base fuera de la muestra usada para ajustar la expresión.

El flujo utilizado puede resumirse en cuatro fases.

1. Construir un marco de variables de explicabilidad a partir de los datos de referencia.
2. Codificar dichas variables mediante el encoder de explicabilidad, manteniendo un conjunto de variables financieramente interpretables.
3. Ajusta el regresor simbólico sobre las predicciones del modelo base.
4. Evalúa la ecuación obtenida sobre el conjunto de test, calculando métricas de fidelidad y almacenando tanto la mejor ecuación como un conjunto de ecuaciones candidatas.

Las variables utilizadas en la capa simbólica coinciden con las variables de explicabilidad del proyecto. Esta decisión favorece que la fórmula resultante sea legible desde un punto de vista financiero. En lugar de ajustar una expresión sobre representaciones internas difíciles de interpretar, la regresión simbólica se aplica sobre variables visibles y relacionadas con el contrato, como el tipo de opción, el precio de ejercicio, el precio del subyacente, el tiempo a vencimiento y el tipo de interés.

La configuración permite los operadores binarios

$$+, -, *, /, \wedge, \quad (54)$$

y los operadores unarios

$$\text{square}(x) = x^2, \quad \text{cube}(x) = x^3. \quad (55)$$

Además, se restringe el operador potencia mediante restricciones específicas para evitar expresiones demasiado inestables o difíciles de interpretar. Estas restricciones son relevantes porque operadores como la división o la potencia pueden producir fórmulas con gran capacidad de ajuste, pero también con comportamientos extremos fuera de la región de datos observada.

La búsqueda se controla mediante parámetros como el número de iteraciones, el número de poblaciones, el tamaño de población, el número de ciclos por iteración, la penalización de parsimonia, el tamaño máximo de expresión, la profundidad máxima y el tiempo máximo de ejecución. En particular, el proyecto utiliza un tamaño de muestra simbólica controlado por `symbolic_sample_size`, un número elevado de iteraciones `symbolic_niterations`, varias poblaciones en paralelo y un límite temporal de ejecución definido por `symbolic_timeout_seconds`. Estos parámetros reflejan el compromiso entre explorar suficientemente el espacio de fórmulas y mantener un coste computacional razonable dentro del dashboard.

F.8 EVALUACIÓN DE FIDELIDAD

Como el modelo simbólico actúa como sustituto, la evaluación principal mide la proximidad entre las predicciones del modelo original y las predicciones de la ecuación simbólica. Si $\hat{y}_i^f = f(x_i)$ representa la predicción del modelo base y $\hat{y}_i^g = g(x_i)$ la predicción simbólica, el residual de fidelidad se define como

$$r_i = \hat{y}_i^f - \hat{y}_i^g. \quad (56)$$

A partir de estos residuos se calculan métricas como RMSE, MAE y R^2 . El RMSE de fidelidad puede escribirse como

$$\text{RMSE}_{fid} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i^f - \hat{y}_i^g)^2}. \quad (57)$$

El MAE de fidelidad se define como

$$\text{MAE}_{fid} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i^f - \hat{y}_i^g|. \quad (58)$$

Estas métricas no comparan directamente la ecuación simbólica con la volatilidad observada, sino con el modelo que se quiere explicar. Por tanto, un bajo error de fidelidad indica que la ecuación simbólica reproduce bien el comportamiento del modelo base en la muestra evaluada.

El coeficiente R^2 de fidelidad mide qué proporción de la variabilidad de las predicciones del modelo base queda explicada por la fórmula simbólica:

$$R_{fid}^2 = 1 - \frac{\sum_{i=1}^n (\hat{y}_i^f - \hat{y}_i^g)^2}{\sum_{i=1}^n (\hat{y}_i^f - \bar{\hat{y}}^f)^2}. \quad (59)$$

Un valor de R_{fid}^2 próximo a uno indica alta fidelidad global, mientras que un valor bajo indica que la fórmula simbólica no captura adecuadamente la variabilidad del modelo original.

F.9 INTERPRETACIÓN DE LA ECUACIÓN SIMBÓLICA

La ecuación simbólica final debe interpretarse como una aproximación analítica al comportamiento del modelo en la región de datos utilizada para entrenar y validar el sustituto. Su utilidad reside en que permite inspeccionar explícitamente qué variables aparecen en la fórmula, cómo se combinan y qué tipo de no linealidades emergen.

Por ejemplo, si la ecuación utiliza principalmente el tiempo a vencimiento y el strike, puede interpretarse que el sustituto simbólico ha identificado esas variables como suficientes para reproducir una parte relevante del comportamiento del modelo. Si aparecen interacciones multiplicativas o cocientes entre variables, puede existir una relación no lineal aprendida por el modelo que merece ser analizada financieramente. Sin embargo, estas lecturas deben hacerse con prudencia: la presencia de una variable en la fórmula no demuestra causalidad, y la ausencia de una variable no implica necesariamente irrelevancia económica.

También es importante considerar la estabilidad de la expresión. La regresión simbólica puede encontrar fórmulas matemáticamente válidas pero sensibles a pequeñas variaciones de entrada, especialmente si incluyen divisiones, potencias o combinaciones de alto grado. Por ello, las ecuaciones deben evaluarse no sólo por su métrica agregada, sino también por su comportamiento en distintas regiones de la superficie de volatilidad, especialmente en vencimientos cortos, extremos de moneyness o zonas con menor densidad de observaciones.

F.10 LIMITACIONES

La regresión simbólica aporta interpretabilidad, pero no elimina las limitaciones propias del aprendizaje estadístico. En primer lugar, la búsqueda es heurística. El algoritmo no garantiza encontrar la mejor expresión posible en términos globales, sino una buena expresión dentro del espacio explorado y bajo las restricciones impuestas.

En segundo lugar, la ecuación encontrada depende del conjunto de operadores permitido. Si se excluyen funciones relevantes, el algoritmo no podrá descubrir expresiones que las necesiten. Si se incluyen demasiados operadores, el espacio de búsqueda se vuelve más amplio y aumenta el riesgo de encontrar fórmulas difíciles de interpretar.

En tercer lugar, la regresión simbólica puede sobreajustar. Una fórmula suficientemente compleja puede aproximar muy bien una muestra concreta y generalizar peor fuera de ella. Por este motivo, en el proyecto se evalúa la fidelidad sobre predicciones de test y se penaliza la complejidad mediante un término de parsimonia.

En cuarto lugar, cuando la regresión simbólica se usa como sustituto, la explicación queda limitada por el modelo base. La fórmula explica el comportamiento del modelo original, no necesariamente el mecanismo real que genera los precios o volatilidades de mercado.

Finalmente, las expresiones simbólicas deben interpretarse dentro del dominio observado. Una fórmula puede ser razonable para los rangos de strike, subyacente, vencimiento y tipos presentes en los datos, pero comportarse de forma inestable si se extrapola fuera de ellos. Por ello, su función principal en este trabajo es explicativa y diagnóstica, no la sustitución directa de los modelos de pricing o de predicción de volatilidad en producción.

F.11 RELACIÓN CON LA EXPLICABILIDAD DEL PROYECTO

Dentro del sistema de explicabilidad desarrollado, la regresión simbólica cumple una función complementaria a otras técnicas. Mientras que SHAP ofrece atribuciones locales y agregaciones globales de importancia, la regresión simbólica intenta condensar el comportamiento del modelo en una fórmula explícita. Esta fórmula puede ayudar a detectar patrones aprendidos, dependencias no lineales, interacciones entre variables y posibles simplificaciones del modelo original.

Su valor metodológico no está en afirmar que la ecuación descubierta sea una nueva ley cerrada de volatilidad implícita, sino en proporcionar una herramienta adicional para auditar modelos complejos. Si una expresión relativamente simple reproduce con alta fidelidad las predicciones de un modelo, entonces parte del comportamiento del modelo puede resumirse de forma transparente. Si, por el contrario, sólo expresiones muy complejas alcanzan una fidelidad aceptable, esto sugiere que el modelo base está utilizando relaciones más difíciles de condensar en una fórmula interpretable.

Por tanto, la regresión simbólica se incorpora en este proyecto como una técnica de explicabilidad global basada en modelos sustitutos. Su objetivo es mejorar la trazabilidad y la comprensión del modelo de volatilidad, manteniendo siempre la distinción entre fidelidad al modelo, precisión frente al mercado e interpretabilidad financiera.

ENTRENAMIENTO PROGRESSIVE ATM

El entrenamiento progressive ATM se desarrolló como estudio paralelo para intentar mejorar el aprendizaje de la superficie. Su hipótesis de partida es financiera: la región ATM suele ser más líquida y central para la formación del nivel de volatilidad, mientras que los extremos de moneyness pueden contener más ruido, menor frecuencia o mayor sensibilidad a microestructura.

El procedimiento ordena las observaciones por distancia a ATM:

$$d_{ATM} = |\log(F/K)|. \quad (60)$$

Después divide el entrenamiento en segmentos. En la configuración actual se usan tres segmentos. Los modelos no iterativos reciben pesos mayores para tramos más cercanos al ATM; los modelos iterativos entrenan de forma acumulativa, empezando por la zona central e incorporando progresivamente tramos más alejados.

Si hay S segmentos ordenados de ATM a tramos más alejados, los pesos conceptuales decrecen con el segmento:

$$w_s \propto S - s, \quad \tilde{w}_i = \frac{w_i}{\bar{w}}. \quad (61)$$

La diferencia por familia es relevante: regresión lineal y Random Forest usan pesos de muestra; XGBoost reparte estimadores entre fases acumulativas; y las redes entrenan sucesivamente sobre datasets acumulados. En los resultados de este trabajo, progressive ATM mejora Quantum Inspired pero no mejora al Random Forest seleccionado. Por tanto, se conserva como estrategia analítica útil, pero no como regla general de entrenamiento.

BIBLIOGRAFÍA

- Daniel W. Apley and Jingyu Zhu. Visualizing the effects of predictor variables in black box supervised learning models. *Journal of the Royal Statistical Society: Series B*, 82(4):1059–1086, 2020.
- Fischer Black. The pricing of commodity contracts. *Journal of Financial Economics*, 3(1-2):167–179, 1976.
- Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- Miles Cranmer. Interpretable machine learning for science with PySR and symboli-cregression.jl. *arXiv preprint arXiv:2305.01582*, 2023.
- Emanuel Derman and Michael B. Miller. *The Volatility Smile*. Wiley, 2016.
- Alex Goldstein, Adam Kapelner, Justin Bleich, and Emil Pitkin. Peeking inside the black box: Visualizing statistical learning with plots of individual conditional expectation. *Journal of Computational and Graphical Statistics*, 24(1):44–65, 2015.
- Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.
- John C. Hull. *Options, Futures, and Other Derivatives*. Pearson, 11 edition, 2022.
- Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.