



IA PARA VALORACIÓN DE OPCIONES: MODELOS DE VOLATILIDAD EXPLICABLES

PEDRO GALLEGO LÓPEZ Y DANIEL RECUERO CORDOBÉS

Trabajo Final de Máster

Máster en Inteligencia Artificial y Computación Cuántica
Aplicada a los Mercados Financieros


Dirección

Enrique Castellanos

INSTITUTO BME

BOLSAS Y MERCADOS ESPAÑOLES

Madrid, 16 de mayo de 2026



IA para valoración de opciones: modelos de volatilidad explicables

Pedro Gallego López
Daniel Recuero Cordobés

Palabras clave:

Volatilidad implícita, opciones IBEX, Black-76, aprendizaje automático, IA explicable, SHAP, dashboard, API, cloud

Resumen

Este Trabajo Final de Máster tiene como objetivo desarrollar modelos de volatilidad implícita para opciones sobre el IBEX mediante técnicas de inteligencia artificial e integrarlos en un marco de explicabilidad riguroso. La motivación central es combinar la capacidad de los modelos de IA para capturar relaciones no lineales complejas en la superficie de volatilidad con los requisitos de interpretabilidad y auditabilidad propios de la modelización financiera tradicional.

A partir de operaciones reales, contratos, futuros subyacentes y series de tipos EONIA/€STR, se construye una base de volatilidad implícita mediante validaciones financieras e inversión numérica del modelo Black-76. Sobre esta base se entrenan varias familias de modelos de regresión: regresión lineal, Random Forest, XGBoost, redes neuronales y una arquitectura *quantum inspired*, inspirada en conceptos de computación cuántica. La evaluación no se limita al error predictivo, sino que incorpora estabilidad temporal, control de sobreajuste, coherencia financiera de la superficie y análisis por tramos de moneyness y vencimiento.

La contribución principal consiste en transformar modelos predictivos en sistemas explicables, auditables y consultables mediante un dashboard y un servicio API. La explicabilidad se aborda con SHAP global y local, superficies de volatilidad, curvas ICE y ALE, árboles surrogate, regresión simbólica, vecinos históricos y diagnósticos de residuales. Esta combinación permite justificar las predicciones con un lenguaje cercano al de los modelos tradicionales, sin renunciar a la capacidad de aproximación de la IA. El resultado es una arquitectura reproducible orientada a la validación de modelos, la auditoría interna y el uso operativo en entornos financieros.

Adicionalmente, se ha implementado una API que permite el despliegue y consumo de estos modelos en distintos contextos de uso.

AI for option pricing: explainable volatility models

Pedro Gallego López
Daniel Recuero Cordobés

Keywords:

Implied volatility, IBEX options, Black-76, machine learning, explainable AI, SHAP, dashboard, API, cloud

Abstract

The main objective of this Master's Thesis is to develop implied-volatility models for IBEX options using artificial-intelligence techniques and to integrate them into a rigorous explainability framework. The central motivation is to combine the ability of AI models to capture complex nonlinear relationships across the volatility surface with the interpretability and auditability requirements of traditional financial modelling.

Starting from real trades, contracts, underlying futures and EONIA/€STR rate series, the project builds an implied-volatility database through financial validations and numerical inversion of the Black-76 pricing model. Several regression families are then trained, including linear regression, Random Forest, XGBoost, neural networks and a quantum-inspired architecture, based on quantum computing concepts as its name suggests. The evaluation is not restricted to predictive error; it also considers temporal stability, overfitting control, financial coherence of the surface, and performance across moneyness and maturity segments.

The main contribution is to turn predictive models into explainable, auditable and queryable systems through a dashboard and an API service. Explainability is addressed through global and local SHAP, volatility surfaces, ICE and ALE curves, surrogate trees, symbolic regression, historical neighbours and residual diagnostics. This combination makes it possible to justify predictions in a language close to traditional financial models, without giving up the approximation power of AI. The resulting architecture is reproducible and oriented towards model validation, internal audit and operational use in financial environments.

Additionally, an API has been implemented to support the deployment and consumption of these models across different usage contexts.

ÍNDICE GENERAL

1. INTRODUCCIÓN	6
1.1. Planteamiento del problema	6
1.2. Relevancia financiera y profesional	7
1.3. Antecedentes	8
1.4. Objetivos	9
1.5. Contribución del TFM	9
1.6. Estructura de la memoria	11
2. MARCO TEÓRICO	12
2.1. Opciones, futuros y volatilidad implícita	12
2.2. Smile, moneyness y estructura temporal	13
2.3. Aprendizaje automático para volatilidad	14
2.4. Explicabilidad en modelos financieros	15
2.5. Infraestructura cloud y reproducibilidad	16
2.6. Métricas de error, estabilidad y fidelidad	17
2.7. Gobierno de modelos y preguntas de validación	18
3. METODOLOGÍA	20
3.1. Diseño general del estudio	20
3.2. Datos y muestra analizada	21
3.3. Validaciones y tratamiento financiero	25
3.4. Variables y feature engineering	26
3.5. Familias de modelos	28
3.6. Splits temporales y selección	30
3.7. Reentrenamiento y progressive ATM	31
3.8. Construcción del dashboard	33
3.9. API, almacenamiento y cloud	35
3.10. Reproducibilidad y trazabilidad	38
3.11. Arquitectura del repositorio	39
3.12. Plan de validación funcional	41
3.13. Riesgos metodológicos y controles	43
4. RESULTADOS Y DISCUSIÓN	45
4.1. Resultados	45
4.1.1. Comparativa general de modelos	45
4.1.2. Entrenamiento estándar frente a progressive ATM	46
4.1.3. Selección del modelo final	47
4.1.4. Diagnóstico de rendimiento	48
4.1.5. Behaviour And Surface	52
4.1.6. Explicabilidad global	53

4.1.7.	Modelos equivalentes: árboles y regresión simbólica	54
4.1.8.	Explicabilidad local y soporte histórico	56
4.1.9.	Síntesis comparativa por temática	57
4.2.	Discusión	59
4.2.1.	Lectura financiera	59
4.2.2.	Lectura de IA y Data Science	60
4.2.3.	Lectura de ingeniería y cloud	61
4.2.4.	Limitaciones	61
5.	CONCLUSIONES	62
A.	ESQUEMA DETALLADO DE DATOS Y ETL	64
B.	MARCO DE DESARROLLO Y CONTROL DE CAMBIOS	68
C.	FUNDAMENTOS DE SHAP	70
D.	CURVAS ICE	74
E.	CURVAS ALE	76
F.	MODELO QUANTUM INSPIRED	79
G.	ÁRBOLES SURROGATE Y REGRESIÓN SIMBÓLICA	82
H.	ENTRENAMIENTO PROGRESSIVE ATM	87

INTRODUCCIÓN

1.1 PLANTEAMIENTO DEL PROBLEMA

La volatilidad implícita es un concepto central en mercados de derivados. En una opción negociada, el precio observable resume expectativas, oferta y demanda, liquidez, microestructura y percepción de riesgo. Sin embargo, para comparar contratos con strikes y vencimientos distintos, los profesionales no suelen razonar únicamente en precios: transforman esos precios en volatilidades implícitas y analizan smiles, skews y estructuras temporales [Hull, 2022, Derman and Miller, 2016].

El problema de este trabajo surge de una doble exigencia en finanzas cuantitativas. Por un lado, los modelos de aprendizaje automático pueden aproximar relaciones no lineales entre strike, subyacente, vencimiento, tipo de interés y volatilidad. Por otro lado, en un entorno financiero no basta con obtener una predicción numéricamente competitiva. El modelo debe poder auditarse: hay que saber dónde falla, qué variables explican sus predicciones, si respeta patrones razonables de la superficie y si una predicción concreta está respaldada por datos históricos similares.

En este contexto, el proyecto construye modelos de volatilidad explicable, consultable y útil vía API. La explicabilidad se entiende en dos niveles. A nivel de ingeniería, sirve para detectar sesgos, errores de datos, incoherencias, discontinuidades y comportamientos no deseados. A nivel financiero y profesional, permite justificar decisiones ante revisiones internas, auditorías, model validation o análisis de riesgo.

Operativamente, el problema se concreta en cuatro preguntas.

- Cómo transformar operaciones reales de mercado en una base de volatilidad implícita que sea consistente, trazable y reutilizable.
- Cómo aproximar la superficie $\sigma(K, T)$ con modelos suficientemente flexibles sin introducir sesgos temporales o dependencias espurias.
- Cómo operacionalizar ese modelo de forma utilizable, de manera que no quede encerrado en notebooks o tablas estáticas.

- Cómo saber cuándo una predicción es robusta y cuándo conviene tratarla con cautela porque está en una región poco soportada o mal explicada.

La memoria se construye alrededor de esa cadena completa. No se limita a entrenar un predictor, sino que conecta datos de mercado, inversión de Black-76, selección de familias, explicabilidad global y local, diagnóstico por zonas de la superficie y despliegue. Ese enfoque es coherente con el tipo de uso que tendría el sistema en un entorno profesional: consulta repetida, revisión crítica y necesidad de justificar el resultado más allá de una métrica agregada.

1.2 RELEVANCIA FINANCIERA Y PROFESIONAL

La volatilidad implícita condensa información de mercado y se utiliza en valoración, cobertura, gestión de riesgos y análisis de escenarios. En opciones sobre índices, la forma de la superficie de volatilidad puede reflejar demanda de protección, asimetría percibida, presión de liquidez o cambios de régimen. Un modelo que suaviza en exceso los extremos de moneyness, que comprime volatilidades extremas o que presenta saltos artificiales en vencimientos cortos puede producir señales engañosas aunque su RMSE agregado sea aceptable.

La literatura clásica de derivados establece que la volatilidad no debe interpretarse como un simple parámetro estadístico fijo, sino como una magnitud inferida del precio bajo un modelo de valoración [Black, 1976, Hull, 2022]. La literatura específica sobre smile muestra que los mercados organizan la volatilidad en torno a moneyness y vencimiento, no solo en torno a niveles absolutos de strike [Derman and Miller, 2016]. Por ello, el proyecto se diseña desde la geometría financiera de la superficie: el aprendizaje automático se usa para aproximar una función de volatilidad, pero la evaluación exige interpretar su forma.

La relevancia práctica aparece en varios frentes.

- **Valoración y marking:** una estimación coherente de volatilidad implícita permite comparar contratos y revisar precios fuera de rango.
- **Gestión de riesgos:** la sensibilidad del error por moneyness y vencimiento importa tanto como el error medio total.
- **Gobierno de modelos:** el área usuaria necesita entender si el modelo reacciona con lógica financiera y no solo si ajusta bien una muestra histórica.
- **Infraestructura analítica:** si el modelo no puede consultarse, versionarse y explicarse, su valor operativo cae de forma drástica.

Desde esa perspectiva, un buen resultado no es únicamente “predecir bien”. También implica poder distinguir entre una predicción bien soportada, una extrapolación razonable y una salida que requiere revisión adicional. Ese matiz es el que justifi-

ca que la memoria dedique espacio tanto a finanzas como a IA y a arquitectura de servicio.

1.3 ANTECEDENTES

La valoración de opciones sobre futuros se apoya tradicionalmente en Black-76 [Black, 1976]. En ese marco, el precio de una opción europea depende del futuro subyacente, el strike, el vencimiento, el tipo de interés y la volatilidad. Cuando el precio de mercado se observa, la volatilidad implícita se obtiene resolviendo numéricamente la ecuación inversa.

En paralelo, el uso de modelos de aprendizaje automático para superficies financieras responde a la necesidad de capturar no linealidades, interacciones y patrones empíricos que no quedan completamente descritos por modelos paramétricos simples. Sin embargo, la adopción profesional de modelos flexibles exige herramientas de interpretación. SHAP proporciona una semántica aditiva para atribuir predicciones a variables [Lundberg and Lee, 2017]; ICE y ALE ayudan a estudiar respuestas funcionales [Goldstein et al., 2015, Apley and Zhu, 2020]; los árboles surrogate y la regresión simbólica aproximan modelos complejos mediante objetos interpretables [Cranmer, 2023].

Los antecedentes relevantes convergen en tres líneas.

- **Línea financiera:** la inversión de modelos como Black-76 convierte precios observados en volatilidades comparables y lleva el problema al terreno de la superficie.
- **Línea empírica:** los smiles y las estructuras temporales muestran que la volatilidad de mercado no es constante y que la relación con strike y vencimiento es no lineal.
- **Línea metodológica:** los modelos de caja negra ganan flexibilidad, pero obligan a complementar la predicción con mecanismos de explicación y validación.

Este trabajo se sitúa precisamente en la intersección de esas tres líneas. Toma la formulación clásica de derivados como base para construir la variable objetivo, utiliza familias de aprendizaje automático sobre datos tabulares para aproximar la función de volatilidad y añade una capa de explicabilidad y servicio para hacer la solución defendible en un contexto profesional.

1.4 OBJETIVOS

El objetivo general es desarrollar una solución reproducible para estimar, explicar y consultar volatilidad implícita de opciones del IBEX. Este objetivo se concreta en los siguientes objetivos específicos:

1. Construir una base de volatilidad implícita a partir de operaciones, contratos, futuros subyacentes y curvas de tipos, con validaciones de calidad y trazabilidad.
2. Diseñar un conjunto de variables financieras coherentes con la geometría de la superficie de volatilidad.
3. Entrenar y comparar varias familias de modelos de regresión bajo una metodología temporal que reduzca lookahead bias y data snooping.
4. Generar componentes de explicabilidad global, local, funcional y de diagnóstico.
5. Implementar una API y un dashboard que permitan consultar predicciones, explicar muestras concretas y revisar el comportamiento del modelo.
6. Preparar infraestructura cloud reproducible para almacenar modelos, paquetes explicativos y metadatos de servicio.

Tomados en conjunto, estos objetivos cubren los tres planos que estructuran la memoria. El primero es **financiero**, porque la variable objetivo y las transformaciones deben respetar la lógica de opciones sobre futuros. El segundo es **de IA y Data Science**, porque la comparación entre familias exige un diseño temporal riguroso, métricas correctas y lectura crítica del error. El tercero es **de ingeniería**, porque el resultado final no es un gráfico aislado, sino un sistema consultable y versionable.

1.5 CONTRIBUCIÓN DEL TFM

La principal contribución del TFM es integrar en un único flujo operativo elementos que habitualmente se tratan por separado: construcción de datos de mercado, inversión de Black-76, entrenamiento de modelos, explicabilidad, diagnóstico financiero, API y despliegue cloud. La Figura 1 resume esta cadena con las mismas dependencias que la documentación técnica.




Figura 1: Vision general del proyecto.

La aportación académica se sitúa en la metodología de modelización y validación; la aportación profesional, en la capacidad de convertir un modelo de volatilidad en una herramienta inspeccionable y desplegable.

De forma más concreta, la contribución del trabajo puede resumirse así:

- **Contribución financiera:** construir una base de volatilidad implícita a partir de datos reales enlazando operaciones de opciones, futuros y curvas de tipos.
- **Contribución metodológica:** comparar familias heterogéneas con el mismo protocolo temporal, las mismas métricas y el mismo criterio de selección.
- **Contribución de explicabilidad:** combinar atribuciones SHAP, curvas ICE y ALE, modelos equivalentes, superficies y vecinos históricos en un único flujo de lectura.
- **Contribución de ingeniería:** dejar el modelo convertido en un paquete auto-contenido consumible por dashboard y API, con almacenamiento reproducible y despliegue desacoplado.

Desde el punto de vista de negocio en derivados, el valor aplicado se concreta en ocho usos directos:

- **Valoración de opciones ilíquidas o poco negociadas:** la predicción se apoya en estructura de superficie y soporte histórico de vecinos, no sólo en una cotización puntual.
- **Interpolación y suavizado de superficies de volatilidad:** el dashboard permite revisar continuidad por moneyness y vencimiento y detectar escalones no deseados.
- **Detección de precios anómalos o errores de mercado:** los residuales por zonas de superficie ayudan a localizar observaciones fuera de patrón.
- **Validación independiente de modelos internos:** el pipeline puede usarse como contraste externo frente a pricers de mesa o librerías internas.
- **Control de riesgos de mesa de derivados:** el error deja de leerse sólo en promedio y se monitoriza por tramos relevantes de moneyness y vencimiento.
- **Explicación ante auditoría interna o model validation:** cada predicción puede justificarse con SHAP, curvas funcionales y evidencia de soporte histórico.
- **Análisis de sensibilidad por moneyness y vencimiento:** superficies locales, ICE y ALE aportan lectura funcional de cómo reacciona el modelo.
- **Soporte a decisiones de cobertura:** la lectura conjunta de smile, term structure y diagnóstico local ofrece contexto operativo para coberturas.

Esa combinación es la que hace que el proyecto no sea sólo un ejercicio de entrenamiento de modelos. El valor añadido está en que cada capa técnica responde a una pregunta concreta y útil: cómo se construye la volatilidad, cómo se estima, cómo se valida, cómo se explica y cómo se despliega.

1.6 ESTRUCTURA DE LA MEMORIA

El [chapter 2](#) presenta los fundamentos financieros, de aprendizaje automático, explicabilidad e infraestructura. El [chapter 3](#) describe la construcción de datos, variables, modelos, validación, dashboard, API y cloud. El [chapter 4](#) analiza las métricas persistentes y la lectura que debe hacerse desde las vistas del dashboard. El [chapter 5](#) resume conclusiones y líneas futuras. Los anexos desarrollan SHAP, ICE, ALE, explicadores equivalentes y entrenamiento progressive ATM con mayor profundidad.

El orden de lectura responde al flujo real del proyecto.

1. En la **Introducción** se delimita el problema y se justifica por qué la explicabilidad es parte del resultado, no un añadido posterior.
2. En el **Marco Teórico** se fijan las piezas conceptuales necesarias para interpretar Black-76, smiles, familias de modelos, métricas y gobierno de modelos.
3. En la **Metodología** se documenta la implementación efectiva: ETL, features, validación temporal, reentrenamiento, generación del paquete de dashboard y despliegue.
4. En **Resultados y Discusión** se conectan métricas, superficies, explicaciones y limitaciones con una lectura financiera y técnica unificada.
5. En los **Anexos** se amplían los mecanismos de explicabilidad y entrenamiento para que la memoria principal conserve foco sin perder profundidad técnica.

MARCO TEÓRICO

2.1 OPCIONES, FUTUROS Y VOLATILIDAD IMPLÍCITA

Una opción financiera otorga a su comprador el derecho, pero no la obligación, de comprar o vender un activo subyacente a un precio de ejercicio K en una fecha futura. En el caso de opciones sobre futuros, el subyacente relevante para valoración es el precio del futuro F . La literatura de derivados enfatiza que el valor de una opción depende de la distribución esperada del subyacente y, de forma operativa, de la volatilidad usada en el modelo de valoración [Hull, 2022].

En el modelo Black-76, una call europea sobre un futuro se valora como:

$$C = e^{-rT} (FN(d_1) - KN(d_2)), \quad (1)$$

donde

$$d_1 = \frac{\ln(F/K) + \frac{1}{2}\sigma^2 T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}. \quad (2)$$

Para una put:

$$P = e^{-rT} (KN(-d_2) - FN(-d_1)). \quad (3)$$

En estas expresiones, r es el tipo de interés, T el tiempo a vencimiento en años, σ la volatilidad y $N(\cdot)$ la función de distribución normal estándar. La volatilidad implícita σ_{imp} es el valor de σ que iguala el precio teórico al precio observado en mercado:

$$P_{mercado} = P_{Black76}(F, K, T, r, \sigma_{imp}). \quad (4)$$

La ecuación (4) no se puede resolver en forma cerrada en general; se obtiene mediante métodos numéricos. En el proyecto se emplea bisección dentro de límites configurados, descartando filas no resolubles o no finitas.

Para el proyecto, esta formulación tiene varias implicaciones directas.

- La calidad de la volatilidad implícita depende de la calidad del precio de opción y del emparejamiento con el futuro subyacente.
- El tiempo a vencimiento no es un mero metadato: entra de forma no lineal a través de $\sqrt{T}$, por lo que errores en fechas o vencimientos contaminan la variable objetivo.
- El tipo de interés afecta tanto al descuento como a la construcción de variables derivadas basadas en el forward ajustado.
- Calls y puts comparten el mismo concepto de volatilidad implícita, pero pueden situarse en zonas distintas de la superficie y, por tanto, inducir respuestas diferentes en el modelo.

Por eso la memoria no trata la volatilidad implícita como una etiqueta estadística cualquiera. Antes de entrenar ningún modelo, la variable objetivo debe quedar bien definida desde el punto de vista financiero y bajo un procedimiento numérico reproducible.

2.2 SMILE, MONEYNES Y ESTRUCTURA TEMPORAL

Si la volatilidad fuese constante, opciones con distinto strike y vencimiento compartirían una misma σ . En mercados reales aparece una superficie de volatilidad:

$$\sigma_{imp} = \sigma(K, T), \quad (5)$$

o, de forma más comparable entre niveles de mercado:

$$\sigma_{imp} = \sigma(m, T), \quad m = \frac{F}{K}. \quad (6)$$

La moneyness m indica la posición relativa del subyacente frente al strike. Su transformación logarítmica,

$$\ell = \log(F/K), \quad (7)$$

es especialmente útil porque centra la región ATM en $\ell = 0$ y trata de forma más simétrica las zonas a ambos lados del strike. La literatura sobre smile subraya que la curvatura y pendiente de la volatilidad implícita contienen información sobre

expectativas de mercado, asimetría y demanda de cobertura [Derman and Miller, 2016].

En la práctica, esta superficie se lee a través de varios patrones.

- **Smile o skew:** describe cómo cambia la volatilidad implícita al alejarse de ATM.
- **Estructura temporal:** muestra cómo cambia la volatilidad con el vencimiento para una región dada de moneyness.
- **Interacción entre ambas:** la curvatura del smile no tiene por qué ser la misma en corto plazo que en vencimientos largos.

Esta lectura geométrica justifica el diseño posterior de variables y visualizaciones. Si el fenómeno financiero se organiza en torno a moneyness y vencimiento, es razonable que el feature engineering, la validación y los gráficos de comportamiento del modelo se construyan también alrededor de esas magnitudes.

2.3 APRENDIZAJE AUTOMÁTICO PARA VOLATILIDAD

El problema de modelización se formula como una regresión supervisada:

$$\hat{\sigma} = f(X), \quad (8)$$

donde X contiene variables financieras observables y transformadas. El proyecto compara familias con diferentes niveles de flexibilidad:

- Regresión lineal, como baseline interpretable y control de complejidad.
- Random Forest, basado en agregación de árboles para capturar interacciones no lineales [Breiman, 2001].
- XGBoost, como boosting regularizado con early stopping y buen rendimiento en datos tabulares [Chen and Guestrin, 2016].
- Redes neuronales densas, como aproximadores flexibles de funciones no lineales [Hornik et al., 1989].
- Una red neuronal clásica *quantum inspired*, que introduce una estructura tensorial inspirada en ideas de representación compacta. No se presenta como computación cuántica real, sino como una variante arquitectónica implementada en código.

La comparación no puede basarse solo en error medio. En datos financieros temporales, una evaluación mal planteada puede introducir fuga de información. Por ello se emplean splits temporales, control de contratos compartidos y k-folds temporales, tal como se desarrolla en el [section 3.6](#).

La comparación entre familias se apoya en cuatro criterios.

- **Capacidad de ajuste:** qué nivel de no linealidad e interacción puede capturar cada familia.
- **Estabilidad temporal:** cómo se comporta el modelo al cambiar de fold o al pasar de validation a test.
- **Coste operativo:** si requiere escalado, early stopping, mayor coste computacional de entrenamiento o persistencia adicional.
- **Interpretación posterior:** hasta qué punto requiere apoyarse en SHAP, modelos surrogate, superficies o vecinos para ser defendible.

Esa es la razón por la que el proyecto no enfrenta “modelos buenos” frente a “modelos malos”, sino familias con perfiles distintos. La regresión lineal aporta una referencia interpretable, los árboles capturan relaciones tabulares robustas, el boosting ofrece flexibilidad adicional y las redes permiten explorar arquitecturas más expresivas.

2.4 EXPLICABILIDAD EN MODELOS FINANCIEROS

La explicabilidad cumple una función técnica y una función de gobierno de modelos. Técnicamente, permite detectar variables dominantes, discontinuidades, extrapolaciones y errores locales. Profesionalmente, facilita responder por qué una predicción se considera razonable y en qué condiciones no debería confiarse en ella.

SHAP descompone la predicción de un modelo en un valor base y contribuciones por variable:

$$\hat{\sigma}(x) = \phi_0 + \sum_{j=1}^p \phi_j(x), \quad (9)$$

donde ϕ_j mide la contribución atribuida a la característica j [Lundberg and Lee, 2017]. En este proyecto se complementa con ICE, ALE, árboles surrogate, regresión simbólica y vecinos históricos. La razón es que ninguna herramienta por sí sola responde todas las preguntas relevantes: SHAP explica contribuciones, ICE muestra trayectorias individuales, ALE estima efectos acumulados locales, los modelos surrogate dan reglas aproximadas y los vecinos informan sobre soporte local.

La lógica de uso de cada técnica es la siguiente:

- **SHAP:** qué variables empujan una predicción y qué drivers dominan globalmente el modelo.
- **ICE:** cómo cambia la salida del modelo cuando se mueve una variable para una observación concreta.
- **ALE:** qué efecto medio local aparece en zonas observadas, mitigando el impacto de combinaciones contrafactuales poco plausibles.

- **Árboles surrogate y regresión simbólica:** si el comportamiento global del predictor puede resumirse mediante reglas o fórmulas más legibles.
- **Vecinos históricos:** si la observación explicada está respaldada por casos parecidos en la muestra de entrenamiento.

Esta combinación encaja especialmente bien en volatilidad implícita, porque el usuario no sólo pregunta “qué predice el modelo”, sino también “por qué”, “con qué soporte”, “con qué suavidad” y “en qué zona falla”.

2.5 INFRAESTRUCTURA CLOUD Y REPRODUCIBILIDAD

Un modelo útil en un contexto profesional necesita más que un notebook. Debe poder cargarse de forma reproducible, exponer predicciones, separar salidas de entrenamiento y servir explicaciones de manera consistente. Por ello el proyecto separa entrenamiento, construcción de paquetes explicativos, dashboard, API y almacenamiento de modelos. La infraestructura cloud no se incorpora como elemento decorativo, sino para resolver problemas operativos: portabilidad de servicios, centralización de modelos, cache local, despliegue independiente de API y dashboard y trazabilidad de versiones.

En términos operativos, eso implica al menos cinco requisitos.

- Persistir el modelo final junto con sus metadatos y, cuando aplica, su scaler.
- Generar un paquete de dashboard que pueda cargarse sin recalcular explicaciones costosas en cada arranque.
- Mantener desacoplados dashboard y API para poder desplegarlos y versionarlos por separado.
- Permitir backend local y backend GCP sin cambiar la interfaz funcional de las aplicaciones.
- Conservar trazabilidad de configuración, rutas, versiones y recursos de infraestructura.

La reproducibilidad, por tanto, no se limita a “poder volver a entrenar”. También exige poder reconstruir qué versión del modelo respondió una consulta, qué componentes explicativos estaban asociados a esa versión y desde qué almacenamiento se cargaron.

En el contexto del TFM, esa reproducibilidad se apoya en varias capas coordinadas.

- **Capa de entrenamiento:** fija datos, parámetros, semillas y métricas para que el proceso pueda repetirse y compararse.
- **Capa de persistencia:** conserva modelo, scaler, metadatos y paquete explicativo como una unidad coherente.

- **Capa de servicio:** hace que API y dashboard lean exactamente la misma versión del modelo, sin reconstrucciones ad hoc.
- **Capa de infraestructura:** permite mover el sistema entre backend local y GCP manteniendo la misma interfaz funcional.

Sin esa separación, el riesgo no sería sólo operativo. También aparecería un problema metodológico: cualquier conclusión obtenida en la memoria podría dejar de ser reproducible en cuanto la versión desplegada divergiera de la versión analizada. Por eso la infraestructura forma parte del diseño científico del trabajo y no sólo de su empaquetado técnico.

2.6 MÉTRICAS DE ERROR, ESTABILIDAD Y FIDELIDAD

La evaluación de un modelo de volatilidad requiere métricas complementarias. El error absoluto medio,

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (10)$$

ofrece una lectura directa en unidades de volatilidad. Es robusto y fácil de comunicar, pero no penaliza de forma diferencial los errores grandes. Por ese motivo se utiliza también RMSE:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (11)$$

El RMSE es especialmente relevante en model validation porque amplifica errores extremos. En una superficie de volatilidad, esos errores pueden aparecer en vencimientos cortos, extremos de moneyness o zonas con menor liquidez. El coeficiente de determinación,

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (12)$$

resume proporción de variabilidad explicada, aunque debe interpretarse con prudencia en datos financieros heterogéneos.

Junto a estas métricas frente a mercado, el dashboard usa métricas de fidelidad para modelos explicables equivalentes. La fidelidad compara el surrogate con el modelo principal, no con la volatilidad real. Esta distinción es importante: un árbol surrogate puede ser muy fiel a un modelo sesgado, y un modelo principal puede tener buen

RMSE pero ser difícil de resumir con reglas simples. Por tanto, la evaluación final debe combinar tres planos: precisión frente a mercado, estabilidad del proceso de selección y fidelidad de las explicaciones.

Cada métrica responde a una pregunta distinta.

- **MAE:** cuánto se equivoca el modelo en promedio en unidades de volatilidad y con una lectura sencilla.
- **RMSE:** cuánto pesan los errores extremos, especialmente relevantes en extremos de moneyness o vencimientos cortos.
- **R²:** qué fracción de variabilidad consigue explicar el predictor sobre la muestra evaluada.
- **Métricas de fidelidad:** qué parte del comportamiento del modelo principal pueden reproducir los modelos equivalentes.

La memoria insiste en esta separación porque evita un error conceptual habitual: confundir una buena explicación del modelo con una buena explicación del mercado. Un surrogate puede ser útil para entender el predictor y, al mismo tiempo, ser insuficiente para justificar por sí solo la calidad financiera del resultado.

2.7 GOBIERNO DE MODELOS Y PREGUNTAS DE VALIDACIÓN

En un entorno financiero, un modelo de volatilidad debería poder responder a preguntas de model validation. Algunas son cuantitativas: cuál es el error fuera de muestra, si existe gap entre entrenamiento y validación, si el error cambia por vencimiento o moneyness, y si el resultado es estable entre folds. Otras son cualitativas pero igualmente relevantes: si el modelo reacciona de forma razonable ante cambios de strike, si produce superficies suaves donde el mercado debería ser continuo, si una predicción manual se encuentra dentro de una región observada o si el predictor depende excesivamente de una variable que no debería dominar.

El diseño del proyecto convierte esas preguntas en vistas concretas del dashboard. La pestaña de diagnóstico responde dónde falla. La pestaña de superficie responde cómo se comporta como función financiera. La explicabilidad global responde qué variables tienen mayor influencia en las predicciones del modelo. La explicabilidad local responde por qué una muestra concreta obtiene un valor determinado y si existen observaciones históricas cercanas. Esta estructura facilita la defensa ante un tribunal porque alinea cada componente técnico con una pregunta profesional.

En consecuencia, el gobierno del modelo se apoya en una lectura guiada.

- Primero se revisa el **rendimiento agregado:** métricas, dispersión y comportamiento train/validation/test.

- Después se analiza el **rendimiento por tramos de moneyness y vencimiento**: error por moneyness, error por maturity y mapas de residuales.
- A continuación se inspecciona el **comportamiento funcional**: superficies, smiles, term structures, ICE y ALE.
- Finalmente se revisa la **explicación del comportamiento del modelo**: SHAP global, explicabilidad local, vecinos y modelos explicativos equivalentes.

Esta secuencia evita que una única visualización condicione toda la interpretación. En un entorno de derivados, la confianza en una predicción surge de la coherencia entre varias vistas, no de una sola gráfica llamativa o de una única métrica sintética.

METODOLOGÍA

3.1 DISEÑO GENERAL DEL ESTUDIO

El estudio tiene carácter empírico y aplicado. Parte de datos de mercado, construye una variable objetivo financiera mediante inversión de Black-76, entrena modelos de regresión y evalúa tanto rendimiento predictivo como coherencia explicativa. La Figura 2 resume el flujo metodológico.




Figura 2: Flujo metodológico del TFM.

El flujo no es lineal sólo en apariencia. Cada bloque deja salidas persistidas y comprobables que sirven de entrada al siguiente, de modo que la metodología puede auditarse por etapas. Primero se consolida la base financiera; después se fija un espacio de variables coherente con la superficie; a continuación se comparan familias bajo un protocolo temporal común; y, por último, se transforma el modelo seleccionado en un sistema consultable.

Este diseño responde a cuatro principios metodológicos.

- **Separación de responsabilidades:** ETL, modelización, explicabilidad y servicio no se mezclan en un único bloque opaco.
- **Trazabilidad de extremo a extremo:** cada predicción puede rastrearse hasta datos, configuración y versión de modelo.

- **Comparabilidad entre familias:** todas las alternativas compiten bajo las mismas reglas de split, métricas y reentrenamiento.
- **Lectura profesional del resultado:** el producto final no es sólo una tabla de métricas, sino un modelo interpretable y servible.

Esta estructura es importante porque condiciona la credibilidad de los resultados. Si el entrenamiento fuese correcto pero las explicaciones o el servicio no reutilizasen exactamente la misma lógica de features, la calidad del sistema quedaría comprometida aunque las métricas numéricas fueran buenas.

3.2 DATOS Y MUESTRA ANALIZADA

El pipeline de datos transforma ficheros de contratos, operaciones y tipos en una base final de volatilidad implícita. La documentación MkDocs identifica tres fuentes principales: contratos, operaciones y series EONIA/€STR. Los contratos aportan información de código, strike y vencimiento; las operaciones aportan precio, cantidad, hora y contrato; los tipos permiten calcular el tipo compuesto aplicable hasta vencimiento.

En el cálculo de tipos se asume una aproximación operativa: no se dispone de un calendario TARGET2 explícito dentro del pipeline, por lo que el conteo de días hábiles se implementa con `pd.bdate_range` (días laborables estándar). La composición se aplica exactamente como en el código: se recorre cada día hábil del intervalo, se toma r_i (retrocediendo al último dato disponible si ese día no existe en la serie) y se multiplica $1 + r_i n_i / 360$, con $n_i = 3$ cuando el día hábil es lunes y $n_i = 1$ en el resto. Después se anualiza como $(\prod_i (1 + r_i n_i / 360) - 1) \cdot 360 / d_c$.

La guía de referencia para la lógica de tipos compuestos es la del BCE para €STR: https://www.ecb.europa.eu/stats/euro-short-term-rates/interest_rate_benchmarks/WG_euro_risk-free_rates/shared/pdf/ecb.Compounded_euro_short-term_rate_calculation_rules.en.pdf. En esta memoria se documenta de forma explícita que la implementación actual reproduce la convención descrita en el código (incluido el peso 3 en lunes) y debe interpretarse como aproximación operativa mientras no se incorpore un calendario TARGET2 completo en la construcción de Rate.

La cadena ETL se materializa por pasos, como muestran las Figuras 4 y 5. Esta organización permite cachear salidas intermedias, validar contratos de datos y aislar responsabilidades: los *StepLoaders* orquestan lectura, cache y validación, mientras que los *builders* construyen la salida material de cada paso.

La Figura 3 resume esta separación entre clases *loader* y clases *builder*. El detalle extenso de las estructuras de datos que va produciendo cada etapa se recoge además

en el [chapter A](#), para no sobrecargar el cuerpo principal con un diagrama demasiado largo.




Figura 3: Esquema de responsabilidades entre *loaders* y *builders* en el ETL.

Los datos se filtran al dominio de opciones IBEX mensuales y futuros mensuales asociados. Las opciones semanales y contratos fuera de dominio se excluyen para mantener coherencia contractual. La salida final contiene fecha y hora de ejecución, código de opción, tipo call/put, precio negociado, strike, futuro subyacente, precio del subyacente, desfase temporal opción-subyacente (minutos), tiempo a vencimiento, tipo compuesto y volatilidad implícita.

El primer paso, Read Raw Step, normaliza ficheros de mercado con o sin cabecera, elimina columnas auxiliares no pertenecientes al esquema final, convierte fechas, horas y numéricos, filtra prefijos IBEX y construye una serie homogénea de tipos. La base de tipos combina EONIA ajustado por el spread configurado antes de la fecha de corte y €STR desde esa fecha.

El segundo paso, Merge Raw Step, une operaciones y contratos por ContractCode y año de sesión, imputa vencimientos con la regla del tercer viernes e imputa strikes desde el tramo configurado del código cuando la fuente no lo trae completo.

Las Figuras [6](#), [7](#), [8](#) y [9](#) resumen visualmente esta fase inicial de normalización y consolidación.

El tercer paso, Product Split Step, divide la base unificada en opciones, futuros y relación opción-futuro por vencimiento. El cuarto, Underlying Step, resuelve el precio de futuro subyacente mediante una unión temporal *as-of*: para cada opción selecciona el último trade del futuro con instante de ejecución menor o igual al de la




Figura 4: Secuencia principal de procesamiento de datos.




Figura 5: Pipeline completo de datos hasta VOLATILITY_DB.

opción. Esta decisión evita lookahead dentro del propio ETL. El quinto, Volatility Step, filtra operaciones sin subyacente fiable o con desfase temporal excesivo, calcula el tipo compuesto hasta vencimiento y resuelve la volatilidad implícita por Black-76 inverso.

En este último paso se aplican reglas de calidad relevantes para evitar sesgos en entrenamiento: se excluyen filas sin subyacente válido, filas con desfase opción-subyacente superior al umbral configurado de 180 minutos, y filas cuya volatilidad implícita no puede resolverse de forma válida (por ejemplo, sin cambio de signo del solver o con soluciones no finitas). Estas decisiones son coherentes con el análisis exploratorio y con las validaciones financieras del pipeline.

La justificación empírica de estos filtros se apoya en el análisis exploratorio documentado en `EDA.ipynb`. También conviene explicitar que los descartes se distribuyen a lo largo de varios pasos: Read Raw Step y Merge Raw Step limpian incoherencias de esquema y dominio; Underlying Step garantiza el emparejamiento temporal sin lookahead y construye el desfase opción-subyacente; y Volatility Step aplica los filtros finales de calidad financiera (incluido el umbral de 180 minutos y la resolubilidad del solver).

Las Figuras 10, 11, 12, 13, 14 y 15 muestran esta segunda fase de separación por producto, asignación del subyacente y cálculo de la volatilidad implícita.




Figura 6: Lectura y normalización de datos fuente.




Figura 7: Construcción de la base homogénea de tipos.




Figura 8: Unión de operaciones con información contractual.




Figura 9: Unión por código de contrato y año de sesión.

3.3 VALIDACIONES Y TRATAMIENTO FINANCIERO

El ETL aplica validaciones transversales: precios positivos, cantidades positivas, ausencia de claves duplicadas, control de missing values, vencimientos coherentes, strikes compatibles con el código de contrato y subyacente temporalmente anterior a la operación de la opción. Esta última condición es crítica para evitar utilizar información futura.

Para evitar ambigüedades, en esta memoria se distinguen dos conceptos de lag: el desfase opción-subyacente del ETL (en minutos) y el lag temporal del split de entrenamiento (en número de fechas) usado más adelante en la validación de modelos.




Figura 10: Separación de operaciones por producto.




Figura 11: Relación opción-futuro por vencimiento.




Figura 12: Asignación de futuro subyacente a cada opción.

El cálculo de volatilidad implícita se realiza en el último paso. Se eliminan operaciones sin subyacente fiable, se calcula el tipo compuesto hasta vencimiento y se resuelve la ecuación (4). Si no existe cambio de signo en el intervalo de búsqueda o la solución es no finita, la observación se marca como no resoluble y no alimenta el entrenamiento. La Figura 16 resume estas validaciones sobre el contrato y su interpretación.

3.4 VARIABLES Y FEATURE ENGINEERING

Las entradas raw visibles son `OptionType`, `StrikePrice`, `UnderlyingPrice`, `TimeToExpiration` y `Rate`. Estas variables son suficientes para reconstruir el vector de entrenamiento y también son comprensibles para un usuario financiero que consulte la API.




Figura 13: Selección temporal as-of del subyacente.

No se aplica una fase de selección de variables ex post (ni filtros automáticos de descarte por importancia) porque el foco metodológico es simular una operación directa con un conjunto de entradas financieras estable, reproducible y utilizable tal cual en API/dashboard. La comparación entre familias se hace, por diseño, sobre el mismo espacio de variables para aislar el efecto de la arquitectura y no de una poda específica de features.

El vector transformado se diseña para representar la geometría de la superficie. La Tabla 1 resume las variables derivadas.

Feature	Fórmula	Motivo
TTEYears	$T = T_{\text{días}}/365$	Vencimiento en años
sqrtTTEYears	$\sqrt{T}$	Escala temporal de Black-76
logMoneyness	$\log(F/K)$	Posición relativa frente al strike
logMoneynessSq	$\log(F/K)^2$	Curvatura del smile
logMoneynessXSqrtTTE	$\log(F/K)\sqrt{T}$	Interacción smile-vencimiento
logForwardMoneyness	$\log(Fe^{rT}/K)$	Ajuste por tipo y vencimiento
rate	r	Sensibilidad directa a tipos
isCall, isPut	Indicadores	Tipo de opción

Cuadro 1: Features financieras utilizadas por los modelos.

Esta elección evita que el modelo dependa de niveles absolutos de strike que pueden cambiar con el régimen de mercado. La moneyness permite comparar contratos negociados en momentos distintos del IBEX, mientras que el vencimiento y sus trans-




Figura 14: Calculo de volatilidad implicita.




Figura 15: Solver por biseccion de la volatilidad implicita.




Figura 16: Validacion e interpretacion del codigo de contrato.

formaciones capturan estructura temporal. Las Figuras 17 y 18 muestran la construcción y motivación financiera de estas variables.

3.5 FAMILIAS DE MODELOS

El repositorio implementa una abstracción común para familias de modelos. Cada familia declara nombre, parámetros fijos, espacio de búsqueda, instanciación, entrenamiento y persistencia. La Tabla 2 resume su papel en el estudio.

Todas las familias heredan una interfaz común: declaran parámetros fijos, espacio de búsqueda, instanciación, entrenamiento, persistencia y número de configuraciones exploradas. Esta homogeneidad permite comparar un baseline lineal, modelos de árboles, boosting y arquitecturas neuronales con el mismo protocolo de selección. En la familia Quantum Inspired, el cálculo sigue siendo clásico: las features se proyectan a un embedding, se reordenan como tensor y se contraen mediante una capa tensor-




Figura 17: Construcción de features financieros.




Figura 18: Motivación financiera de las features.

Familia	Papel metodológico
Regresión lineal	Baseline interpretable para evaluar cuánto aporta la no linealidad.
Random Forest	Modelo tabular robusto ante interacciones y no linealidades sin escalado.
XGBoost	Boosting regularizado con early stopping interno y alta capacidad predictiva.
Red neuronal secuencial	Aproximador flexible con escalado de variables numéricas y early stopping sobre validación interna.
Quantum Inspired NN	Variante clásica de red neuronal con estructura tensorial inspirada en ideas cuánticas; se evalúa como arquitectura implementada, no como computación cuántica física.

Cuadro 2: Familias de modelos entrenadas en el proyecto.

train antes de una capa densa final. El concepto y su implementación práctica se detallan en el [chapter F](#).

La elección de familias responde a una lógica comparativa y no decorativa.

- La **regresión lineal** fija una referencia interpretable y permite medir cuánto valor añade la no linealidad una vez creadas las features correctas.
- **Random Forest** y **XGBoost** representan dos formas distintas de explotar interacciones tabulares complejas sin exigir el mismo tipo de preprocesado que las redes.
- Las **redes neuronales** sirven para comprobar si una arquitectura más flexible mejora realmente el problema o sólo incrementa el coste y la complejidad de explicación.
- La variante **Quantum Inspired** introduce una hipótesis arquitectónica diferenciada manteniendo computación clásica, lo que permite valorar su aportación real frente a alternativas más estándar.

La interfaz común del repositorio hace además que la comparación sea metodológicamente limpia. Todas las familias pasan por los mismos splits temporales, las mismas métricas y el mismo proceso de reentrenamiento y conversión a paquete de dashboard. Eso evita que una familia “gane” por haber sido evaluada con un protocolo distinto del resto. Las Figuras 19, 20 y 21 muestran la abstracción común, el protocolo de selección y la arquitectura Quantum Inspired.




Figura 19: Abstracción común de familias de modelos.




Figura 20: Selección de modelos mediante k-folds temporales.




Figura 21: Arquitectura Quantum Inspired clásica basada en tensor-train.

3.6 SPLITS TEMPORALES Y SELECCIÓN

La validación sigue tres principios. Primero, el orden temporal se respeta: train precede a validation y test. Segundo, puede existir un lag de fechas entre bloques para reducir contaminación temporal. Tercero, se controla la exclusividad de contratos: si el mismo contrato aparece en más de un split, se conserva en un único bloque según volumetría y prioridad.

Esta regla es relevante porque una opción puede negociarse durante varios días. Si un contrato aparece en entrenamiento y validación, el modelo podría aprender rasgos idiosincráticos del contrato y ofrecer una estimación optimista. Las Figuras 22, 23, 24, 25 y 26 resumen la lógica temporal, la separación con lag y el control de contratos compartidos.




Figura 22: Flujo de modelización de volatilidad.




Figura 23: Control temporal y exclusividad de contratos.

La búsqueda de hiperparámetros se realiza con k-folds temporales. Estos k-folds se construyen exclusivamente dentro del bloque de entrenamiento, de modo que validation y test externos quedan fuera del proceso de búsqueda. Para cada candidato se calculan MAE, RMSE y R^2 en train y validation. La selección usa una métrica compuesta:

En XGBoost y en redes neuronales, además, se usa un split interno temporal de train para early stopping. Este mecanismo regula el entrenamiento dentro de cada candidato, pero no reemplaza la validación temporal externa ni la evaluación final en test.

$$CE_1 = RMSE_{val} + \alpha \cdot std(RMSE_{val}) + \beta \cdot \max(0, RMSE_{val} - RMSE_{train}). \quad (13)$$

Esta métrica penaliza error de validación, inestabilidad entre folds y gap de sobreajuste. Según la configuración del repositorio, $\alpha = 0,25$ y $\beta = 0,75$. Las Figuras 27 y 28 resumen la búsqueda de hiperparámetros y el early stopping interno.

3.7 REENTRENAMIENTO Y PROGRESSIVE ATM

Después de seleccionar hiperparámetros, el modelo se reentrena en dos fases: train/validation y final test. En la fase final se ajusta con trainval y se evalúa contra test. La métrica de reentrenamiento incorpora el rendimiento observado en selección:




Figura 24: Esquema conceptual de particiones temporales.




Figura 25: Control de contratos compartidos entre splits.




Figura 26: Construcción de k-folds temporales.

$$CE_2 = RMSE_{val} + \gamma \cdot CE_1 + \beta \cdot \max(0, RMSE_{val} - RMSE_{train}), \quad (14)$$

con $\gamma = 0,25$ y $\beta = 0,75$ en la configuración actual.

Es importante precisar que CE_2 se utiliza para monitorizar consistencia en la fase train/validation. La evaluación definitiva de generalización del modelo se realiza siempre sobre el bloque test fuera de muestra.

El proyecto incluye una variante progressive ATM. Ordena observaciones por $|\log(F/K)|$, de más cercano al ATM a más alejado, y divide el entrenamiento en segmentos. La idea financiera es aprender primero la zona central, habitualmente más líquida y estable, y después incorporar zonas más alejadas. En modelos no iterativos se implementa mediante pesos; en XGBoost y redes se implementa mediante fases acumulativas. Por su carácter experimental, esta variante se menciona aquí y




Figura 27: Búsqueda de hiperparámetros por familia.



Figura 28: Early stopping con validación interna.

se desarrolla en el [chapter H](#). Las Figuras 29 y 30 muestran el reentrenamiento del mejor candidato y los segmentos ATM.

3.8 CONSTRUCCIÓN DEL DASHBOARD

El dashboard no entrena modelos. Consume paquetes autocontenidos generados desde modelos finales. Cada paquete contiene dataset con predicciones, residuales y error absoluto, muestras para explicabilidad local, puntos de referencia de superficies, SHAP global y local, árboles surrogate, regresor simbólico, vecinos, superficies, ICE, ALE y diagnóstico agregado.

La transformación de un modelo final a este paquete no modifica el predictor: carga el runtime, aplica el mismo feature engineering sobre train y test, calcula artefactos explicativos y persiste una carpeta autocontenida en `src/dashboard/saved_models/`.

La aplicación se estructura en cuatro pestañas, resumidas en la Tabla 3. Esta organización responde a preguntas distintas y evita confundir error predictivo con explicación.

En particular, la lectura SHAP se divide en dos niveles complementarios: **SHAP global** en la pestaña *Global Explainability* (drivers y patrones agregados) y **SHAP local** en la pestaña *Sample Explainability*, donde se muestra el *Local SHAP Waterfall* para justificar una predicción concreta.




Figura 29: Reentrenamiento del mejor candidato.



Figura 30: Entrenamiento progresivo ATM por segmentos.

Las Figuras 31, 32 y 33 muestran las entradas precomputadas, la arquitectura del dashboard y la conversión del modelo final a paquete visualizable.

Las vistas del dashboard son necesarias para localizar dónde aparece esa comprensión. El scatter *predicted vs actual* debe confirmar si los extremos altos y bajos se acercan a la media; el residual heatmap debe separar error por moneyiness y vencimiento; y las cajas *Error by Moneyiness* y *Error by Maturity* deben indicar si los extremos de moneyiness o los vencimientos cortos concentran el fallo. Las Figuras 34, 35, 36, 37 y 38 muestran estos flujos y vistas; en particular, la vista local de *Sample Explainability* es la puerta de entrada al *Local SHAP Waterfall* y al contexto de vecinos históricos.

Pestaña	Pregunta principal
Behaviour And Surface	¿Cómo responde el modelo ante cambios de moneyiness, vencimiento y otras variables financieras?
Global Explainability	¿Qué variables y patrones dominan las predicciones globales?
Sample Explainability	¿Por qué una muestra concreta recibe esa volatilidad y tiene soporte histórico?
Diagnosis	¿Dónde acierta y dónde falla el modelo en la superficie?

Cuadro 3: Pestañas del dashboard y función analítica.




Figura 31: Entradas precomputadas consumidas por el dashboard.




Figura 32: Arquitectura de servicios del dashboard.

3.9 API, ALMACENAMIENTO Y CLOUD

La API se implementa con FastAPI como un servicio *ad hoc* independiente del dashboard. Puede servir cualquier modelo preparado bajo este flujo de entrenamiento, sin depender de la capa visual. El código expone endpoints de salud, predicción y explicabilidad local:

- `/health`
- `/run_model/predict/`
- `/run_model/sample_explainability/`

La petición incluye modelo, tipo de opción, strike, subyacente, tiempo a vencimiento, tipo de interés y, opcionalmente, código de contrato y volatilidad real.

La respuesta de predicción incluye el modelo, la volatilidad estimada y la entrada normalizada. La respuesta de explicabilidad local añade waterfall SHAP, payload de contribuciones, vecinos históricos y distancias. API y dashboard comparten modelos y paquetes autocontenidos de dashboard, lo que reduce el riesgo de explicar una versión distinta de la usada para predecir.

El backend de almacenamiento puede ser local o GCP. En GCP se usan Cloud Storage para modelos y paquetes de dashboard, Artifact Registry para imágenes de contenedor, Cloud Run para API y dashboard, e IAM para permisos. Terraform define los recursos y permite reproducir la infraestructura. La parte crítica es mantener sincronizados modelo, scaler, metadatos y paquete explicativo; por eso el reentrenamiento




Figura 33: Conversion de modelo final a paquete visualizable.




Figura 34: Flujo de la pestana Behaviour And Surface.

miento final dispara su construcción después de guardar el modelo. La Figura 39 resume este esquema de despliegue.

Metodológicamente, esta capa cumple tres funciones.

- **Función de servicio:** exponer predicción y explicabilidad local con la misma interfaz de entrada que utiliza la interfaz visual.
- **Función de consistencia:** asegurar que dashboard y API cargan exactamente el mismo modelo y el mismo paquete explicativo.
- **Función de despliegue:** separar imágenes, dependencias y escalado de API y dashboard para que cada servicio pueda evolucionar de forma independiente.

Esta separación se observa también en `src/api` y `src/dashboard`: la API concentra endpoints HTTP, mientras que el dashboard concentra composición visual, servicios




Figura 35: Vistas de diagnostico del modelo final.




Figura 36: Flujo de la pestaña Global Explainability.




Figura 37: Flujo de la pestaña Sample Explainability.

y callbacks. Ambas piezas reutilizan almacenamiento y configuración comunes, lo que facilita auditoría y versionado.

El recorrido operativo de una consulta ayuda a entender mejor esta capa.

1. La aplicación cliente envía variables financieras visibles y, si existe, información contextual adicional como contrato o volatilidad observada.
2. La API valida el payload, reconstruye internamente las features transformadas y ejecuta el runtime del modelo seleccionado.
3. Si se pide explicabilidad local, la misma petición desencadena cálculo de contribuciones, recuperación de vecinos y empaquetado de la respuesta interpretativa.
4. Dashboard y API leen los mismos recursos persistidos, por lo que la diferencia entre ambos canales está en la presentación y no en la lógica del modelo.

Esta última idea es especialmente importante. La memoria no presenta dos sistemas paralelos, uno visual y otro programático, sino dos interfaces sobre la misma base modelística y explicativa. Eso reduce riesgo de inconsistencia y hace más defendible el uso profesional del conjunto.

La Figura 39 también deja explícita la separación entre almacenamiento, artefactos de modelo y servicios desplegados.




Figura 38: Construcción de superficies locales de volatilidad.

3.10 REPRODUCIBILIDAD Y TRAZABILIDAD

La reproducibilidad se apoya en cuatro mecanismos: configuración de entrenamiento y datos, enums de esquemas, salidas persistidas y tests. La configuración define columnas, splits temporales, lag entre bloques, métricas de selección, progressive training y parámetros de generación de explicaciones (muestras SHAP, vecinos y superficies). Los enums centralizan nombres de columnas y tipos de dominio. Las salidas persistidas guardan modelo, scaler cuando aplica, metadatos y paquete de dashboard. Los tests cubren utilidades de datos, modelos, dashboard, API y configuración.

Además, el desarrollo no se ha tratado como una secuencia aislada de notebooks, sino como un proyecto software versionado. El repositorio se ha trabajado en Git sobre GitHub, con ramas temáticas para funcionalidades y documentación, commits incrementales, sincronización remota mediante pull/push e integración posterior sobre ramas compartidas. Este marco permite discutir cada cambio con contexto técnico, aislar regresiones y mantener trazabilidad entre implementación, validación y versión desplegable. El [chapter B](#) recoge esta dimensión metodológica con más detalle.

Esa trazabilidad no es abstracta; está fijada en parámetros concretos.

- El split temporal usa `train_size=0.85` y `lag=15` (en fechas), con cinco folds temporales y penalizaciones CE_1/CE_2 para selección y reentrenamiento.
- El alcance de los artefactos explicativos se fija con `shap_background_size=24`, `shap_explain_size=48`, `neighbors_k=200` y `surface_grid_size=24`.
- La reconstrucción de features se centraliza para que entrenamiento, dashboard y API compartan exactamente la misma transformación.




Figura 39: Arquitectura cloud del sistema: almacenamiento, artefactos y servicios de API/dashboard.

- Los artefactos explicativos (muestras SHAP, puntos de referencia, vecinos, superficies, ICE y ALE) se generan con semilla controlada para conservar comparabilidad entre ejecuciones.

La consecuencia es clara: si cambia un schema, una ruta o una transformación, el cambio queda aislado y visible. Eso reduce el riesgo de inconsistencias no evidentes entre el modelo analizado y el modelo efectivamente servido. Las Figuras 40 y 41 muestran la configuración centralizada y los modos de carga local o GCP.




Figura 40: Configuración centralizada del proyecto.




Figura 41: Carga local o GCP desde configuración cliente-servidor.

3.11 ARQUITECTURA DEL REPOSITORIO

La arquitectura del repositorio sigue una separación por funcionalidades. Esta decisión es relevante para reproducibilidad y defensa técnica: cada paquete tiene un cometido identificable y las salidas persistidas pasan de una etapa a otra sin mezclar entrenamiento, explicación y servicio. Las Figuras 42, 43, 44 y 45 muestran la estructura lógica, la secuencia de ejecución, la cadena de salidas y las dependencias entre paquetes.

Paquete o carpeta	Responsabilidad principal
src/config	Carga de configuración, rutas absolutas, logging y objetos de configuración por dominio.
src/enums	Definición centralizada de columnas, tipos de contrato, tipos de opción y nombres de modelos.
src/exceptions	Excepciones de dominio usadas en validaciones de datos y control de errores del ETL.
src/data_management	ETL de datos: loaders, builders, validaciones y utilidades de contrato.
src/volatility_models	Preparación de datos de entrenamiento, splits, k-folds, selección y reentrenamiento.
src/python_models	Abstracciones de familias de modelos y estructuras persistentes de dashboard.
src/model2dashboard	Conversión de modelos finales en paquetes explicativos autocontenidos.
src/dashboard	Aplicación Dash, servicios, callbacks, gráficos y utilidades de validación.
src/api	API FastAPI para predicción y explicabilidad local.
resources	Configuración declarativa (datos, modelos y cliente-servidor) consumida por el runtime.
dockerfiles	Definiciones de imagen para API, dashboard, LaTeX y utilidades de documentación.
scripts	Automatizaciones auxiliares de soporte operativo y generación de artefactos.
terraform	Infraestructura cloud reproducible: buckets, registro de imágenes, Cloud Run e IAM.

Cuadro 4: Arquitectura lógica del repositorio.




Figura 42: Estructura lógica del repositorio.




Figura 43: Secuencia de ejecución entre paquetes.

La Tabla 4 muestra que el dashboard no reentrena modelos y la API no reconstruye explicaciones desde cero salvo en casos de explicabilidad local manual. Esta separación reduce el acoplamiento y facilita detectar errores. Si una predicción de API no coincide con la vista del dashboard, el problema puede acotarse a carga del paquete autocontenido, transformación de features o versión de modelo.

Vista así, la arquitectura no es sólo una organización de carpetas. Es una forma de aislar responsabilidades, simplificar depuración y poder justificar cada paso del flujo de principio a fin.

Desde esa misma lógica, la arquitectura se apoya en un flujo de trabajo de ingeniería más próximo al de un proyecto real que al de un experimento ad hoc: ramas de trabajo, commits trazables, validaciones antes de integrar y control explícito de cambios sobre código, configuración, documentación y despliegue.

3.12 PLAN DE VALIDACIÓN FUNCIONAL

Además de la validación estadística, el proyecto requiere validación funcional. El sistema debe demostrar que los modelos y paquetes de dashboard se cargan, que las



Figura 44: Cadena de salidas persistidas del proyecto.




Figura 45: Dependencias principales entre paquetes de src.

features se reconstruyen de forma consistente y que las explicaciones corresponden al modelo seleccionado. La validación funcional se organiza en cuatro niveles:

1. Validación de datos: esquemas, tipos, claves, precios, cantidades, vencimientos, strikes y subyacente temporalmente anterior.
2. Validación de entrenamiento: splits temporales, exclusividad de contratos, métricas por fold, selección de hiperparámetros y persistencia de metadatos.
3. Validación del paquete autocontenido: correspondencia entre modelo, scaler, predicciones, residuos, SHAP, vecinos, superficies y modelos surrogate.
4. Validación de servicio: endpoints de salud, predicción, explicabilidad local, carga desde backend local o GCP y coherencia con dashboard.

Este plan no sustituye la revisión de resultados, pero evita que la memoria dependa únicamente de tablas finales. Un modelo con buen RMSE no sería aceptable si los componentes explicativos no correspondieran a ese mismo modelo o si la API reconstruyera las features con una transformación distinta.

La evidencia de esta validación aparece en dos formas complementarias.

- **Automática**, mediante tests sobre configuración, utilidades de datos, runtime de modelos, API, plots y servicios del dashboard.
- **Manual guiada**, mediante contraste entre vistas del dashboard, comparación API-dashboard y revisión de muestras representativas con explicabilidad local.

La primera detecta errores de contrato o serialización. La segunda detecta incoherencias funcionales que sólo aparecen al leer el modelo como superficie financiera y como sistema de consulta real.

3.13 RIESGOS METODOLÓGICOS Y CONTROLES

Los principales riesgos metodológicos se anticipan desde el diseño. El primero es el lookahead bias, controlado mediante orden temporal y subyacentes anteriores a la opción. El segundo es data snooping, mitigado separando búsqueda de hiperparámetros, reentrenamiento y evaluación final. El tercero es memorización de contratos, tratado con exclusividad de contratos entre splits. El cuarto es extrapolación en zonas poco cubiertas, diagnosticada con vecinos históricos y heatmaps de error. El quinto es confundir explicabilidad del modelo con verdad de mercado; por ello los surrogates se presentan con métricas de fidelidad y los resultados se contrastan frente a residuales y superficies.

La Tabla 5 resume esta lógica.

Riesgo	Control aplicado
Uso de información futura	Orden temporal, lag y subyacente anterior a la operación de opción.
Selección oportunista	K-folds temporales y métricas compuestas CE_1 y CE_2 .
Memorización de contrato	Asignación de contratos compartidos a un único split.
Extrapolación local	Vecinos históricos, distancias y mapas PCA locales.
Explicaciones engañosas	SHAP, ICE/ALE, surrogates y diagnóstico usados de forma complementaria.
Inconsistencia operativa	Paquete autocontenido con modelo, metadatos, scalar y explicaciones.

Cuadro 5: Riesgos metodológicos y controles implementados.

Leída en conjunto, la tabla resume una idea central del trabajo: cada riesgo importante tiene un control técnico explícito y una evidencia asociada en el dashboard, la API o los metadatos persistidos. Esa correspondencia entre riesgo, control y comprobación es lo que hace defendible la metodología más allá de la métrica final.

RESULTADOS Y DISCUSIÓN

El entrenamiento final deja un resultado principal: el mejor equilibrio fuera de muestra corresponde a Random Forest con entrenamiento estándar. En el conjunto de test obtiene $RMSE = 0,088403$, $MAE = 0,054366$ y $R^2 = 0,790941$. La lectura de resultados se organiza en tres planos: rendimiento predictivo, impacto del entrenamiento progressive ATM y capacidad de explicación del modelo final mediante dashboard.

4.1 RESULTADOS

4.1.1 Comparativa general de modelos

Modelo	Entrenamiento	MAE test	RMSE test	R^2 test	CE ₂
Regresión lineal	estándar	0.067585	0.183824	0.096059	0.133738
Regresión lineal	progressive ATM	0.070544	0.187747	0.057069	0.132802
Random Forest	estándar	0.054366	0.088403	0.790941	0.089361
Random Forest	progressive ATM	0.054337	0.088533	0.790326	0.091597
XGBoost	estándar	0.054604	0.091735	0.774885	0.086826
XGBoost	progressive ATM	0.057295	0.113606	0.654747	0.093189
Red neuronal secuencial	estándar	0.055425	0.113506	0.655354	0.090209
Red neuronal secuencial	progressive ATM	0.055634	0.120161	0.613754	0.096304
Quantum Inspired NN	estándar	0.056056	0.143025	0.452787	0.089332
Quantum Inspired NN	progressive ATM	0.055597	0.117404	0.631276	0.100256

Cuadro 6: Comparación final de modelos en test y métrica compuesta de reentrenamiento train/validation.

La Tabla 6 muestra que las familias de árboles dominan el test. Random Forest estándar obtiene el menor RMSE y el mayor R^2 ; XGBoost estándar queda cerca, pero con RMSE ligeramente superior. Las redes neuronales no superan a las familias de árboles en esta muestra, aunque la variante Quantum Inspired mejora claramente al aplicar progressive ATM frente a su versión estándar.

La comparación deja tres mensajes claros.

- El problema parece premiar modelos tabulares capaces de capturar interacciones no lineales sin requerir un ajuste tan delicado como el de las redes.
- La diferencia entre Random Forest y XGBoost es pequeña en valor absoluto, pero suficiente para inclinar la selección final hacia el bosque.
- Las arquitecturas más complejas no aportan automáticamente mejor generalización, lo que refuerza la necesidad de validar fuera de muestra y no por intuición tecnológica.

Por tanto, el resultado agregado ya sugiere una lectura metodológica útil: en esta base de volatilidad implícita, la ventaja no proviene de la familia más sofisticada en abstracto, sino de la que mejor equilibra flexibilidad, robustez y estabilidad temporal.

4.1.2 Entrenamiento estándar frente a progressive ATM

Familia	RMSE base	RMSE prog.	Δ	Lectura
Regresión lineal	0.183824	0.187747	+0.003923	Empeora levemente.
Random Forest	0.088403	0.088533	+0.000130	Prácticamente neutro.
XGBoost	0.091735	0.113606	+0.021871	Degrada test.
Red neuronal secuencial	0.113506	0.120161	+0.006655	Degrada test.
Quantum Inspired NN	0.143025	0.117404	-0.025621	Mejora clara.

Cuadro 7: Impacto agregado de progressive ATM frente a entrenamiento estándar.

El entrenamiento progressive ATM no produce una mejora universal. En Random Forest, que ya es el mejor modelo, el cambio es casi neutro; en XGBoost y en la red secuencial empeora el RMSE test; en Quantum Inspired sí actúa como regularizador útil. Esto encaja con la interpretación metodológica: ordenar por cercanía a ATM puede estabilizar arquitecturas iterativas más sensibles, pero también puede sesgar el aprendizaje si los extremos de moneyness contienen información necesaria para test. Por tanto, progressive ATM debe tratarse como variante experimental y no como decisión automática.

La evidencia sugiere una lectura por familias.

- En **Random Forest**, la proximidad de resultados indica que el bosque ya capta bien la señal central sin necesitar currículum de entrenamiento.
- En **XGBoost** y en la **red secuencial**, el deterioro sugiere que priorizar ATM puede dejar peor representadas zonas relevantes para la generalización final.

- En **Quantum Inspired**, la mejora apunta a que la estrategia sí puede actuar como regularizador estructural cuando la arquitectura es más sensible al orden de aprendizaje.

La conclusión práctica es sobria: progressive ATM es útil como hipótesis de trabajo y como herramienta de análisis, pero su activación debe justificarse por evidencia empírica en cada familia concreta.

4.1.3 Selección del modelo final

Elemento	Valor final
Modelo seleccionado	Random Forest
Estrategia de entrenamiento	Estándar, sin progressive ATM
Ruta del modelo	src/volatility_models/ trained_models/random_forest.joblib
Hiperparámetros principales	500 árboles, profundidad máxima 8, min_samples_leaf=10, max_features=0.5, max_samples=0.6
RMSE test	0.088403
MAE test	0.054366
R^2 test	0.790941
Argumento principal de selección	Menor RMSE test y mejor R^2 , con diferencia pequeña pero consistente frente a XGBoost.
Riesgo principal detectado	Predicciones menos dispersas que la volatilidad real: $\sigma_{\hat{y},test} = 0,149458$ frente a $\sigma_{y,test} = 0,193345$.

Cuadro 8: Ficha del modelo final seleccionado.

La decisión no se basa solo en el mínimo RMSE. Random Forest también conserva buena capacidad de generalización en train/validation: $RMSE_{train} = 0,071027$, $RMSE_{val} = 0,071080$ y $R^2_{val} = 0,653348$. XGBoost tiene el CE_2 más bajo en train/validation, pero su test queda por detrás. La elección final prioriza rendimiento fuera de muestra, estabilidad razonable y menor degradación al pasar de validación a test.

La selección final combina criterios cuantitativos y operativos.

- **Criterio cuantitativo principal:** mejor RMSE test entre todas las alternativas evaluadas.
- **Criterio de estabilidad:** gap contenido entre entrenamiento, validación y test, sin señales fuertes de sobreajuste.

- **Criterio operativo:** buen encaje con las herramientas de diagnóstico, explicabilidad y servicio generadas para el paquete final.

Con ello, la elección deja de ser una simple foto de leaderboard. El Random Forest final es el candidato que mejor soporta la transición desde el entrenamiento hasta el uso interpretado en dashboard y API.

4.1.4 Diagnóstico de rendimiento

El diagnóstico debe interpretarse a partir del test. La desviación estándar de la volatilidad real es 0.193345 y la de las predicciones de Random Forest es 0.149458. Esta diferencia indica compresión parcial de la variabilidad: el modelo captura la estructura general, pero tiende a suavizar extremos. La desviación estándar residual es 0.085859, coherente con un RMSE de 0.088403.



Figura 46: Comparativa de la pestaña *Diagnosis* en los dos finalistas: Random Forest (modelo seleccionado) y XGBoost.

Las vistas del dashboard son necesarias para localizar dónde aparece esa compresión. El scatter *predicted vs actual* debe confirmar si los extremos altos y bajos se acercan a la media; el residual heatmap debe separar error por moneyness y vencimiento; y las cajas *Error by Moneyness* y *Error by Maturity* deben indicar si los extremos de moneyness o los vencimientos cortos concentran el fallo. La conclusión accionable es que el modelo es competitivo agregadamente, pero su uso debe acompañarse de diagnóstico por zonas de la superficie cuando se consulten contratos poco líquidos o alejados de ATM.

La Figura 46 confirma lo anterior y permite además una lectura transversal de todas las capturas de diagnóstico: Random Forest y XGBoost concentran los mejores indicadores (RMSE 0,0884 y 0,0917, respectivamente), mientras que Sequential NN (0,1135), Quantum Inspired (0,1430) y, sobre todo, la regresión lineal (0,1838) muestran mayor pérdida de ajuste global. En paralelo, los *Financial Warnings* son in-

formativos: la regresión lineal no dispara alertas de discontinuidad local, pero lo hace a costa de mayor error agregado; en cambio, los modelos más expresivos mejoran ajuste pero pueden introducir saltos locales en smile o term-structure, especialmente en muestras no centrales.

En la práctica, el diagnóstico debe responder tres preguntas consecutivas.

- Si el error está repartido de forma homogénea o se concentra en zonas concretas de la superficie.
- Si la dispersión de predicciones es suficiente o si el modelo tiende a comprimir sistemáticamente los extremos.
- Si los fallos observados son compatibles con escasez de datos, con dificultades intrínsecas del problema o con una arquitectura demasiado rígida.

Este nivel de detalle es necesario porque dos modelos con RMSE parecido pueden implicar riesgos operativos muy distintos. Uno puede fallar de forma estable y moderada; otro puede acertar el promedio pero perder control justo en las zonas más delicadas para valoración o revisión manual.

4.1.4.1 *Análisis del impacto del entrenamiento Progressive ATM*

El proyecto incluyó una variante experimental denominada Progressive ATM (o *Entrenamiento Progresivo Ordenado por ATM*): un enfoque de currículum de aprendizaje que reordena cronológicamente el entrenamiento para presentar primero observaciones cercanas al ATM (moneyness bajo, $|\log(F/K)| < 0,05$), donde concentra la máxima liquidez y menor ruido, para después incorporar progresivamente observaciones hacia extremos de moneyness y vencimientos cortos. La motivación financiera es doble: (1) la zona ATM en opciones sobre índices suele ser la más líquida y menos afectada por sesgos de selección; (2) entrenar primero en datos menos ruidosos podría regularizar arquitecturas sensibles al orden de presentación, como redes neuronales secuenciales y modelos cuánticos inspirados.

Metodología de evaluación. Se reentrenaron independientemente los cinco modelos de la familia de seleccionados bajo esta variante, conservando la validación cruzada 5-fold y los mismos hiperparámetros que en el entrenamiento estándar. Se compararon las métricas test de RMSE, MAE y R^2 entre ambas versiones (estándar vs. ATM) para cada familia. El análisis se complementó con inspección visual de residual heatmaps en el dashboard para verificar si la reordenación producía cambios en la distribución espacial del error (por moneyness y vencimiento).

Resultados observacionales en lo visualizado en el dashboard:

- **Linear Regression (RMSE 0.1838 estándar $\rightarrow$ 0.1877 ATM).** El entrenamiento ATM no produce un modelo mejor. El incremento en RMSE de +0.0039 (+0.21 %),

acompañado de deterioro en MAE (+0.0161) y reducción de R^2 (-0.0219), sugiere que el currículum de ATM no regulariza un modelo ya lineal e inflexible. El residual heatmap en versión ATM muestra mayor concentración relativa de error en bandas específicas de moneyness (entorno $0,95 < m < 1,05$), compatibles con un ajuste lineal que persevera en capturar curvatura local sin el beneficio de datos iniciales informativos. Este resultado es esperado: un modelo lineal no se beneficia de ordenamientos que privilegian información local, puesto que su hipótesis es global.

- **Random Forest (RMSE 0.0884 estándar → 0.0885 ATM).** El modelo más robusto permanece prácticamente invariante. El cambio $\Delta\text{RMSE} = +0,0001$ (0.01 %), $\Delta\text{MAE} = -0,0001$, y $\Delta R^2 = -0,0006$ son negligibles y dentro del ruido estocástico de validación cruzada. El residual heatmap ATM es indistinguible del estándar. Random Forest ya generaliza a través de bootstrapping y agregación de árboles profundos, generando capacidad de regularización inherente. El currículum ATM añade un factor extrínseco que no mejora esta capacidad, confirmando que los modelos ya óptimos no se benefician de reordenamientos de datos de entrenamiento.
- **XGBoost (RMSE 0.0917 estándar → 0.1136 ATM).** La variante ATM no produce un modelo mejor; al contrario, se observa una degradación clara. El incremento en RMSE de +0.0219 (+2.39 %), acompañado de $\Delta\text{MAE} = +0,0027$ y $\Delta R^2 = -0,1202$ (caída de 12 puntos porcentuales en varianza explicada), refleja un efecto perjudicial. El heatmap de diagnóstico ATM muestra intensificación de concentración roja (error absoluto alto) en bandas de vencimiento corto/mediano (0.05 a 0.25 años) y moneyness extrema. La hipótesis interpretativa es que XGBoost, al entrenarse primero en datos homogéneos y centrales (ATM), desarrolla un sesgo inicial hacia esa región. Cuando posteriormente observa datos extremos, su capacidad adaptativa (ya fijada en direcciones ATM) lucha por recalibrar, resultando en superficie menos flexible globalmente. Este efecto sugiere que el boosting secuencial es sensible al orden de entrada y puede sufrir de regularización excesiva en la primera fase.
- **Sequential NN (RMSE 0.1135 estándar → 0.0885 ATM).** La variante ATM produce un modelo mejor. La reducción en RMSE de -0.0250 (-22.03 %), manteniendo estable MAE, indica que el currículum de ATM efectivamente regulariza la red neuronal secuencial. El heatmap residual ATM es visiblemente más uniforme, sin concentraciones rojas en extremos como se observa en la versión estándar. La interpretación es directa: una red secuencial sin mecanismos de regularización explícita (dropout, batch-norm con configuración ATM) sufre de convergencia deficiente cuando enfrenta datos desordenados. El currículum ATM le permite aprender primero patrones estables en región de baja varianza, estableciendo pesos iniciales informados antes de adaptar a variabilidad creciente. Este hallazgo valida la hipótesis de motivación: arquitecturas iterativas sensibles pueden beneficiarse del currículum.

- **Quantum Inspired (RMSE 0.1430 estándar $\rightarrow$ 0.1174 ATM).** La variante ATM produce un modelo mejora substancial. La reducción en RMSE de -0.0256 (-17.90 %), junto con incremento dramático en R^2 de +0.1785 (pasando de 0.4528 a 0.6313, un aumento de 18 puntos porcentuales), revela que el modelo cuántico inspirado es altamente sensible al orden de entrenamiento. El heatmap ATM muestra reducción visible de concentración roja en extremos de moneyness y vencimiento. El modelo cuántico, basado en búsqueda variacional con inicialización aleatoria, es especialmente vulnerable a convergencia prematura en mínimos locales pobres. Entrenar primero en región ATM de bajo ruido permite al algoritmo establecer línea base de convergencia robusta, desde la cual la progresión hacia datos extremos se realiza de forma más estable. Este es el caso más dramático de regularización por currículum.

Síntesis interpretativa del impacto ATM por arquitectura. Los resultados revelan un patrón sistemático: la técnica Progressive ATM no produce un modelo mejor de forma universal, sino que su efectividad depende críticamente de la arquitectura subyacente.

MODELOS YA ÓPTIMOS (RANDOM FOREST, Y EN MENOR MEDIDA XGBOOST BASE):

El currículum ATM no mejora; en XGBoost incluso resulta perjudicial. La razón es que estos modelos ya poseen mecanismos de regularización o agregación intrínsecos (bootstrap, boosting) que no se benefician de reordenamientos externos. Forzar un orden artificial puede introducir sesgo de inicialización que degrada capacidad global de la arquitectura, particularmente en modelos iterativos como boosting.

MODELOS DE BAJA CAPACIDAD O CONVERGENCIA FRÁGIL (SEQUENTIAL NN, QUANTUM INSPIRED):

El currículum ATM produce mejoras tangibles. Estos modelos carecen de regularización inherente y son sensibles a inicialización y orden de muestras. Entrenar primero en región ATM establece trayectoria de aprendizaje más robusta, evitando convergencia a mínimos pobres que es frecuente cuando se enfrentan datos heterogéneos desde el inicio.

MODELOS LINEALES (LINEAR REGRESSION): El orden es irrelevante puesto que la hipótesis es global. No hay beneficio de regularización local.

Implicación para la selección de modelo en producción. Random Forest, bajo entrenamiento estándar (sin ATM), mantiene su posición como modelo seleccionado para la solución de producción. No solo logra las métricas más competitivas (RMSE 0.0884), sino que permanece robusto frente a variantes experimentales como ATM. Un modelo que no mejora con ATM es un indicador de que ya ha alcanzado un nivel de regularización apropiado: no es excesivamente sensible a ruido, y su capacidad de generalización es estable. Por el contrario, modelos que mejoran significativamente con ATM (Sequential NN, Quantum Inspired) sugieren que su arquitectura es intrínsecamente frágil y requeriría monitoreo cuidadoso en producción.

Conclusión sobre Progressive ATM. La técnica debe considerarse una variante experimental de refinamiento, útil únicamente para arquitecturas específicas que sufran de convergencia deficiente o sensibilidad a orden de datos. No constituye una mejora universal del pipeline estándar, y en algunos casos (XGBoost, Linear Regression) resulta innecesaria o contraproducente. Su valor académico está en la validación de que modelos de baja capacidad intrínseca pueden beneficiarse de estrategias de currículum; su aplicación práctica debe limitarse a escenarios donde se identifique explícitamente convergencia frágil durante ajuste de hiperparámetros. Para la solución final presentada, el entrenamiento estándar (sin Progressive ATM) es preferible: es más simple, es reproducible, y produce el modelo más robusto.

4.1.5 Behaviour And Surface

El modelo final debe leerse como función financiera, no solo como tabla de errores. Las superficies generadas alrededor de puntos de referencia del test permiten inspeccionar $\hat{\sigma}(m, T)$, smiles y estructuras temporales. Dado que Random Forest es un modelo por particiones, la revisión visual debe prestar especial atención a escalones locales: un bosque puede aproximar bien puntos observados y aun así producir transiciones menos suaves que un modelo paramétrico.




Figura 47: Contraste de *Behaviour And Surface* para la misma muestra (ID 1406): Random Forest frente a XGBoost.

La lectura recomendada es usar al menos tres puntos de referencia: una observación ATM líquida, una observación en extremos de moneyness y una observación de vencimiento corto. Si el dashboard muestra saltos alrededor de un punto, la explicación debe cruzarse con vecinos y residual heatmap antes de atribuirlo a señal financiera. Si el smile es suave y el error local bajo, la predicción es más defendible.

La Figura 47 muestra que Random Forest y XGBoost conservan una geometría muy próxima en la muestra comparada, lo que sugiere estabilidad funcional en lo visualizado en el dashboard, sin implicar por sí solo que el patrón deba repetirse en

cualquier trade. En ambos aparecen avisos heurísticos de saltos locales, coherentes con arquitecturas de árboles, pero las curvas smile y term-structure mantienen forma financiera interpretable (mínimo en entorno ATM y descenso de volatilidad al aumentar vencimiento para moneyness fija). Al contrastar con Linear Regression en el resto de lo visualizado en dashboard, se observa un patrón compatible con mayor suavidad formal y menor capacidad para capturar variación efectiva fuera de la zona central.

Una secuencia de lectura útil en esta pestaña es la siguiente:

- fijar un ancla representativa y revisar primero el heatmap local;
- comprobar después la superficie 3D para detectar escalones o zonas artificialmente planas;
- descender a smile y term structure para ver si la geometría sigue siendo razonable en cortes financieros conocidos;
- contrastar finalmente con ICE, ALE, vecinos y diagnóstico por zonas de la superficie cuando aparezcan formas dudosas.

Este orden es importante porque evita interpretar una gráfica aislada fuera de contexto. Un escalón puede ser inocuo si coincide con una zona bien soportada y de bajo error, o problemático si aparece en una región escasa y con extrapolación local.

4.1.6 Explicabilidad global

La explicación global debe comprobar que los drivers principales son coherentes con la geometría de volatilidad: moneyness, vencimiento, subyacente, strike, tipo y tipo de opción. SHAP se calcula sobre variables raw visibles y el runtime reconstruye las features transformadas, por lo que una contribución de StrikePrice o UnderlyingPrice debe interpretarse en relación con moneyness y no como efecto causal aislado.




Figura 48: SHAP global comparado en los dos modelos con mejor rendimiento fuera de muestra: Random Forest y XGBoost.

La lectura correcta combina ranking, signo local y dependence plots. Si una variable domina el ranking pero tiene colores mezclados o contribuciones con mucha dispersión, el modelo está usando interacciones. Esa conclusión es razonable en opciones, porque strike, subyacente y vencimiento no son independientes. Si aparecen saltos en dependence plots, deben contrastarse con las superficies y con diagnóstico por zonas de la superficie.

En las cinco variantes revisadas, y para lo que se visualiza en dashboard, la jerarquía global aparece estable: Time To Expiration (days) como driver principal y Strike Price como segundo, seguidas por Underlying Price; Rate y Option Type tienen peso menor. La Figura 48 hace visible esta regularidad, que coincide con la lectura financiera esperada de superficie. El punto importante es que la consistencia entre modelos se observa en el orden de importancia, no necesariamente en la magnitud de impacto: Quantum Inspired y Sequential NN muestran dispersión SHAP más amplia para algunos rangos, coherente con su mayor sensibilidad local en otras pestañas.

Para que la lectura global sea sólida, conviene exigir tres coherencias a la vez.

- **Coherencia estadística:** que las variables más importantes aparezcan de forma estable en varias visualizaciones SHAP.
- **Coherencia financiera:** que los drivers dominantes sean compatibles con la geometría de moneyness, vencimiento y tipo.
- **Coherencia con error:** que un patrón llamativo en SHAP pueda contrastarse con residual heatmap, superficies y casos locales.

Si una variable parece importante pero esa importancia no se refleja ni en las superficies ni en la lectura por zonas del error, la conclusión debe tomarse con cautela. La explicabilidad global no sustituye al resto de vistas; las organiza.

4.1.7 Modelos equivalentes: árboles y regresión simbólica




Figura 49: Contraste de árboles surrogate por profundidad en Random Forest y XGBoost.

Modelo	RMSE simbólico	MAE simbólico	R^2 simbólico
Regresión lineal	0.0244	0.0135	0.7585
Quantum Inspired NN	inf	inf	inf
Random Forest	339.9547	3.5845	-5,173,729.5872
Sequential NN	0.0376	0.0316	0.8890
XGBoost	0.0378	0.0219	0.9264

Cuadro 9: Fidelidad de regresión simbólica reportada en dashboard por familia de modelo.

Los modelos equivalentes explican el predictor, no la verdad de mercado. Para Random Forest, las métricas de fidelidad de árboles surrogate son:

Profundidad	RMSE fidelidad	MAE fidelidad	R^2 fidelidad
2	0.139477	0.053488	0.129099
4	0.135217	0.050783	0.181486
8	0.141899	0.058392	0.098593
16	0.144616	0.053187	0.063747

Cuadro 10: Fidelidad de árboles surrogate frente al Random Forest seleccionado.

La fidelidad de los árboles es limitada: ni siquiera profundidades altas reproducen bien el comportamiento completo del bosque. Esto no invalida el modelo principal, pero sí limita el uso de reglas simples como explicación global. La regresión simbólica generada para este paquete muestra métricas no utilizables para defensa del Random Forest, con RMSE de fidelidad extremadamente alto; por tanto, la memoria debe apoyarse en SHAP, ICE/ALE, superficies y vecinos para explicar el modelo final. La conclusión no debe forzarse: el predictor es bueno, pero no se resume bien en una fórmula compacta en esta ejecución.

La Figura 49, junto con la Tabla 10 y la Tabla 9, permite una conclusión transversal: la facilidad para explicar un modelo mediante reglas o fórmulas compactas no coincide necesariamente con su capacidad predictiva final en test. El mejor modelo por error de mercado (Random Forest) es precisamente uno de los menos compresibles simbólicamente en esta ejecución, mientras que XGBoost y Sequential NN admiten surrogates simbólicos más fieles.

La lectura correcta de estos modelos equivalentes es prudente.

- Si la fidelidad es baja, las reglas o fórmulas sólo valen como resumen parcial y no como explicación suficiente del modelo principal.

- Si la fidelidad mejora con mucha complejidad, la conclusión útil no es que exista una explicación compacta, sino precisamente que el predictor no se deja comprimir bien.
- Si la fidelidad fuese alta con baja complejidad, entonces sí tendría sentido dar más peso a reglas o ecuaciones en la discusión global.

4.1.8 Explicabilidad local y soporte histórico

El análisis local debe seleccionar una muestra representativa y una muestra problemática. Para cada una, el waterfall SHAP explica la predicción como suma de valor base y contribuciones. Los vecinos históricos, calculados contra train en el espacio transformado y estandarizado, indican si la muestra está dentro de una región conocida. En el paquete se guardan hasta 200 vecinos por muestra, usando una referencia de entrenamiento de hasta 20.000 observaciones.




Figura 50: Explicabilidad local en modo *dataset* para la misma muestra (ID 465): comparación Random Forest vs XGBoost.




Figura 51: Explicabilidad local en modo *manual input* (stress corto vencimiento): contraste de coherencia local y soporte histórico en ambos finalistas.

La interpretación profesional debe combinar ambas piezas. Si una muestra tiene waterfall coherente y vecinos cercanos con volatilidades similares, la explicación es

sólida. Si el waterfall parece razonable pero los vecinos están lejos, el modelo puede estar extrapolando; en ese caso, la predicción debe revisarse con diagnóstico por zonas de la superficie y superficie local.

El contraste entre Figuras 50 y 51 muestra una coherencia especialmente relevante para defensa técnica. En la muestra real (ID 465), Random Forest y XGBoost predicen prácticamente el mismo nivel ($\sim 0,233$ y $\sim 0,231$), con waterfall de signo consistente: Time To Expiration aporta caída y Underlying Price compensa parcialmente al alza, en línea con su papel dominante en SHAP global. En el caso manual de vencimiento corto, ambos modelos reducen volatilidad prevista respecto al valor base y, al mismo tiempo, los vecinos aparecen a distancia alta ($\sim 0,85$), señalando un escenario de menor soporte histórico. Esta combinación (coherencia de mecanismo + menor densidad local) justifica usar la explicación local como guía de prudencia, no como validación automática de calidad de mercado.

Como regla práctica, una explicación local es más defendible cuando se cumplen tres condiciones.

- El signo y magnitud de las contribuciones SHAP son compatibles con la intuición financiera del caso.
- Los vecinos cercanos muestran contratos, moneyness y vencimientos realmente parecidos.
- El error por zonas del modelo no es anómalamente alto en esa área.

Cuando falla alguna de esas tres condiciones, la lectura debe cambiar: la explicación sigue diciendo cómo razona el modelo, pero deja de ser una justificación sólida de que la predicción sea fiable en términos de mercado.

4.1.9 Síntesis comparativa por temática

Para cerrar la lectura de dashboard con una vista única y defendible, la Tabla 11 resume las conclusiones cualitativas por temática (filas) y por familia de modelo (columnas). Esta síntesis se apoya en las capturas de diagnóstico, comportamiento, explicabilidad global/local y modelos equivalentes revisadas en esta sección.

Esta síntesis permite sostener dos mensajes, con alcance observacional sobre lo visualizado en el dashboard. Primero, la estructura explicativa principal aparece consistente entre familias: el vencimiento domina y el strike ocupa una posición secundaria relevante, coherente con la geometría de superficie. Segundo, las diferencias clave entre modelos no están tanto en qué variables miran, sino en cómo transforman esa información en estabilidad local, error por zonas y facilidad de explicación compacta. Para afirmar universalidad sobre todos los trades sería necesario un contraste estadístico adicional fuera de las muestras visualizadas.

Temática	Reg. lineal	Random Forest	XGBoost	Sequential NN	Quantum Inspired
Driver SHAP dominante	TTE (muy dominante)	TTE (estable)	TTE (estable)	TTE (estable)	TTE (estable)
Segundo driver global	Strike (alto)	Strike (alto)	Strike (alto)	Strike (medio)	Strike (medio)
Rendimiento diagnóstico test	Bajo	Alto (mejor)	Alto (2º)	Medio-bajo	Bajo
Suavidad de superficie local	Alta (simple)	Media (escalones locales)	Media (escalones locales)	Media-baja	Media-baja
Patrón smile/skew en ICE-ALE	Visible, menos rico	Visible y consistente	Visible y consistente	Visible, más inestable	Visible, más inestable
Coherencia Global → Sample	Media	Alta	Alta	Media	Media
Soporte histórico en casos manuales exigentes	N/A en muestra principal	Distancia alta en estrés corto T	Distancia alta en estrés corto T	N/A en muestra principal	N/A en muestra principal
Compresibilidad en modelo equivalente (simbólico/árbol)	Alta (simple)	Muy baja (no compactable)	Media-alta	Media-alta	Muy baja/No utilizable

Cuadro 11: Síntesis de conclusiones por temática y por familia de modelo a partir de lo visualizado en el dashboard. TTE: Time To Expiration.

4.2 DISCUSIÓN

La pregunta planteada en [section 1.1](#) puede responderse afirmativamente con matices. Sí es posible construir un modelo útil y consultable para volatilidad implícita de opciones del IBEX; el Random Forest seleccionado ofrece buen error fuera de muestra. El matiz es que la explicación no puede descansar en un único resumen global: la fidelidad de modelos equivalentes simples es limitada, y la defensa técnica debe combinar SHAP, superficies, ICE/ALE, vecinos y diagnóstico.

4.2.1 *Lectura financiera*

Financieramente, el proyecto trata la volatilidad como superficie y no como serie unidimensional. El buen RMSE agregado es relevante, pero el dato más importante para gestión de riesgos es dónde se produce el error. La compresión de volatilidades extremas sugiere que deben revisarse los extremos de moneyness y los vencimientos cortos con más cuidado. Este comportamiento es plausible en derivados: esas zonas suelen tener menos liquidez, más ruido de microestructura y mayor sensibilidad al desfase entre opción y futuro subyacente.

- El modelo final es útil para lectura agregada y consulta, pero no debe tratarse como atajo automático del juicio financiero en zonas extremas.
- La geometría de la superficie sigue siendo el criterio principal de plausibilidad: smiles, term structures y suavidad local importan tanto como el error medio.
- La lectura de vecinos y soporte histórico es especialmente valiosa cuando se analiza un contrato poco líquido o lejano de ATM.

En otras palabras, el trabajo refuerza una idea clásica en derivados: el resultado útil no es un único número, sino una predicción situada dentro de una estructura de superficie, de un contexto de mercado y de una evidencia histórica comparable.

También conviene subrayar una implicación práctica. Cuando el modelo se usa como apoyo a valoración o revisión manual, la pregunta correcta no es sólo si “acierta de media”, sino si conserva lógica financiera en la zona concreta que se está consultando. Esa exigencia explica por qué el documento dedica espacio a smiles, extremos de moneyness, vencimientos cortos y soporte local, y no sólo a tablas globales de error.

Aportación frente a enfoques clásicos.

La comparación con enfoques clásicos debe plantearse como complementariedad y mejora operativa, no como sustitución automática. Los enfoques paramétricos (por ejemplo, parametrizaciones estáticas de superficie o ajustes locales ad hoc) aportan

estructura financiera explícita y son valiosos para gobernanza. La propuesta de este TFM añade valor en escenarios donde esa estructura no basta por sí sola:

- **Mayor flexibilidad empírica:** captura interacciones no lineales entre moneyness, vencimiento, subyacente y tipo con menor rigidez funcional.
- **Mejor lectura por zonas:** añade diagnóstico de error por región de superficie, clave para contratos ilíquidos o extremos de moneyness.
- **Capacidad de control y auditoría:** incorpora trazabilidad y explicaciones locales/globales en el mismo flujo de servicio.
- **Validación cruzada de pricing:** permite contrastar salidas de modelos clásicos internos con una referencia empírica independiente.

En términos prácticos, la mejora no es sólo bajar una métrica agregada. La mejora principal es disponer de una *superficie utilizable*: consultable, explicable y controlable en producción, especialmente en los casos donde las reglas clásicas requieren juicio manual intensivo.

4.2.2 Lectura de IA y Data Science

Desde la perspectiva de IA, la comparación muestra que modelos tabulares de árboles son más adecuados que redes densas para esta muestra. Random Forest y XGBoost aprovechan interacciones no lineales sin exigir escalado y ofrecen mejor test. La métrica CE_2 favorece a XGBoost en train/validation, pero el test favorece a Random Forest; esto ilustra por qué la selección final no debe quedarse en validación. Progressive ATM mejora Quantum Inspired, pero no a las familias que ya generalizan mejor.

- La validación temporal es más importante que una mejora marginal en entrenamiento.
- La estabilidad entre train, validation y test pesa más que una única métrica brillante en una fase intermedia.
- La explicabilidad posterior también importa: un modelo competitivo pero imposible de leer exige más apoyos y más cautela en su defensa.

Desde esta perspectiva, el trabajo también deja una lección de alcance más general: en datos financieros tabulares, una arquitectura más compleja no merece preferencia por defecto. Primero debe demostrar que generaliza mejor; después, que esa mejora compensa el coste extra de explicación, mantenimiento y servicio.

4.2.3 *Lectura de ingeniería y cloud*

La dimensión cloud aporta valor porque no se usa como adorno: resuelve almacenamiento, carga de modelos, despliegue independiente de API y dashboard y trazabilidad. La separación entre modelo, paquete explicativo, API, dashboard y almacenamiento reduce acoplamientos y facilita auditoría. La principal cautela operativa es mantener sincronizados modelo, scaler, metadatos y componentes explicativos; de lo contrario, el sistema podría predecir con una versión y explicar con otra.

- El almacenamiento centralizado evita duplicidades manuales y facilita compartir la misma versión entre servicios.
- El despliegue desacoplado permite que un problema en dashboard no bloquee necesariamente la API, y viceversa.
- La reproducibilidad de infraestructura es útil sólo si el pipeline mantiene coherencia entre modelo servido y explicaciones persistidas.

La consecuencia práctica es que la ingeniería no aparece aquí como una capa secundaria. Es parte del argumento de calidad del trabajo: un modelo que no puede versionarse, servirse y auditarse con coherencia pierde valor aunque su ajuste estadístico sea aceptable.

4.2.4 *Limitaciones*

Las limitaciones se agrupan en cuatro bloques. Primero, la volatilidad implícita depende de la calidad del enlace opción-subyacente y del solver Black-76. Segundo, el conjunto de datos es heterogéneo en liquidez y cobertura de moneyness/vencimiento, por lo que los extremos deben diagnosticarse localmente. Tercero, la explicabilidad aproxima comportamientos del modelo y no sustituye validación económica. Cuarto, el despliegue cloud exige disciplina de versionado para evitar inconsistencias entre modelos, paquetes de dashboard y metadatos.

- No toda región del espacio de entrada tiene la misma densidad histórica ni la misma calidad de soporte.
- Un modelo explicable sigue pudiendo estar equivocado si aprende sesgos sistemáticos de los datos.
- Las visualizaciones ayudan a detectar problemas, pero no convierten por sí solas una predicción en económicamente válida.

Además, hay una limitación estructural que conviene dejar explícita: el proyecto explica muy bien cómo razona el modelo entrenado, pero no agota por sí solo la validación económica del mercado. Siempre queda margen para contrastar con enfoques paramétricos, con criterios de liquidez más finos o con reglas de suavidad impuestas ex ante sobre la superficie.

CONCLUSIONES

Este TFM desarrolla una cadena integral para estimar volatilidad implícita en opciones del IBEX y convertir el resultado en un sistema explicable y operable. El trabajo parte de datos de mercado, construye una base de volatilidad mediante inversión de Black-76, entrena familias de modelos bajo validación temporal y genera explicaciones y diagnósticos. El modelo final seleccionado es Random Forest estándar, con $RMSE = 0,088403$, $MAE = 0,054366$ y $R^2 = 0,790941$ en test.

La primera conclusión es que la calidad de un modelo de volatilidad no puede evaluarse solo con métricas agregadas. En derivados, la forma de la superficie, el comportamiento por moneyness y vencimiento y la localización del error son elementos centrales. Por ello el dashboard no se plantea como una capa estética, sino como parte del mecanismo de validación. En el modelo seleccionado aparece comprensión parcial de variabilidad, ya que la desviación estándar de predicciones en test es inferior a la de la volatilidad real.

La segunda conclusión es que la explicabilidad aporta valor en dos planos. En ingeniería, ayuda a detectar fallos, fugas, sesgos y discontinuidades. En finanzas, permite justificar predicciones y analizar si el modelo se comporta de forma compatible con intuición económica y revisión profesional.

La tercera conclusión es que la arquitectura de software condiciona la utilidad del modelo. Al separar ETL, entrenamiento, paquetes explicativos, API, dashboard y almacenamiento, el proyecto facilita reproducibilidad, mantenimiento y despliegue. Esta separación también reduce el riesgo de que las explicaciones se calculen sobre versiones distintas de las usadas en predicción.

La cuarta conclusión es que progressive ATM no debe presentarse como mejora universal. En esta ejecución mejora la arquitectura Quantum Inspired, pero no al Random Forest final ni a XGBoost. Su utilidad depende de si estabiliza la zona ATM sin degradar los extremos de moneyness ni los vencimientos menos representados.

Desde la perspectiva financiera aplicada, la contribución diferencial frente a enfoques clásicos es doble. Primero, aporta una referencia empírica flexible para valo-

ración y validación en zonas con menor liquidez o cobertura irregular. Segundo, incorpora mecanismos de explicación y control (SHAP, ICE/ALE, vecinos y diagnóstico por superficie) que facilitan auditoría interna, model validation y soporte a decisiones de cobertura.

Por ello, el avance del TFM no debe leerse sólo como una mejora de RMSE. Debe leerse como mejora de **capacidad operativa**: detectar anomalías, justificar decisiones, analizar sensibilidad por moneyness/vencimiento y usar el modelo como herramienta de control de riesgos de mesa.

Como líneas futuras, se proponen: ampliar el análisis con más ventanas temporales, incorporar métricas específicas por liquidez, explorar modelos con restricciones de suavidad financiera, automatizar validaciones de superficie más exigentes y reforzar el versionado de modelos y paquetes explicativos en cloud. También sería natural comparar la superficie aprendida con enfoques paramétricos clásicos o con modelos híbridos que impongan estructura financiera explícita.

ESQUEMA DETALLADO DE DATOS Y ETL

Este anexo reúne el detalle estructural de las tablas intermedias y finales generadas por el pipeline de datos. Su objetivo no es introducir lógica nueva, sino dejar trazabilidad precisa sobre qué base produce cada etapa del ETL y cómo se encadenan Read Raw Step, Merge Raw Step, Product Split Step, Underlying Step y Volatility Step.

La Figura 52 muestra la fase de ingestión y consolidación inicial. La Figura 53 recoge la separación por producto y la construcción de la relación opción-subyacente. La Figura 54 resume los filtros finales y la construcción de VOLATILITY_DB.




Figura 52: Detalle estructural del ETL (I): fuentes de entrada, normalización inicial y consolidación contractual.




Figura 53: Detalle estructural del ETL (II): separación por producto y construcción de la relación opción-subyacente.




Figura 54: Detalle estructural del ETL (III): filtros previos y construcción final de VOLATILITY_DB.

MARCO DE DESARROLLO Y CONTROL DE CAMBIOS

Una parte relevante del valor metodológico del proyecto es que no se ha construido como un prototipo monolítico difícil de auditar, sino como un repositorio vivo gestionado con prácticas habituales de ingeniería. El trabajo se ha desarrollado sobre Git y GitHub, con ramas específicas para líneas funcionales distintas, integración progresiva y versionado explícito de código, configuración, documentación y artefactos asociados.

Esta forma de trabajo aporta varias garantías prácticas. Primero, cada cambio queda ligado a un conjunto acotado de commits, lo que permite reconstruir por qué se modificó una validación, una ruta de datos, una configuración de entrenamiento o una pieza del dashboard. Segundo, la separación por ramas reduce el riesgo de mezclar cambios heterogéneos en una misma entrega: ETL, explainability, modelos, API, cloud o documentación pueden evolucionar de forma controlada antes de integrarse. Tercero, la sincronización con remoto y la integración posterior facilitan un flujo compatible con revisión mediante *pull requests*, incluso cuando parte del trabajo se haya hecho en iteraciones rápidas de investigación aplicada.

En este contexto, commit, pull y push no son sólo operaciones operativas. Funcionan como mecanismo de trazabilidad metodológica. Un resultado experimental pasa a ser defendible no únicamente porque produzca una métrica, sino porque puede asociarse a una versión concreta del pipeline, de la configuración y de los tests que la acompañan. Esto es especialmente importante en un proyecto que combina datos financieros, entrenamiento temporal, explicabilidad, dashboard, API e infraestructura cloud, ya que pequeños cambios en una parte pueden alterar silenciosamente el comportamiento de otra.

Los tests y validaciones automatizadas refuerzan ese marco. El repositorio mantiene una batería de pruebas distribuida por dominios (datos, modelos, dashboard, API, configuración y utilidades) y se complementa con validaciones manuales guiadas sobre artefactos desplegables. En la práctica, esto aproxima el TFM al ciclo de vida de un proyecto real: desarrollar una mejora en una rama, verificar contratos y coheren-

cia funcional, integrar el cambio y conservar una historia versionada que permita depuración, rollback conceptual y defensa técnica.

Por tanto, el uso de Git y de un flujo de integración disciplinado no es un detalle accesorio de implementación. Forma parte de la metodología del trabajo: asegura reproducibilidad, facilita control de cambios, reduce regresiones y hace que el sistema final pueda justificarse no sólo por lo que predice, sino por cómo se ha construido, validado e integrado.

FUNDAMENTOS DE SHAP

SHAP se basa en una lectura cooperativa de la contribución de variables a una predicción. Su ventaja práctica es que proporciona una descomposición aditiva como la de (9). En este proyecto se usa con un explicador de permutación para tratar de forma homogénea modelos heterogéneos. Esta decisión sacrifica eficiencia frente a explicadores especializados, pero aporta una semántica común entre familias.

La Figura 55 resume este fundamento de descomposición aditiva.




Figura 55: Descomposicion SHAP desde valor base hasta prediccion explicada.

La atribución SHAP procede de los valores de Shapley. Para una feature j , el valor se interpreta como la contribución marginal media de esa feature al incorporarse a todos los subconjuntos posibles de variables:

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)], \quad (15)$$

donde N es el conjunto de features, S un subconjunto que no contiene j , p el número de features, $v(S)$ el valor esperado del modelo cuando se conocen las variables de S , y ϕ_j la contribución asignada a j .

La interpretación de SHAP debe ser cuidadosa. Un valor SHAP positivo indica que, para una observación y respecto al valor base, la variable empuja la predicción al alza. No implica causalidad. Además, si las variables están correlacionadas, la atribución depende de cómo el explicador define la ausencia o permutación de features.

El repositorio usa `shap.Explainer(..., algorithm="permutation")`. El presupuesto mínimo de evaluación por fila es:

$$max_evals = 2p + 1. \quad (16)$$

El fondo se toma de una muestra controlada por `shap_background_size`; las filas explicadas globalmente por `shap_explain_size`; y las filas locales por `sample_option_size`. Las explicaciones se calculan sobre variables raw visibles: `OptionType`, `StrikePrice`, `UnderlyingPrice`, `TimeToExpiration` y `Rate`. Esta decisión mejora la lectura financiera, aunque internamente el runtime reconstruya `logMoneyness`, `sqrtTTEYears` y el resto de features derivadas mediante el encoder de explicabilidad. Las Figuras 56, 57, 58, 59 y 60 muestran estos artefactos globales y locales.




Figura 56: Estructura de datos usada por las visualizaciones SHAP.



Figura 57: Lectura conjunta de visualizaciones SHAP.




Figura 58: Construcción de una explicación local waterfall.

El beeswarm muestra contribuciones individuales por feature; la importancia media absoluta ordena variables por $\frac{1}{n} \sum_i |\phi_j(x_i)|$; el dependence plot relaciona x_{ij} con $\phi_j(x_i)$; y el heatmap permite comparar perfiles explicativos entre observaciones. El waterfall local parte de ϕ_0 y suma contribuciones hasta $\hat{\sigma}(x_i)$. Los vecinos históricos completan la explicación local: SHAP identifica drivers de predicción y los vecinos indican soporte empírico.

Una lectura disciplinada de SHAP en este proyecto sigue cuatro pasos.

- **Paso 1:** revisar el ranking global para identificar qué variables organiza el modelo con más intensidad.




Figura 59: Calculo de vecinos y proyeccion local.




Figura 60: Relacion entre SHAP local y soporte historico.

- **Paso 2:** contrastar esas variables con dependence plots para ver si la relación es monótona, heterogénea o claramente interactiva.
- **Paso 3:** bajar a waterfalls locales cuando interese justificar un contrato concreto.
- **Paso 4:** validar el contexto con vecinos y diagnóstico por zonas de la superficie, especialmente si la muestra está en extremos de moneyness o en vencimientos cortos.

Este anexo es importante porque evita dos errores frecuentes. El primero es leer SHAP como causalidad económica. El segundo es creer que una explicación local muy detallada equivale a una garantía de calidad de la predicción. SHAP explica cómo reparte el modelo la predicción; no demuestra que la relación aprendida sea una ley financiera.

CURVAS ICE

ICE, *Individual Conditional Expectation*, muestra cómo cambia la predicción para observaciones individuales cuando se modifica una feature y se mantienen las demás constantes. Para una feature j , una observación x_i y un valor contrafactual z :

$$ICE_i^{(j)}(z) = f(z, x_{i,-j}), \quad (17)$$

donde $x_{i,-j}$ representa todas las variables salvo la feature analizada. Cada línea ICE es una trayectoria individual de predicción.

La Figura 61 muestra el flujo de construcción de estas curvas.




Figura 61: Construcción de curvas ICE por feature.

En el proyecto, `build_ice_frame` muestrea hasta `ice_sample_size=24` filas, crea un grid de `curve_points=25` por cuantiles y evalúa `StrikePrice`, `UnderlyingPrice`, `TimeToExpiration` y `Rate`. ICE revela heterogeneidad: curvas paralelas indican efectos similares; pendientes diferentes o cruces sugieren interacciones; saltos o dientes pueden indicar discontinuidades del modelo o zonas poco soportadas.

ICE no debe confundirse con PDP. Un PDP promedia curvas ICE:

$$PDP_j(z) = \frac{1}{n} \sum_{i=1}^n f(z, x_{i,-j}). \quad (18)$$

El promedio puede ocultar comportamientos opuestos entre observaciones. Además, ICE puede generar contrafactuales poco realistas, por ejemplo cambiar strike manteniendo fijo el resto hasta producir moneyness fuera de distribución. Por eso sus curvas deben leerse con vecinos, superficie local y diagnóstico por zonas de la superficie.

En la práctica, conviene usar ICE para responder preguntas muy concretas.

- Qué ocurre con la predicción si se mueve el strike manteniendo fijo el contexto de una observación real.
- Si el efecto del vencimiento es homogéneo o depende mucho del régimen de moneyness.
- Si el tipo de interés tiene un impacto directo o aparece diluido frente a las variables geométricas de la superficie.

Patrones de lectura útiles:

- **Curvas casi paralelas:** el modelo usa la feature con una respuesta relativamente estable.
- **Curvas que se cruzan:** la relación depende claramente del contexto de otras variables.
- **Dientes o escalones:** posible efecto de particiones del modelo, sparsidad local o zonas poco observadas.

Por tanto, ICE no se usa aquí como una figura decorativa. Se usa para revelar heterogeneidad que un promedio global escondería y para someter al modelo a una lectura funcional cercana a la intuición financiera del usuario.

CURVAS ALE

ALE, *Accumulated Local Effects*, estima el efecto medio acumulado de una feature usando variaciones locales dentro de zonas observadas. Complementa a ICE porque resume un efecto agregado menos vulnerable a combinaciones contrafactuales irreales cuando las variables están correlacionadas.

$$ALE_j(z) = \int_{z_0}^z E \left[\frac{\partial f(X)}{\partial X_j} \mid X_j = s \right] ds - C. \quad (19)$$

La constante C centra la curva para que su media sea cero. Un valor ALE positivo no significa volatilidad positiva, sino efecto acumulado por encima del promedio de referencia.

La Figura 62 resume el cálculo por bins y su acumulación.

La implementación por bins calcula bordes por cuantiles entre 0.05 y 0.95, con 13 puntos. Para cada intervalo $[l_k, u_k]$, selecciona observaciones I_k , predice dos escenarios locales y calcula:

$$\Delta_k = \frac{1}{|I_k|} \sum_{i \in I_k} [f(u_k, x_{i,-j}) - f(l_k, x_{i,-j})]. \quad (20)$$

Después acumula y centra:

$$ALE_k^u = \sum_{r \leq k} \Delta_r, \quad ALE_k = ALE_k^u - \frac{1}{K} \sum_{r=1}^K ALE_r^u. \quad (21)$$

En opciones, ALE es útil porque `StrikePrice` y `UnderlyingPrice` determinan moneyness, `TimeToExpiration` depende de calendarios de vencimiento y `Rate` depende de fecha y plazo. ALE no elimina todas las dificultades de correlación, pero evita




Figura 62: Construcción de curvas ALE por bins locales.

promediar de forma indiscriminada sobre combinaciones globales poco plausibles [Apley and Zhu, 2020].

ALE debe interpretarse como efecto relativo acumulado, no como nivel absoluto.

- Si la curva ALE crece de forma sostenida, esa feature empuja la predicción al alza en las zonas observadas.
- Si la curva es casi plana, el efecto medio local es débil o está compensado entre regímenes distintos.
- Si aparecen cambios bruscos, conviene comprobar si corresponden a bins con poca densidad o a comportamiento realmente no lineal del modelo.

La complementariedad con ICE es clave.

- ICE muestra trayectorias individuales y, por tanto, heterogeneidad.
- ALE resume el efecto agregado dentro de zonas observadas y, por tanto, mejora la robustez de la lectura.

Si ambos apuntan en la misma dirección, la conclusión es más sólida. Si discrepan, el modelo probablemente está mezclando regímenes o usando interacciones que conviene revisar con superficies y diagnóstico por zonas de la superficie.

MODELO QUANTUM INSPIRED

Este anexo resume únicamente lo diferencial de la familia *Quantum Inspired*. En este trabajo no implica computación cuántica real, sino una arquitectura **clásica** con factorización tensorial para modelar interacciones complejas de la superficie de volatilidad.

Implementación específica.

La lógica principal está en el archivo `src/python_models/volatility_models/volatility_model_family.py`. El anexo se apoya en dos piezas:

- **TensorTrainLayer:** implementa la contracción tensor-train (validación de forma en `build` y contracción en `call`).
- **QuantumInspiredNNFamily:** define cómo se tensoriza el embedding y cómo se integra la capa TT en el modelo final.

Las funciones realmente diferenciales son:

- `_get_tt_configurations`: fija `tensor_dims`, `tt_ranks` y `tt_output_dim`.
- `instantiate_model`: construye una cadena de seis pasos: Input, embedding, Reshape, TensorTrainLayer, bloque denso y salida.

Mecánica interna relevante (sin entrar en detalles genéricos de Keras).

En la implementación, `instantiate_model` fija primero una configuración TT concreta (por ejemplo `[2,2,2,2]` o `[2,2,3,3]`), y de ahí deriva el tamaño del embedding como:

$$\text{embedding_dim} = \prod_{k=1}^d n_k. \quad (22)$$

Después, el flujo es estrictamente estructural: la capa densa de embedding produce un vector de tamaño $\prod n_k$, Reshape lo convierte en un tensor de orden d , y

TensorTrainLayer aplica la contracción TT para generar `tt_output_dim` características comprimidas.

TensorTrainLayer impone además restricciones que son propias del formalismo TT: valida que los rangos tengan longitud $d + 1$, que las fronteras sean $[1, \dots, 1]$, y construye núcleos con forma (r_k, n_k, r_{k+1}) . Esto evita implementaciones ambiguas y asegura que la factorización usada sea coherente con la descomposición tensor-train estándar.

Diferencia frente a una red densa estándar.

Una red normal encadena capas densas con matrices completas de pesos. La variante Quantum Inspired impone estructura:

- convierte el embedding en tensor multiíndice;
- modela interacciones mediante núcleos TT con rangos internos controlados;
- sustituye parte de la parametrización densa por una parametrización factorizada.

La diferencia práctica más importante es que en una red densa la complejidad crece por matrices completas entre capas, mientras que aquí queda gobernada por `tensor_dims` y `tt_ranks`. Por eso los rangos TT actúan como mando directo del compromiso entre capacidad de aproximación y regularización estructural.

Además, en esta familia los hiperparámetros `tt_configuration` no son decorativos: definen simultáneamente el orden tensorial, los rangos internos y la dimensión de salida TT. Por tanto, modificar esa configuración cambia de forma directa la clase funcional que el modelo puede representar.

En forma simplificada:

$$z \rightarrow \mathcal{Z}(i_1, \dots, i_d), \quad \hat{\sigma}(x) = f_{TT}(\mathcal{Z}; \Theta_{TT}), \quad (23)$$

$$f_{TT}(\mathcal{Z}) \approx \sum_{i_1, \dots, i_d} G_1[i_1] G_2[i_2] \cdots G_d[i_d] \mathcal{Z}(i_1, \dots, i_d), \quad (24)$$

donde los rangos TT regulan el equilibrio entre capacidad e inducción de estructura.

Esto es precisamente lo que justifica la etiqueta *quantum inspired* en este TFM: se adopta una parametrización inspirada en redes tensoriales usadas en modelos cuánticos simulados clásicamente, pero toda la inferencia y el entrenamiento se realizan en hardware clásico y bajo el mismo protocolo de validación que el resto de familias.

Lectura práctica en este TFM.

La familia no gana al Random Forest en test, pero sí mejora cuando se combina con progressive ATM. Eso justifica su valor como hipótesis arquitectónica específica: aporta una vía alternativa para capturar estructura multivariable sin cambiar el protocolo de evaluación respecto a las demás familias.

ÁRBOLES SURROGATE Y REGRESIÓN SIMBÓLICA

Los modelos surrogate aproximan el comportamiento del modelo principal con una representación más interpretable. Formalmente, buscan una función h tal que:

$$\hat{\sigma}_{principal}(x) \approx h(x). \quad (25)$$

La variable objetivo de h no es la volatilidad real, sino la predicción del modelo principal. Por tanto, la fidelidad mide capacidad de imitación, no precisión frente a mercado. Esta distinción es esencial para evitar una interpretación incorrecta en auditoría.

La Figura 63 muestra el flujo de entrenamiento y evaluación de árboles surrogate.

Los árboles surrogate ofrecen reglas por particiones. Profundidades bajas facilitan lectura, pero pueden perder fidelidad; profundidades altas imitan mejor, pero se vuelven menos explicables. El dashboard conserva varios niveles de profundidad para elegir el equilibrio adecuado.

Qué es la regresión simbólica en este contexto.

La regresión simbólica busca una expresión matemática explícita que aproxime al modelo principal:

$$\hat{\sigma}_{principal}(x) \approx h_{sym}(x), \quad (26)$$

donde h_{sym} no se fija a priori (como una recta o un polinomio de grado cerrado), sino que se descubre mediante búsqueda sobre combinaciones de operadores. En términos de explicabilidad, su valor potencial es ofrecer una fórmula compacta y auditable en lugar de una caja negra.

Por qué es importante para explicabilidad.




Figura 63: Entrenamiento y evaluación de arboles surrogate.

Su interés no es solo estético. Si una expresión de complejidad moderada mantiene buena fidelidad, permite:

- resumir el comportamiento global del modelo con una regla algebraica interpretable;
- discutir dependencias funcionales de forma directa (signos, curvatura, términos dominantes);
- complementar SHAP/ICE/ALE con una síntesis global más legible para revisión técnica.

Al mismo tiempo, hay que controlar dos riesgos: fórmulas aparentemente limpias pero con baja fidelidad, y fórmulas fieles pero económicamente poco defendibles. Por eso se revisan conjuntamente error, complejidad y estabilidad de candidatos [Cranmer, 2023]. Las Figuras 64 y 65 muestran esta búsqueda y su lectura conjunta.

Cómo se ha implementado en este TFM.

En el proyecto, los árboles se entrenan con `DecisionTreeRegressor` para profundidades 2, 4, 8 y 16. La configuración usa `surrogate_sample_size=12000` y `surrogate_min_samples_leaf=80`.

La regresión simbólica usa PySR con una muestra de 2500 observaciones, búsqueda evolutiva, operadores binarios $+$, $-$, $\times$, $/$, $\wedge$, operadores unarios `square` y `cube`, límite de complejidad y `timeout`. La variable objetivo es siempre la predicción del modelo principal, no la volatilidad real observada.

Esta distinción metodológica es clave: tanto en árboles surrogate como en regresión simbólica se evalúa **fidelidad de imitación** del modelo final, no capacidad de pricing frente a mercado.

Este anexo distingue dos tipos de legibilidad.

- **Legibilidad por reglas:** propia de árboles surrogate, útil para umbrales y particiones del espacio explicativo.
- **Legibilidad algebraica:** propia de la regresión simbólica, útil cuando el comportamiento puede resumirse mediante una fórmula compacta.

La decisión de usar uno u otro depende del modelo final y de la fidelidad obtenida.

- Si un árbol poco profundo ya imita bien al modelo principal, la lectura por reglas puede ser suficiente.
- Si la fórmula simbólica logra buena fidelidad con complejidad moderada, aporta una síntesis especialmente valiosa.
- Si ambos fallan, la conclusión útil no es negativa, sino diagnóstica: el modelo principal necesita otras herramientas de explicación y no debe comprimirse artificialmente.




Figura 64: Entrenamiento del modelo simbolico surrogate.




Figura 65: Búsqueda evolutiva de expresiones simbolicas.

Lectura práctica recomendada en la memoria.

En este trabajo, la regresión simbólica debe leerse como *explicador complementario*: aporta valor cuando consigue fidelidad suficiente con complejidad controlada. Si no alcanza ese equilibrio, su papel sigue siendo útil como evidencia de que el modelo no se deja comprimir bien en una sola expresión y debe interpretarse con el conjunto SHAP + ICE/ALE + diagnóstico por superficie + vecinos.

ENTRENAMIENTO PROGRESSIVE ATM

El entrenamiento progressive ATM se desarrolló como estudio paralelo para intentar mejorar el aprendizaje de la superficie. Su hipótesis de partida es financiera: la región ATM suele ser más líquida y central para la formación del nivel de volatilidad, mientras que los extremos de moneyness pueden contener más ruido, menor frecuencia o mayor sensibilidad a microestructura.

El procedimiento ordena las observaciones por distancia a ATM:

$$d_{ATM} = |\log(F/K)|. \quad (27)$$

Después divide el entrenamiento en segmentos. En la configuración actual se usan tres segmentos. Los modelos no iterativos reciben pesos mayores para tramos más cercanos al ATM; los modelos iterativos entrenan de forma acumulativa, empezando por la zona central e incorporando progresivamente tramos más alejados.

Si hay S segmentos ordenados de ATM a tramos más alejados, los pesos conceptuales decrecen con el segmento:

$$w_s \propto S - s, \quad \tilde{w}_i = \frac{w_i}{\bar{w}}. \quad (28)$$

La diferencia por familia es relevante: regresión lineal y Random Forest usan pesos de muestra; XGBoost reparte estimadores entre fases acumulativas; y las redes entrenan sucesivamente sobre datasets acumulados. En los resultados de este trabajo, progressive ATM mejora Quantum Inspired pero no mejora al Random Forest seleccionado. Por tanto, se conserva como estrategia analítica útil, pero no como regla general de entrenamiento.

Desde el punto de vista operativo, el enfoque progressive ATM debe leerse como una hipótesis controlada.

- Hipótesis financiera: la zona ATM concentra parte relevante de la señal más líquida y estable.
- Hipótesis algorítmica: algunas arquitecturas pueden beneficiarse de aprender primero esa región central antes de absorber tramos más alejados y ruidosos.
- Criterio de aceptación: sólo merece mantenerse si mejora test o si aporta una ventaja clara en suavidad y lectura de superficie sin degradar el resto.

En este trabajo, la evidencia es mixta.

- Resulta útil para la variante Quantum Inspired.
- Es prácticamente neutro en Random Forest.
- Deteriora el resultado final en otras familias como XGBoost o la red secuencial.

Eso obliga a una conclusión metodológica sobria: progressive ATM es una estrategia interesante para explorar, no una mejora universal ni una receta que deba imponerse a todas las familias.

BIBLIOGRAFÍA

- Daniel W. Apley and Jingyu Zhu. Visualizing the effects of predictor variables in black box supervised learning models. *Journal of the Royal Statistical Society: Series B*, 82(4):1059–1086, 2020.
- Fischer Black. The pricing of commodity contracts. *Journal of Financial Economics*, 3(1-2):167–179, 1976.
- Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- Miles Cranmer. Interpretable machine learning for science with PySR and symboli-cregression.jl. *arXiv preprint arXiv:2305.01582*, 2023.
- Emanuel Derman and Michael B. Miller. *The Volatility Smile*. Wiley, 2016.
- Alex Goldstein, Adam Kapelner, Justin Bleich, and Emil Pitkin. Peeking inside the black box: Visualizing statistical learning with plots of individual conditional expectation. *Journal of Computational and Graphical Statistics*, 24(1):44–65, 2015.
- Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.
- John C. Hull. *Options, Futures, and Other Derivatives*. Pearson, 11 edition, 2022.
- Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.