



UNIVERSIDAD
DE GRANADA

VOLATILIDAD IMPLICITA EXPLICABLE EN OPCIONES SOBRE EL IBEX

PEDRO GALLEGO LOPEZ

Trabajo Fin de Master

Master en Inteligencia Artificial y Computacion Cuantica Aplicada a los Mercados Financieros

Tutores

Tutor academico por determinar

Tutor profesional por determinar

INSTITUTO BME

BOLSAS Y MERCADOS ESPAÑOLES

Madrid, Mayo de 2026

DECLARACION DE ORIGINALIDAD

El autor declara que esta memoria describe un trabajo desarrollado en el contexto del Trabajo Fin de Master y que las fuentes externas utilizadas se citan en la bibliografía. La documentación técnica del repositorio, situada en doc/docs/, se ha empleado como fuente principal para reconstruir el diseño, la metodología, los resultados y los anexos técnicos del proyecto.

LICENCIA Y AVISO

La memoria tiene finalidad academica. Los resultados y ejemplos incluidos no constituyen recomendacion de inversion, valoracion oficial de cartera ni asesoramiento financiero. Las referencias a BME, MEFF, ECB, EONIA, euro short-term rate y otros elementos de mercado se utilizan para contextualizar el estudio y la procedencia conceptual de los datos y procedimientos.

La plantilla LaTeX conserva la estructura tecnica de la plantilla classicthesis utilizada como referencia en el proyecto indicado por el autor. El contenido de esta memoria ha sido adaptado al Trabajo Fin de Master sobre volatilidad implicita explicable.

RESUMEN

Este Trabajo Fin de Master desarrolla una cadena completa para estimar y explicar la volatilidad implícita de opciones sobre el IBEX a partir de operaciones reales de mercado. La volatilidad implícita no se observa directamente: se obtiene invirtiendo un modelo de valoración, en este caso Black-76, para encontrar la volatilidad que hace compatible el precio teórico con el precio negociado. Sobre esa base se construye un conjunto de datos depurado, se entrenan varias familias de modelos de regresión y se genera un dashboard orientado a inspeccionar tanto el rendimiento como el comportamiento financiero del modelo.

La metodología combina un ETL reproducible, validaciones de calidad, feature engineering financiero, particiones temporales sin fuga de información, búsqueda de hiperparámetros mediante k-folds temporales y evaluación final fuera de muestra. Se comparan regresión lineal, Random Forest, XGBoost, redes neuronales secuenciales y una red neuronal inspirada en tensor-train. Los resultados muestran que los modelos no lineales capturan mejor la superficie de volatilidad que el baseline lineal; en las ejecuciones disponibles, Random Forest alcanza el mejor compromiso cuantitativo, con RMSE de test cercano a 0,0884 y R^2 de test cercano a 0,791.

La contribución principal del trabajo no es solo predictiva, sino explicable. El sistema transforma el modelo final en artefactos de interpretabilidad global y local: SHAP, curvas ICE y ALE, superficies de volatilidad, árboles surrogate, regresión simbólica, vecinos cercanos y diagnósticos de residuos. Estos elementos permiten analizar que variables sostienen una predicción, donde falla el modelo y hasta que punto las aproximaciones interpretables son fieles al estimador principal.

ABSTRACT

This Master's thesis develops an end-to-end pipeline to estimate and explain the implied volatility of IBEX options from real market transactions. Implied volatility is not directly observed: it is obtained by inverting a pricing model, here Black-76, in order to find the volatility that makes the theoretical price consistent with the traded price. The resulting dataset is cleaned, validated and used to train several regression model families. A dashboard then turns the selected model into an inspectable system rather than a purely predictive black box.

The methodology combines a reproducible ETL, data quality checks, financial feature engineering, chronological train-validation-test splits, temporal k-fold hyperparameter search and final out-of-sample evaluation. Linear regression, Random Forest, XGBoost, sequential neural networks and a tensor-train-inspired neural network are compared under a common modelling interface. The available results show that non-linear models capture the volatility surface more effectively than the linear baseline. Among the reported final-test runs, Random Forest provides the best quantitative compromise, with a test RMSE close to 0.0884 and a test R^2 close to 0.791.

The main contribution is not only predictive accuracy but explainability. The final model is converted into global and local interpretability artifacts: SHAP values, ICE and ALE curves, volatility surfaces, surrogate trees, symbolic regression, nearest neighbours and residual diagnostics. These artifacts make it possible to understand which variables support a prediction, where the model fails, and how faithful the interpretable approximations are to the main estimator.

ÍNDICE GENERAL

DECLARACION DE ORIGINALIDAD	2
LICENCIA Y AVISO	3
RESUMEN	4
ABSTRACT	5
INTRODUCCION	10
I. MEMORIA	11
1. INTRODUCCION	12
1.1. Planteamiento del problema	12
1.2. Justificacion academica y profesional	13
1.3. Antecedentes	13
1.4. Objetivos	14
1.5. Contribucion del TFM	15
1.6. Estructura del documento	15
1.7. Preguntas de investigacion	16
1.8. Alcance y exclusiones	16
1.9. Criterios de exito	17
2. MARCO TEORICO	18
2.1. Opciones, futuros y volatilidad implicita	18
2.2. Modelo Black-76	19
2.3. Superficie de volatilidad	19
2.4. Aprendizaje automatico supervisado	20
2.5. Familias de modelos	20
2.6. Validacion temporal y sesgos	21
2.7. Explicabilidad global y local	21
2.8. Respuesta funcional: ICE y ALE	22
2.9. Modelos equivalentes	22
2.10. Tipos de interes y descuento	23
2.11. Moneyness y vencimiento como ejes financieros	23
2.12. Errores y residuos en volatilidad	23
2.13. Explicabilidad y gobernanza de modelos	24
2.14. Complejidad frente a interpretabilidad	24
2.15. Riesgo de medicion en volatilidad implicita	25
2.16. Densidad de datos y extrapolacion	25

3.	METODOLOGIA	26
3.1.	Diseno del estudio	26
3.2.	Fuentes de datos y alcance temporal	26
3.3.	Pipeline ETL	27
3.3.1.	Read Raw Step	27
3.3.2.	Merge Raw Step	27
3.3.3.	Product Split Step	27
3.3.4.	Underlying Step	28
3.3.5.	Volatility Step	28
3.4.	Validaciones de calidad	28
3.5.	Base final y estadísticas descriptivas	29
3.6.	Variables de modelado	29
3.7.	Particiones temporales	30
3.8.	Entrenamiento y seleccion	30
3.9.	Reentrenamiento y progressive training	31
3.10.	Construcción del dashboard	31
3.11.	Operación y despliegue	32
3.12.	Protocolo reproducible de ejecución	32
3.13.	Manejo de contratos compartidos	32
3.14.	Tratamiento de outliers	33
3.15.	Feature engineering financiero	33
3.16.	Justificación de familias	34
3.17.	Metadatos como parte del resultado	34
3.18.	Construcción de artefactos explicables	34
3.19.	Criterios de lectura de resultados	35
3.20.	Calidad de software	35
3.21.	Gestión de dependencias	36
3.22.	Ciclo de vida de una predicción	36
3.23.	Razonamiento sobre muestras del dashboard	36
4.	RESULTADOS Y DISCUSION	38
4.1.	Hallazgo principal	38
4.2.	Resultados cuantitativos	38
4.3.	Interpretación del rendimiento	39
4.4.	Discusión sobre progressive training	39
4.5.	Explicabilidad global	40
4.6.	Explicabilidad local	41
4.7.	Superficies, ICE y ALE	41
4.8.	Diagnóstico de errores	42
4.9.	Respuesta a la pregunta de investigación	42
4.10.	Limitaciones	42
4.11.	Comparación detallada de modelos	43

4.12.	Generalizacion temporal	44
4.13.	Lectura financiera de los resultados	44
4.14.	Discusion sobre datos y filtros	44
4.15.	Coherencia de explicaciones	45
4.16.	Uso ante un tribunal o usuario profesional	45
4.17.	Riesgos residuales	46
4.18.	Escenarios de uso	46
4.19.	Comparacion con un enfoque puramente teorico	47
4.20.	Discusion sobre ausencia de resultados visuales en la memoria	47
4.21.	Sintesis interpretativa	47
5.	CONCLUSIONES	49
5.1.	Conclusiones principales	49
5.2.	Implicaciones practicas	50
5.3.	Lineas futuras	50
5.4.	Balance final	51
5.5.	Recomendaciones de uso	51
5.6.	Trabajo pendiente para una version final entregable	51
II.	ANEXOS	54
A.	ANEXO A: REPOSITORIO Y CONFIGURACION	55
A.1.	Estructura logica	55
A.2.	Configuracion centralizada	55
A.3.	Paquetes de src	56
A.4.	Artefactos persistidos	56
B.	ANEXO B: PIPELINE DE DATOS	57
B.1.	Vision general del ETL	57
B.2.	Read Raw Step	57
B.3.	Merge Raw Step	57
B.4.	Product Split Step	58
B.5.	Underlying Step	58
B.6.	Volatility Step	58
B.7.	Columnas finales	58
C.	ANEXO C: MODELOS DE VOLATILIDAD	59
C.1.	Vision general	59
C.2.	Caracteristicas	59
C.3.	Splits y k-folds	59
C.4.	Entrenamiento	60
C.5.	Reentrenamiento	60
C.6.	Familias	60
D.	ANEXO D: DASHBOARD Y EXPLICABILIDAD	61
D.1.	Cometido del dashboard	61

D.2.	De modelo a bundle	61
D.3.	Explicabilidad global	61
D.4.	Superficies y respuesta	62
D.5.	Explicabilidad local	62
D.6.	Diagnostico	62
E.	ANEXO E: OPERACION, API Y DESPLIEGUE	63
E.1.	API	63
E.2.	Almacenamiento	63
E.3.	Docker y Terraform	63
E.4.	Activos estaticos de documentacion	63
F.	ANEXO F: MATRIZ DE TRAZABILIDAD DE DOCUMENTACION	65
F.1.	Inicio y repositorio	65
F.2.	Datos	65
F.3.	Modelos	66
F.4.	Dashboard	66
F.5.	Operacion y activos de documentacion	67

INTRODUCCION

MOTIVACION INICIAL

La volatilidad implícita es una de las magnitudes más usadas para resumir el precio de las opciones. En la práctica profesional no se interpreta solamente como un parámetro técnico de un modelo de valoración, sino como una forma compacta de comparar contratos con strikes, vencimientos y condiciones de mercado distintas. Sin embargo, esa misma utilidad la convierte en una variable delicada: no se observa de manera directa, depende del modelo de inversión empleado y cambia con la microestructura de negociación.

El proyecto que se documenta en esta memoria parte de operaciones reales de opciones y futuros sobre el IBEX. A partir de contratos, ejecuciones y curvas de tipos, se construye una base de volatilidad implícita, se entrena un conjunto de modelos de regresión y se exponen sus predicciones mediante artefactos explicables. La pregunta central es si se puede construir una herramienta que aproxime la volatilidad implícita con calidad suficiente y, al mismo tiempo, permita inspeccionar por qué predice lo que predice.

Esta introducción se desarrolla con más detalle en el capítulo [1](#). Aquí se anticipa la idea principal: en un contexto financiero regulado, un modelo preciso pero opaco resulta insuficiente. La explicabilidad no se trata como un complemento estético, sino como un requisito para diagnosticar comportamiento, detectar regiones de riesgo y comunicar limitaciones.

Parte I

MEMORIA

Fundamentos teoricos, disen0 experimental y resultados de la estimacion
explicable de volatilidad implicita.

INTRODUCCION

1.1 PLANTEAMIENTO DEL PROBLEMA

El precio de una opcion resume informacion sobre expectativas, cobertura, liquidez, microestructura y aversion al riesgo. Para comparar contratos distintos no basta con mirar su precio monetario, porque una opcion con vencimiento corto, otra con vencimiento largo, una call fuera de dinero y una put muy dentro de dinero tienen escalas de precio diferentes. La volatilidad implicita proporciona una normalizacion: es la volatilidad que, introducida en un modelo de valoracion, reproduce el precio negociado en mercado.

El problema de investigacion de este trabajo se formula asi: dado un contrato de opcion sobre el IBEX, su strike, su tipo call/put, el precio del futuro subyacente, el tiempo hasta vencimiento y el tipo de interes aplicable, se quiere estimar la volatilidad implicita y explicar los factores que sostienen esa estimacion. La funcion objetivo puede escribirse como:

$$\hat{\sigma} = f(\text{tipo}, K, F, \tau, r),$$

donde K es el strike, F es el precio del futuro subyacente, τ el tiempo hasta vencimiento y r el tipo libre de riesgo usado en la valoracion. La variable objetivo σ procede de resolver:

$$P_{\text{mercado}} = P_{\text{Black76}}(F, K, \tau, r, \sigma).$$

Esta formulacion revela dos niveles de dificultad. El primero es financiero y numerico: construir una base fiable de volatilidades implicitas requiere unir operaciones, contratos, futuros subyacentes y curvas de tipos, y despues resolver una ecuacion no lineal por cada operacion valida. El segundo es estadistico: una vez calculada la

volatilidad implícita, hay que aprender una superficie que no es lineal, que presenta smiles, cambios por vencimiento y sensibilidad distinta en zonas at-the-money y en alas.

1.2 JUSTIFICACION ACADEMICA Y PROFESIONAL

El interés académico del trabajo reside en unir tres áreas que suelen tratarse por separado. La primera es la valoración de derivados, con Black-76 como modelo de referencia para opciones sobre futuros [3]. La segunda es el aprendizaje automático aplicado a datos tabulares financieros, donde los modelos de árboles, boosting y redes neuronales compiten con baselines lineales. La tercera es la explicabilidad, que permite examinar atribuciones globales y locales mediante técnicas como SHAP [10], ICE [8], ALE [1], árboles surrogate y regresión simbólica.

El interés profesional es aún más directo. En un entorno de mercado no basta con que un modelo produzca una cifra. Los equipos de riesgo, validación, tecnología y negocio necesitan responder preguntas operativas: que variables dominan la predicción, que regiones de moneyness o vencimiento concentran error, si una predicción concreta está apoyada por observaciones históricas cercanas, y si una aproximación interpretable reproduce con fidelidad el comportamiento del modelo principal. Por tanto, la explicabilidad se incorpora como parte del producto final y no como una fase posterior.

1.3 ANTECEDENTES

La literatura clásica de valoración de opciones parte de Black-Scholes y sus extensiones. Para opciones sobre futuros, Black-76 adapta la estructura de valoración al precio forward o futuro [3]. La volatilidad implícita se usa posteriormente como representación de mercado, porque permite pasar del precio observado a una magnitud comparable entre contratos. La idea de superficie de volatilidad aparece cuando se observa que la volatilidad implícita no es constante, sino que depende del strike y del vencimiento; este hecho motiva aproximaciones de smiles, skews y term structures, así como modelos de volatilidad local o estocástica [7, 9, 2].

En aprendizaje automático, los modelos de árboles y ensembles han demostrado buen comportamiento en datos tabulares. Random Forest combina múltiples árboles entrenados con aleatoriedad para reducir varianza [4]; XGBoost implementa gradient boosting regularizado y eficiente [5]. Las redes neuronales ofrecen capacidad de apro-

ximacion flexible, y las estructuras tensoriales, como tensor-train, buscan representar interacciones de forma compacta [11]. En este trabajo no se presupone a priori que la familia mas compleja sea la mejor: la comparacion se realiza mediante particiones temporales y metricas fuera de muestra.

En explicabilidad, SHAP proporciona una semantica aditiva de atribucion basada en valores de Shapley [12, 10]; ICE y ALE estudian la respuesta de la prediccion ante cambios de variables; los arboles surrogate traducen el modelo a reglas aproximadas; y la regresion simbolica busca ecuaciones cerradas que resuman relaciones no lineales [6]. El proyecto combina estas tecnicas para cubrir interpretabilidad global, local y funcional.

1.4 OBJETIVOS

El objetivo general es construir y documentar un sistema reproducible para estimar y explicar volatilidad implicita de opciones sobre el IBEX. Este objetivo se descompone en los siguientes objetivos especificos:

1. Construir una base de volatilidad implicita a partir de datos de contratos, operaciones, futuros y tipos de interes.
2. Implementar validaciones de calidad que eviten precios no positivos, vencimientos incoherentes, claves ambiguas, valores perdidos y uso de informacion posterior a la operacion.
3. Definir variables financieras compactas que representen moneyness, vencimiento, tipo de interes y tipo de opcion sin introducir identificadores que faciliten memorizacion.
4. Comparar varias familias de modelos bajo una interfaz comun y con separacion temporal entre entrenamiento, validacion y test.
5. Seleccionar modelos mediante metricas de error y criterios de robustez, evitando lookahead bias y data snooping.
6. Transformar el modelo final en artefactos explicables que permitan auditar rendimiento, drivers globales, predicciones locales y comportamiento de superficie.
7. Documentar todos los componentes del repositorio, incluidos datos, modelos, dashboard, API, configuracion y despliegue.

1.5 CONTRIBUCION DEL TFM

La contribucion del trabajo es una arquitectura completa que conecta datos de mercado, calculo financiero, aprendizaje automatico y explicabilidad. La memoria no se limita a presentar un experimento aislado. Describe una cadena operativa en la que cada etapa materializa su salida, valida sus entradas y conserva metadatos suficientes para reproducir decisiones.

El resultado final tiene tres capas. La primera es la capa de datos, que produce VOLATILITY_DB con 312.615 observaciones validas de opciones entre el 2 de enero de 2017 y el 28 de junio de 2022. La segunda es la capa de modelado, que compara familias lineales, ensembles y redes bajo el mismo protocolo. La tercera es la capa de explicabilidad, que genera un bundle de dashboard autocontenido con predicciones, residuos, SHAP, superficies, curvas de respuesta, vecinos y modelos equivalentes.

La aportacion especifica esta en hacer que la explicabilidad sea verificable. Un arbol surrogate o una expresion simbolica no se presentan como verdad de mercado, sino como aproximaciones al modelo principal con metricas de fidelidad. Del mismo modo, una contribucion SHAP local se complementa con vecinos cercanos y diagnostico de soporte historico. Esta distincion es fundamental para no confundir interpretacion del modelo con causalidad financiera.

1.6 ESTRUCTURA DEL DOCUMENTO

El capitulo 2 desarrolla los fundamentos teoricos de volatilidad implicita, Black-76, aprendizaje automatico y explicabilidad. El capitulo 3 describe la metodologia replicable: fuentes de datos, ETL, validaciones, features, particiones, familias de modelos y generacion del dashboard. El capitulo 4 presenta los resultados cuantitativos y discute su interpretacion financiera y tecnica. El capitulo 5 sintetiza los hallazgos, limitaciones y lineas futuras.

Los anexos recogen la documentacion tecnica disponible en doc/docs/. Se han organizado por repositorio, datos, modelos, dashboard, operacion y una matriz de trazabilidad que menciona cada pagina Markdown fuente. De este modo, la memoria principal mantiene una narrativa academica y los anexos conservan el detalle operativo necesario para reproducir el sistema.

1.7 PREGUNTAS DE INVESTIGACION

La pregunta general se descompone en preguntas mas concretas que guian la memoria:

1. Que procedimiento permite transformar operaciones de mercado en una base de volatilidad implicita suficientemente limpia para entrenar modelos.
2. Que representacion de variables financieras evita memorizar contratos y conserva informacion economica relevante.
3. Que familias de modelos equilibran capacidad predictiva, estabilidad temporal y facilidad de explicacion.
4. Que tecnicas de explicabilidad son adecuadas para auditar un modelo de volatilidad implicita desde perspectivas global, local y funcional.
5. Que limitaciones aparecen al interpretar un modelo entrenado sobre volatilidades calculadas y no observadas directamente.

Estas preguntas reflejan que el TFM no es solamente una competicion de modelos. Si el objetivo fuera minimizar una metrica en un conjunto de test, bastaria con presentar la tabla de resultados. En cambio, el valor del trabajo esta en mostrar una cadena completa: desde la lectura de ficheros hasta la explicacion local de una prediccion concreta.

1.8 ALCANCE Y EXCLUSIONES

El alcance del trabajo se limita a opciones sobre IBEX y futuros asociados disponibles en el repositorio. Se estudian operaciones comprendidas entre 2017 y junio de 2022. La memoria no intenta calibrar un modelo teorico de volatilidad estocastica ni construir una superficie arbitrage-free de produccion. Tampoco pretende proporcionar precios de mercado oficiales. El foco es construir una aproximacion supervisada de la volatilidad implicita calculada y hacerla inspeccionable.

Quedan fuera del alcance varias extensiones relevantes: incorporar order book, modelar spreads bid-ask, incluir variables macroeconomicas, analizar dividendos de manera independiente, estudiar otros indices o comparar mercados internacionales. Estas exclusiones no restan interes al trabajo; delimitan un problema abordable con los datos y codigo disponibles.

1.9 CRITERIOS DE EXITO

El trabajo se considera satisfactorio si cumple cuatro criterios. Primero, la base final debe ser trazable: cada columna importante debe poder explicarse desde una fuente o transformacion. Segundo, el protocolo de evaluacion debe ser temporal y evitar fugas. Tercero, el modelo seleccionado debe superar de forma clara al baseline lineal. Cuarto, el dashboard debe permitir explicar tanto el rendimiento agregado como predicciones individuales.

Estos criterios son deliberadamente mas amplios que una metrica unica. En finanzas, la confianza en un modelo surge de una combinacion de datos, metodologia, resultados, diagnostico y gobernanza. Un modelo con buen RMSE pero sin trazabilidad puede ser inutil para validacion; un modelo muy interpretable pero impreciso puede servir como benchmark, pero no como predictor final; un dashboard visualmente rico pero sin fidelidad de surrogates puede inducir conclusiones erroneas.

MARCO TEORICO

2.1 OPCIONES, FUTUROS Y VOLATILIDAD IMPLICITA

Una opcion financiera otorga a su comprador el derecho, pero no la obligacion, de comprar o vender un activo subyacente en condiciones predefinidas. En una call, el derecho es comprar; en una put, vender. El strike K fija el precio de ejercicio y el vencimiento determina el horizonte temporal del contrato. En el caso estudiado, las opciones se negocian sobre el IBEX y se relacionan con futuros mensuales que actuan como subyacente operativo.

El precio de una opcion depende de varias magnitudes: nivel del subyacente, strike, tiempo hasta vencimiento, tipo de interes, dividendos o carry, y volatilidad esperada. La volatilidad no entra como una variable observable directa. En la practica se invierte un modelo de valoracion: se busca la volatilidad que iguala el precio teorico al precio observado. Esa volatilidad se denomina volatilidad implicita y se interpreta como una representacion de mercado, no como una estimacion directa de volatilidad historica.

La volatilidad implicita tiene ventajas claras. Permite comparar opciones de precios absolutos muy distintos, estudiar la estructura por vencimientos y strikes, y detectar patrones como smiles y skews. Tambien tiene limitaciones: depende del modelo de valoracion usado, puede ser inestable en opciones iliquidas, y puede amplificar errores de precio, tiempo o tipo de interes. Por eso la construccion del dataset es parte central de la metodologia.

2.2 MODELO BLACK-76

Black-76 valora opciones europeas sobre futuros. Si F es el precio del futuro, K el strike, r el tipo libre de riesgo, T el tiempo hasta vencimiento y σ la volatilidad, las formulas de call y put son:

$$C = e^{-rT} (FN(d_1) - KN(d_2)),$$

$$P = e^{-rT} (KN(-d_2) - FN(-d_1)),$$

donde:

$$d_1 = \frac{\ln(F/K) + \frac{1}{2}\sigma^2 T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}.$$

El proyecto usa esta relacion en sentido inverso. Para cada operacion de opcion se conocen precio negociado, strike, tipo de opcion, vencimiento, tipo compuesto y futuro subyacente asociado. La volatilidad implicita es la raiz de la ecuacion:

$$g(\sigma) = P_{Black76}(F, K, T, r, \sigma) - P_{mercado} = 0.$$

El problema numerico exige acotar el dominio de busqueda, tratar casos degenerados y descartar observaciones que no admiten una solucion coherente. La configuracion del repositorio fija un rango de volatilidad entre 10^{-8} y 10, tolerancia 10^{-8} y filtros adicionales sobre tipo de operacion y lag maximo del subyacente. Estas decisiones no son detalles de implementacion menores: determinan que precios entran en el estudio.

2.3 SUPERFICIE DE VOLATILIDAD

Si Black-76 asumiera volatilidad constante, todas las opciones sobre el mismo subyacente y vencimiento compartirian la misma volatilidad. El mercado real no se comporta asi. La volatilidad implicita suele depender de la moneyness y del vencimiento. La moneyness mide la posicion relativa del strike frente al subyacente; una forma comun y estable es la log-moneyness:

$$m = \ln \left(\frac{K}{F} \right).$$

En este trabajo tambien se considera la forward moneyness, que incorpora el ajuste temporal por tipo de interes. La superficie resultante permite observar smiles, alas y term structures. Modelar esa superficie con aprendizaje automatico equivale a aproximar una funcion no lineal con restricciones economicas implicitas: suavidad razonable, sensibilidad distinta por zonas y comportamiento interpretable ante cambios de vencimiento, strike o subyacente.

2.4 APRENDIZAJE AUTOMATICO SUPERVISADO

El problema de modelado se plantea como regresion supervisada. Cada observacion contiene un vector de caracteristicas X_i y una volatilidad implicita observada y_i . El modelo aprende una funcion f y produce $\hat{y}_i = f(X_i)$. Las metricas principales son MAE, RMSE y R^2 :

$$MAE = \frac{1}{n} \sum_i |y_i - \hat{y}_i|,$$

$$RMSE = \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2},$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

El MAE mide el error medio en unidades de volatilidad y es robusto ante errores extremos. El RMSE penaliza mas los errores grandes y se usa como metrica principal de seleccion. El R^2 mide la proporcion de variabilidad explicada frente a un predictor constante.

2.5 FAMILIAS DE MODELOS

La regresion lineal se usa como baseline. Su principal ventaja es la interpretabilidad: cada coeficiente resume una sensibilidad promedio condicionada a las demas variables. Su limitacion es evidente en una superficie de volatilidad no lineal: solo captura curvatura si se introducen transformaciones y terminos de interaccion.

Random Forest promedia arboles entrenados sobre muestras bootstrap y subconjuntos de variables. Es robusto, capta interacciones y no exige escalado de variables. Su prediccion es dificil de expresar en una formula compacta, pero puede analizarse con SHAP, arboles surrogate y diagnosticos de superficie.

XGBoost construye un ensamble secuencial de arboles. Cada arbol corrige errores residuales del conjunto anterior y la regularizacion controla complejidad. En datos tabulares suele ser competitivo, aunque su comportamiento tambien requiere herramientas de explicabilidad para entender dependencias y regiones de error.

Las redes neuronales secuenciales aproximan funciones no lineales mediante capas densas. Requieren escalado numerico y mecanismos de control como early stopping. La red inspirada en tensor-train introduce una estructura compacta para representar interacciones, con la intencion de reducir parametros y organizar la complejidad.

2.6 VALIDACION TEMPORAL Y SESGOS

En datos financieros, la validacion aleatoria puede producir conclusiones optimistas. Si observaciones futuras influyen en el entrenamiento, aparece lookahead bias. Si los hiperparametros se seleccionan mirando el conjunto de test, aparece data snooping. El proyecto evita estas fugas mediante separacion temporal: train precede a validation y validation precede a test. Ademas, se controla que un mismo contrato de opcion no aparezca simultaneamente en particiones distintas.

La exclusividad por contrato es relevante porque un contrato puede negociarse durante varios dias. Si un modelo ve un contrato en entrenamiento y despues se evalua sobre el mismo contrato en test, puede aprender características idiosincraticas de ese contrato y sobrestimar su capacidad de generalizacion.

2.7 EXPLICABILIDAD GLOBAL Y LOCAL

La explicabilidad global busca responder que variables gobiernan el modelo en conjunto. SHAP permite descomponer una prediccion en una suma de contribuciones:

$$f(x) = \phi_0 + \sum_{j=1}^p \phi_j.$$

El valor base ϕ_0 representa la prediccion media de referencia y cada ϕ_j mide la contribucion atribuida a una variable. El repositorio usa un explicador por permutacion, adecuado para tratar como caja negra familias heterogeneas.

La explicabilidad local se centra en una prediccion concreta. Un waterfall SHAP muestra que variables empujan la prediccion hacia arriba o hacia abajo respecto al valor base. Los vecinos cercanos aportan otra dimension: indican si la muestra tiene soporte historico en el espacio de features o si se parece poco a las observaciones de entrenamiento.

2.8 RESPUESTA FUNCIONAL: ICE Y ALE

Las curvas ICE muestran como cambia la prediccion de muestras individuales cuando se modifica una variable y se mantienen las demas constantes. Son utiles para observar heterogeneidad: dos opciones pueden reaccionar de forma distinta a cambios de moneyness o vencimiento. Su riesgo es generar contrafactuales irreales cuando combina valores que no aparecen en mercado.

Las curvas ALE miden efectos acumulados locales y reducen parte del problema de extrapolacion al usar intervalos donde existen datos. Por ello son especialmente utiles cuando las variables estan correlacionadas. En este TFM, ICE y ALE se interpretan conjuntamente: ICE muestra dispersion individual; ALE resume tendencia media local.

2.9 MODELOS EQUIVALENTES

Los arboles surrogate y la regresion simbolica aproximan las predicciones del modelo principal, no la volatilidad verdadera. Esta distincion es central. Un surrogate con baja fidelidad no debe usarse para explicar el modelo principal; un surrogate con alta fidelidad puede resumir reglas o formulas utiles, pero sigue heredando las limitaciones del estimador que imita.

El dashboard conserva metricas de fidelidad como RMSE, MAE y R^2 entre predicciones del surrogate y predicciones del modelo principal. Esta capa ayuda a comunicar modelos complejos ante usuarios tecnicos y no tecnicos sin presentar reglas simplificadas como certezas absolutas.

2.10 TIPOS DE INTERES Y DESCUENTO

En Black-76 el tipo de interes entra como factor de descuento e^{-rT} . En periodos de tipos cercanos a cero o negativos, como buena parte del intervalo 2017–2022 en Europa, su impacto puede parecer secundario frente a moneyness y vencimiento. Aun así, ignorarlo introduce una inconsistencia: dos opciones identicas en strike y futuro pero con vencimientos distintos no tienen el mismo descuento.

El proyecto combina EONIA y euro short-term rate. La transicion entre referencias se controla por fecha de corte y spread configurado. Esta parte es importante porque el tipo usado en el solver no es un simple valor puntual: debe ser compatible con el periodo hasta vencimiento. En la base final el tipo medio es negativo, lo que obliga a no asumir formulas simplificadas pensadas para entornos de tipos positivos.

2.11 MONEYNES Y VENCIMIENTO COMO EJES FINANCIEROS

La moneyness resume donde se encuentra el strike respecto al subyacente. En opciones at-the-money, pequenos cambios en volatilidad suelen tener gran impacto en precio. En opciones muy dentro o fuera de dinero, la sensibilidad puede comportarse de manera distinta y depender mas de liquidez, vencimiento y precision del precio observado. Por ello, segmentar o diagnosticar por moneyness es esencial.

El vencimiento introduce otra dimension. A vencimientos cortos, el precio puede ser muy sensible a pequenos errores de tiempo o de subyacente. A vencimientos largos, la superficie puede incorporar expectativas mas amplias y menor densidad de operaciones. El producto de log-moneyness y raiz de vencimiento incluido en las features busca capturar que el efecto de alejarse de ATM no es igual en todos los horizontes.

2.12 ERRORES Y RESIDUOS EN VOLATILIDAD

Medir error en volatilidad implicita requiere cuidado. Un error absoluto de 0,05 puede ser moderado o elevado segun el nivel de volatilidad, vencimiento y uso operativo. No obstante, MAE y RMSE son adecuados como primera aproximacion porque trabajan en la misma escala que la variable objetivo. El RMSE penaliza errores grandes y, por tanto, es especialmente util para detectar modelos que fallan en regiones extremas.

El residual $y - \hat{y}$ conserva signo. Si es positivo, el modelo subestima la volatilidad implícita; si es negativo, la sobreestima. En un contexto de cobertura, ambos errores pueden tener implicaciones distintas. Una subestimación sistemática en las alas podría infravalorar riesgo de movimientos extremos; una sobreestimación sistemática podría sesgar decisiones de precio o margen.

2.13 EXPLICABILIDAD Y GOBERNANZA DE MODELOS

La explicabilidad en este TFM se aproxima a la gobernanza de modelos. No se limita a dibujar importancias. Un modelo gobernable debe permitir reconstruir datos, justificar selección de hiperparámetros, comprobar rendimiento fuera de muestra, localizar fallos y comunicar límites. SHAP, ICE, ALE y surrogates son herramientas dentro de ese marco.

También hay que reconocer sus riesgos. SHAP depende de una distribución de referencia y de cómo se tratan dependencias entre variables. ICE puede mostrar contrafactuales sin soporte histórico. ALE reduce ese problema, pero resume efectos medios locales. Un árbol surrogate puede parecer claro y aun así tener fidelidad insuficiente. La regresión simbólica puede encontrar una fórmula compacta pero inestable fuera de muestra. Por eso el dashboard combina explicadores y conserva métricas de fidelidad.

2.14 COMPLEJIDAD FRENTE A INTERPRETABILIDAD

La relación entre complejidad e interpretabilidad no es lineal. Un modelo lineal es fácil de leer, pero si no captura la superficie, sus coeficientes explican una aproximación pobre. Un Random Forest es menos transparente internamente, pero si predice mejor y se acompaña de buenos explicadores, puede ser más útil. La interpretabilidad relevante no es solo transparencia del algoritmo, sino capacidad de responder preguntas concretas con evidencia.

Este punto justifica comparar varias familias. La regresión lineal fija el mínimo interpretable. Random Forest y XGBoost representan modelos tabulares potentes. Las redes prueban si una aproximación diferenciable y paramétrica aporta ventajas. La red tensor-train explora una estructura más compacta para interacciones. La decisión final se apoya en métricas, diagnósticos y explicabilidad.

2.15 RIESGO DE MEDICION EN VOLATILIDAD IMPLICITA

La variable objetivo del trabajo no procede de una etiqueta manual ni de una medicion fisica directa. Es el resultado de una inversion numerica. Por ello existe riesgo de medicion. Si el precio de mercado contiene ruido, si el futuro subyacente asociado no refleja exactamente el instante de la opcion, si el tipo compuesto no es representativo o si el tiempo hasta vencimiento se calcula con una convencion incorrecta, la volatilidad resultante puede desplazarse.

Este riesgo no invalida el estudio, pero condiciona su interpretacion. El modelo aprende la volatilidad implicita calculada bajo un conjunto de reglas. En consecuencia, una prediccion correcta significa coherencia con esa construccion, no necesariamente con una volatilidad “verdadera” independiente. La documentacion del ETL y de las validaciones es la forma de controlar este riesgo: cuanto mas explicitas son las reglas, mas auditable es la variable objetivo.

2.16 DENSIDAD DE DATOS Y EXTRAPOLACION

Los modelos supervisados interpolan con mayor confianza en regiones densas del espacio de entrenamiento. En opciones, la densidad no es uniforme. Suele haber mas operaciones cerca de strikes y vencimientos liquidos, y menos en alas o vencimientos largos. Esto implica que la misma metrica global puede esconder zonas con soporte muy distinto.

La explicabilidad local mediante vecinos aborda esta cuestion. Si una muestra tiene vecinos cercanos en entrenamiento, la prediccion se apoya en informacion historica comparable. Si no los tiene, la prediccion puede ser extrapolacion. El dashboard no elimina esa extrapolacion, pero la hace visible. Esta visibilidad es especialmente importante en volatilidad, donde las zonas extremas pueden ser precisamente las mas relevantes para gestion de riesgo.

METODOLOGIA

3.1 DISEÑO DEL ESTUDIO

El estudio es empírico y experimental. Es empírico porque parte de operaciones reales de mercado y de series de tipos. Es experimental porque compara varias familias de modelos bajo una metodología común y analiza el resultado con un conjunto de artefactos explicables. La unidad observacional final es una operación de opción para la que se ha podido asociar un futuro subyacente anterior o simultáneo, calcular el tiempo hasta vencimiento, obtener un tipo compuesto y resolver la volatilidad implícita.

La metodología se organiza en cuatro bloques: construcción de datos, generación de variables, entrenamiento de modelos y explicabilidad. Cada bloque produce artefactos persistentes. Esta decisión facilita la replicabilidad: una etapa puede reejecutarse, validarse y depurarse sin recomputar todo el proyecto.

3.2 FUENTES DE DATOS Y ALCANCE TEMPORAL

El repositorio trabaja con ficheros de mercado de 2017 a 2022, contratos, operaciones y series EONIA/euro short-term rate. La configuración declara `first_year=2017` y `last_year=2022`. Las fuentes se transforman en bases intermedias:

- `CCONTRACTS_C2`: información contractual, strike y vencimiento.
- `TGENTRADES`: operaciones ejecutadas, precio, cantidad, hora y contrato.
- `RATES_DATABASE`: tipos usados para calcular el tipo compuesto hasta vencimiento.

El dominio se restringe a opciones y futuros sobre IBEX con vencimientos mensuales. Las opciones semanales y contratos fuera del dominio se descartan para mantener coherencia entre producto modelado y subyacente asociado.

3.3 PIPELINE ETL

El ETL se implementa como una secuencia de StepLoaders y builders. Los StepLoaders orquestan lectura, cache y validacion; los builders construyen las salidas materiales. La cadena documentada en `doc/docs/data/` contiene cinco pasos.

3.3.1 *Read Raw Step*

El primer paso normaliza cabeceras y tipos, filtra el universo IBEX y construye la base de tipos. La configuracion define columnas esperadas para contratos, operaciones y rates. La limpieza temprana evita que etapas posteriores mezclen problemas de lectura con problemas financieros.

3.3.2 *Merge Raw Step*

El segundo paso une operaciones y contratos por fecha de sesion y codigo de contrato. Tambien imputa vencimientos y strikes cuando pueden reconstruirse desde el codigo de contrato. La codificacion declara prefijos CIBX, PIBX y FIBX, longitudes esperadas, posiciones de mes y anio, y mapa de letras de futuros. El vencimiento se asume en el tercer viernes del mes con hora de expiracion configurada.

3.3.3 *Product Split Step*

El tercer paso separa opciones y futuros. Genera bases de operaciones de opciones, operaciones de futuros y relacion opcion-subyacente. Esta separacion es necesaria porque las opciones aportan el precio a invertir y los futuros aportan el subyacente usado por Black-76.

3.3.4 *Underlying Step*

El cuarto paso enlaza cada opcion con una ejecucion de futuro temporalmente valida mediante una union as-of. La regla fundamental es no usar informacion posterior a la operacion de la opcion. La salida incluye precio del subyacente, fecha-hora del subyacente y lag en minutos.

3.3.5 *Volatility Step*

El quinto paso filtra operaciones, calcula tipos compuestos hasta vencimiento y resuelve la volatilidad implicita. La configuracion fija un filtro de tipo de operacion M, lag maximo de subyacente de 180 minutos y parametros del solver. La salida final, VOLATILITY_DB, contiene 19 columnas y 312.615 observaciones validas.

3.4 VALIDACIONES DE CALIDAD

Las validaciones transversales son:

- Precios y cantidades positivos.
- Claves sin duplicados ambiguos.
- Ausencia de valores perdidos en salidas materializadas.
- Vencimientos coherentes con codigos de contrato.
- Strike coherente con el codigo de opcion.
- Subyacente temporalmente anterior o simultaneo.
- Volatilidad implicita resoluble dentro del rango configurado.

Estas validaciones persiguen replicabilidad y calidad financiera. Una volatilidad calculada sobre un subyacente posterior, un vencimiento mal interpretado o un precio no positivo tendria apariencia numerica, pero no significado economico valido.

3.5 BASE FINAL Y ESTADISTICAS DESCRIPTIVAS

La base VOLATILITY_DB cubre operaciones entre el 2 de enero de 2017 y el 28 de junio de 2022. Contiene 151.424 calls y 161.191 puts. La volatilidad implicita media es 0,2061, con mediana 0,1738, primer cuartil 0,1419 y tercer cuartil 0,2265. El maximo observado, 8,8457, indica la presencia de casos extremos que justifican el uso de metricas robustas y diagnosticos por region.

El lag del subyacente en la base final tiene mediana 0,080 minutos y media 7,991 minutos, con maximo inferior a 180 minutos por el filtro configurado. El tiempo hasta vencimiento medio es 23,44 dias, con mediana 21,20 dias. El tipo de interes medio es negativo, -0,5511 en las unidades de la base, coherente con el periodo europeo de tipos bajos y negativos.

Base	Filas	Columnas
TRADE_IBEX_DB	16.468.230	13
OPTIONS_TRADES_DB	428.448	12
FUTURES_TRADES_DB	16.039.780	12
OPTION_TRADES_UNDERLYING_DB	428.448	16
VOLATILITY_DB	312.615	19

Cuadro 1: Tamanos de las principales bases materializadas.

3.6 VARIABLES DE MODELADO

La configuracion conserva de VOLATILITY_DB fecha-hora de ejecucion, codigo de contrato, tipo de opcion, strike, precio del subyacente, tiempo hasta vencimiento, tipo de interes y volatilidad implicita. Sin embargo, no todas estas columnas se usan como predictores. La fecha-hora y el codigo de contrato se conservan para trazabilidad y particiones, no como entradas finales del modelo.

Las variables raw de entrada son tipo de opcion, strike, subyacente, tiempo hasta vencimiento y tipo. A partir de ellas se generan features financieras:

- TTEYears: tiempo hasta vencimiento en anios.
- sqrtTTEYears: raiz del tiempo, coherente con la escala de Black-76.
- logMoneyness: $\ln(K/F)$.

- `logMoneynessSq`: curvatura de la moneyness.
- `logMoneynessXSqrtTTE`: interaccion entre moneyness y vencimiento.
- `logForwardMoneyness`: moneyness ajustada forward.
- `rate`: tipo de interes.

Estas variables evitan depender de identificadores y expresan relaciones financieras conocidas. Tambien facilitan la interpretacion posterior, porque SHAP, ICE y ALE pueden relacionarse con conceptos de superficie de volatilidad.

3.7 PARTICIONES TEMPORALES

La configuracion usa `train_size=0.85` y un lag temporal de 15 dias. Los datos generados se distribuyen en:

Split	Filas	Columnas	Periodo
Train	243.791	12	2017-01-02 a 2020-11-09
Validation	26.093	12	2020-12-01 a 2021-08-10
Trainval	273.223	12	2017-01-02 a 2021-08-10
Test	36.973	12	2021-09-01 a 2022-06-28

Cuadro 2: Particiones temporales de entrenamiento y evaluacion.

La busqueda de hiperparametros se realiza dentro de train mediante cinco k-folds temporales y dos bloques extra. El test final se reserva para evaluacion y visualizacion; no interviene en la seleccion de hiperparametros.

3.8 ENTRENAMIENTO Y SELECCION

Todas las familias comparten una abstraccion comun. Cada familia declara nombre, parametros fijos, espacio de busqueda, instanciacion, entrenamiento y persistencia. Esta interfaz reduce diferencias accidentales entre modelos y permite que la comparacion se centre en capacidad predictiva y estabilidad.

La seleccion no usa solamente RMSE medio. El repositorio define metricas compuestas que penalizan desviacion entre folds y sobreajuste. Una de ellas tiene la forma:

$$CE_1 = RMSE_{val} + \alpha \cdot std(RMSE_{val}) + \beta \cdot \text{máx}(0, RMSE_{val} - RMSE_{train}).$$

Esta expresion favorece modelos con buen error medio, baja variabilidad entre folds y brecha razonable entre entrenamiento y validacion. Para redes y XGBoost se emplea early stopping. Las familias neuronales ajustan un scaler solo con los datos permitidos en cada fase.

3.9 REENTRENAMIENTO Y PROGRESSIVE TRAINING

Una vez seleccionados los hiperparametros, el modelo se reentrena. Hay una fase train/validation y una fase final test. El progressive training ordena segmentos por cercania a at-the-money e incorpora progresivamente regiones mas alejadas. La intuicion es que la zona central suele ser mas estable y liquida, mientras que las alas requieren aprender comportamientos mas extremos.

El progressive training se adapta a cada familia. Random Forest usa pesos mayores en segmentos mas cercanos a ATM. XGBoost reparte estimadores entre fases acumulativas. Las redes ajustan fases sucesivas conservando conocimiento previo. Esta variante no se asume superior en todos los casos; se evalua empiricamente.

3.10 CONSTRUCCION DEL DASHBOARD

El paquete `model2dashboard` transforma modelos entrenados en bundles visualizables. Carga el modelo final y sus metadatos, reconstruye features, genera predicciones sobre test, calcula residuos y error absoluto, y produce artefactos explicables:

- SHAP global y local.
- Arboles surrogate para varias profundidades.
- Regresion simbolica con PySR.
- Superficies de volatilidad sobre anclas representativas.

- Curvas ICE y ALE.
- Vecinos cercanos frente al split de entrenamiento.
- Diagnosticos agregados y mapas de error.

El dashboard se organiza en pestañas: Global Explainability, Behaviour and Surface, Sample Explainability y Diagnosis. Cada pestaña responde a una pregunta distinta y evita reducir la evaluación del modelo a una sola métrica.

3.11 OPERACION Y DESPLIEGUE

El repositorio incluye API con FastAPI, almacenamiento local o GCP, dockerfiles y terraform. La API permite predicción y explicabilidad local. La configuración de `clientserver.json` declara URL base, timeout, cache, rutas locales de modelos y rutas de almacenamiento cloud. Esta capa no es el foco cuantitativo del TFM, pero demuestra que el modelo puede integrarse como servicio y no solo como notebook experimental.

3.12 PROTOCOLO REPRODUCIBLE DE EJECUCION

La reproducibilidad se apoya en una secuencia fija. Primero se cargan recursos de configuración. Después se ejecuta el ETL por pasos: lectura raw, merge, split por producto, asociación de subyacente y volatilidad. A continuación se generan datos de entrenamiento y particiones. Luego se ejecuta búsqueda de hiperparámetros por familia, reentrenamiento train/validation y reentrenamiento final test. Por último, se construye el bundle del dashboard.

Esta secuencia evita dependencias implícitas. Si cambia la configuración del solver, debe regenerarse `VOLATILITY_DB`. Si cambian las features, deben regenerarse splits y modelos. Si cambia la configuración de dashboard, basta con reconstruir bundles desde modelos ya entrenados, siempre que los artefactos requeridos sigan existiendo.

3.13 MANEJO DE CONTRATOS COMPARTIDOS

Una particularidad de las opciones es que un mismo contrato puede aparecer durante muchas sesiones. Si se hiciera un split puramente por filas, el modelo podría ver

en train operaciones del mismo contrato que aparece en test. Aunque las fechas fueran distintas, el código de contrato contiene información sobre vencimiento y strike, y podría inducir una forma de memorización.

El proyecto resuelve esta situación asignando contratos compartidos a una única partición según prioridad. La regla conserva la jerarquía de evaluación: test debe permanecer limpio frente a trainval, y validation frente a train. Esta decisión sacrifica algunas filas, pero mejora la credibilidad de la evaluación fuera de muestra.

3.14 TRATAMIENTO DE OUTLIERS

La base final conserva volatilidades extremas cuando superan las validaciones del solver y de dominio. Esta decisión evita limpiar en exceso el fenómeno que se quiere modelar. Sin embargo, la presencia de un máximo de volatilidad implícita de 8,8457 obliga a interpretar RMSE con cuidado y a complementar con MAE y diagnósticos por región.

Los outliers pueden proceder de varias fuentes: opciones con precio muy pequeño, vencimientos cortos, baja liquidez, diferencias temporales entre opción y futuro, o episodios de mercado tensionado. En lugar de eliminarlos de manera manual, el proyecto los deja visibles para que el dashboard muestre donde se concentran los errores. Esta estrategia es más transparente que ocultar observaciones difíciles sin un criterio financiero documentado.

3.15 FEATURE ENGINEERING FINANCIERO

El feature engineering intenta equilibrar conocimiento financiero y aprendizaje automático. Usar strike y subyacente por separado permite que modelos no lineales descubran relaciones, pero la log-moneyness introduce una escala más natural. La raíz del tiempo hasta vencimiento se alinea con la forma de Black-76, donde la volatilidad aparece multiplicada por $\sqrt{T}$. La interacción entre log-moneyness y raíz de vencimiento permite representar que smiles y term structures no son independientes.

El tipo de opción se mantiene porque calls y puts pueden tener distinta distribución de precios y liquidez, aunque bajo paridad teórica compartan información. El tipo de interés se incluye porque afecta al descuento y a forward moneyness. La fecha y el contrato se conservan para control y trazabilidad, pero no como variables predictivas principales para evitar fuga y memorización.

3.16 JUSTIFICACION DE FAMILIAS

La regresion lineal responde a la pregunta: cuanto se puede explicar con una relacion sencilla. Random Forest responde a la pregunta: que rendimiento se logra con particiones robustas y poca necesidad de ajuste de escala. XGBoost responde a la pregunta: si un boosting regularizado mejora la frontera de error en datos tabulares. Las redes neuronales responden a la pregunta: si una funcion parametrica flexible aprovecha mejor las features continuas. La red tensor-train responde a la pregunta: si una estructura compacta de interacciones aporta ventaja frente a una red densa convencional.

No todas las familias tienen el mismo coste operacional. Los modelos lineales son baratos y faciles de versionar. Random Forest puede ocupar mas memoria y ser mas lento en inferencia si tiene muchos arboles. XGBoost suele ser eficiente, pero sus hiperparametros influyen mucho. Las redes requieren dependencias pesadas y escalado. Estas diferencias tambien importan si el modelo se expone via API.

3.17 METADATOS COMO PARTE DEL RESULTADO

Los metadatos no son un subproducto. En cada familia se guardan resultados de busqueda, parametros probados, mejor configuracion, metricas agregadas, resultados de reentrenamiento y metricas finales. En modelos con early stopping se guarda informacion de mejor iteracion o epoca. En dashboard se conserva configuracion de muestras, metricas de surrogates y parametros de explicabilidad.

Esta decision facilita auditoria. Si un modelo produce una prediccion discutible, no basta con mirar el fichero serializado. Hay que saber con que datos se entreno, que particion uso, que parametros tuvo, que rendimiento alcanzo y que explicadores se generaron. La memoria adopta esa vision: el modelo es el conjunto de estimador, datos, configuracion y metadatos.

3.18 CONSTRUCCION DE ARTEFACTOS EXPLICABLES

La construccion del dashboard no se ejecuta de forma interactiva desde cero para cada grafico. Muchos artefactos se precomputan para que la interfaz sea fluida y reproducible. Se toman muestras de test para SHAP, anclas para superficies, muestras para ICE/ALE, conjuntos para vecinos y subconjuntos para regresion simbolica. La configuracion fija tamanos y semillas.

Este enfoque tiene ventajas y compromisos. Precomputar reduce coste y estabiliza visualizaciones, pero las explicaciones se refieren a las muestras elegidas. Por eso el dashboard tambien permite entrada manual para predicciones locales, siempre con las cautelas de soporte historico. La combinacion de artefactos precomputados y calculos locales ofrece un equilibrio pragmatico.

3.19 CRITERIOS DE LECTURA DE RESULTADOS

Los resultados se leen en tres niveles. El primer nivel es cuantitativo: MAE, RMSE y R^2 en test. El segundo es estructural: residuos por moneyness, vencimiento y superficie. El tercero es explicativo: drivers SHAP, respuesta ICE/ALE, reglas surrogate, formulas simbolicas y vecinos. Un modelo solo se considera adecuado si supera razonablemente los tres niveles.

Esta jerarquia evita seleccionar un modelo solo por una metrica. Si dos modelos tienen RMSE parecido, puede preferirse el que tenga errores mas estables, explicaciones mas coherentes o mejor soporte local. Si un modelo es ligeramente mejor en RMSE pero produce superficies irregulares o surrogates de baja fidelidad, su uso operativo seria mas discutible.

3.20 CALIDAD DE SOFTWARE

El repositorio separa codigo de configuracion, datos, modelos, dashboard y API. Esta separacion facilita pruebas y mantenimiento. Los enums de columnas reducen errores por cadenas literales. Los loaders encapsulan validaciones y los builders encapsulan transformaciones. Las configuraciones JSON hacen que muchas decisiones sean modificables sin editar codigo.

La presencia de pruebas en tests/ y configuracion de pytest sugiere una orientacion a calidad. En un TFM aplicado, esta parte es relevante porque los resultados dependen de software ejecutable. Una memoria basada en notebooks aislados puede ser dificil de reproducir; una memoria conectada a paquetes, tests, configuracion y artefactos persistidos tiene mayor trazabilidad.

3.21 GESTION DE DEPENDENCIAS

El fichero `requirements.txt` incluye `pandas`, `numpy`, `scikit-learn`, `shap`, `matplotlib`, `plotly`, `dash`, `pydantic`, `fastapi`, `uvicorn`, `google-cloud-storage`, `pysr`, `keras`, `xgboost`, `tensorflow` y `mkdocs`, entre otros. Estas dependencias reflejan las capas del proyecto: datos, modelado, explicabilidad, visualizacion, API, cloud y documentacion.

La gestion de dependencias tambien afecta a replicabilidad. Versiones distintas de XGBoost, TensorFlow o SHAP pueden cambiar resultados o formatos de serializacion. Por ello, una version final del TFM deberia conservar el entorno usado para producir los metadatos de resultados. La memoria documenta los resultados disponibles, pero la reproduccion exacta requiere respetar versiones y datos.

3.22 CICLO DE VIDA DE UNA PREDICCION

El ciclo de vida de una prediccion empieza con una fila raw o una entrada manual: tipo de opcion, strike, subyacente, tiempo hasta vencimiento y tipo. El sistema transforma esas variables en features, aplica el modelo seleccionado y devuelve volatilidad predicha. Si la fila pertenece al dataset de test, puede calcular residual y error absoluto porque existe volatilidad implicita observada. Si es manual, solo hay prediccion y explicaciones condicionadas.

Despues se anaden capas de interpretacion. SHAP local explica la contribucion de cada variable. Los vecinos informan soporte historico. Las superficies e ICE/ALE contextualizan como cambiaria la prediccion si se modificara una variable. El diagnostico global permite comparar esa prediccion con patrones generales de error. Este ciclo convierte una salida numerica en una decision informada.

3.23 RAZONAMIENTO SOBREMUESTRAS DEL DASHBOARD

El dashboard no puede calcular todos los artefactos exhaustivamente para millones de combinaciones. Por eso usa muestras: background SHAP, muestras explicadas, anclas de superficie, puntos de curvas y vecinos. La configuracion fija esos tamanos para equilibrar coste y representatividad. Por ejemplo, el tamano de background SHAP controla el coste de permutaciones; el tamano de vecinos controla memoria y tiempo de consulta; el grid de superficie controla resolucion visual.

La eleccion de muestras introduce variabilidad. Para reducirla se usa semilla aleatoria. Aun asi, una conclusion basada en una visualizacion concreta debe leerse como diagnostico de la muestra usada, no como prueba universal. Esta cautela es parte de la metodologia y evita sobreinterpretar graficos.

RESULTADOS Y DISCUSION

4.1 HALLAZGO PRINCIPAL

El hallazgo principal es que los modelos no lineales superaron de forma clara a la regresion lineal en la estimacion de volatilidad implicita fuera de muestra. En las ejecuciones finales disponibles, Random Forest obtuvo el mejor resultado de test, con MAE 0,054366, RMSE 0,088403 y R^2 0,790941. XGBoost quedo cerca, con RMSE 0,091735 y R^2 0,774885. Las redes inspiradas en tensor-train mejoraron al baseline lineal, aunque quedaron por debajo de los ensembles de arboles en la mejor configuracion observada.

4.2 RESULTADOS CUANTITATIVOS

La tabla 3 resume las metricas finales. Los valores proceden de los metadatos de reentrenamiento final sobre trainval y evaluacion en test.

La regresion lineal presenta el peor RMSE y el menor R^2 . Este resultado es coherente con el marco teorico: una superficie de volatilidad real tiene curvaturas, interacciones y comportamientos por regiones que dificilmente se capturan con una aproximacion lineal global. La linealidad sigue siendo util como control de complejidad y como referencia interpretable.

Random Forest y XGBoost muestran resultados muy similares en MAE, pero Random Forest reduce mas los errores grandes, como refleja el RMSE. El resultado sugiere que los patrones de volatilidad implicita del dataset se ajustan bien a particiones no lineales del espacio de features. La diferencia entre versiones progresivas y no progresivas no es uniforme: el progressive training mejora de forma importante la red

Modelo	MAE test	RMSE test	R^2 test
Regresion lineal	0,067585	0,183824	0,096059
Regresion lineal progresiva	0,070544	0,187747	0,057069
Red tensor-train	0,056056	0,143025	0,452787
Red tensor-train progresiva	0,055597	0,117404	0,631276
Random Forest	0,054366	0,088403	0,790941
Random Forest progresivo	0,054337	0,088533	0,790326
XGBoost	0,054604	0,091735	0,774885
XGBoost progresivo	0,057295	0,113606	0,654747

Cuadro 3: Metricas finales de test por familia de modelo.

tensor-train, pero no mejora Random Forest y empeora XGBoost en las ejecuciones disponibles.

4.3 INTERPRETACION DEL RENDIMIENTO

La diferencia entre MAE y RMSE es informativa. Varios modelos tienen MAE alrededor de 0,054–0,057, pero RMSE mas disperso. Esto indica que el error tipico puede ser parecido mientras que los errores extremos difieren. En finanzas de derivados, esos extremos importan: suelen concentrarse en regiones de baja liquidez, vencimientos muy cortos, moneyness extrema o episodios de mercado tensionado.

El R^2 de Random Forest y XGBoost confirma que los modelos capturan una parte sustancial de la variabilidad de test. No obstante, un R^2 cercano a 0,79 no significa que el modelo sea perfecto ni que pueda sustituir procedimientos de mercado. Significa que, dadas las variables utilizadas, el modelo explica gran parte de la variacion observada en la volatilidad implicita calculada. Quedan errores que deben analizarse con diagnosticos por region.

4.4 DISCUSION SOBRE PROGRESSIVE TRAINING

El progressive training parte de una hipotesis razonable: aprender primero las zonas mas cercanas a ATM puede estabilizar el modelo antes de incorporar alas. Los resultados muestran que esta idea no es universal. En la red tensor-train progresiva,

el RMSE baja de 0,143025 a 0,117404 y el R^2 sube de 0,452787 a 0,631276. En cambio, Random Forest apenas cambia y XGBoost empeora frente a su versión no progresiva.

La interpretación es que la utilidad del entrenamiento progresivo depende de la dinámica interna de la familia. En redes, continuar entrenamiento por fases puede ordenar el aprendizaje de interacciones. En ensembles de árboles, la partición del espacio y los pesos por segmento ya capturan mucha heterogeneidad sin necesidad de fases. En boosting, repartir estimadores por fases puede limitar la capacidad de corregir residuos globales si la secuencia no queda bien equilibrada.

4.5 EXPLICABILIDAD GLOBAL

La explicabilidad global responde a que variables sostienen las predicciones del modelo. El proyecto calcula SHAP mediante permutación para mantener una interfaz común entre familias. Esto permite comparar regresión lineal, Random Forest, XGBoost y redes bajo una misma semántica de contribución aditiva.

En un modelo de volatilidad implícita, se espera que moneyness, vencimiento y sus interacciones tengan peso relevante. Si SHAP indicara dependencia dominante de variables sin interpretación financiera o patrones incompatibles con la teoría, sería una señal de alerta. Por eso el dashboard no muestra solo importancias medias; también incluye dependence plots, heatmaps de contribuciones y comparación visual entre variables.

Los árboles surrogate complementan SHAP al traducir el modelo principal a reglas. Una profundidad baja puede revelar cortes principales de moneyness y vencimiento. Si la fidelidad es baja, esas reglas solo sirven como intuición parcial. Si una profundidad moderada logra buen RMSE de fidelidad, el comportamiento del modelo es más resumible y, por tanto, más comunicable.

La regresión simbólica busca una ecuación cerrada que aproxime predicciones del modelo principal. Su valor está en producir una expresión compacta para discusión, no en reemplazar automáticamente el modelo operativo. El dashboard conserva complejidad, pérdida, score y métricas de fidelidad para evitar sobreinterpretar una fórmula atractiva pero imprecisa.

4.6 EXPLICABILIDAD LOCAL

La explicabilidad local permite analizar una prediccion concreta. El waterfall SHAP descompone la diferencia entre valor base y prediccion final. En opciones, esta lectura es util para explicar si una volatilidad alta se debe a moneyness extrema, vencimiento corto, tipo de opcion o combinaciones de variables.

Los vecinos cercanos aportan soporte empirico. Una prediccion puede tener contribuciones SHAP aparentemente razonables y aun asi estar lejos de observaciones historicas. El proyecto calcula vecinos contra el split de train transformado para evitar usar el mismo test como soporte. La proyeccion PCA ayuda a visualizar si la muestra cae en una region poblada o aislada.

Esta combinacion reduce un riesgo frecuente de la explicabilidad local: explicar matematicamente cualquier salida aunque el punto este fuera de distribucion. En un sistema financiero, una prediccion fuera de soporte debe marcarse como menos fiable, aunque el modelo devuelva una cifra.

4.7 SUPERFICIES, ICE Y ALE

La pestana Behaviour and Surface estudia como cambia la volatilidad predicha al mover moneyness, vencimiento, strike, subyacente o tipo. Las superficies de volatilidad se generan alrededor de anclas reales del test. Esto evita construir superficies completamente abstractas y mantiene el analisis ligado a condiciones observadas.

Los heatmaps y superficies 3D muestran forma global local: smiles, pendientes y cambios por vencimiento. Las curvas smile resumen cortes por moneyness; las term structures resumen cortes por vencimiento. Los checks financieros avisan de posibles incoherencias, como patrones excesivamente irregulares.

ICE y ALE cumplen funciones distintas. ICE muestra respuestas individuales y permite observar heterogeneidad entre contratos. ALE resume efectos medios locales reduciendo extrapolacion en regiones con poca densidad. En conjunto, ambas herramientas ayudan a distinguir una sensibilidad general de comportamientos particulares.

4.8 DIAGNOSTICO DE ERRORES

La pestana Diagnosis presenta metricas agregadas, scatter predicted vs actual, heat-maps de residuos y errores por moneyness y vencimiento. Esta capa es necesaria porque una metrica global puede ocultar fallos sistematicos. Un modelo con buen RMSE medio puede subestimar volatilidad en alas, sobreestimar en vencimientos cortos o degradarse en episodios concretos.

El residual se define como $y_i - \hat{y}_i$. Residuos positivos indican subestimacion de volatilidad; residuos negativos, sobreestimacion. El error absoluto mide magnitud local. Los mapas por moneyness y vencimiento permiten identificar regiones donde el modelo requiere mas datos, mejores features o restricciones financieras adicionales.

4.9 RESPUESTA A LA PREGUNTA DE INVESTIGACION

La pregunta inicial era si se podia construir una herramienta que estimara volatilidad implicita y explicara sus predicciones. Los resultados disponibles apoyan una respuesta afirmativa con matices. La estimacion es razonable fuera de muestra para familias no lineales, especialmente Random Forest y XGBoost. La explicabilidad esta integrada en el flujo y cubre niveles global, local, funcional y de diagnostico.

El matiz es que la calidad depende del dominio de datos y de la region de la superficie. El sistema no convierte automaticamente una prediccion en verdad de mercado. La volatilidad implicita de entrada se calcula con Black-76 y filtros especificos; el modelo aprende esa construccion. Por tanto, la interpretacion debe entenderse como explicacion de un modelo entrenado sobre una base construida, no como descubrimiento causal de precios.

4.10 LIMITACIONES

La primera limitacion es la dependencia de Black-76. El modelo de inversion es adecuado para opciones sobre futuros, pero impone supuestos. Las volatilidades implicitas calculadas heredan esos supuestos y cualquier error de inputs.

La segunda limitacion es la microestructura. Aunque se filtra por lag de subyacente y tipo de operacion, las operaciones reales pueden reflejar liquidez desigual, horquillas, episodios de stres o negociaciones no representativas. Algunas volatilidades extremas probablemente proceden de estas condiciones.

La tercera limitacion es la ausencia de variables adicionales de mercado. El modelo usa tipo de opcion, strike, subyacente, vencimiento y tipo. Podrian incorporarse variables de liquidez, hora de sesion, volumen, volatilidad realizada, indicadores macro o informacion de order book si estuvieran disponibles.

La cuarta limitacion es la interpretacion de los explicadores. SHAP, ICE, ALE, surrogates y regresion simbolica explican el comportamiento del modelo bajo ciertos supuestos y muestras. No prueban causalidad ni garantizan estabilidad fuera del dominio observado.

4.11 COMPARACION DETALLADA DE MODELOS

La regresion lineal obtiene RMSE de test 0,183824. Su R^2 de 0,096059 indica que apenas mejora a un predictor constante en el bloque final. La version progresiva empeora ligeramente. Esto sugiere que segmentar el entrenamiento no soluciona la rigidez estructural del modelo. Aunque las features incluyen no linealidades basicas, la relacion global sigue siendo demasiado compleja para una combinacion lineal.

La red tensor-train mejora claramente la regresion lineal. La version no progresiva alcanza RMSE 0,143025 y R^2 0,452787; la progresiva alcanza RMSE 0,117404 y R^2 0,631276. Esta mejora muestra que ordenar el aprendizaje por segmentos de money-ness puede ayudar a una arquitectura neuronal. Aun asi, el resultado queda lejos de los ensembles de arboles, probablemente porque los datos tabulares y el tamano de muestra favorecen particiones no lineales directas.

Random Forest presenta la mejor metrica final. La version progresiva tiene MAE levemente menor, 0,054337 frente a 0,054366, pero RMSE levemente mayor, 0,088533 frente a 0,088403. La diferencia es pequena y no justifica preferir la variante progresiva si se prioriza RMSE. El modelo no progresivo queda como mejor candidato por simplicidad y rendimiento.

XGBoost logra RMSE 0,091735, muy cercano a Random Forest. Su version progresiva cae a RMSE 0,113606. La diferencia sugiere que el boosting se beneficia de optimizar globalmente la secuencia de arboles, mientras que dividir estimadores por segmentos puede limitar su capacidad de corregir errores residuales en todo el espacio.

4.12 GENERALIZACION TEMPORAL

El test cubre desde septiembre de 2021 hasta junio de 2022, periodo posterior al trainval. Esta separacion es exigente porque evalua el modelo en fechas no usadas durante seleccion. La diferencia entre trainval y test muestra degradacion esperable. Por ejemplo, Random Forest pasa de RMSE trainval 0,070600 a test 0,088403; XGBoost de 0,074342 a 0,091735. La brecha existe, pero no destruye el rendimiento.

En la regresion lineal, la brecha es mayor en terminos relativos y el R^2 test queda muy bajo. Esto refuerza la idea de que un modelo con sesgo alto no solo falla en entrenamiento, sino que tampoco generaliza bien ante cambios temporales. En redes, la brecha tambien es relevante, lo que puede indicar sensibilidad a regimenes o necesidad de regularizacion y variables adicionales.

4.13 LECTURA FINANCIERA DE LOS RESULTADOS

El mejor comportamiento de Random Forest y XGBoost es coherente con una superficie por regiones. En volatilidad implicita, la sensibilidad puede cambiar bruscamente entre opciones ATM y alas, vencimientos cortos y medios, calls y puts. Los arboles capturan este tipo de particiones de forma natural. Ademas, no requieren que las variables esten escaladas ni que la relacion sea suave globalmente.

Sin embargo, que un modelo de arboles funcione bien no implica que la superficie real sea discontinua. La prediccion final de un ensemble puede aproximar funciones suaves mediante muchas particiones. Por eso las superficies generadas en el dashboard son necesarias: permiten observar si el modelo aprendido presenta saltos o irregularidades no deseadas.

La volatilidad implicita media de la base es 0,2061, con mediana 0,1738. Un RMSE de 0,0884 representa una fraccion importante de la volatilidad media, pero debe interpretarse considerando que la distribucion tiene cola larga y maximos extremos. El MAE de 0,0544 indica que el error tipico absoluto es menor que el RMSE y que parte de la penalizacion procede de errores grandes.

4.14 DISCUSION SOBRE DATOS Y FILTROS

La reduccion desde 428.448 operaciones de opciones con subyacente hasta 312.615 volatilidades finales muestra que el solver y los filtros eliminan una parte relevante.

Esta reduccion es esperable: no toda operacion produce una volatilidad implicita estable dentro del rango definido, y no toda asociacion de subyacente cumple el filtro final.

El filtro de lag maximo de 180 minutos es conservador en comparacion con la mediana final de 0,080 minutos. La media de 7,991 minutos indica que algunas observaciones tienen lags mas altos, pero la mayor parte de la base usa subyacentes muy cercanos temporalmente. Esto mejora la credibilidad de la inversion Black-76, porque el precio del futuro usado refleja condiciones proximas a la operacion de opcion.

El tiempo hasta vencimiento medio de 23,44 dias indica predominio de vencimientos relativamente cortos, coherente con opciones mensuales negociadas. El maximo de 623 dias en la base final revela que tambien hay observaciones largas, aunque no dominan. Esta mezcla justifica incluir vencimiento y raiz de vencimiento como variables, y diagnosticar errores por madurez.

4.15 COHERENCIA DE EXPLICACIONES

Un resultado cuantitativo aceptable debe ir acompanado de explicaciones coherentes. En un modelo financiero, seria sospechoso que una variable irrelevante dominara SHAP o que la respuesta a moneyness fuera contraria a patrones esperados sin razon de mercado. La documentacion del dashboard establece precisamente esa lectura: usar visualizaciones SHAP para detectar drivers, ICE/ALE para respuesta y superficies para coherencia financiera.

La existencia de modelos equivalentes aporta una segunda prueba. Si un arbol surrogate de baja profundidad logra fidelidad razonable, se puede comunicar el comportamiento principal con reglas sencillas. Si necesita profundidad alta, el modelo es mas complejo y conviene evitar narrativas simplificadas. La regresion simbolica cumple un papel similar, pero con formulas en lugar de reglas.

4.16 USO ANTE UN TRIBUNAL O USUARIO PROFESIONAL

La memoria puede defenderse mostrando tres evidencias. Primero, la cadena de datos esta materializada y validada: no se parte de una tabla opaca. Segundo, la evaluacion temporal reserva test final y controla contratos compartidos. Tercero, la explicabilidad no se limita a importancias, sino que integra diagnostico de rendimiento, comportamiento de superficie y soporte local.

Ante un usuario profesional, la recomendación sería no presentar el modelo como motor autónomo de precios. Es una herramienta de análisis y explicación de volatilidad implícita calculada. Puede servir para identificar patrones, comparar familias, estudiar regiones de error y generar predicciones orientativas. Para uso de producción harían falta validaciones adicionales, monitorización continua y controles de calidad intradía.

4.17 RIESGOS RESIDUALES

Persisten riesgos incluso con el protocolo aplicado. Puede existir cambio de régimen posterior a junio de 2022. Puede haber sesgos en las operaciones disponibles frente al universo total de cotizaciones. Puede haber dependencia de convenciones de vencimiento o de tipos. Puede haber regiones con pocas observaciones donde el modelo interpola o extrapola sin suficiente soporte.

La respuesta del proyecto a estos riesgos no es eliminarlos por completo, sino hacerlos visibles. Los vecinos muestran soporte local; los heatmaps muestran errores por región; las superficies muestran irregularidades; los metadatos conservan configuración. Esta filosofía es adecuada para un TFM aplicado: construir una herramienta que no solo predice, sino que también expone sus propias zonas de duda.

4.18 ESCENARIOS DE USO

Un primer escenario de uso es la revisión de un modelo candidato. El usuario selecciona una familia, revisa métricas finales, observa predicted vs actual y después inspecciona SHAP global. Si las variables dominantes son coherentes con teoría financiera, avanza a superficies y diagnósticos. Si aparecen dependencias inesperadas, vuelve a revisar features o datos.

Un segundo escenario es el análisis de una operación concreta. El usuario selecciona una muestra de test, observa volatilidad real, predicha y residual. El waterfall SHAP indica que variables empujaron la predicción. Los vecinos muestran si existen operaciones similares en entrenamiento. Si el residual es alto y los vecinos son escasos, la conclusión no es solo que el modelo falló, sino que la región puede estar mal representada.

Un tercer escenario es la comunicación de comportamiento global. Los árboles surrogate y la regresión simbólica permiten presentar reglas o fórmulas aproximadas. Esta comunicación es útil en defensa académica y en reuniones de validación, siem-

pre que se acompañe de fidelidad. Una regla simple con baja fidelidad puede ser pedagógica, pero no debe usarse para justificar decisiones operativas.

4.19 COMPARACION CON UN ENFOQUE PURAMENTE TEORICO

Un enfoque puramente teórico podría calibrar una superficie paramétrica o un modelo de volatilidad local. Ese enfoque tiene ventajas: puede incorporar restricciones financieras y producir superficies suaves. Sin embargo, exige decisiones de parametrización y calibración. El enfoque de este TFM es distinto: aprende una aproximación supervisada desde datos de operaciones y después audita su comportamiento.

Ambos enfoques no son excluyentes. Un trabajo futuro podría usar los modelos de machine learning como herramienta de interpolación inicial y después imponer restricciones de ausencia de arbitraje. También podría usar modelos teóricos para generar features adicionales o benchmarks. La contribución de este TFM es mostrar que la aproximación data-driven puede ser trazable y explicable.

4.20 DISCUSION SOBRE AUSENCIA DE RESULTADOS VISUALES EN LA MEMORIA

El repositorio contiene un dashboard diseñado para visualizaciones interactivas. Esta memoria prioriza tablas, descripciones y anexos porque se construye a partir de la documentación disponible y de metadatos locales. En una versión final compilada sería recomendable exportar capturas de las pestañas principales: SHAP global, superficie de volatilidad, waterfall local, vecinos y diagnóstico.

La ausencia de capturas no impide documentar el sistema, pero limita la comunicación visual. Las figuras permitirían comprobar rápidamente si las superficies son suaves, si los residuos se concentran en regiones concretas y si las contribuciones SHAP son financieramente razonables. Por tanto, se recomienda añadirlas cuando se establezca el modelo final elegido.

4.21 SINTESIS INTERPRETATIVA

La síntesis de resultados es la siguiente. La cadena de datos produce una muestra amplia y temporalmente ordenada. Los modelos lineales no capturan suficiente estructura. Los ensembles de árboles son los mejores candidatos. Las redes muestran potencial, especialmente con entrenamiento progresivo, pero no lideran las métricas.

La explicabilidad es suficientemente rica para diagnosticar comportamiento y comunicar limitaciones.

El resultado no debe presentarse como cierre definitivo. Es una base solida para iterar. La mejora mas prometedora no necesariamente sera cambiar de algoritmo, sino enriquecer variables y mejorar controles de superficie. Con datos de liquidez y capturas visuales del dashboard, el trabajo podria evolucionar hacia una herramienta mas cercana a validacion profesional.

CONCLUSIONES

5.1 CONCLUSIONES PRINCIPALES

El trabajo ha construido una memoria técnica y académica para un sistema de estimación explicable de volatilidad implícita en opciones sobre el IBEX. La cadena parte de operaciones y contratos, asocia futuros subyacentes, calcula tipos compuestos, invierte Black-76 y produce una base final con 312.615 observaciones válidas. Sobre esa base se entrenan familias de modelos y se genera una capa de explicabilidad orientada a uso operativo.

La primera conclusión es que la calidad del dato es el núcleo del problema. La volatilidad implícita no aparece en las fuentes originales; se construye. Por tanto, los filtros de precio, cantidad, vencimiento, strike, subyacente temporalmente válido y solver numérico son tan importantes como el algoritmo de aprendizaje.

La segunda conclusión es que la no linealidad importa. La regresión lineal ofrece una referencia interpretable, pero su rendimiento fuera de muestra queda lejos de Random Forest y XGBoost. Esto confirma que la superficie de volatilidad requiere capturar interacciones y curvaturas.

La tercera conclusión es que el mejor modelo cuantitativo disponible fue Random Forest, con RMSE de test 0,088403 y R^2 0,790941. XGBoost obtuvo un resultado cercano. La red tensor-train progresiva mostró una mejora notable frente a su versión no progresiva, pero no alcanzó a los ensembles de árboles.

La cuarta conclusión es que la explicabilidad debe evaluarse como un sistema, no como un único gráfico. SHAP aporta atribución, ICE y ALE respuesta funcional, superficies lectura financiera, vecinos soporte local, y surrogates fidelidad aproximada. Cada herramienta cubre una pregunta distinta y sus limitaciones se compensan parcialmente entre sí.

5.2 IMPLICACIONES PRACTICAS

Desde el punto de vista practico, el proyecto puede servir como base para una herramienta de analisis de volatilidad. Un usuario podria cargar un modelo final, seleccionar una muestra de test o introducir variables manuales, obtener una prediccion y revisar explicaciones locales y globales. La API y el almacenamiento local/GCP apuntan a una arquitectura desplegable.

Para equipos de model risk o validacion, el valor esta en la trazabilidad. La memoria y los anexos identifican de donde sale cada dato, que validaciones se aplican, como se separan las muestras, que metricas se usan y que artefactos explicables se generan. Esta trazabilidad reduce la distancia entre experimento academico y herramienta auditable.

5.3 LINEAS FUTURAS

Una primera extension natural es enriquecer las variables con liquidez, volumen, hora intradia, bid-ask spread, volatilidad realizada y medidas de regimen de mercado. Estas variables podrian explicar parte de los residuos extremos.

Una segunda linea es imponer restricciones financieras o regularizaciones sobre la superficie. Por ejemplo, penalizar irregularidades excesivas o incoherencias conocidas podria mejorar robustez, especialmente en zonas poco pobladas.

Una tercera linea es comparar la inversion Black-76 con alternativas o ajustes especificos para dividendos, tipos y convenciones de mercado. La variable objetivo podria cambiar si se modifica la forma de calcular el precio teorico.

Una cuarta linea es ampliar la validacion temporal con backtesting por ventanas moviles y evaluacion por regimenes. El periodo 2017–2022 incluye cambios de tipos y episodios de estres; separarlos podria revelar estabilidad o fragilidad de cada familia.

Finalmente, la explicabilidad podria evaluarse con usuarios. Un dashboard tecnicamente completo no garantiza que las explicaciones sean comprensibles o utiles para distintos perfiles. Diseñar pruebas de uso con analistas, validadores y docentes permitiria priorizar visualizaciones y mejorar comunicacion.

5.4 BALANCE FINAL

El balance final es positivo con una cautela metodologica. El proyecto demuestra que una arquitectura de datos, modelos y explicabilidad puede aplicarse a volatilidad implicita de opciones IBEX con resultados cuantitativos razonables. Tambien demuestra que la documentacion tecnica existente puede transformarse en una memoria academica coherente, siempre que se separe el relato principal de los anexos operativos.

La cautela es que el modelo aprende una variable construida. La volatilidad implicita depende de Black-76, del subyacente asociado, del tipo compuesto, de la hora de ejecucion y del filtro de operaciones. Cualquier conclusion sobre prediccion debe leerse dentro de ese marco. La fortaleza del trabajo es precisamente que ese marco queda documentado.

5.5 RECOMENDACIONES DE USO

Para uso academico, se recomienda emplear la memoria como documento principal y los anexos como guia tecnica. Para uso de desarrollo, se recomienda mantener sincronizada la matriz de trazabilidad con doc/docs/: si se anade una pagina de documentacion, debe reflejarse en el anexo correspondiente. Para uso de validacion, se recomienda conservar metadatos de cada ejecucion y no sobrescribir resultados sin versionado.

Para uso financiero, se recomienda tratar el dashboard como herramienta de inspeccion. Una prediccion debe acompanarse de su explicacion local, vecinos cercanos y diagnostico de region. Si una muestra cae fuera de soporte, la salida debe interpretarse con prudencia aunque el modelo devuelva un valor numerico.

5.6 TRABAJO PENDIENTE PARA UNA VERSION FINAL ENTREGABLE

Antes de entregar una version definitiva, convendria reemplazar los tutores pendientes en `variables.sty`, revisar estilo institucional de portada, anadir figuras propias del dashboard si se desea una memoria mas visual y compilar con una distribucion LaTeX instalada. Tambien seria conveniente revisar terminologia con el tutor, especialmente en torno a unidades de tipos y convenciones de mercado.

Estas tareas no cambian la sustancia tecnica del trabajo, pero mejoran presentacion y ajuste formal. La memoria ya recoge la estructura exigida por la guia: titulo, resumen, introduccion, marco teorico, metodologia, resultados y discusion, conclusiones y bibliografia.

BIBLIOGRAFÍA

- [1] Daniel W. Apley and Jingyu Zhu. Visualizing the effects of predictor variables in black box supervised learning models. *Journal of the Royal Statistical Society: Series B*, 82(4):1059–1086, 2020.
- [2] Lorenzo Bergomi. *Stochastic Volatility Modeling*. CRC Press, 2016.
- [3] Fischer Black. The pricing of commodity contracts. *Journal of Financial Economics*, 3(1-2):167–179, 1976.
- [4] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [5] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [6] Miles Cranmer, Alvaro Sanchez-Gonzalez, Peter Battaglia, Rui Xu, Kyle Cranmer, David Spergel, and Shirley Ho. Discovering symbolic models from deep learning with inductive biases. *Advances in Neural Information Processing Systems*, 2020.
- [7] Bruno Dupire. Pricing with a smile. *Risk*, 7(1):18–20, 1994.
- [8] Alex Goldstein, Adam Kapelner, Justin Bleich, and Emil Pitkin. Peeking inside the black box: Visualizing statistical learning with plots of individual conditional expectation. *Journal of Computational and Graphical Statistics*, 24(1):44–65, 2015.
- [9] John C. Hull. *Options, Futures, and Other Derivatives*. Pearson, 10 edition, 2018.
- [10] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, 2017.
- [11] Ivan V. Oseledets. Tensor-train decomposition. *SIAM Journal on Scientific Computing*, 33(5):2295–2317, 2011.
- [12] Lloyd S. Shapley. A value for n-person games. *Contributions to the Theory of Games*, 2:307–317, 1953.

Parte II

ANEXOS

Anexos tecnicos que recogen la trazabilidad completa de la documentacion disponible en [doc/docs/](#).



ANEXO A: REPOSITORIO Y CONFIGURACION

Este anexo resume la documentacion de `doc/docs/repository/`. El repositorio esta organizado para separar responsabilidades: configuracion, enums, gestion de datos, modelos, conversion a dashboard, interfaz de usuario, API, pruebas y recursos. La raiz contiene tambien notebooks exploratorios, datos, salidas, infraestructura y la documentacion MkDocs.

A.1 ESTRUCTURA LOGICA

El flujo logico de ejecucion es: datos fuente, ETL, base de volatilidad, generacion de features, entrenamiento, reentrenamiento, conversion a dashboard, ejecucion de UI/API y despliegue. Esta separacion evita que una pieza conozca demasiados detalles de otra. El ETL produce bases fiables; las familias de modelos entrenan estimadores; `model2dashboard` hace de puente hacia los artefactos explicables.

A.2 CONFIGURACION CENTRALIZADA

La configuracion vive en `resources/`. `data_config.json` define rango temporal, codificacion de contratos, columnas, prefijos, filtros, hora de vencimiento y parametros del solver de volatilidad. `volatility_models_config.json` define columnas de entrenamiento, features, splits, k-folds, metricas y progressive training. `dashboard_models_config.json` fija tamanos de muestras, SHAP, vecinos, superficies, ICE, ALE, surrogate trees y regresion simbolica. `clientserver.json` declara rutas de modelos, cache, almacenamiento local/GCP y configuracion de API/dashboard. `cloud_config.json` completa la parte cloud.

A.3 PAQUETES DE src

src/config carga y valida configuracion. src/enums centraliza nombres de columnas y contratos. src/data_management implementa loaders y builders del ETL. src/volatility_models contiene utilidades de entrenamiento y modelos persistidos. src/python_models define abstracciones serializables de modelos y artefactos. src/model2dashboard construye bundles explicables. src/dashboard implementa la aplicacion Dash. src/api expone prediccion y explicabilidad local.

A.4 ARTEFACTOS PERSISTIDOS

El repositorio guarda bases intermedias en data/, modelos entrenados en src/volatility_models/trained_models, metadatos en src/volatility_models/trained_metadata y bundles de dashboard en src/dashboard/saved_models. Esta persistencia permite inspeccionar resultados sin repetir todo el pipeline.

B

ANEXO B: PIPELINE DE DATOS

Este anexo recoge la documentacion de `doc/docs/data/`: vision general del ETL, lectura raw, union de mercado y contratos, separacion por producto, asociacion del subyacente y calculo de volatilidad implicita.

B.1 VISION GENERAL DEL ETL

El ETL transforma contratos, operaciones y tipos en `VOLATILITY_DB`. Cada paso consume bases previas, aplica validaciones y materializa una salida. Las entradas conceptuales son contratos `CCONTRACTS_C2`, trades `TGENTRADES` y series `EONIA/euro short-term rate`. Las salidas principales son contratos IBEX limpios, trades IBEX, opciones, futuros, relacion opcion-subyacente, opciones con subyacente y volatilidad implicita.

B.2 READ RAW STEP

La lectura raw normaliza cabeceras y tipos, filtra contratos del universo IBEX y construye la base de tipos. El documento `raw-read.md` detalla entradas, normalizacion, filtrado y validaciones. La decision clave es que los errores de formato se corrigen o descartan al principio, antes de que se mezclen con calculos financieros.

B.3 MERGE RAW STEP

`merge-raw.md` documenta la union por contrato y fecha. Tambien describe imputacion de vencimientos, imputacion de strikes y calculo de tiempo hasta vencimiento.

La coherencia entre código de contrato, strike y vencimiento se verifica con la configuración de códigos.

B.4 PRODUCT SPLIT STEP

`product-split.md` separa opciones y futuros. Las opciones se renombran con `OptionContractCode` los futuros, con `FutureContractCode`. La relación opción-subyacente se construye a partir de madurez y convenciones de contrato. Esta relación permite buscar después el futuro temporalmente válido para cada opción.

B.5 UNDERLYING STEP

`underlying.md` describe la unión temporal as-of entre opción y futuro. El criterio es usar el futuro más cercano anterior o simultáneo, evitando información futura. La salida incluye `UnderlyingPrice`, `UnderlyingExecDatetime` y `UnderlyingLagMinutes`. La base intermedia contiene 428.448 filas antes del filtrado final de volatilidad.

B.6 VOLATILITY STEP

`volatility.md` documenta limpieza de operaciones, validaciones, tipo compuesto, fórmula Black-76, solver de volatilidad implícita, filtro por tipo de operación y salida final. La base final contiene 312.615 filas, 151.424 calls y 161.191 puts. El filtro de lag máximo de 180 minutos y la resolución numérica eliminan observaciones no aptas.

B.7 COLUMNAS FINALES

`VOLATILITY_DB` contiene fecha, código de opción, tipo call/put, mercado, identificador de trade, precio de opción, cantidad, tipo de trade, strike, madurez, fecha-hora de ejecución, tiempo a vencimiento, tipo, código de futuro, precio del subyacente, fecha-hora del subyacente, lag y volatilidad implícita.



ANEXO C: MODELOS DE VOLATILIDAD

Este anexo sintetiza `doc/docs/models/`: vision general, features, splits, entrenamiento, reentrenamiento y familias.

C.1 VISION GENERAL

La parte de modelos toma `VOLATILITY_DB`, selecciona columnas, aplica split temporal `train/validation/test`, controla contratos compartidos, genera features, ejecuta k-folds temporales, selecciona hiperparametros, reentrena y evalua en test. La variable objetivo es `ImpliedVolatility`.

C.2 CARACTERISTICAS

`features.md` distingue variables originales y derivadas. Las originales son tipo de opcion, strike, subyacente, tiempo hasta vencimiento y tipo. Las derivadas incluyen `TTEYears`, `sqrtTTEYears`, `logMoneyness`, `logMoneynessSq`, `logMoneynessXSqrtTTE`, `logForwardMoneyness` y `rate`. El dashboard conserva tambien variables raw para lectura financiera.

C.3 SPLITS Y K-FOLDS

`splits-kfolds.md` documenta split temporal, exclusividad de contratos, k-folds temporales, lookahead bias y data snooping. La prioridad es que test no contamine `trainval` y que `validation` no comparta contratos con `train`. Los k-folds se construyen dentro del bloque de entrenamiento.

C.4 ENTRENAMIENTO

`training.md` describe búsqueda de hiperparametros, metricas base, metrica de seleccion, early stopping, escalado y artefactos. Las metricas base son MAE, RMSE y R^2 . La seleccion compuesta penaliza error medio, variabilidad entre folds y brecha train-validation. Las redes y XGBoost usan validacion interna para early stopping.

C.5 REENTRENAMIENTO

`retraining-progressive.md` documenta reentrenamiento no progresivo y progresivo. La fase final ajusta con trainval y evalua en test. El progressive training segmenta por moneyness para incorporar primero zonas mas cercanas a ATM y despues alas.

C.6 FAMILIAS

`families.md` compara regresion lineal, Random Forest, XGBoost, redes neuronales secuenciales y red tensor-train. `linear-regression.md` actua como baseline interpretable. `random-forest.md` capta no linealidades mediante ensembles. `xgboost.md` usa boosting regularizado. `neural-networks.md` describe redes densas con escalado y early stopping. `tensor-train.md` introduce una capa inspirada en tensor-train para interacciones compactas.

ANEXO D: DASHBOARD Y EXPLICABILIDAD

Este anexo recoge `doc/docs/dashboard/`. El dashboard convierte modelos entrenados en una herramienta inspeccionable.

D.1 COMETIDO DEL DASHBOARD

`dashboard/index.md` define selector de modelo, arquitectura de servicios y pestañas. El dashboard trabaja con modelos guardados, metadatos, datasets de test y artefactos explicables. Sus pestañas principales son Global Explainability, Behaviour and Surface, Sample Explainability y Diagnosis.

D.2 DE MODELO A BUNDLE

`model-to-dashboard.md` documenta descubrimiento del runtime, dataset de dashboard, SHAP, arboles surrogate, regresion simbolica, superficies, ICE, ALE, vecinos y estructura del bundle. El bundle incluye predicciones de test, residuos, error absoluto, features transformadas y artefactos precomputados.

D.3 EXPLICABILIDAD GLOBAL

`global-explainability.md` describe la pestaña global. `global/shap-fundamentals.md` explica SHAP, valores de Shapley, aproximacion por permutacion, variables raw y limitaciones. `global/shap-visualizations.md` recoge beeswarm, importancia media absoluta, dependence plot y heatmap de contribuciones.

`global/surrogate-trees.md` documenta árboles surrogate, profundidad, fidelidad y reglas textuales. `global/symbolic-regression.md` describe regresión simbólica con PySR, complejidad, configuración, fidelidad y uso correcto. Ambos explican el modelo principal, no directamente la verdad de mercado.

D.4 SUPERFICIES Y RESPUESTA

`behaviour-surface.md` define la pestaña Behaviour and Surface. `behaviour/volatility-surface.md` documenta heatmaps, superficies 3D, smiles, term structures y checks financieros. `behaviour/ice.md` explica curvas ICE, interpretación, diferencia con PDP y riesgo de contrafactuales irreales. `behaviour/ale.md` explica curvas ALE, ventaja frente a PDP y uso conjunto con ICE.

D.5 EXPLICABILIDAD LOCAL

`sample-explainability.md` recoge modo de muestra, formulario manual, salida de muestra, waterfall local y vecinos. `sample/local-shap-waterfall.md` explica muestras de dataset y manuales, valor base, lectura financiera, relación con residual y limitaciones. `sample/neighbours.md` documenta vecinos, soporte local, PCA y relación con SHAP local.

D.6 DIAGNOSTICO

`diagnosis.md` describe Performance Summary, predicted vs actual, residual heatmap, error by moneyness, error by maturity y warnings financieros. Esta pestaña vincula métricas globales con regiones concretas de fallo.

ANEXO E: OPERACION, API Y DESPLIEGUE

E.1 API

`doc/docs/operations/api-deployment.md` documenta la API de prediccion y explicabilidad local. El servicio carga modelos, aplica el mismo procesamiento de features y devuelve predicciones con metadatos. La explicabilidad local se apoya en los artefactos del modelo seleccionado y en la estructura de dashboard.

E.2 ALMACENAMIENTO

La configuracion permite almacenamiento local y GCP. En local, los modelos entrenados se buscan en `src/volatility_models/trained_models`, los metadatos en `src/volatility_models/trained_metadata/retrained_metadata` y los bundles en `src/dashboard/saved_models`. En GCP se parametrizan buckets y prefijos.

E.3 DOCKER Y TERRAFORM

Los dockerfiles empaquetan servicios. Terraform define infraestructura cuando se use despliegue cloud. Aunque la evaluacion cuantitativa no depende de estas piezas, su presencia indica que el proyecto se ha pensado como sistema desplegable.

E.4 ACTIVOS ESTATICOS DE DOCUMENTACION

La carpeta `doc/docs/javascripts/` contiene configuracion de MathJax, inicializacion de Mermaid y ajustes de etiquetas de navegacion. `doc/docs/stylesheets/extra.`

css contiene estilos adicionales. Estos ficheros no alteran la metodologia financiera, pero forman parte de la documentacion navegable y explican por que los diagramas y formulas se muestran correctamente en MkDocs.

ANEXO F: MATRIZ DE TRAZABILIDAD DE DOCUMENTACION

Este anexo menciona explicitamente cada pagina Markdown fuente de `doc/docs/` y su ubicacion en la memoria. Se presenta como lista por bloques para evitar problemas de compilacion con rutas largas dentro de tablas.

F.1 INICIO Y REPOSITORIO

- `index.md`: introduccion, metodologia general y lectura recomendada del proyecto.
- `repository/index.md`: Anexo A, estructura logica y responsabilidades.
- `repository/configuration.md`: Anexo A, configuracion centralizada.
- `repository/src-packages.md`: Anexo A, paquetes de `src`.

F.2 DATOS

- `data/index.md`: capitulo de metodologia y Anexo B, vision del ETL.
- `data/raw-read.md`: Anexo B, lectura raw.
- `data/merge-raw.md`: Anexo B, union de mercado y contratos.
- `data/product-split.md`: Anexo B, separacion de opciones y futuros.
- `data/underlying.md`: Anexo B, asociacion temporal del subyacente.

- `data/volatility.md`: marco teorico, metodologia y Anexo B, Black-76 y solver.

F.3 MODELOS

- `models/index.md`: capitulo de metodologia y Anexo C.
- `models/features.md`: metodologia y Anexo C, feature engineering.
- `models/splits-kfolds.md`: marco teorico, metodologia y Anexo C.
- `models/training.md`: metodologia y Anexo C, seleccion y metricas.
- `models/retraining-progressive.md`: resultados y Anexo C, progressive training.
- `models/families.md`: marco teorico, resultados y Anexo C.
- `models/families/linear-regression.md`: marco teorico, resultados y Anexo C.
- `models/families/random-forest.md`: marco teorico, resultados y Anexo C.
- `models/families/xgboost.md`: marco teorico, resultados y Anexo C.
- `models/families/neural-networks.md`: marco teorico y Anexo C.
- `models/families/tensor-train.md`: marco teorico, resultados y Anexo C.

F.4 DASHBOARD

- `dashboard/index.md`: metodologia y Anexo D, cometido del dashboard.
- `dashboard/model-to-dashboard.md`: metodologia y Anexo D, bundle visualizable.
- `dashboard/global-explainability.md`: resultados y Anexo D.
- `dashboard/global/shap-fundamentals.md`: marco teorico, discusion y Anexo D.

- `dashboard/global/shap-visualizations.md`: discusion y Anexo D.
- `dashboard/global/surrogate-trees.md`: marco teorico, discusion y Anexo D.
- `dashboard/global/symbolic-regression.md`: marco teorico, discusion y Anexo D.
- `dashboard/behaviour-surface.md`: resultados y Anexo D.
- `dashboard/behaviour/volatility-surfaces.md`: resultados y Anexo D.
- `dashboard/behaviour/ice.md`: marco teorico, resultados y Anexo D.
- `dashboard/behaviour/ale.md`: marco teorico, resultados y Anexo D.
- `dashboard/sample-explainability.md`: resultados y Anexo D.
- `dashboard/sample/local-shap-waterfall.md`: resultados y Anexo D.
- `dashboard/sample/neighbours.md`: resultados y Anexo D.
- `dashboard/diagnosis.md`: resultados y Anexo D.

F.5 OPERACION Y ACTIVOS DE DOCUMENTACION

- `operations/api-deployment.md`: metodologia y Anexo E.
- `javascripts/mathjax-config.js`: Anexo E, soporte de renderizado matematico en MkDocs.
- `javascripts/mermaid-init.js`: Anexo E, soporte de diagramas Mermaid.
- `javascripts/nav-labels.js`: Anexo E, ajustes de navegacion.
- `stylesheets/extra.css`: Anexo E, estilos adicionales de la documentacion.