



IA PARA VALORACIÓN DE OPCIONES: MODELOS DE VOLATILIDAD EXPLICABLES

PEDRO GALLEGO LÓPEZ Y DANIEL RECUERO CORDOBÉS

Trabajo Final de Máster

Máster en Inteligencia Artificial y Computación Cuántica
Aplicada a los Mercados Financieros


Dirección

Enrique Castellanos

INSTITUTO BME

BOLSAS Y MERCADOS ESPAÑOLES

Madrid, 10 de mayo de 2026



IA para valoración de opciones: modelos de volatilidad explicables

Pedro Gallego López
Daniel Recuero Cordobés

Palabras clave:

Volatilidad implícita, opciones IBEX, Black-76, aprendizaje automático, IA explicable, SHAP, dashboard, API, cloud

Resumen

Este Trabajo Final de Máster tiene como objetivo principal construir modelos de volatilidad implícita para opciones sobre el IBEX que sean tan fiables y potentes como los modelos modernos de inteligencia artificial, pero tan explicables como los modelos matemáticos tradicionales usados en finanzas cuantitativas. El trabajo parte de una tensión central: los modelos de IA pueden capturar relaciones no lineales complejas en la superficie de volatilidad, mientras que los modelos clásicos ofrecen una estructura interpretable y auditable. La propuesta busca unir ambas propiedades en una solución práctica.

A partir de operaciones reales, contratos, futuros subyacentes y series de tipos EONIA/€STR, se construye una base de volatilidad implícita mediante validaciones financieras e inversión numérica del modelo Black-76. Sobre esta base se entrenan varias familias de modelos de regresión: regresión lineal, Random Forest, XGBoost, redes neuronales y una arquitectura *quantum inspired*, inspirada en conceptos de computación cuántica. La evaluación no se limita al error predictivo, sino que incorpora estabilidad temporal, control de sobreajuste, coherencia financiera de la superficie y análisis regional por moneyness y vencimiento.

La contribución principal consiste en convertir modelos predictivos en artefactos explicables, auditables y consultables mediante un dashboard. La explicabilidad se aborda con SHAP global y local, superficies de volatilidad, curvas ICE y ALE, árboles surrogate, regresión simbólica, vecinos históricos y diagnósticos de residuales. Esta combinación permite justificar las predicciones con un lenguaje cercano al de los modelos tradicionales, sin renunciar a la capacidad de aproximación de la IA. El resultado es una arquitectura reproducible orientada a model validation, auditoría interna y uso operativo en entornos financieros.

Adicionalmente se ha habilitado una API para que cualquier persona pueda correr y usar estos modelos

AI for option pricing: explainable volatility models

Pedro Gallego López
Daniel Recuero Cordobés

Keywords:

Implied volatility, IBEX options, Black-76, machine learning, explainable AI, SHAP, dashboard, API, cloud

Abstract

The main objective of this Master's Thesis is to build implied-volatility models for IBEX options that are as reliable and powerful as modern artificial intelligence models, while remaining as explainable as traditional mathematical models used in quantitative finance. The work addresses a central tension: AI models can capture complex nonlinear relationships across the volatility surface, whereas classical models provide structure, interpretability and auditability. The proposed solution aims to combine both properties in a practical modelling framework.

Starting from real trades, contracts, underlying futures and EONIA/€STR rate series, the project builds an implied-volatility database through financial validations and numerical inversion of the Black-76 pricing model. Several regression families are then trained, including linear regression, Random Forest, XGBoost, neural networks and a quantum-inspired architecture, based on quantum computing concepts as its name suggests. The evaluation is not restricted to predictive error; it also considers temporal stability, overfitting control, financial coherence of the surface, and regional behaviour across moneyness and maturity.

The main contribution is to turn predictive models into explainable, auditable and queryable artefacts through a dashboard and a FastAPI service. Explainability is addressed through global and local SHAP, volatility surfaces, ICE and ALE curves, surrogate trees, symbolic regression, historical neighbours and residual diagnostics. This combination makes it possible to justify predictions in a language close to traditional financial models, without giving up the approximation power of AI. The resulting architecture is reproducible and oriented towards model validation, internal audit and operational use in financial environments.

Additionally, an API has been enabled so that anyone can run and use these models.

ÍNDICE GENERAL

1. INTRODUCCIÓN	6
1.1. Planteamiento del problema	6
1.2. Relevancia financiera y profesional	6
1.3. Antecedentes	7
1.4. Objetivos	7
1.5. Contribución del TFM	8
1.6. Estructura de la memoria	8
2. MARCO TEÓRICO	9
2.1. Opciones, futuros y volatilidad implícita	9
2.2. Smile, moneyness y estructura temporal	10
2.3. Aprendizaje automático para volatilidad	10
2.4. Explicabilidad en modelos financieros	11
2.5. Infraestructura cloud y reproducibilidad	11
2.6. Métricas de error, estabilidad y fidelidad	12
2.7. Gobierno de modelos y preguntas de validación	13
3. METODOLOGÍA	14
3.1. Diseño general del estudio	14
3.2. Datos y muestra analizada	14
3.3. Validaciones y tratamiento financiero	15
3.4. Variables y feature engineering	15
3.5. Familias de modelos	16
3.6. Splits temporales y selección	16
3.7. Reentrenamiento y progressive ATM	18
3.8. Construcción del dashboard	18
3.9. API, almacenamiento y cloud	20
3.10. Reproducibilidad y trazabilidad	20
3.11. Arquitectura del repositorio	20
3.12. Plan de validación funcional	21
3.13. Riesgos metodológicos y controles	22
4. RESULTADOS Y DISCUSIÓN	23
4.1. Resultados	23
4.1.1. Comparativa general de modelos	23
4.1.2. Entrenamiento estándar frente a progressive ATM	24
4.1.3. Selección del modelo final	24
4.1.4. Diagnóstico de rendimiento	24
4.1.5. Behaviour And Surface	25
4.1.6. Explicabilidad global	25

4.1.7.	Modelos equivalentes: árboles y regresión simbólica	26
4.1.8.	Explicabilidad local y soporte histórico	26
4.2.	Discusión	26
4.2.1.	Lectura financiera	26
4.2.2.	Lectura de IA y Data Science	27
4.2.3.	Lectura de ingeniería y cloud	27
4.2.4.	Limitaciones	27
5.	CONCLUSIONES	28
A.	FUNDAMENTOS DE SHAP, ICE Y ALE	29
B.	ÁRBOLES SURROGATE Y REGRESIÓN SIMBÓLICA	30
C.	ENTRENAMIENTO PROGRESSIVE ATM	31
D.	GUÍA DE INSERCIÓN DE RESULTADOS FINALES	32

INTRODUCCIÓN

1.1 PLANTEAMIENTO DEL PROBLEMA

La volatilidad implícita es una magnitud central en mercados de derivados. En una opción negociada, el precio observable resume expectativas, oferta y demanda, liquidez, microestructura y percepción de riesgo. Sin embargo, para comparar contratos con strikes y vencimientos distintos, los profesionales no suelen razonar únicamente en precios: transforman esos precios en volatilidades implícitas y analizan smiles, skews y estructuras temporales [Hull, 2022, Derman and Miller, 2016].

El problema de este trabajo surge de una tensión habitual en finanzas cuantitativas. Por un lado, los modelos de aprendizaje automático pueden aproximar relaciones no lineales entre strike, subyacente, vencimiento, tipo de interés y volatilidad. Por otro lado, en un entorno financiero no basta con obtener una predicción numéricamente competitiva. El modelo debe poder auditarse: hay que saber dónde falla, qué variables explican sus predicciones, si respeta patrones razonables de la superficie y si una predicción concreta está respaldada por datos históricos similares.

En este contexto, el proyecto construye modelos de volatilidad explicable, consultable y útil vía API. La explicabilidad se entiende en dos niveles. A nivel de ingeniería, sirve para detectar sesgos, errores de datos, incoherencias, discontinuidades y comportamientos no deseados. A nivel financiero y profesional, permite justificar decisiones ante revisiones internas, auditorías, model validation o análisis de riesgo.

1.2 RELEVANCIA FINANCIERA Y PROFESIONAL

La volatilidad implícita condensa información de mercado y se utiliza en valoración, cobertura, gestión de riesgos y análisis de escenarios. En opciones sobre índices, la forma de la superficie de volatilidad puede reflejar demanda de protección, asimetría percibida, presión de liquidez o cambios de régimen. Un modelo que suaviza en exceso las alas, que comprime volatilidades extremas o que presenta saltos artificiales

en vencimientos cortos puede producir señales engañosas aunque su RMSE agregado sea aceptable.

La literatura clásica de derivados establece que la volatilidad no debe interpretarse como un simple parámetro estadístico fijo, sino como una magnitud inferida del precio bajo un modelo de valoración [Black, 1976, Hull, 2022]. La literatura específica sobre smile muestra que los mercados organizan la volatilidad en torno a moneyness y vencimiento, no solo en torno a niveles absolutos de strike [Derman and Miller, 2016]. Por ello, el proyecto se diseña desde la geometría financiera de la superficie: el aprendizaje automático se usa para aproximar una función de volatilidad, pero la evaluación exige interpretar su forma.

1.3 ANTECEDENTES

La valoración de opciones sobre futuros se apoya tradicionalmente en Black-76 [Black, 1976]. En ese marco, el precio de una opción europea depende del futuro subyacente, el strike, el vencimiento, el tipo de interés y la volatilidad. Cuando el precio de mercado se observa, la volatilidad implícita se obtiene resolviendo numéricamente la ecuación inversa.

En paralelo, el uso de modelos de aprendizaje automático para superficies financieras responde a la necesidad de capturar no linealidades, interacciones y patrones empíricos que no quedan completamente descritos por modelos paramétricos simples. Sin embargo, la adopción profesional de modelos flexibles exige herramientas de interpretación. SHAP proporciona una semántica aditiva para atribuir predicciones a variables [Lundberg and Lee, 2017]; ICE y ALE ayudan a estudiar respuestas funcionales [Goldstein et al., 2015, Apley and Zhu, 2020]; los árboles surrogate y la regresión simbólica aproximan modelos complejos mediante objetos interpretables [Cranmer, 2023].

1.4 OBJETIVOS

El objetivo general es desarrollar una solución reproducible para estimar, explicar y consultar volatilidad implícita de opciones del IBEX. Este objetivo se concreta en los siguientes objetivos específicos:

1. Construir una base de volatilidad implícita a partir de operaciones, contratos, futuros subyacentes y curvas de tipos, con validaciones de calidad y trazabilidad.
2. Diseñar un conjunto de variables financieras coherentes con la geometría de la superficie de volatilidad.

3. Entrenar y comparar varias familias de modelos de regresión bajo una metodología temporal que reduzca lookahead bias y data snooping.
4. Generar artefactos de explicabilidad global, local, funcional y de diagnóstico.
5. Implementar una API y un dashboard que permitan consultar predicciones, explicar muestras concretas y revisar el comportamiento del modelo.
6. Preparar infraestructura cloud reproducible para almacenar artefactos y desplegar servicios.

1.5 CONTRIBUCIÓN DEL TFM

La principal contribución del TFM es integrar en un único flujo operativo elementos que habitualmente se tratan por separado: construcción de datos de mercado, inversión de Black-76, entrenamiento de modelos, explicabilidad, diagnóstico financiero, API y despliegue cloud. La Figura 1 resume esta cadena.

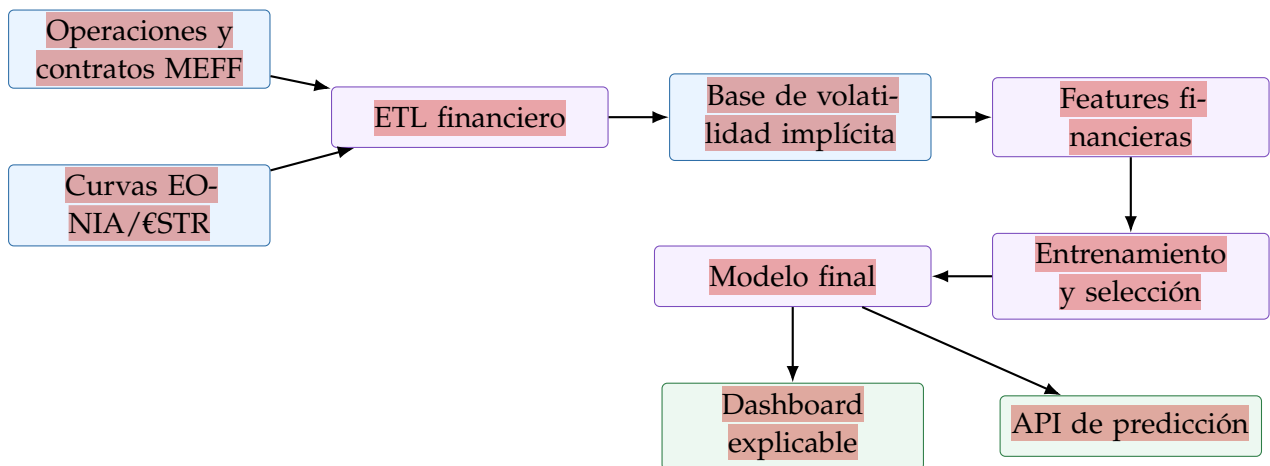


Figura 1: Visión general del proyecto: de los datos de mercado a servicios consultables.

La aportación académica se sitúa en la metodología de modelización y validación; la aportación profesional, en la capacidad de convertir un modelo de volatilidad en una herramienta inspeccionable y desplegable.

1.6 ESTRUCTURA DE LA MEMORIA

El [chapter 2](#) presenta los fundamentos financieros, de aprendizaje automático, explicabilidad e infraestructura. El [chapter 3](#) describe la construcción de datos, variables, modelos, validación, dashboard, API y cloud. El [chapter 4](#) deja preparado el análisis empírico final, con placeholders para métricas y figuras. El [chapter 5](#) resume las conclusiones y líneas futuras. Los anexos desarrollan SHAP, explicadores equivalentes y entrenamiento progressive ATM con mayor profundidad.

MARCO TEÓRICO

2.1 OPCIONES, FUTUROS Y VOLATILIDAD IMPLÍCITA

Una opción financiera otorga a su comprador el derecho, pero no la obligación, de comprar o vender un activo subyacente a un precio de ejercicio K en una fecha futura. En el caso de opciones sobre futuros, el subyacente relevante para valoración es el precio del futuro F . La literatura de derivados enfatiza que el valor de una opción depende de la distribución esperada del subyacente y, de forma operativa, de la volatilidad usada en el modelo de valoración [Hull, 2022].

En el modelo Black-76, una call europea sobre un futuro se valora como:

$$C = e^{-rT} (FN(d_1) - KN(d_2)), \quad (1)$$

donde

$$d_1 = \frac{\ln(F/K) + \frac{1}{2}\sigma^2 T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}. \quad (2)$$

Para una put:

$$P = e^{-rT} (KN(-d_2) - FN(-d_1)). \quad (3)$$

En estas expresiones, r es el tipo de interés, T el tiempo a vencimiento en años, σ la volatilidad y $N(\cdot)$ la función de distribución normal estándar. La volatilidad implícita σ_{imp} es el valor de σ que iguala el precio teórico al precio observado en mercado:

$$P_{mercado} = P_{Black76}(F, K, T, r, \sigma_{imp}). \quad (4)$$

La ecuación (4) no se resuelve cerradamente en general; se obtiene mediante métodos numéricos. En el proyecto se emplea bisección dentro de límites configurados, descartando filas no resolubles o no finitas.

2.2 SMILE, MONEYNES Y ESTRUCTURA TEMPORAL

Si la volatilidad fuese constante, opciones con distinto strike y vencimiento compartirían una misma σ . En mercados reales aparece una superficie de volatilidad:

$$\sigma_{imp} = \sigma(K, T), \quad (5)$$

o, de forma más comparable entre niveles de mercado:

$$\sigma_{imp} = \sigma(m, T), \quad m = \frac{F}{K}. \quad (6)$$

La moneyness m indica la posición relativa del subyacente frente al strike. Su transformación logarítmica,

$$\ell = \log(F/K), \quad (7)$$

es especialmente útil porque centra la región ATM en $\ell = 0$ y trata de forma más simétrica regiones a ambos lados del strike. La literatura sobre smile subraya que la curvatura y pendiente de la volatilidad implícita contienen información sobre expectativas de mercado, asimetría y demanda de cobertura [Derman and Miller, 2016].

2.3 APRENDIZAJE AUTOMÁTICO PARA VOLATILIDAD

El problema de modelización se formula como una regresión supervisada:

$$\hat{\sigma} = f(X), \quad (8)$$

donde X contiene variables financieras observables y transformadas. El proyecto compara familias con diferentes niveles de flexibilidad:

- Regresión lineal, como baseline interpretable y control de complejidad.
- Random Forest, basado en agregación de árboles para capturar interacciones no lineales [Breiman, 2001].

- XGBoost, como boosting regularizado con early stopping y buen rendimiento en datos tabulares [Chen and Guestrin, 2016].
- Redes neuronales densas, como aproximadores flexibles de funciones no lineales [Hornik et al., 1989].
- Una red neuronal clásica *quantum inspired*, que introduce una estructura tensorial inspirada en ideas de representación compacta. No se presenta como computación cuántica real, sino como una variante arquitectónica implementada en código.

La comparación no puede basarse solo en error medio. En datos financieros temporales, una evaluación mal planteada puede introducir fuga de información. Por ello se emplean splits temporales, control de contratos compartidos y k-folds temporales, tal como se desarrolla en el [section 3.6](#).

2.4 EXPLICABILIDAD EN MODELOS FINANCIEROS

La explicabilidad cumple una función técnica y una función de gobierno de modelos. Técnicamente, permite detectar variables dominantes, discontinuidades, extrapolaciones y errores locales. Profesionalmente, facilita responder por qué una predicción se considera razonable y en qué condiciones no debería confiarse en ella.

SHAP descompone la predicción de un modelo en un valor base y contribuciones por variable:

$$\hat{\sigma}(x) = \phi_0 + \sum_{j=1}^p \phi_j(x), \quad (9)$$

donde ϕ_j mide la contribución atribuida a la característica j [Lundberg and Lee, 2017]. En este proyecto se complementa con ICE, ALE, árboles surrogate, regresión simbólica y vecinos históricos. La razón es que ninguna herramienta por sí sola responde todas las preguntas relevantes: SHAP explica contribuciones, ICE muestra trayectorias individuales, ALE estima efectos acumulados locales, los surrogates dan reglas aproximadas y los vecinos informan sobre soporte local.

2.5 INFRAESTRUCTURA CLOUD Y REPRODUCIBILIDAD

Un modelo útil en un contexto profesional necesita más que un notebook. Debe poder cargarse de forma reproducible, exponer predicciones, separar artefactos de entrenamiento y servir explicaciones de manera consistente. Por ello el proyecto separa: entrenamiento, construcción de bundles explicables, dashboard, API y alma-

cenamiento de artefactos. La infraestructura cloud no se incorpora como elemento decorativo, sino para resolver problemas operativos: portabilidad de servicios, centralización de modelos, cache local, despliegue independiente de API y dashboard y trazabilidad de versiones.

2.6 MÉTRICAS DE ERROR, ESTABILIDAD Y FIDELIDAD

La evaluación de un modelo de volatilidad requiere métricas complementarias. El error absoluto medio,

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (10)$$

ofrece una lectura directa en unidades de volatilidad. Es robusto y fácil de comunicar, pero no penaliza de forma diferencial los errores grandes. Por ese motivo se utiliza también RMSE:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (11)$$

El RMSE es especialmente relevante en model validation porque amplifica errores extremos. En una superficie de volatilidad, esos errores pueden aparecer en vencimientos cortos, alas o regiones con menor liquidez. El coeficiente de determinación,

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (12)$$

resume proporción de variabilidad explicada, aunque debe interpretarse con prudencia en datos financieros heterogéneos.

Junto a estas métricas frente a mercado, el dashboard usa métricas de fidelidad para modelos explicables equivalentes. La fidelidad compara el surrogate con el modelo principal, no con la volatilidad real. Esta distinción es importante: un árbol surrogate puede ser muy fiel a un modelo sesgado, y un modelo principal puede tener buen RMSE pero ser difícil de resumir con reglas simples. Por tanto, la evaluación final debe combinar tres planos: precisión frente a mercado, estabilidad del proceso de selección y fidelidad de las explicaciones.

2.7 GOBIERNO DE MODELOS Y PREGUNTAS DE VALIDACIÓN

En un entorno financiero, un modelo de volatilidad debería poder responder a preguntas de model validation. Algunas son cuantitativas: cuál es el error fuera de muestra, si existe gap entre entrenamiento y validación, si el error cambia por vencimiento o moneyness, y si el resultado es estable entre folds. Otras son cualitativas pero igualmente relevantes: si el modelo reacciona de forma razonable ante cambios de strike, si produce superficies suaves donde el mercado debería ser continuo, si una predicción manual se encuentra dentro de una región observada o si el predictor depende excesivamente de una variable que no debería dominar.

El diseño del proyecto convierte esas preguntas en vistas concretas del dashboard. La pestaña de diagnóstico responde dónde falla. La pestaña de superficie responde cómo se comporta como función financiera. La explicabilidad global responde qué variables organizan las predicciones. La explicabilidad local responde por qué una muestra concreta obtiene un valor determinado y si existen observaciones históricas cercanas. Esta estructura facilita la defensa ante un tribunal porque alinea cada componente técnico con una pregunta profesional.

METODOLOGÍA

3.1 DISEÑO GENERAL DEL ESTUDIO

El estudio tiene carácter empírico y aplicado. Parte de datos de mercado, construye una variable objetivo financiera mediante inversión de Black-76, entrena modelos de regresión y evalúa tanto rendimiento predictivo como coherencia explicativa. La Figura 2 resume el flujo metodológico.




Figura 2: Flujo metodológico del TFM.

3.2 DATOS Y MUESTRA ANALIZADA

El pipeline de datos transforma ficheros de contratos, operaciones y tipos en una base final de volatilidad implícita. La documentación MkDocs identifica tres fuentes principales: contratos, operaciones y series EONIA/€STR. Los contratos aportan información de código, strike y vencimiento; las operaciones aportan precio, cantidad, hora y contrato; los tipos permiten calcular el tipo compuesto aplicable hasta vencimiento.

La cadena ETL se materializa por pasos, como muestra la Figura 3. Esta organización permite cachear salidas intermedias, validar contratos de datos y aislar responsabilidades.




Figura 3: Pipeline ETL para construir la base de volatilidad implícita.

Los datos se filtran al dominio de opciones IBEX mensuales y futuros mensuales asociados. Las opciones semanales y contratos fuera de dominio se excluyen para mantener coherencia contractual. La salida final contiene fecha y hora de ejecución, código de opción, tipo call/put, precio negociado, strike, futuro subyacente, precio del subyacente, lag temporal, tiempo a vencimiento, tipo compuesto y volatilidad implícita.

3.3 VALIDACIONES Y TRATAMIENTO FINANCIERO

El ETL aplica validaciones transversales: precios positivos, cantidades positivas, ausencia de claves duplicadas, control de missing values, vencimientos coherentes, strikes compatibles con el código de contrato y subyacente temporalmente anterior a la operación de la opción. Esta última condición es crítica para evitar utilizar información futura.

El cálculo de volatilidad implícita se realiza en el último paso. Se eliminan operaciones sin subyacente fiable, se calcula el tipo compuesto hasta vencimiento y se resuelve la ecuación (4). Si no existe cambio de signo en el intervalo de búsqueda o la solución es no finita, la observación se marca como no resoluble y no alimenta el entrenamiento.

3.4 VARIABLES Y FEATURE ENGINEERING

Las entradas raw visibles son `OptionType`, `StrikePrice`, `UnderlyingPrice`, `TimeToExpiration` y `Rate`. Estas variables son suficientes para reconstruir el vector de entrenamiento y también son comprensibles para un usuario financiero que consulte la API.

El vector transformado se diseña para representar la geometría de la superficie. La Tabla 1 resume las variables derivadas.

Feature	Fórmula	Motivo
TTEYears	$T = T_{\text{días}}/365$	Vencimiento en años
sqrtTTEYears	$\sqrt{T}$	Escala temporal de Black-76
logMoneyness	$\log(F/K)$	Posición relativa frente al strike
logMoneynessSq	$\log(F/K)^2$	Curvatura del smile
logMoneynessXSqrtTTE	$\log(F/K)\sqrt{T}$	Interacción smile-vencimiento
logForwardMoneyness	$\log(Fe^{rT}/K)$	Ajuste por tipo y vencimiento
rate	r	Sensibilidad directa a tipos
isCall, isPut	Indicadores	Tipo de opción

Cuadro 1: Features financieras utilizadas por los modelos.

Esta elección evita que el modelo dependa de niveles absolutos de strike que pueden cambiar con el régimen de mercado. La moneyness permite comparar contratos negociados en momentos distintos del IBEX, mientras que el vencimiento y sus transformaciones capturan estructura temporal.

3.5 FAMILIAS DE MODELOS

El repositorio implementa una abstracción común para familias de modelos. Cada familia declara nombre, parámetros fijos, espacio de búsqueda, instanciación, entrenamiento y persistencia. La Tabla 2 resume su papel en el estudio.

3.6 SPLITS TEMPORALES Y SELECCIÓN

La validación sigue tres principios. Primero, el orden temporal se respeta: train precede a validation y test. Segundo, puede existir un lag de fechas entre bloques para reducir contaminación temporal. Tercero, se controla la exclusividad de contratos: si el mismo contrato aparece en más de un split, se conserva en un único bloque según volumetría y prioridad.

Esta regla es relevante porque una opción puede negociarse durante varios días. Si un contrato aparece en entrenamiento y validación, el modelo podría aprender rasgos idiosincráticos del contrato y ofrecer una estimación optimista. La Figura 4 resume la lógica.

Familia	Papel metodológico
Regresión lineal	Baseline interpretable para evaluar cuánto aporta la no linealidad.
Random Forest	Modelo tabular robusto ante interacciones y no linealidades sin escalado.
XGBoost	Boosting regularizado con early stopping y alta capacidad predictiva.
Red neuronal secuencial	Aproximador flexible con escalado de variables numéricas.
Quantum Inspired NN	Variante clásica de red neuronal con estructura tensorial inspirada en ideas cuánticas; se evalúa como arquitectura implementada, no como computación cuántica física.

Cuadro 2: Familias de modelos entrenadas en el proyecto.




Figura 4: Control temporal y exclusividad de contratos durante la validación.

La búsqueda de hiperparámetros se realiza con k-folds temporales. Para cada candidato se calculan MAE, RMSE y R^2 en train y validation. La selección usa una métrica compuesta:

$$CE_1 = RMSE_{val} + \alpha \cdot std(RMSE_{val}) + \beta \cdot \max(0, RMSE_{val} - RMSE_{train}). \quad (13)$$

Esta métrica penaliza error de validación, inestabilidad entre folds y gap de sobreajuste. Según la configuración del repositorio, $\alpha = 0,25$ y $\beta = 0,75$.

3.7 REENTRENAMIENTO Y PROGRESSIVE ATM

Después de seleccionar hiperparámetros, el modelo se reentrena en dos fases: train/validation y final test. En la fase final se ajusta con trainval y se evalúa contra test. La métrica de reentrenamiento incorpora el rendimiento observado en selección:

$$CE_2 = RMSE_{val} + \gamma \cdot CE_1 + \beta \cdot \max(0, RMSE_{val} - RMSE_{train}), \quad (14)$$

con $\gamma = 0,25$ y $\beta = 0,75$ en la configuración actual.

El proyecto incluye una variante progressive ATM. Ordena observaciones por $|\log(F/K)|$, de más ATM a alas, y divide el entrenamiento en segmentos. La idea financiera es aprender primero la zona central, habitualmente más líquida y estable, y después incorporar regiones más alejadas. En modelos no iterativos se implementa mediante pesos; en XGBoost y redes se implementa mediante fases acumulativas. Por su carácter experimental, esta variante se menciona aquí y se desarrolla en el [chapter C](#).

3.8 CONSTRUCCIÓN DEL DASHBOARD

El dashboard no entrena modelos. Consume bundles generados desde modelos finales. Cada bundle contiene dataset con predicciones, residuales y error absoluto, muestras para explicabilidad local, anclas de superficies, SHAP global y local, árboles surrogate, regresor simbólico, vecinos, superficies, ICE, ALE y diagnóstico agregado.

La aplicación se estructura en cuatro pestañas, resumidas en la Tabla 3. Esta organización responde a preguntas distintas y evita confundir error predictivo con explicación.

Pestaña	Pregunta principal
Behaviour And Surface	¿Cómo responde el modelo ante cambios de money-ness, vencimiento y otras variables financieras?
Global Explainability	¿Qué variables y patrones dominan las predicciones globales?
Sample Explainability	¿Por qué una muestra concreta recibe esa volatilidad y tiene soporte histórico?
Diagnosis	¿Dónde acierta y dónde falla el modelo en la superficie?

Cuadro 3: Pestañas del dashboard y función analítica.




Figura 5: Construcción conceptual del dashboard explicable.

3.9 API, ALMACENAMIENTO Y CLOUD

La API se implementa con FastAPI. El código expone endpoints de salud, predicción y explicabilidad local: `/health`, `/run_model/predict/` y `/run_model/sample_explainability/`. La petición incluye modelo, tipo de opción, strike, subyacente, tiempo a vencimiento, tipo de interés y, opcionalmente, código de contrato y volatilidad real.

La respuesta de predicción incluye el modelo, la volatilidad estimada y la entrada normalizada. La respuesta de explicabilidad local añade waterfall SHAP, payload de contribuciones, vecinos históricos y distancias. API y dashboard comparten modelos y bundles, lo que reduce el riesgo de explicar un artefacto distinto al que predice.

El backend de almacenamiento puede ser local o GCP. En GCP se usan Cloud Storage para artefactos, Artifact Registry para imágenes, Cloud Run para API y dashboard, e IAM para permisos. Terraform define los recursos y permite reproducir la infraestructura. La Figura 6 representa el flujo operativo.




Figura 6: Modelo de almacenamiento y ejecución local/GCP.

3.10 REPRODUCIBILIDAD Y TRAZABILIDAD

La reproducibilidad se apoya en cuatro mecanismos: configuración JSON, enums de esquemas, artefactos persistidos y tests. La configuración declara columnas, splits, métricas, progressive training, tamaños de muestra de dashboard, parámetros SHAP, vecinos y regresión simbólica. Los enums centralizan nombres de columnas y tipos de dominio. Los artefactos guardan modelo, scaler cuando aplica, metadatos y bundle. Los tests cubren utilidades de datos, modelos, dashboard, API y configuración.

3.11 ARQUITECTURA DEL REPOSITORIO

La arquitectura del repositorio sigue una separación por responsabilidades. Esta decisión es relevante para reproducibilidad y defensa técnica: cada paquete tiene un

cometido identificable y los artefactos pasan de una etapa a otra sin mezclar entrenamiento, explicación y servicio.

Paquete o carpeta	Responsabilidad principal
src/config	Carga de configuración, rutas absolutas, logging y objetos de configuración por dominio.
src/enums	Definición centralizada de columnas, tipos de contrato, tipos de opción y nombres de modelos.
src/data_management	ETL de datos: loaders, builders, validaciones y utilidades de contrato.
src/volatility_models	Preparación de datos de entrenamiento, splits, k-folds, selección y reentrenamiento.
src/python_models	Abstracciones de familias de modelos y estructuras persistentes de dashboard.
src/model2dashboard	Conversión de modelos finales en bundles explicables autocontenidos.
src/dashboard	Aplicación Dash, servicios, callbacks, gráficos y utilidades de validación.
src/api	API FastAPI para predicción y explicabilidad local.
terraform	Infraestructura cloud reproducible: buckets, Artifact Registry, Cloud Run e IAM.

Cuadro 4: Arquitectura lógica del repositorio.

La Tabla 4 muestra que el dashboard no reentrena modelos y la API no reconstruye artefactos de explicación desde cero salvo en casos de explicabilidad local manual. Esta separación reduce el acoplamiento y facilita detectar errores. Si una predicción de API no coincide con la vista del dashboard, el problema puede acotarse a carga de bundle, transformación de features o versión de artefacto.

3.12 PLAN DE VALIDACIÓN FUNCIONAL

Además de la validación estadística, el proyecto requiere validación funcional. El sistema debe demostrar que los artefactos se cargan, que las features se reconstruyen de forma consistente y que las explicaciones corresponden al modelo seleccionado. La validación funcional se organiza en cuatro niveles:

1. Validación de datos: esquemas, tipos, claves, precios, cantidades, vencimientos, strikes y subyacente temporalmente anterior.
2. Validación de entrenamiento: splits temporales, exclusividad de contratos, métricas por fold, selección de hiperparámetros y persistencia de metadatos.

3. Validación de bundle: correspondencia entre modelo, scaler, predicciones, residuos, SHAP, vecinos, superficies y surrogates.
4. Validación de servicio: endpoints de salud, predicción, explicabilidad local, carga desde backend local o GCP y coherencia con dashboard.

Este plan no sustituye la revisión de resultados, pero evita que la memoria dependa únicamente de tablas finales. Un modelo con buen RMSE no sería aceptable si los artefactos explicables no correspondieran a ese mismo modelo o si la API reconstruyera las features con una transformación distinta.

3.13 RIESGOS METODOLÓGICOS Y CONTROLES

Los principales riesgos metodológicos se anticipan desde el diseño. El primero es el lookahead bias, controlado mediante orden temporal y subyacentes anteriores a la opción. El segundo es data snooping, mitigado separando búsqueda de hiperparámetros, reentrenamiento y evaluación final. El tercero es memorización de contratos, tratado con exclusividad de contratos entre splits. El cuarto es extrapolación en regiones poco cubiertas, diagnosticada con vecinos históricos y heatmaps de error. El quinto es confundir explicabilidad del modelo con verdad de mercado; por ello los surrogates se presentan con métricas de fidelidad y los resultados se contrastan frente a residuales y superficies.

La Tabla 5 resume esta lógica.

Riesgo	Control aplicado
Uso de información futura	Orden temporal, lag y subyacente anterior a la operación de opción.
Selección oportunista	K-folds temporales y métricas compuestas CE_1 y CE_2 .
Memorización de contrato	Asignación de contratos compartidos a un único split.
Extrapolación local	Vecinos históricos, distancias y mapas PCA locales.
Explicaciones engañosas	SHAP, ICE/ALE, surrogates y diagnóstico usados de forma complementaria.
Inconsistencia operativa	Bundle autocontenido con modelo, metadatos, scaler y artefactos.

Cuadro 5: Riesgos metodológicos y controles implementados.

RESULTADOS Y DISCUSIÓN

Este capítulo queda preparado para incorporar los resultados finales del entrenamiento. La lectura recomendada es progresiva: primero se comparan todas las familias y estrategias de entrenamiento; después se selecciona el mejor modelo; finalmente se analiza ese modelo con las pestañas del dashboard.

4.1 RESULTADOS

4.1.1 Comparativa general de modelos

Modelo	Entrenamiento	MAE	RMSE	R^2	CE ₁ / CE ₂	Comentario
Regresión lineal	estándar	–	–	–	–	–
Random Forest	estándar	–	–	–	–	–
XGBoost	estándar	–	–	–	–	–
Red neuronal	estándar	–	–	–	–	–
Quantum Inspired NN	estándar	–	–	–	–	–
Regresión lineal	progressive ATM	–	–	–	–	–
Random Forest	progressive ATM	–	–	–	–	–
XGBoost	progressive ATM	–	–	–	–	–
Red neuronal	progressive ATM	–	–	–	–	–
Quantum Inspired NN	progressive ATM	–	–	–	–	–

Cuadro 6: Plantilla para la comparación final de modelos.

La Tabla 6 deberá leerse en relación con la metodología de [section 3.6](#). El modelo con menor error no debería seleccionarse automáticamente si presenta una dispersión elevada entre folds, un gap acusado entre train y validation o comportamientos financieros incoherentes en la superficie.

4.1.2 Entrenamiento estándar frente a progressive ATM

Segmento de moneyness	RMSE estándar	RMSE progressive	Diferencia	Lectura financiera
ATM	–	–	–	–
Intermedio	–	–	–	–
Alas	–	–	–	–

Cuadro 7: Plantilla para analizar el impacto de progressive ATM por región de moneyness.

La comparación debe distinguir mejora agregada y mejora regional. Un progressive ATM puede ser útil si estabiliza la zona central sin degradar en exceso las alas. Si mejora el RMSE total pero introduce discontinuidades o sesgos en regiones OTM/ITM, la decisión deberá justificarse con el dashboard y no solo con métricas agregadas.

4.1.3 Selección del modelo final

Elemento	Valor final
Modelo seleccionado	–
Estrategia de entrenamiento	–
RMSE test	–
MAE test	–
R^2 test	–
Argumento principal de selección	–
Riesgo principal detectado	–

Cuadro 8: Ficha pendiente del modelo final seleccionado.

4.1.4 Diagnóstico de rendimiento

El análisis de diagnóstico debe responder si el error se distribuye de forma homogénea o si se concentra en regiones específicas de la superficie. En particular, conviene revisar vencimientos cortos, vencimientos largos, región ATM y alas. Una nube *predicted vs actual* próxima a la diagonal indicaría calibración general; una pendiente inferior a uno sugeriría compresión de volatilidades extremas. El heatmap de residuales permitirá localizar fallos que una métrica global ocultaría.

Para que el análisis sea defendible, cada figura de diagnóstico debe concluir con una frase accionable. Por ejemplo: si el error aumenta en vencimientos cortos, debe

indicarse si el fenómeno se atribuye a microestructura, escasez de datos, sensibilidad temporal o limitación del modelo. Si los errores se concentran en alas, debe conectarse con liquidez y cobertura de moneyness. Si la nube predicted vs actual muestra compresión, debe revisarse si el modelo está suavizando volatilidades extremas o si la variable objetivo presenta outliers de mercado.

4.1.5 *Behaviour And Surface*

Esta sección debe analizar el modelo como función financiera. La pregunta central no es solo si predice bien puntos históricos, sino si genera superficies razonables alrededor de observaciones representativas. La lectura debe cubrir nivel de volatilidad, pendiente por moneyness, curvatura del smile, evolución por vencimiento y warnings de consistencia. Si aparecen saltos o discontinuidades, deberán relacionarse con falta de soporte local, microestructura o limitaciones del modelo.

Se recomienda escoger al menos tres anclas: una observación ATM líquida, una observación en alas y una observación con vencimiento corto. Esta selección permite mostrar que el dashboard no solo funciona en el caso más favorable. En cada ancla conviene documentar si el smile es suave, si la term structure cambia de forma gradual y si los surface checks generan avisos. Cuando el modelo final se seleccione, esta sección será una de las más relevantes para la defensa, porque traduce el predictor a lenguaje financiero.

4.1.6 *Explicabilidad global*

La explicación global debe identificar los drivers principales del modelo. Una importancia elevada de log-moneyness o vencimiento sería coherente con la teoría de superficie. Una importancia dominante de variables menos esperadas debería investigarse: puede revelar una relación real, una interacción omitida o un problema de ingeniería de datos.

La lectura de SHAP debe incluir dirección, magnitud y heterogeneidad. No basta con indicar que una variable aparece en primer lugar; debe revisarse si valores altos de esa variable elevan o reducen la volatilidad predicha, si el efecto cambia por tipo de opción y si existen interacciones visibles en dependence plots. Esta interpretación debe conectarse con la Tabla 1: las features no se eligieron por conveniencia algorítmica, sino para reflejar smile, vencimiento, tipo y forward moneyness.

4.1.7 Modelos equivalentes: árboles y regresión simbólica

Los modelos equivalentes deben tratarse como explicadores del predictor, no como sustitutos automáticos del modelo final. Si un árbol de baja profundidad obtiene fidelidad razonable, puede ofrecer reglas útiles para defensa ante tribunal o revisión interna. Si solo modelos muy complejos aproximan el predictor, la interpretabilidad global será más limitada y convendrá apoyarse en SHAP, ICE/ALE y diagnóstico.

4.1.8 Explicabilidad local y soporte histórico

El análisis local debe seleccionar al menos una muestra representativa y, si procede, una muestra problemática. Para cada una, se interpretará la predicción como suma de valor base y contribuciones SHAP, y se verificará si existen vecinos históricos cercanos. Una explicación local con vecinos distantes debe presentarse con cautela: el modelo puede estar extrapolando.

En una revisión profesional, esta pestaña permite responder preguntas de tipo “por qué este contrato tiene esta volatilidad”. La respuesta debe combinar contribuciones y soporte: SHAP identifica los drivers de la predicción; los vecinos indican si existen casos similares en el entrenamiento. Si ambas piezas son coherentes, la explicación es más sólida. Si SHAP ofrece una historia plausible pero no hay vecinos cercanos, la predicción puede seguir siendo numéricamente válida, pero su uso debe marcarse como extrapolación.

4.2 DISCUSIÓN

La discusión debe responder a la pregunta planteada en [section 1.1](#): si es posible construir un modelo de volatilidad útil y explicable para opciones del IBEX. La respuesta no dependerá únicamente del error test; deberá integrar coherencia financiera, estabilidad temporal, comportamiento de la superficie, explicabilidad local y capacidad operativa.

4.2.1 Lectura financiera

El análisis financiero deberá comprobar si los resultados son compatibles con la lectura de volatilidad como superficie. La existencia de mayor error en alas o vencimientos cortos no sería necesariamente sorprendente; podría vincularse con menor liquidez, ruido de microestructura o mayor sensibilidad a desfases temporales. Lo

relevante será demostrar que esas limitaciones han sido identificadas y no quedan ocultas por métricas agregadas.

4.2.2 *Lectura de IA y Data Science*

Desde la perspectiva de IA, deberán valorarse capacidad predictiva, robustez, regularización, estabilidad y riesgo de sobreajuste. La métrica compuesta CE_1 ayuda a evitar selecciones oportunistas; CE_2 permite revisar el reentrenamiento final. Si un modelo flexible obtiene mejor RMSE pero presenta peor estabilidad o explicaciones incoherentes, la selección deberá argumentarse cuidadosamente.

4.2.3 *Lectura de ingeniería y cloud*

La dimensión cloud aporta valor si permite reproducir y consultar el modelo fuera del entorno de entrenamiento. La separación entre modelo, bundle, API, dashboard y almacenamiento reduce acoplamientos y facilita auditoría. La principal cautela operativa es mantener sincronizados modelo, scaler, metadatos y artefactos explicables.

4.2.4 *Limitaciones*

Las limitaciones esperadas se agrupan en cuatro bloques. Primero, la volatilidad implícita depende de la calidad del enlace opción-subyacente y del solver Black-76. Segundo, el conjunto de datos puede ser heterogéneo en liquidez y cobertura de moneyness/vencimiento. Tercero, la explicabilidad aproxima comportamientos del modelo y no sustituye validación económica. Cuarto, el despliegue cloud exige disciplina de versionado para evitar inconsistencias entre artefactos.

CONCLUSIONES

Este TFM desarrolla una cadena integral para estimar volatilidad implícita en opciones del IBEX y convertir el resultado en un sistema explicable y operable. El trabajo parte de datos de mercado, construye una base de volatilidad mediante inversión de Black-76, entrena familias de modelos bajo validación temporal y genera artefactos de explicación y diagnóstico.

La primera conclusión es que la calidad de un modelo de volatilidad no puede evaluarse solo con métricas agregadas. En derivados, la forma de la superficie, el comportamiento por moneyness y vencimiento y la localización del error son elementos centrales. Por ello el dashboard no se plantea como una capa estética, sino como parte del mecanismo de validación.

La segunda conclusión es que la explicabilidad aporta valor en dos planos. En ingeniería, ayuda a detectar fallos, fugas, sesgos y discontinuidades. En finanzas, permite justificar predicciones y analizar si el modelo se comporta de forma compatible con intuición económica y revisión profesional.

La tercera conclusión es que la arquitectura de software condiciona la utilidad del modelo. Al separar ETL, entrenamiento, bundles, API, dashboard y almacenamiento, el proyecto facilita reproducibilidad, mantenimiento y despliegue. Esta separación también reduce el riesgo de que las explicaciones se calculen sobre artefactos distintos de los usados en predicción.

Como líneas futuras, se proponen: ampliar el análisis con más ventanas temporales, incorporar métricas específicas por liquidez, explorar modelos con restricciones de suavidad financiera, automatizar validaciones de superficie más exigentes y reforzar el versionado de artefactos en cloud. También sería natural comparar la superficie aprendida con enfoques paramétricos clásicos o con modelos híbridos que impongan estructura financiera explícita.



FUNDAMENTOS DE SHAP, ICE Y ALE

SHAP se basa en una lectura cooperativa de la contribución de variables a una predicción. Su ventaja práctica es que proporciona una descomposición aditiva como la de (9). En este proyecto se usa con un explicador de permutación para tratar de forma homogénea modelos heterogéneos. Esta decisión sacrifica eficiencia frente a explicadores especializados, pero aporta una semántica común entre familias.

La interpretación de SHAP debe ser cuidadosa. Un valor SHAP positivo indica que, para una observación y respecto al valor base, la variable empuja la predicción al alza. No implica causalidad. Además, si las variables están correlacionadas, la atribución depende de cómo el explicador define la ausencia o permutación de features.

Las curvas ICE muestran para cada observación cómo cambiaría la predicción al variar una feature manteniendo el resto constante. Son útiles para detectar heterogeneidad: dos contratos pueden reaccionar de forma distinta al mismo cambio de moneyness si difieren en vencimiento o tipo de opción. Su limitación es que pueden generar combinaciones contrafactuales poco realistas.

ALE estima efectos locales acumulados dentro de regiones observadas, por lo que suele ser menos vulnerable a correlaciones que un PDP clásico [Apley and Zhu, 2020]. En el dashboard, ICE y ALE son complementarias: ICE muestra trayectorias individuales y ALE resume un efecto agregado local.

ÁRBOLES SURROGATE Y REGRESIÓN SIMBÓLICA

Los modelos surrogate aproximan el comportamiento del modelo principal con una representación más interpretable. Formalmente, buscan una función h tal que:

$$\hat{\sigma}_{principal}(x) \approx h(x). \quad (15)$$

La variable objetivo de h no es la volatilidad real, sino la predicción del modelo principal. Por tanto, la fidelidad mide capacidad de imitación, no precisión frente a mercado. Esta distinción es esencial para evitar una interpretación incorrecta en auditoría.

Los árboles surrogate ofrecen reglas por particiones. Profundidades bajas facilitan lectura, pero pueden perder fidelidad; profundidades altas imitan mejor, pero se vuelven menos explicables. El dashboard conserva varios niveles de profundidad para elegir el equilibrio adecuado.

La regresión simbólica busca expresiones cerradas con operadores matemáticos. Su atractivo es producir fórmulas compactas que pueden discutirse financieramente. Su riesgo es doble: puede sobreajustar la predicción del modelo principal y puede proponer expresiones difíciles de justificar económicamente. Por ello se revisan conjuntamente error, complejidad y estabilidad de candidatos [Cranmer, 2023].

ENTRENAMIENTO PROGRESSIVE ATM

El entrenamiento progressive ATM se desarrolló como estudio paralelo para intentar mejorar el aprendizaje de la superficie. Su hipótesis de partida es financiera: la región ATM suele ser más líquida y central para la formación del nivel de volatilidad, mientras que las alas pueden contener más ruido, menor frecuencia o mayor sensibilidad a microestructura.

El procedimiento ordena las observaciones por distancia a ATM:

$$d_{ATM} = |\log(F/K)|. \quad (16)$$

Después divide el entrenamiento en segmentos. En la configuración actual se usan tres segmentos. Los modelos no iterativos reciben pesos mayores para regiones más ATM; los modelos iterativos entrenan de forma acumulativa, empezando por la zona central e incorporando progresivamente alas.




Figura 7: Esquema conceptual del entrenamiento progressive ATM.

La evaluación de esta variante debe realizarse por regiones. Si mejora ATM pero degrada las alas, puede seguir siendo útil en aplicaciones centradas en contratos líquidos, pero no debería presentarse como mejora universal. Si reduce error agregado y preserva coherencia de superficie, se convierte en una estrategia defendible para estabilizar entrenamiento.

GUÍA DE INSERCIÓN DE RESULTADOS FINALES

Para completar la memoria se recomienda insertar los resultados en el siguiente orden:

1. Tabla global de todos los modelos en [Table 6](#).
2. Comparativa estándar frente a progressive ATM en [Table 7](#).
3. Ficha del modelo final en [Table 8](#).
4. Figuras de diagnosis: performance summary, predicted vs actual, residual heatmap, error by moneyiness y error by maturity.
5. Figuras de behaviour and surface: heatmap, superficie 3D, smile, term structure y warnings.
6. Figuras de explicabilidad global: SHAP summary, feature importance, dependence y heatmap.
7. Figuras de modelos equivalentes: fidelidad de árboles, árbol interpretable y fórmula simbólica.
8. Figuras de explicabilidad local: waterfall SHAP, vecinos y mapa PCA.

Cada figura debe citarse explícitamente en el texto y conectarse con una conclusión financiera o técnica. Una figura sin interpretación no añade evidencia al argumento de la memoria.

BIBLIOGRAFÍA

- Daniel W. Apley and Jingyu Zhu. Visualizing the effects of predictor variables in black box supervised learning models. *Journal of the Royal Statistical Society: Series B*, 82(4):1059–1086, 2020.
- Fischer Black. The pricing of commodity contracts. *Journal of Financial Economics*, 3(1-2):167–179, 1976.
- Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- Miles Cranmer. Interpretable machine learning for science with PySR and symboli-cregression.jl. *arXiv preprint arXiv:2305.01582*, 2023.
- Emanuel Derman and Michael B. Miller. *The Volatility Smile*. Wiley, 2016.
- Alex Goldstein, Adam Kapelner, Justin Bleich, and Emil Pitkin. Peeking inside the black box: Visualizing statistical learning with plots of individual conditional expectation. *Journal of Computational and Graphical Statistics*, 24(1):44–65, 2015.
- Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.
- John C. Hull. *Options, Futures, and Other Derivatives*. Pearson, 11 edition, 2022.
- Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, 2017.